

AI의 거시경제 영향 분석


남 창 우

KOREA DEVELOPMENT INSTITUTE



AI의 거시경제 영향 분석

남창우



연구보고서 2026-01

AI의 거시경제 영향 분석

저 자

남창우 | 한국개발연구원 선임연구위원

발간사

최근 인공지능, 특히 생성형 AI의 등장은 우리 경제와 사회 전반에 중대한 변화를 예고하고 있다. 지식노동과 서비스업까지 자동화의 범위가 빠르게 확장되는 상황에서, AI가 생산성과 성장, 고용과 분배에 어떤 영향을 미칠지에 대한 체계적인 분석은 정책당국과 기업, 국민 모두에게 더 이상 미룰 수 없는 과제가 되었다.

이러한 문제의식을 바탕으로 본 보고서 『AI의 거시경제 영향 분석』은 한국의 직업·과업 구조와 기업·산업 데이터를 결합하여, AI 자동화의 가능성과 경제성, 기업생산성, 그리고 장기적인 거시경제 파급효과를 연계적으로 평가하고자 하였다. 제2장에서는 생성형 AI의 기술 진화와 경제적 의미를 정리하고, 제3장에서는 직업을 구성하는 과업 단위에서 AI 노출도와 자동화의 경제성을 계량화하였다. 제4장에서는 기업활동조사를 활용하여 AI 활용이 1인당 매출과 고용에 미치는 효과를 실증적으로 분석하였으며, 제5장에서는 과업기반 거시모형을 통해 향후 10~15년간 AI 확산이 총요소생산성과 성장, 고용·임금에 미칠 수 있는 경로를 모의실험하였다. 마지막으로 제6장에서는 이러한 분석 결과를 토대로, 시장 친화적 규제 정비, 데이터·컴퓨팅 인프라 확충, 재교육·전환지원, 취약직종·산업에 대한 선제적 대응 등 정책적 시사점과 기업의 AI 전환 전략을 제시하였다.

물론 급속한 기술발전과 불확실성을 본 연구에 모두 반영하기에는 한계가 있고, AI가 과학기술 혁신과 아이디어 생산을 가속하는 경로 등에 대해서는 보다 장기적인 연구가 필요하다. 그럼에도 불구하고 본 보고서가 AI 시대를 준비하는 데 필요한 현실적인 출발점과 논의의 기반을 제공하기를 기대하며, 향후 학계와 정책현장에서의 심도 있는 후속연구와 활발한 토론을 기대한다. 마지막으로 본 보고서의 내용은 저자 개인의 의견이며 본원의 공식적인 견해가 아님을 밝혀 두는 바이다.

2026년 7월
한국개발연구원 원장
김 세 직

목차

발간사

요 약 1

제1장 서 론 5

제2장 생성형 AI의 기술 진화와 경제적 의미 12

제1절 생성형 AI의 기술 진화 12

1. 트랜스포머의 등장: 대규모 사전학습의 시작 12

2. 인간 지도학습: 인스트럭션 튜닝과 머신러닝 강화학습 15

3. 초장문맥 처리와 AI의 에이전트화 17

4. 멀티모달 통합: 텍스트에서 이미지 · 음성 · 비디오로 20

5. 수평형 對 수직형 AI: 범용 플랫폼과 도메인 특화 23

제2절 AI 활용의 경제적 의미 26

1. AI의 노동과업(labor task)에 대한 대체 對 보완 26

2. AI의 확산에 따른 노동소득 분배와 임금의 효과 28

3. AI의 생산성 J-커브 가설: 보이지 않는 투자와 시차 효과 30

제3절 맺음말: AI 기술 진화와 경제적 가치 32

제3장 AI 자동화: 경제성을 중심으로 35

제1절 AI 자동화 가능성 추정 37

1. AI 자동화 가능성의 개념 37

2. AI 자동화 가능성 추정 방법론	45
3. AI 자동화 가능성 분석 결과	55
제2절 AI 자동화의 경제성 분석	66
1. AI 자동화의 경제성 도입	66
2. AI 자동화의 경제성 분석 방법론	70
3. AI 자동화의 경제성 분석 결과	80
제3절 AI 자동화의 거시경제적 의미	88
1. AI 자동화의 영향을 받는 경제규모	88
2. 기존 문헌과의 비교 및 경제학적 의미	95
3. 정책적 시사점	96
제4장 AI가 기업생산성에 미치는 영향	100
제1절 AI 활용 현황	101
1. 기업활동조사에 따른 AI 활용률	101
2. AI 활용 현황: 기업정보화통계조사	106
3. AI 활용 현황의 정책적 함의	109
제2절 실증분석 방법론	113
1. 기업활동조사 자료를 이용한 패널분석	113
2. Propensity Score Matching을 이용한 분석	119
제3절 실증분석 결과	123
1. 패널 IV 분석	123
2. PSM 분석	134
제4절 소 결	141
제5장 AI가 거시경제에 미치는 영향	143
제1절 AI 도입 확산으로 인한 TFP 성장기여	145
1. 과업기반 경제모형	145

2. AI 도입의 확산으로 인한 총요소생산성(TFP) 개선	152
제2절 AI 활용이 장기 고용 및 임금에 미치는 영향	161
1. 분석방법론	163
2. 분석 결과	169
3. AI 자동화가 향후 10년 일자리 대체 및 임금에 미치는 영향	176
제3절 소 결	183
제6장 결론 및 정책 방안	186
제1절 본 연구의 요약 및 한계	186
1. 본 연구의 요약	186
2. 본 연구의 경제학적 의의와 한계	188
제2절 AI 전환을 위한 정책 방안과 기업 전환 전략	190
1. AI 전환을 위한 정책 방안	190
2. 기업의 AI 전환 전략	196
3. 정책 방안의 한계와 위험 및 보완대책	200
참고문헌	203
부 록	209
ABSTRACT	217

◆ 표 목 차

<표 1- 1> AI의 거시경제 효과를 분석한 논문들의 가정 및 분석 결과	8
<표 3- 1> 과업대상(object type) 분류	50
<표 3- 2> 과업대상의 모달리티	50
<표 3- 3> 과업행위의 유형 분류	51
<표 3- 4> LLM 프롬프트 정보 요약	52
<표 3- 5> 한국고용직업 대분류에 따른 과업 및 기초통계량	56
<표 3- 6> AI score의 AI 구현 지표 및 규칙화 지표 분해(단위과업 수)	59
<표 3- 7> 한국고용직업 중분류에 따른 AI 자동화 지표별 상위 순위	60
<표 3- 8> 한국고용직업 세분류에 따른 AI 자동화 지표별 상위 순위	62
<표 3- 9> AI 시스템 구축비용 정리	71
<표 3-10> 데이터 라벨링 가격 요인 분해	73
<표 3-11> 라벨링 시간	74
<표 3-12> 학습 데이터량 결정 요인	75
<표 3-13> AI 학습비용 모수	76
<표 3-14> AI 자동화의 경제성 상위 직업군	82
<표 3-15> AI 자동화의 경제성 하위 직업군	83
<표 3-16> AI 자동화의 경제성 상위 산업	85
<표 3-17> AI 자동화의 경제성 하위 산업	87
<표 3-18> AI 자동화의 영향을 받는 상위 산업별 종사자 규모	89
<표 3-19> AI 자동화의 영향을 받는 상위 산업별 매출액 비중	90
<표 3-20> AI 자동화의 영향을 받는 상위 직업별 근로자 규모	93
<표 3-21> AI 자동화의 영향을 받는 상위 직업별 임금 비중	94

<표 4- 1> AI 활용률(부문별)	102
<표 4- 2> 산업별 AI 활용률(2023년 기준)	104
<표 4- 3> 주요 변수 기초통계량(2017~23년)	124
<표 4- 4> 패널 IV 분석: 로그(1인당 매출액)	126
<표 4- 5> 패널 IV 분석: 로그(상용근로자 수)	128
<표 4- 6> 패널 IV 분석: 로그(매출액)	129
<표 4- 7> 패널 IV 분석(4차 산업혁명 기술 제외): 로그(1인당 매출액)	131
<표 4- 8> 패널 IV 분석(4차 산업혁명 기술 제외): 로그(상용근로자 수)	131
<표 4- 9> 주요 산업별 패널 IV 분석의 주요 결과	132
<표 4-10> AI 활용 분야별 패널 IV 분석의 주요 결과	133
<표 4-11> PSM 후 패널 분석: 로그(1인당 매출액)	135
<표 4-12> PSM 후 패널 분석: 로그(상용근로자 수)	135
<표 4-13> PSM 후 패널 분석: 로그(매출액)	137
<표 4-14> PSM 후 DID 패널 분석: 로그(1인당 매출액) 차분	137
<표 4-15> PSM 후 DID 패널 분석: 로그(상용근로자 수) 차분	138
<표 4-16> PSM 후 DID 패널 분석: 로그(매출액) 차분	138
<표 4-17> AI 도입 이후 기간별 회귀분석	139
<표 5- 1> AI 도입의 TFP 성장률 민감도 분석	153
<표 5- 2> AI의 거시경제 효과를 분석한 논문들의 가정 및 분석 결과	156
<표 5- 3> TFP 성장률 추정 방법 비교(2017~21년, 총산출 기준)	158
<표 5- 4> 주요 변수 기초통계량(로그값)	170
<표 5- 5> 직종별 고용규모 10년 로그차분에 대한 횡단면 분석	172
<표 5- 6> 직종별 시간당 임금 10년 로그차분에 대한 횡단면 분석	172
<표 5- 7> 직종별 시간당 임금 10년 로그차분에 대한 횡단면 IV 분석	174
<표 5- 8> 직종별 시간당 임금 10년 로그차분에 대한 횡단면 IV 분석: 파급효과	174

표목차

<표 5- 9> AI로 대체될 연간 근로자 규모 179

<표 5-10> AI 자동화가 직종별 시간당 실질임금에 미치는 영향 180

<표 5-11> 향후 10년 후 AI 대체에 따른 임금불평등도: 지니계수 182

<부표 1> 직능수준별 임직 필요조건 209

<부표 2> 약한 도구변수(Weak IV) 검정 통계 214

<부표 3> 약한 도구변수(Weak IV) 검정 및 과식별 검정 통계 215

◆ 그 림 목 차

[그림 3- 1] 직능수준·연봉수준별 평균 AI 자동화 지표	64
[그림 4- 1] AI 활용률: 기업규모별(250인 미만·이상)	105
[그림 5- 1] AI 활용 확산으로 인한 15년간 TFP 성장기여도 경로	155
[그림 5- 2] 직종별 시간당 임금 상승률 및 고용규모 증감률	162
[그림 5- 3] 정형과업 비중과 AI 자동화 가능 과업 및 AI 노출 과업 비중	177
[부도 1] 직업에 대한 전망과 AI score 관계	209
[부도 2] AI 자동화 5대 지표 분포	210
[부도 3] AI score의 분포(0 제외)	211
[부도 4] C_j^M 의 분포	211
[부도 5] $C_j^{\text{데이터}}$ 의 분포 및 누적 분포	212
[부도 6] n_{ij} 의 분포	212
[부도 7] n_{ij}^* 의 분포	213
[부도 8] 기업규모별 경제성 있는 AI 자동화 과업 비중	213
[부도 9] 산업별 AI 활용의 TFP 기여: 15년 누적	216

요 약

각 장의 내용을 간략히 정리하면 다음과 같다. 제1장에서는 ChatGPT를 계기로 본격화된 생성형 AI 확산을 한국경제의 구조적 저성장·인구 감소와 결부하여 문제의식을 제기한다. AI를 단순한 기술 변화가 아니라 과업(task) 단위의 비용구조를 변화시키는 충격으로 규정하고, 노동 대체와 보완이 동시에 작동하는 과업기반(task-based) 분석 관점을 채택한다. 특히 한국의 고용·산업 구조와 디지털 인프라 수준을 반영한 실증분석을 통해, AI가 총요소생산성(TFP), 기업성과, 고용과 임금분포에 미칠 영향을 정량적으로 평가하는 것을 연구 목표로 설정한다. 이를 위해 5개의 장에 걸쳐 AI의 기술 진화, 과업 자동화 가능성과 경제성, 기업생산성, 거시경제 파급효과, 마지막으로 AI 전환을 위한 정책·기업 전략까지 연결하는 통합적 분석 틀을 설명한다.

제2장에서는 트랜스포머, 대규모 사전학습, 인스트럭션 튜닝 및 인간 피드백 강화학습 등 생성형 AI의 기술발전 경로를 다섯 단계로 나누어 정리한다. 초기에는 번역·검색 등 제한된 영역에서 생산성 향상이 나타났으나, AI의 거대언어모형(Large Language Model: LLM)과 멀티모달모형의 등장으로 코드, 이미지, 음성까지 포괄하는 범용기술로 진화하였음을 보여준다. 이러한 기술은 지식노동 과업의 시간 단축과 품질 개선을 통해 미시적 생산성을 높이고, 동시에 새로운 사업모델과 산업을 창출하는 잠재력을 가진다. 다만, 과도한 기대, 성능의 편차, 규제·윤리 문제

등으로 인해 거시적 생산성 효과는 지연될 수 있으며, 이에 따라 정책은 J-커브형 전환 경로를 감안해 설계되어야 함을 주장한다.

제3장에서는 한국고용직업분류(KECO)와 임금직업포털(Workpedia) 직무기술서를 바탕으로 6천여 개 단위과업을 추출하여, 결과측정 가능성, 데이터 가용성, 맥락 의존성, 인간 판단 필요성, 에이전트화 가능성 등 5대 지표로 AI 자동화 가능성을 계량한다. 이어 Svanberg · Thompson 방식의 AI 비용 모형을 적용하여 국내 임금수준, 데이터 · 컴퓨팅 비용을 반영한 과업 단위의 경제성을 산출하고, 실제로 기술적으로 가능하면서 경제적으로도 수지타산이 맞는 과업 비중을 계산한다. 분석 결과, AI 자동화 노출도는 IT, 경영 · 사무, 영업 · 상담 직무에서 높지만, 경제성이 확보된 자동화 과업 비중은 전체 임금의 일부에 그치며, 특히 중소기업과 오프라인 · 고맥락 업무에서 자동화 유인이 낮음을 보여준다. 이는 AI의 고용 충격이 전면적이거나 급작스럽기보다는 산업 · 직종별로 점진적이고 이질적으로 나타날 수 있음을 의미한다.

제4장에서는 기업활동조사 패널자료를 이용하여 AI 활용이 기업성과에 미치는 영향을 실증적으로 추정한다. 2017~23년 동안 AI 활용 기업의 비중은 1%대에서 6% 수준으로 상승하였으며, 특히 정보통신, 금융, 전기 · 가스, 교육서비스 등에서 활용률이 높고, 대기업에 집중되는 특징을 보인다. 패널 IV 분석 및 성향점수매칭 결과, AI 도입기업은 비도입기업보다 1인당 매출과 총매출이 유의하게 높아지지만 고용수준에서는 단기적으로 큰 감소 효과가 나타나지 않는다. 이는 AI가 현재까지는 인건비 절감보다는 생산성 · 매출 증대를 통해 기업성과를 개선하고 있음을 시사하며, 인력 구조조정보다는 빅데이터 · 클라우드 등 다른 4차 산업혁명 기술 및 조직 · 프로세스 혁신과 병행될 때 효과가 크다는 점을 보여준다. 더불어, 추정치는 이후 거시모형에서 AI에 의한 생산성 향상률(비용절감률)의 핵심 계수로 활용된다.

제5장에서는 과업기반 생산함수와 Hulten 정리를 활용하여, 제3 · 4장에서 도출한 노출도 · 경제성 · 기업생산성 효과를 한국경제의 TFP 성장 경로와 연결한다. 우선 AI에 노출되고 경제성까지 확보된 산업 · 과업별

GDP 비중, AI 채택률, 생산성 향상률(비용절감률) 및 노동소득분배율을 곱해, 향후 10~15년간 AI가 기여할 TFP 증가폭을 1차적으로 근사한다. 이어 산업 간 생산성 차이, 수요탄력, 투입·산출 연결구조를 반영할 때 Baumol 효과로 인해 TFP 개선이 일부 상쇄될 수 있음을 보인다. 분석 결과, 한국의 AI 확산은 장기적으로 TFP와 노동생산성을 유의하게 높일 잠재력이 있으나, 도입 속도, 산업구조, 보완투자 수준에 따라 효과의 범위가 크게 달라질 수 있음을 확인한다. 또한 자동화 충격이 직종별 노동수요와 임금분포에 미치는 이질적 영향을 고려할 때, 성장 효과와 분배 효과를 동시에 관리하는 정책 조합이 필요함을 강조한다.

제6장에서는 앞선 장들의 분석을 종합하여, 생성형 AI 확산이 한국경제에 가져올 생산성·고용·분배 효과를 요약하고, 이를 바탕으로 정책·기업의 전략 방향을 제시한다. 미시적 분석과 국내 기업 자료는 AI가 개별 과업·기업 수준에서 상당한 생산성 향상을 가져올 수 있음을 보여주지만, 거시 차원에서의 TFP 제고는 노출도, 경제성, 채택률, 보완투자 등 여러 조건을 충족해야 한다는 점이 확인된다. 이에 따라 정책 측면에서는 시장왜곡을 최소화하는 범위 내에서 데이터·컴퓨팅 인프라, 인적 자본, 규범·제도 등 보완적 자산에 대한 투자와 사회안전망 강화를 중점 과제로 제안한다. 기업 측면에서는 업종·규모별 여건을 고려해 AI를 인력대체가 아니라 업무보완과 신사업 발굴 수단으로 활용하면서, 조직의 구조와 인사·교육 체계를 함께 개편할 것을 권고한다. 마지막으로, 정책 방안에 내재한 한계와 위험을 인정하고, 모니터링과 보완정책을 통해 AI 전환 과정의 불확실성을 관리하는 것이 중요하다고 결론짓는다.

제1장

서론

2022년 11월 30일 OpenAI가 ChatGPT(GPT 3.5 계열)¹라는 생성형(generative) 인공지능(artificial intelligence: AI)의 상용화를 최초로 발표한 후 다양한 생성형 AI들이 매우 빠르게 발전하고 있다. NIST(national institute of standards and technology)에 따르면 생성형 AI는 “학습된 자료를 바탕으로 내용물(contents) 형태의 분포와 양식을 모방하여 새로운 내용물을 만드는 일련의 기술군”으로 정의된다.² 특히 내용물(contents)에는 텍스트, 이미지, 영상, 오디오, 코드 등 대부분의 사회·문화·경제적 내용물이 포함되어 있어, 생성형 AI가 글로벌 사회·경제에 미치는 영향이 매우 빠르게 확대되고 있다.

특히 생성형 AI의 특성상 노동자의 과업(tasks)을 보완(complementary)하여 노동시간을 절약하거나, 노동자의 특정 과업을 대체(displacement 혹은 replacement) 혹은 자동화(automation)하는 방식으로 경제에 상당한 영향을 미칠 것으로 예측하고 있다. 이러한 인간 과업의 보완 및 자동화는 거시경제적 측면에서 총요소생산성(total factor productivity: TFP) 및 GDP에 직접적으로 영향을 미칠 가능성이 높다. 또한 AI 기술발전에 따른 추가적인 데이터센터 및 AI 반도체 등에 대한 막대한 자본투자는 기존의

1 ChatGPT(5.1)의 답변을 참고하였다.

2 https://csrc.nist.gov/glossary/term/generative_artificial_intelligence?(최종접속일: 2025. 10. 5).

자본구조에 변화를 일으킬 수도 있다. 더불어, 노동시장 측면에서는 AI에 직접적으로 노출된 과업들을 수행하는 직무에 대한 수요가 변화함에 따라 소득불평등이 심화될 수도 있다.

이러한 AI의 경제적 영향들 중 거시경제에 미치는 영향에 대한 다양한 논의들이 진행되었다. 예를 들어 Chui *et al.*(2023)은 AI의 63개 활용사례를 통해 AI가 연간 2.6조달러에서 최대 4.4조달러까지 경제적 가치를 창출할 것이라고 주장하였다. 영국의 2021년 GDP가 3.1조달러인 것을 고려하면, AI가 매년 거의 영국 경제규모의 새로운 부가가치를 창출한다고 판단한 것이다. 또한 Goldman Sachs의 Briggs *et al.*(2023)은 생성형 AI가 향후 10년간 글로벌 GDP를 7% 증가시키고, 노동생산성도 1.5%p 제고할 것이라고 추정하였다. 추후 논의하겠지만, 생성형 AI의 사용비용을 고려하였을 때 주로 선진국을 중심으로 AI의 경제적 효과에 대한 논의가 진행되고 있다. 이는 대부분의 선진국이 인구구조의 고령화와 더불어 생산성 정체를 겪고 있어서 생성형 AI의 적극적 활용을 통해 경제적 활력을 되찾기 위한 것으로 판단된다. 특히 한국은 향후 생산가능인구의 빠른 감소로 인해 잠재성장률이 빠르게 하락할 것으로 예상되어 생성형 AI 활용을 통한 과업의 자동화 및 보완 가능성을 검토하는 것은 중장기적으로 잠재성장 동력을 확보하기 위해 매우 중요할 것으로 판단된다.

다만, 앞서의 낙관적 보고서들과는 다르게, Acemoglu(2024)는 향후 10년간 AI의 거시경제적 영향은 최대 0.66%를 넘지 않을 것이라고 추정하고 있다. 이러한 결과는 실제로 AI의 영향을 받을 수 있는 직무(jobs/positions) 혹은 과업(tasks)의 비중(20%)이 높다 하더라도 이 중 향후 10년 이내에 실제로 수익성 있게 AI로 자동화될 비율은 Svanberg *et al.*(2024)의 연구 결과를 반영하여 단지 23%로 판단하였기 때문이다.³ 이렇게 되면, AI에 의해 영향을 받을 과업들의 GDP 비중은 향후 10년간 전체 과업들의 4.6%(=20%×23%)에 불과한 것으로 계산된다. 특히 Acemoglu(2024)는 기술적 가능성 외에도 현실적인 AI 적용 및 투자의 제약을 지

3 본 연구에서는 직업(occupation) 관련 용어 번역을 다음과 같이 통일하고자 한다. 과업(task), 직무(job), 직무내용/책임(duty/responsibility), 업무배정/과제(assignment).

적하며 AI의 거시경제적 영향에 대한 과도한 평가를 경계한다. 예를 들어 그는 미국 기업 중 AI 개발에 투자하는 기업군은 일명 빅테크 및 소수의 특정 벤처기업들에 집중되어 있고, 생성형 AI가 소수의 빅테크 기업에 의해 독점된다면 AI에 노출된 과업들을 대부분 수행하는 중소기업의 AI 도입 속도가 늦어질 수 있다고 지적한다. 또한 그는 현재 산업계의 우선순위가 근로자의 생산성을 향상시키는 새로운 과업(new good tasks)을 창출하는 것보다는 소셜 미디어 검색 및 디지털 광고 등을 통한 개인 정보의 자동화와 수익화에 초점이 맞춰져 있다고 비판한다. 결국 이러한 흐름이 AI의 긍정적인 거시경제 효과를 창출하기 어렵게 만든다고 주장한다.

사실, 이러한 결과들을 좀 더 엄밀히 분해하면, AI가 거시경제, 특히 TFP에 미치는 영향은 각 단계에서 어떤 가정을 어떻게 추정했느냐에 따라 다르다. 요컨대 AI가 거시경제에 미치는 영향을 분석하기 위해서는 미시적 분석에서 거시적 분석으로 진행하는 방법이 필요하다. 우선 노동의 과업별 AI 노출도(exposure)를 분석하고, 기업별로 각 과업에 대해서 경제성이 확보되어 자동화할지에 대한 도입률(adoption rate)을 예측해야 한다. 그리고 실제 AI를 통해 달성될 비용절감을 계산하여야 한다. 여기까지 추정되면, 마지막으로 AI에 노출된 노동소득분배율(labor share)을 통해 AI에 의해 제고될 수 있는 TFP 증가율은 다음과 같이 추정할 수 있다(Acemoglu, 2024; Aghion and Bunel, 2024; OECD, 2024).

$$\begin{aligned} \text{향후 10년 AI에 의한 TFP 증가율} &= \text{AI에 노출된 GDP 비중} \\ &\times \text{AI의 경제적 수익성이 있는 과업 비중} \\ &\times \text{AI로 인한 생산성 향상} \\ &\times \text{AI에 노출된 노동소득분배율} \end{aligned}$$

<표 1-1>은 AI의 거시경제적 영향을 분석한 보고서들의 각 가정과 분석 결과를 정리한 것이다. 특히 Acemoglu(2024), Aghion and Bunel(2024), OECD(2024)는 과업기반(task-based) 접근방식을 채택하여 유사한 분석틀을 공유하였지만, 핵심 가정 및 모형 방식의 차이로 인해 도출된 AI 도

<표 1-1> AI의 거시경제 효과를 분석한 논문들의 가정 및 분석 결과

구분	Briggs <i>et al.</i> (2023)	Aghion and Bune(2024)	OECD(2024)	Acemoglu (2024)
생산성 / 비용절감	30% 증가	27~40% 비용절감	30% 생산성 이득(비용절감)	27% 비용절감
AI 노출 비중	전체 일자리의 약 2/3	18.5~68%	12~50% (평균 35%)	20%
AI 도입률/ 경제성 비중	50%	23~80%	23% 또는 40%	23%
연평균 TFP 성장기여도	1.0%p	0.68%p	0.25~0.6%p	0.064%p

자료: OECD(2024)의 Table 1을 인용 수정.

입의 예상 TFP 기여도는 상이하게 나타났다. 특히 TFP 기여도의 범위는 Acemoglu(2024)의 보수적인 추정치인 0.064%p에서 Briggs *et al.*(2023)의 공격적인 추정치 1.0%p 이상까지 넓게 분포하고 있다. Briggs *et al.*(2023)은 AI 노출도와 AI 도입률을 각각 66%, 50% 정도로 가정하여 꽤 높은 AI의 TFP 기여도를 산출하였다. Aghion and Bune(2024)은 Acemoglu (2024)가 기본 추정치에서 제외한 Peng *et al.*(2023)의 높은 코딩 생산성 증가분(55.8%)까지 포함하여 세 연구의 평균인 40%를 노동비용 절감률로 제시하였다.

OECD(2024) 같은 경우는 Briggs *et al.*(2023) 방법론과 Acemoglu(2024), Aghion and Bune(2024)의 방법론의 중간 접근방식을 사용하였다.⁴ 우선 Acemoglu(2024)의 방법론을 이용하여 산업별 생산성 증가를 계산하고, 이 산업별 증가분을 Baqaee and Farhi(2019)의 다중부문 일반균형모형(multi-sector general equilibrium model)을 통해 총합한다. 이 방법론은 부문 간 투입-산출 연계(input-output linkages), 수요 변화에 따른 가격변동, 그리고 부문 간 요소 재배치(factor reallocation)의 제약을 고려한다.

하지만 위의 분석 결과들은 각 국가들의 기업분포, AI 투자, 노동시장

4 Briggs *et al.*(2023)은 AI를 사용하는 기업에서 관찰된 성과를 바탕으로 노동 대체 및 재배치에 가정을 도입하여 거시적 효과를 도출하였다. 이 방법은 엄밀한 거시경제이론 모형에 기반하지는 않는다.

유연성 등 복합적인 경제적 환경에 따라 매우 다르게 추정될 수 있다. 따라서 본 연구는 AI가 사회·경제에 미치는 다양한 영향들 중 한국의 거시경제 환경을 고려하여 한국경제에 미치는 영향을 미시적 단계에서 거시적 단계로 구분하여 분석하고자 한다. 우선 제2장에서는 분석을 수행하기 전에 생성형 AI의 발전사와 핵심 기능을 살펴본다. 특히 생성형 AI를 가능하게 한 트랜스포머(transformer) 및 인간 피드백 강화학습(reinforcement learning from human feedback: RLHF)을 검토한다. 더불어, 이미지·영상 영역의 확산모형(diffusion model), 실시간 멀티모달(multi-modal) 상호작용과 초장문맥(long context) 기술이 어떻게 생성형 AI를 발전시키게 했는지 살펴본다. 이를 통해 실시간 멀티모달 기능, 초장문맥(long context), 톨사용·구조화 출력(structured outputs) 기능을 설명한다. 또한 향후 AI의 발전 방향에 대해서 모색한다. 예를 들어 최근 매우 빠르게 발전되고 있는 에이전트화, 온디바이스·개방형 생태계의 발전 가능성 및 AI 신뢰성과 통제 가능성 제고에 대해서 설명한다. 마지막으로 이러한 AI의 기술 및 기능이 어떻게 생산현장에서 효과를 가지거나 가질 수 있는지 실증사례 등을 가지고 경제적 시사점을 정리한다.

제3장에서는 직업별 수준에서 세부적 과업이 AI에 의해 어느 정도 자동화되거나 보완될 수 있는지 분석한다. 동시에, AI 자동화의 비용구조를 고려하여 경제적 채택 가능성까지 분석한다. 특히 한국고용직업분류(KECO)의 수행직무(과업)기술(task description) 자료를 이용하여 AI의 자동화 및 보완 가능성을 분석한다. 임금직업포털(Workpedia)에 있는 총 537개의 직업에 대한 과업기술(task descriptions)을 6,824개의 수행과업(object)과 과업행위(verb) 조합의 단위과업(unit task)으로 구분하고, 결과측정 가능성(objective outcome measurability), 데이터 가용성(data availability and quality), 맥락 의존성(context dependence), 창의성/판단 필요성(human judgment necessity)을 기준으로 과업의 자동화 및 보완 가능성을 확률적으로 계산한다. 더불어, Svanberg *et al.*(2024), Thompson *et al.*(2024)에서 사용한 경제성 분석 방법론을 발전시켜서, 각 과업의 경제성을 직업·산업별로 분석하여 과업이 경제적(실효적)으로 AI 자동화 가능성에 노출된

종사자·매출액·임금 규모를 추정한다.

제4장에서는 기업별 AI 활용이 기업의 생산성에 미치는 영향을 분석한다. 특히 Acemoglu(2024) 등이 사용하는 AI 도입이 기업에 직접 미치는 경제적 효과는 기존 문헌의 AI 자동화를 통한 과업 단위 시간단축 등 비용절감 효과를 차용한다. 하지만 본 연구는 국가데이터처의 기업활동조사 설문자료와 본 연구에서 분석한 경제성 지표 등을 활용하여 AI의 도입이 기업별 1인당 매출액, 고용규모 및 총매출에 미치는 영향을 패널 도구변수(IV) 분석과 성향점수매칭(PSM) 패널 분석 및 이중차분 분석을 사용하여 추정한다. 그리고 이 실증분석 결과를 향후 10~15년간 AI에 의한 총요소생산성(TFP) 증가율 계산을 위해 AI의 생산성 증가 효과의 기초모수로 사용한다.

제5장에서는 제3장 및 제4장에서 추정한 기초모수를 사용하여 AI 활용의 확산이 한국경제의 총요소생산성(TFP) 성장에 미치는 영향을 추정한다. 특히 거시경제 영향을 분석하기 위해 과업기반 생산함수(task-based production function)를 가정하고, 일반균형모형(general equilibrium model) 하에서 Hulten 정리(Hulten's theorem)를 적용한다. 또한 AI 활용 충격이 장기 고용규모 및 임금에 미치는 영향을 직종별 횡단면 IV 분석을 통해 추정하여 AI가 장기적으로 직종 간 임금불평도에 미치는 영향을 분석한다. 선형적이지만, AI 활용 확산으로 자동화가 가능한 과업(직종)에서는 수요가 감소함에 따라 자본 및 AI 투입이 증가하는 가운데 전반적으로 자본-노동 비율이 상승하고 임금이 상대적으로 하락할 가능성이 높다. 이러한 구조적 변화는 산업·직무 간 노동의 재배치와 임금분포의 이질화를 초래하여 임금소득불평등을 심화시킬 가능성이 있기 때문에 제5장에서 심도 깊게 분석한다.

제6장에서는 제2, 3, 4, 5장에서 핵심적으로 발견한 연구 결과를 요약 정리하고, 본 연구의 경제적 의의와 더불어 한계점을 지적한다. 마지막에서는 분석 결과를 바탕으로 정부 및 기업 등이 대응해야 할 정책 방안 및 기업의 AI 전환 전략 등을 제시한다. 특히 큰 틀에서 향후 한국경제가 풀어야 할 AI 혁신 및 규제정책 방향, 노동시장에 대한 정책 방안, 마지

막으로 교육 및 인재 양성 정책 방안 등에 대해서 논의한다. 기업 측면에서는 향후 거시경제적 흐름의 변화에 대응하여 어떻게 기업 전략을 수립해야 하는지 논의한다.

제2장

생성형 AI의 기술 진화와 경제적 의미

제1절 생성형 AI의 기술 진화

본 절에서는 생성형 AI의 발전 과정을 다섯 가지 주요 기술 단계로 분류하고, 각 단계별 기술적 전환점에 대해서 논의할 뿐 아니라 해당 기술이 어떠한 경제적 의미를 가지고 있는지 살펴보고자 한다. 특히 단계별 기술의 개념과 대표적 사례를 소개하고, 노동시장 및 생산성에 미친 영향과 정책적 시사점을 제시한다.

1. 트랜스포머의 등장: 대규모 사전학습의 시작

2017년 구글(Google)의 연구원들은 AI 발전사에 매우 중요한 이정표가 될 논문 “Attention is All You Need”를 발표한다(Vaswani *et al.*, 2017). 이 논문은 현재 대부분의 생성형 AI가 따라하는 트랜스포머(transformer) 딥러닝 모형구조를 제안한다. 트랜스포머는 어텐션(attention) 메커니즘을 활용해 순차적 데이터 처리의 한계를 극복한 신경망 구조로, 이전의 순환 신경망(recurrent neural network: RNN)이나 장단기 메모리(long short-term memory)보다 병렬화가 용이하고 긴 문장도 효율적으로 처리할 수 있다. 이 혁신 덕분에 훨씬 대규모의 데이터로 사전학습(self-supervised

pre-training)이 가능해졌고, AI가 언어나 이미지의 장기 의존관계까지 포착할 수 있게 되었다. 좀 더 쉬운 말로 하면, 기본적으로 프로그램은 인간의 뇌만큼 기억이나 추론에 있어서 효율적이지 못하기 때문에 어떤 특정 정보와 시간적으로 떨어진 정보를 연결시켜서 추론하는 것, 즉 장기 의존(추론)관계를 유지하는 것이 어렵다. 그러나 트랜스포머는 이를 가능하게 함으로써 딥러닝 분야의 분수령으로 평가되며, 이후 현대 생성형 AI의 기반이 되었다.

트랜스포머 모형은 셀프 어텐션(self-attention)이라는 논리를 통해 입력 데이터의 각 요소가 서로 간에 얼마나 연관을 가지는지 계산하는 방식으로 동작한다.⁵ 예를 들어 “나는 복숭아를 좋아해”라는 문장을 번역할 때, 단어 ‘좋아해’를 이해하기 위해 단어 ‘복숭아’와 ‘좋아해’의 관계의 중요도를 계산하여 문맥을 이해하고 더 나은 번역이나 요약을 수행한다. 즉, RNN이 단어를 한 줄로 차례대로 읽는다면, 트랜스포머는 모든 단어를 동시에 고려하면서 중요한 단어 및 단어 간 관계에 가중치를 부여하는 방식으로 작업을 수행한다. 이를 통해 멀리 떨어진 단어들 사이의 관계, 혹은 문장의 앞뒤 맥락까지 효과적으로 포착하고, 병렬연산을 통해 학습 속도를 높인 것이다. 이러한 방식은 자연어 처리뿐 아니라 이미지, 음성 등 다른 데이터에도 적용 가능하다. 실제로 트랜스포머 기반 비전모형(ViT)은 이미지 인식 성능에서 합성곱 신경망(convolutional neural network: CNN)⁶을 능가했고, 확산모형(diffusion model)⁷ 등 이미지 생성기나 음성 합성에도 트랜스포머 구조가 활용되고 있다.

이러한 트랜스포머 개념을 토대로 각종 초거대모형이 탄생하게 되는데, 가장 먼저 Google이 2018년 텍스트 마스크 예측을 통한 양방향 사전

5 트랜스포머 관련 내용은 IBM의 웹페이지(<https://www.ibm.com/think/topics/transformer-model>) 내용을 정리하였다(최종접속일: 2025. 10. 5).

6 CNN은 이미지, 비디오 등 시각적 데이터를 분석하기 위해 설계된 딥러닝 알고리즘으로 인간의 시각 피질 기능을 모방하여 이미지의 공간적 특징을 추출하고 패턴을 인식하는데 탁월한 성능을 보여준다.

7 확산모형은 이미지, 음성 등 데이터에 노이즈를 추가하고 제거하는 과정을 반복학습하여 고품질의 새 이미지를 생성하는 생성형 AI 모형의 한 종류이다.

학습 모형인 BERT를 발표한다. 이 모형은 자연어 이해를 대폭 향상시킨 대표적인 모형으로서 이후 Google 검색 등 다양한 서비스에 활용되어 성능을 향상시켰다. OpenAI가 2020년에 발표한 GPT-3는 트랜스포머 디코더(decoder)를 통해 대용량 텍스트를 비지도(unsupervised) 사전학습한(pre-training) 생성형 모형이다. 특히 당시 GPT-3(2020)은 1,750억 파라미터로 최대 규모였고, 간단한 프롬프트만으로도 다양한 텍스트 생성 작업을 수행해 화제가 되었다. 이 외에도 Google의 T5(2019), Meta의 LLaMA(2023) 등 여러 트랜스포머 기반 대규모 언어모형(LLM)이 등장하면서 기술경쟁을 촉발하였다. 또한 트랜스포머 개념은 이미지 생성모형(DALL-E, Stable Diffusion 등)의 핵심인 확산 과정에도 적용되어, 텍스트-이미지 변환 성능을 크게 높였다.

트랜스포머로 인한 대규모 사전학습의 도입은 AI를 범용적으로 사용할 수 있게 만든 계기가 되었다. 이전까지 AI는 개별 작업에 특화된 모형들이 많았지만, 기반모형(foundation model)의 등장으로 하나의 거대모형이 여러 과업을 통합 수행할 가능성을 열었다(Chui *et al.*, 2023). 이는 범용기술(general purpose technology: GPT)의 탄생으로, 한 번 거대한 말뭉치를 학습한 언어모형이 번역, 요약, 질문응답 등 다양한 업무에 재사용됨으로써 규모의 경제를 실현할 수 있게 된 것이다. 기업들은 더 이상 각 작업마다 별도 AI를 개발하지 않고, 사전학습된 거대모형을 파인튜닝하여 활용함으로써 개발비용과 시간을 절약할 수 있다. 이러한 작업방식의 변화는 IT산업의 생산성 향상과 서비스 혁신을 가속화하는 토대가 되었다.

다만, 초기 단계에서 이 기술의 가능성에 비해 즉각적인 경제 효과는 제한적이었다. 트랜스포머 기반모형들은 주로 빅테크 연구소에서 개발되어 논문이나 데모 형태로 존재하였고, 실제 비즈니스에 적용되기까지는 추가 연구와 인프라 투자가 필요하였다. 그럼에도 기계번역 분야에서는 이미 구글 번역 등에 트랜스포머 기술이 채택되어 번역 품질이 크게 향상되었고, 이는 국제 의사소통 비용을 낮추는 생산성 향상 요인으로 작용하였다. 또한 트랜스포머로 가능해진 대용량 사전학습은 이후 등장하

는 챗봇 및 창작 AI들의 기반이 되어, 향후 지식노동 자동화의 가능성을 시사하였다(Chui *et al.*, 2023). 요약하면, 1단계에서 트랜스포머는 생성형 AI의 경제적 파급력을 예고하며 AI 시대의 서막을 여는 신호탄이었다.

2. 인간 지도학습: 인스트럭션 튜닝과 머신러닝 강화학습

트랜스포머로 인해 등장하기 시작한 대규모 언어모형(*large language model*: LLM)들의 초기 버전은 방대한 학습내용을 담고 있음에도 불구하고 사용자(인간)의 지시(혹은 명령)를 정확히 이해하고 따르는 능력이 제한적이었다. 이를 개선하기 위해 등장한 기법이 인스트럭션 튜닝(*instruction tuning*)과 인간 피드백 강화학습(RLHF)이다. 2022년 OpenAI는 GPT-3 모델을 사용자 지침에 따라 응답하도록 미세조정한 InstructGPT를 선보였고, 나아가 채팅 형식으로 대화할 수 있도록 한 ChatGPT를 공개하였다(Chui *et al.*, 2023). ChatGPT는 사용자의 질문 의도를 파악하고 일관된 대화로 답변하는 능력이 크게 향상되어, 출시 2개월 만에 전 세계 1억명 이상이 사용하게 되었다.⁸

인스트럭션 튜닝이란 모형에 다양한 명령-응답 예시를 지도학습(*supervised learning*)시켜서, 사람이 지시하는 형식의 입력에 잘 대응하도록 한 것이다. 예를 들어 “한 문장으로 요약해줘” 같은 지시문에 올바른 출력 형태를 내도록 시범을 보여주어 모형을 훈련하는 것이다. 한편, RLHF는 인간 평가자들이 모형의 답변에 점수를 매겨 선호도를 표시하면, 이를 토대로 모형이 보상신호를 얻어 좀 더 바람직한 응답을 생성하도록 강화학습하는 방식이다. 이 과정을 통해 모형은 단순한 정답뿐 아니라 맥락(*context*)에 적절하고 유용한 답변을 하도록 조정된다. 이러한 지도학습과 비지도학습의 혼합 기법 덕분에 최신 LLM은 사람의 의도를 더욱 정확히 이해하고 따르게 된다. 그 결과, 사용자는 프롬프트 공학에 능숙하지 않아도, 일상언어로 질문하거나 요청해도 모형이 그 의도를 파

8 <https://www.reuters.com/technology/chatgpt-sets-record-fastest-growing-user-base-analyst-note-2023-02-01/>(최종접속일: 2025. 10. 5).

악해 원하는 작업을 수행하는 사용자 친화적인 AI가 구현되었다.

대표모형의 첫 번째 예로는 ChatGPT를 들 수 있다. ChatGPT는 인스트럭션 튜닝과 RLHF를 거친 OpenAI의 대화형 AI로 복잡한 질문에 대한 답변, 에세이 작성, 코딩 등 광범위한 작업을 수행한다. 이를 통해 생성형 AI가 실생활 업무에 활용될 수 있음을 보여준 첫 번째 대규모 사례이다 (Chui *et al.*, 2023). 두 번째 대표모형은 2023년에 발표된 Claude 모형이다. OpenAI 출신들이 설립한 Anthropic의 AI로, 헌법 기반 AI(constitutional AI) 등의 새로운 접근법으로 안전하고 일관된 대화를 지향한다.⁹ Claude 역시 RLHF를 활용하여 유해한 내용 생산을 억제하고 유익한 응답을 생성하도록 조정되었다.

이 단계에서 생성형 AI는 비로소 범용적인 활용성을 갖추며 AI 분야로 본격 진입하게 되었다. 특히 인간의 언어로 소통하며 명령을 실시간 처리할 수 있게 된 덕분에, 기업과 개인은 AI를 여러 업무의 조력자로 활용하기 시작했다. 특히 과업 단위 생산성 향상에 긍정적인 영향을 끼친다는 연구 결과들이 속속 발표되었다. 예를 들어 Noy and Zhang(2023)에 따르면 ChatGPT 지원을 받은 참가자들의 업무문서 작성시간이 절반으로 단축되었고, Kalliamvakou(2024)는 코드 보조 AI(Github Copilot 등)를 사용한 개발자들의 코딩 시간이 최대 2배 빨라지는 사례를 관찰하였다.¹⁰ Brynjolfsson *et al.*(2023)은 AI 챗봇을 상담사에게 제공한 결과 평균 14%의 생산성 향상이 나타났으며, 특히 신입직원의 생산성이 크게 증가했다고 설명한다. 이처럼 지식노동자 1인당 산출 증가가 단기적으로 확인되면서, 기업들은 생산성 향상을 기대하며 생성형 AI 도입을 가속화하고 있다.

9 Constitutional AI란 사람의 대규모 수작업 레이블에 지나치게 의존하지 않고, ‘헌법(원칙 집합)’을 모형의 행동 기준으로 삼아 모형이 스스로(또는 모형이 다른 모형을 감독하여) 답변을 평가·개선하도록 만드는 정렬(alignment)기법이다.

(<https://www.anthropic.com/research/constitutional-ai-harmlessness-from-ai-feedback> 최종접속일: 2025. 10. 5).

10 <https://github.blog/news-insights/research/research-quantifying-github-copilots-impact-on-developer-productivity-and-happiness/>(최종접속일: 2025. 10. 5).

3. 초장문맥 처리와 AI의 에이전트화

2023년에 들어오면서 LLM의 문맥 처리 능력이 획기적으로 개선되었다. 예를 들어 Anthropic사의 Claude 모형은 2023년 3월에 약 9천 토큰(몇 천 단어)까지 문맥을 처리할 수 있었는데, 불과 두 달 후에는 약 10만 토큰(약 7만 5천 영어 단어)으로 컨텍스트 길이를 확장하여 장편 소설 한 권 분량의 텍스트도 한 번에 다룰 수 있게 되었다(Chui *et al.*, 2023). OpenAI의 GPT-4 역시 최대 3만 2천 토큰의 문맥 버전을 공개하여, 긴 문서를 한꺼번에 입력하고 분석·요약하는 작업이 가능해졌다. 동시에 에이전트형 AI의 개념이 부상하였는데, 이는 AI가 단순히 한 번의 질문에 답하는 것을 넘어 도구를 사용하고 연속적 추론을 통해 자율적으로 과제를 수행하도록 만든 것이다. 2023년 초에 공개된 AutoGPT 등은 사용자가 목표만 주면 AI 에이전트들이 자체적으로 하위 작업을 계획·실행하며, 필요시 인터넷 검색이나 코드 실행 같은 외부 도구를 활용하여 목표 달성을 시도한다.¹¹ 이런 기술의 발전은 AI를 단순 대화 상대에서 능동적 업무수행자로 격상시키는 전환점을 만들었다고 볼 수 있다.

초장문맥(long context) 처리란 AI 모형이 한 번에 기억하고 활용할 수 있는 입력의 제한이 늘어나는 것을 의미한다. 문맥의 범위가 긴 모형은 대용량 문서, 복잡한 보고서, 다수의 대화 내역 등을 통째로 학습하여 일관성 있는 응답을 생성할 수 있게 한다. 예컨대 수십 페이지짜리 계약서를 통째로 AI에 입력하고 요점을 묻거나, 소설 전편을 주고 결말을 이어 쓰게 하는 업무가 가능한 것이다. 문맥이 확장되면서 추론 능력도 향상되었는데, 이전에는 잊어버리던 앞부분 정보를 끝까지 참조하여 긴 논증이나 줄거리 유지가 가능해졌다.

AI의 에이전트화는 자율적으로 행동할 수 있는 AI를 의미한다. 즉, 전통적 LLM은 사용자가 한 질문을 던지면 한 답을 주는 1회성 상호작용이었는데, 에이전트 AI는 목표 지향적으로 연속 동작함으로써 주어진 목표

¹¹ <https://www.ibm.com/think/topics/autogpt>(최종접속일: 2025. 10. 5).

를 달성하기 위해 스스로 다음 행동을 결정하고, 그 과정에서 필요한 정보를 검색하거나 계산, 다른 AI 호출 등의 도구 활용을 수행한다.¹² 그리고 각 단계 결과를 바탕으로 다음 단계를 계획하며 상호순환을 형성한다. 이를 통해 AI는 비교적 복잡한 작업을 인간의 개입 없이 끝까지 처리할 수 있는 기능을 가지게 되었다. 예를 들어 “우리 회사 경쟁사 분석 보고서를 작성해줘”라는 업무를 주면, AI 에이전트는 웹에서 경쟁사 정보를 찾아 읽고, 표를 만들고, 요약정리를 거쳐 하나의 보고서를 완성하는 식이다. 이러한 프로세스는 과거엔 사람이 여러 단계를 거치며 작업해야 했지만, 이제 AI가 마치 인간처럼 역할을 수행하게 된 것이다.

대표적인 AutoGPT는 오픈소스 프로젝트로 여러 개의 GPT 에이전트를 생성하여 협동 작업을 수행한다. 예컨대 한 에이전트는 아이디어를 내고, 다른 하나는 그것을 구체화하며, 또 다른 에이전트는 인터넷에서 자료를 찾아오는 식으로 팀을 이루는 것이다.¹³ 즉, AutoGPT는 “주어진 예산으로 마케팅 계획 세우기” 같은 다단계 업무를 목표로 하면, 하위 과제를 자동 분할하고 순차적으로 해결함으로써 인간의 프롬프트 없이도 연속 작업을 진행한다. 특히 LangChain 프레임워크라는 기술은 AI의 에이전트화를 가능하게 해주는 라이브러리이다. Python 등에서 사용하는 라이브러리로, LLM이 외부 도구(예: 웹 검색, 데이터베이스 질의, 계산기 등)를 사용할 수 있도록 해줌으로써 AI가 자신의 학습내용을 넘어 실시간 정보를 검색하고, 사실 확인을 거쳐 답변 정확도를 높이는 RAG(Retrieval-Augmented Generation) 기법을 확산시켰다. 예를 들어 Bing 챗봇은 질문에 대해 웹검색을 실행한 후 최신 정보를 종합해 답변하고 출처를 표시하는데, 이런 형태의 검색결합형 생성이 RAG의 사례라 할 수 있다.¹⁴

초장문맥과 에이전트화로 인해 AI의 적용 범위와 자동화 수준이 한층 확대되었다. 특히 경제적으로 중요한 의미를 몇 가지로 살펴볼 수 있는데, 우선 복잡한 지식 작업의 자동화가 가능해졌다는 것이다. 이제 AI는

¹² 각주 11을 참고

¹³ 각주 11을 참고

¹⁴ <https://python.langchain.com/docs/introduction/>(최종접속일: 2025. 10. 5).

단순 Q&A나 짧은 글쓰기뿐 아니라, 장문의 문서분석이나 종합적인 연구 업무도 수행할 수 있게 되었다. 예컨대 변호사가 해야 했던 계약서 검토 요약, 컨설턴트가 하던 시장조사 보고서 작성 등의 작업 일부를 AI가 맡을 수 있다. 이는 전문직 분야의 일부 업무까지 자동화 또는 보완할 수 있음을 의미한다. 과거에는 인간 전문가들만 가능한 줄 알았던 고차원 과업도, AI가 충분한 문맥을 갖고 일관성 있게 추론하면서 처리할 수 있는 시대가 온 것이다. 따라서 사무직의 생산성이 크게 향상될 잠재력이 있으며, 기업은 인력 투입을 줄이거나 동일 인력으로 더 많은 업무 처리를 기대할 수 있게 되었다. 특히 초장문맥과 에이전트 기능의 융합은 법률, 회계, 연구개발 등 문서 집약적 산업에서 일정 부분 생산성을 제고할 가능성이 높은 것으로 판단된다.

더불어, 업무 프로세스의 자율화가 가능해짐에 따라 재설계가 필요하다. 즉, AI 에이전트가 사람의 지휘 없이도 일련의 업무를 수행할 수 있다면, 기업의 업무 프로세스 자체를 재구성해야 할 필요가 생긴다. 예컨대 고객지원 프로세스에서, AI가 고객 문의를 접수하고 관련 정보를 조회해 해결책을 제공한 뒤 필요한 경우 인간 직원에게만 특이 사례를 이관하도록 할 수 있다. 이는 업무 흐름의 자동화이며, 중간중간 사람이 개입하던 단계를 AI가 대체함으로써 비용절감과 처리 속도를 향상시킬 수 있다. Chui *et al.*(2023)은 조직이 AI 에이전트를 중심으로 운영을 재편해, 기업 전반에서 엔터프라이즈급 가치를 달성하려는 움직임이 있다고 설명한다. 다만, 현재 많은 기업들이 생성형 AI를 시범활용 중이지만 뚜렷한 성과를 내지 못한 경우도 많은데, 이는 기존 프로세스에 단순 적용해서는 한계가 있고 근본적인 운영모형의 혁신이 필요하다는 것을 의미한다 (Chui *et al.*, 2023). 따라서 AI 에이전트의 등장은 기업들이 업무표준(standard operating procedure)을 재정립하고, 인적자원 역할을 재정의하게 만드는 등 기업이 조직을 AI의 기능에 맞추어 재설계하도록 요구하고 있다.

4. 멀티모달 통합: 텍스트에서 이미지 · 음성 · 비디오로

생성형 AI는 이제 텍스트를 넘어 이미지, 음성, 영상 등 멀티모달 데이터를 처리하고 생성하는 단계로 접어들었다. 2022년에 공개된 OpenAI의 DALL-E 2와 Stability AI의 Stable Diffusion은 사용자의 텍스트 프롬프트만으로 고해상도 이미지를 자동 생성하고 있다. 같은 해 Midjourney를 이용해 그린 그림이 미술대회에서 우승하며 예술계 논쟁을 불러일으키기도 했다.¹⁵ 2023년에는 OpenAI의 GPT-4가 이미지 입력을 이해하고 분석하는 멀티모달모형으로 발표되어, 사진 속 장면 설명이나 손으로 그린 스케치를 코드로 바꾸는 등의 시연을 선보였다. 음성 분야에서는 Whisper (OpenAI) 등 고성능 음성인식모형과, VALL-E(마이크로소프트) 등의 음성합성모형이 등장하여 텍스트와 음성 간 자유로운 변환이 가능해졌다.¹⁶ 영상 분야도 Runway Gen-2 등 텍스트로부터 짧은 영상을 생성하는 모형이 나오며 초기 단계에 진입하였다.¹⁷ 이처럼 멀티모달 통합은 AI가 인간의 모든 감각 정보를 다루는 방향으로 진화하고 있음을 보여준다.

멀티모달(multi-modal) AI란 한마디로 여러 가지 형태의 데이터를 동시에 처리하거나 생성할 수 있는 AI이다. 사람으로 치면 글을 읽고(텍스트), 그림을 보고(이미지), 말을 듣고(음성) 종합적으로 이해하는 능력이라고 할 수 있다. 이전까지 AI 모형들은 대체로 한 가지 양식(modality)에 특화돼 있었지만, 최신 거대모형들은 시각언어모형(vision-language model: VLM)처럼 이미지를 입력받아 설명을 텍스트로 출력하거나, 음성합성모형이 텍스트 입력을 사람 목소리로 읽어주는 등 크로스-모달(cross-modal) 작업을 할 수 있다.¹⁸ 이러한 통합은 주로 공통 표현공간을 학습함으로써 이뤄지는데, 예를 들어 OpenAI의 CLIP 모형은 이미지와 텍스트를 동일한 임베딩 공간에 맵핑하여 사진과 설명 문장을 서로 연결할 수 있게 했

15 <https://www.weforum.org/stories/2024/02/ai-creative-industries-davos/>(최종접속일: 2025. 10. 5).

16 <https://www.microsoft.com/en-us/research/project/vall-e-x/>(최종접속일: 2025. 10. 5).

17 <https://runwayml.com/research/gen-2/>(최종접속일: 2025. 10. 5).

18 <https://www.ibm.com/kr-ko/think/topics/vision-language-models/>(최종접속일: 2025. 10. 5).

다.¹⁹ 멀티모달 생성형 AI는 한 걸음 더 나아가 텍스트 프롬프트로 이미지나 영상 생성, 또는 반대로 이미지 입력에 대한 텍스트 생성(예: 캡션 달기)을 수행한다. 음성과 텍스트 간 변환도 양방향으로 가능해져, 사용자가 음성으로 질문하면 AI가 이를 텍스트로 이해하고 답변을 다시 음성으로 말해 주는 음성 인터페이스도 구현되고 있다. 요컨대 멀티모달 AI는 인간의 다양한 표현 수단을 아우르는 범용인지모형을 향해 발전하고 있는 것이다(Chui *et al.*, 2023).

이미지 생성의 대표모형 중 Stable Diffusion은 대중에게 공개된 텍스트-이미지 생성모형으로, 누구나 PC에서 예술작품이나 디자인 시안을 생성할 수 있게 했다.²⁰ 이로 인해 마케팅 시각자료, UI 시안 제작 등에 걸리는 시간이 대부분 단축되고 있다. Midjourney는 예술가들과 디자이너들에게 인기가 높은 서비스로, 독창적이고 복잡한 삽화도 몇 초 만에 뽑아내고 있다.²¹ 2023년에는 Adobe도 Firefly라는 이미지 생성 AI를 출시해, 상업적으로 이용 가능한, 즉 저작권에 문제없는 이미지 생성을 할 수 있게 되었다.²² 대표적 시각언어모형인 OpenAI GPT-4의 이미지 이해기능은 입력그림을 보고 맥락을 이해하여 대답해 준다. 예를 들어 냉장고 속 식재료 사진을 보여주면 GPT-4가 가능한 요리 메뉴를 추천해 주고, 손으로 그린 홈페이지 스케치를 입력하면 HTML/CSS 코드를 생성해 웹페이지로 구현해 준다.^{23,24} Google의 PaLM-E는 로봇의 카메라 비전과 언어모형을 결합해, 로봇에게 “찬장에서 사과 주스 가져와”라고 하면 실제 카메라 영상을 보며 주스를 찾아 집어오는 등 멀티모달 로봇 제어를 선보였다.²⁵ 음성 및 영상 쪽에서는 OpenAI의 Whisper가 100여 개 언어를 실시간 음

19 <https://openai.com/index/clip/>(최종접속일: 2025. 10. 5).

20 <https://stablediffusion.com/>(최종접속일: 2025. 10. 5).

21 <https://www.midjourney.com/home>(최종접속일: 2025. 10. 5).

22 https://www.adobe.com/vn_en/products/firefly.html(최종접속일: 2025. 10. 5).

23 <https://www.facebook.com/openai/posts/show-chatgpt-whats-in-your-fridge-and-get-recipe-ideas-in-time-for-dinner/1309628284292112/>(최종접속일: 2025. 10. 5).

24 <https://x.com/gdb/status/1635826383141376002>(최종접속일: 2025. 10. 5).

25 <https://research.google/blog/palm-e-an-embodied-multimodal-language-model/>(최종접속일: 2025. 10. 5).

성을 텍스트로 변환해 주며, 팟캐스트나 화상회의 녹취록 작성 등에 활용되고 있다.²⁶ VALL-E와 ElevenLabs 등의 음성합성은 몇 초 분량의 샘플 음성을 듣고도 그 사람 목소리 스타일로 임의의 문장을 합성해 낸다. 이는 오디오북 자동제작이나 영화더빙 등에 응용될 수 있다. 특히 영상 생성은 아직 초기지만, 간단한 애니메이션 GIF나 3~5초짜리 동영상을 텍스트로 만들 수 있고, 딥페이크 기술의 발전으로 영화에서 배우의 나이를 젊게 만드는(예: 인디애나 존스 신작에서 80세 해리슨 포드를 AI로 젊게 표현²⁷) 사례도 등장했다. 향후 광고 영상이나 교육용 영상의 상당 부분을 AI가 제작하는 시대도 가능해질 것으로 전망된다.

이러한 멀티모달 AI의 등장은 창의력이 필요한 산업의 생산성에 상당한 영향을 미칠 것으로 판단된다. 특히 이제는 전문디자이너가 아니어도 AI를 이용해 시각자료를 손쉽게 만들 수 있고, 성우 없이도 음성 내레이션을 생성할 수 있다. 이는 자연스럽게 콘텐츠 제작비용 감소와 생산성 제고로 이어질 수 있다. 예를 들어 스타트업이 광고 영상을 만들 때 예전에는 그래픽 디자이너, 촬영 스태프, 편집자 등이 필요했지만, 이제는 기획자가 AI에 아이디어를 설명해 이미지를 얻고, AI 음성으로 내레이션을 입혀 1인 제작에 가까운 효율을 낼 수 있는 것이다. 이에 Chui *et al.* (2023)은 생성형 AI가 마케팅, 디자인 분야에서 대량의 맞춤형 콘텐츠를 저비용으로 만들어 매출증대와 비용절감을 동시에 가져올 수 있다고 분석한다. 이러한 생산성 제고 효과는 특히 중소기업과 개인 창작자에게 유리하여, 과거보다 적은 자본으로도 고품질 콘텐츠를 생산함으로써 시장의 접근 장벽을 낮추는 시장의 개방 효과도 기대된다.

그러나 멀티모달 생성형 AI를 이용한 콘텐츠 생성은 기존 지적재산권 체계와 충돌을 일으키며 경제적 이해관계에 영향을 주고 있다. 예를 들어 AI 이미지 모형은 인터넷의 방대한 그림 데이터를 학습했는데, 여기엔 인간 창작자들의 저작물이 필연적으로 포함되어 있다. 이에 대해 창

26 <https://openai.com/ko-KR/index/whisper/>(최종접속일: 2025. 10. 5).

27 <https://www.weforum.org/stories/2024/02/ai-creative-industries-davos/>(최종접속일: 2025. 10. 5).

작자들은 무단 도용이라며 반발하고 있고, 몇몇 소송(Getty Images와 시 각예술가집단의 Stability AI, Midjourney, DeviantArt 등에 대한 소송 등)이 진행 중이다.²⁸ 결과적으로 향후 AI 트레이닝 데이터에 대한 비용지불이나 새로운 규범이 필요할 수 있는데, 이는 AI 기업의 비용구조와 비즈니스 모형에 영향을 줄 것이다. 또한 잘못된 정보 생성(딥페이크 영상으로 가짜뉴스 생산 등)이나 프라이버시 침해(특정인 얼굴 합성 등)에 대한 우려로 각국 정부가 규제책을 논의 중이다. 예컨대 2026년에 발효되는 EU의 AI 법안은 생성형 AI가 만든 이미지·영상에는 AI 산출물 표시를 의무화하는 조항을 포함하고 있다.²⁹ 이러한 규제는 AI 활용에 필요한 신뢰를 구축하도록 해 AI 수용성을 높이는 긍정적 효과도 있지만, 과도하면 혁신의 속도를 둔화시켜 경제적 가치 창출을 늦출 가능성도 있다. 따라서 AI 관련 윤리와 혁신의 균형을 찾는 정책적 대응이 매우 중요한 시점이다.

5. 수평형 對 수직형 AI: 범용 플랫폼과 도메인 특화

모형 개발 방향의 분화가 생성형 AI 생태계를 더욱 빠르게 발전시키고 있다. 한 갈래는 OpenAI, Google, Meta 등이 추구하는 수평적(horizontal) 접근, 즉 초거대 범용모형시장이고, 다른 갈래는 산업별·용도별 수직적(vertical) 특화모형시장이다. 수평형은 거대한 파라미터 집합을 가진 하나의 범용모형을 학습시킨 뒤, 이를 다양한 목적으로 미세조정(fine tuning)하거나 API(application programming interface) 형태로 제공함으로써 확장성과 범용성을 극대화하고, 수직형은 각 조직이나 업계에서 자체 데이터와 규칙으로 비교적 작은 언어모형을 미세 조정하거나 별도로 학습하여, 해당 도메인 지식에 정통하고 관련 규제 요건을 준수하는 맞춤형으로 개발된다. 이 둘의 관계는 마치 Windows나 Android 같은 범용 플랫폼과 특

²⁸ <https://www.reuters.com/legal/getty-images-lawsuit-says-stability-ai-misused-photos-train-ai-2023-02-06/>(최종접속일: 2025. 10. 5).

²⁹ <https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-50>(최종접속일: 2025. 10. 5).

정 업무용 소프트웨어와 같은 관계로 볼 수 있다. 이렇게 수평형 對 수직형의 분화는 비즈니스 전략과 정책 요인이 함께 작용한 결과이다. 빅테크들은 거대한 범용모형을 선도함으로써 AI 인프라를 장악하고, 모든 산업에 API로 침투하는 플랫폼 전략을 취하는 것이고, 반면 도메인 전문기업이나 정부기관 등은 범용모형에 의존하자니 데이터 종속과 규제 위험이 우려되고, 범용모형이 제공하지 못하는 미세한 조정과 높은 신뢰성을 원하기 때문에 자체 특화모형 개발을 추진하고 있는 것이다.

좀 더 자세히 설명하자면, 예를 들어 범용모형인 GPT-4는 문학부터 과학, 코딩까지 폭넓은 지식을 학습하여, 사용자 프롬프트에 따라 글쓰기, 계산, 추론 등 다양한 작업을 수행하기 때문에 매우 거대하게 만들수록 성능이 향상되는 경향이 있고, 한번 학습에 막대한 비용이 들지만 그 결과물을 API 등으로 많은 이용자에게 서비스하여 비용을 회수하여 규모의 경제를 실현할 수 있으나, 단점은 개별 분야에 대한 최적화가 부족하고 통제가 어렵다는 것이다.

수직형(도메인 특화) 모형에서는 금융 분야의 용어·문체에 익숙한 BloombergGPT 같은 경우 금융 전문 뉴스, 보고서 등 약 7,000억 토큰 이상으로 훈련하여 일반 GPT보다 금융 관련 자연어 처리 작업(natural language processing: NLP)에서 뛰어난 성능을 보였다.³⁰ Google이 개발한 Med-PaLM 같은 경우는 의학 논문과 임상 데이터로 훈련되어, 미국 의사 시험 문제를 전문가 수준으로 풀어낼 정도이다.³¹ 이렇게 특화된 모형은 해당 영역의 용어, 규범, 문맥을 잘 이해하기 때문에 정확도와 신뢰성이 높다. 또한 기업으로서는 데이터 프라이버시나 규제 준수(예: 환자 개인 정보 보호 등)를 위해 자체 모형을 사내 구축하는 수요도 크다. 따라서 수직형 모형의 최대 장점은 특정 맥락에 최적화되고 안정적이라는 것이며, 단점은 상대적으로 범용성이 떨어지고 규모 면에서 한계가 있다는 것이다.

30 <https://www.bloomberg.com/company/press/bloomberggpt-50-billion-parameter-llm-tuned-finance/> (최종접속일: 2025. 10. 5).

31 <https://sites.research.google/med-palm/> (최종접속일: 2025. 10. 5).

수평형 對 수직형 구조의 분화는 AI의 기술 확산과 가치분배 측면에서 여러 시사점을 던져 준다. 우선, 생산성 극대화와 맥락 적합성이다. 범용 모형은 다양한 업무에 적용되어 경제 전반의 생산성을 끌어올릴 잠재력이 크기 때문에 만약 누구나 강력한 AI에 접근 가능하다면 혁신 속도가 빨라지고 전체 경제규모가 커질 수 있다. 반면, 특화모형은 각 부문에서 정밀한 성능개선을 통해 리스크 관리와 신뢰성 제고에 기여해야 한다. 예를 들어 의료 AI는 범용모형보다 특화모형이 오진 위험이 낮고, 금융 AI는 규제기준에 맞춰 내용을 필터링하는 등 도메인 요구에 부합하는 장점을 가진다. 이는 국지적 최적화를 통해 해당 분야의 생산성을 향상시키고, 실수로 인한 비용(예: 의료 오진)을 줄이는 경제적 효과가 있다. 따라서 범용과 특화는 경쟁하기보다는 보완관계로, 각자의 영역에서 가치창출을 극대화하는 방향으로 발전할 것으로 판단된다.

두 번째는 산업 가치사슬과 경쟁체제이다. 범용모형을 만드는 기업은 엄청난 초기 투자와 연구인력이 필요해 상위 몇 개 기업에 쏠리는 경향이 있다. 이에 따라 AI 분야의 과점화 우려가 존재하고, 극소수 범용모형이 시장을 지배하면, 이들이 가격 결정력과 기술 주도권을 갖게 되어 경제적 이익이 한쪽에 편중될 가능성을 노출하고 있다. 반면, 오픈소스나 특화모형의 확산은 진입 장벽을 낮추고 경쟁을 촉진한다. Gartner는 2025년까지 기업의 60% 이상이 오픈소스 LLM을 최소 하나 이상 도입할 것으로 전망하면서 기업들의 빅테크 모형에 대한 의존도가 낮아질 것이라고 보고 있다. 분산된 AI의 가치분배가 가능할 것이라고 설명한다.³² 실제로 Bloomberg는 거대 범용모형 대신 자체 BloombergGPT를 개발하여, 내부 금융 데이터로 특화된 모형을 보유하게 됨으로써 자신의 가치사슬 통제력을 확보했다.³³ 이러한 움직임은 각 산업의 유력 기업들이 AI 주도권을 잡기 위해 투자할 것을 의미하며, AI 기술력이 곧 산업 경쟁력의 핵심 자산이 되어가고 있음을 의미한다.

³² <https://dextralabs.com/blog/best-open-source-llm-model/>(최종접속일: 2025. 10. 5).

³³ 각주 30 참조

마지막으로는 규제와 표준의 차이이다. 수평 對 수직 분화에는 규제 준수와 현지화 이슈도 매우 중요하다. 글로벌 범용모형은 하나로 전 세계에 서비스되므로, 각국의 상이한 법률·문화적 요구를 모두 만족시키기 어렵다. 예컨대 어떤 나라에서는 허용되는 표현이 다른 나라에서는 불쾌감을 줄 수 있고, 개인정보 규제가 달라 적용에 제약이 생길 수 있다. 이럴 때 현지 기업이나 정부가 자국 특화 AI를 만들면 규제를 준수하면서도 자체 기준에 맞는 출력을 얻을 수 있다. 이는 AI 주권과도 연결되는 문제로, EU, 중국 등에서 자체 대형모형 개발을 장려하는 이유이기도 하다. 따라서 향후에는 글로벌 표준형 AI와 지역별 특화 AI가 공존하게 되고, 이는 서비스 수출입이나 데이터 교류 측면에서 무역 장벽 또는 표준 경쟁으로 나타날 수 있다. 경제적으로 지역산업 보호 효과가 있지만, 다른 한편으로 비용중복과 규모의 경제 상실 우려도 존재한다. 이를 해결하기 위해 국제 협력을 통한 AI 윤리·안전 표준화가 논의되고 있으며, 범용모형 기업들도 각국 정부와 협력해 준법체계를 마련하려고 노력하고 있다(OECD, 2025).

정리하면, 생성형 AI의 발전 방향이 하나의 거대두뇌 對 여러 전문두뇌로 갈라지는 모습이다. 경제 전반의 혁신을 이끌 거대 범용모형과, 섬세하고 믿을 수 있는 특화모형이 병행 발전할 것으로 보이며, 이것이 산업 생태계의 재편과 부가가치 분배구조에 영향을 미치게 될 것으로 보인다. 궁극적으로는 범용 플랫폼의 확산력과 특화솔루션의 맞춤형 가치가 균형을 이뤄, 다양한 수요를 충족시키는 방향으로 진화하는 것이 바람직할 것으로 사료된다.

제2절 AI 활용의 경제적 의미

1. AI의 노동과업(labor task)에 대한 대체 對 보완

본 연구의 핵심 주제 중 하나이기도 한 생성형 AI의 과업대체 가능성

이나 보완 가능성은 다양하게 논의되고 있다. Chui *et al.*(2023)의 분석에 따르면, 최신 AI는 직원들이 업무에 쓰는 시간의 60~70%에 해당하는 시간을 자동화할 잠재력이 있다고 분석하였다. 특히 자연어 처리 능력이 향상됨에 따라, 과거 자동화가 어려웠던 고숙련 직무의 일부 과업까지 대체 가능하다고 주장한다. IMF 연구(Cazzaniga *et al.*, 2024)는 선진국 일자리의 약 60%가 AI에 노출되어 있으며, 그중 절반(30%)은 AI가 업무역량을 보완해 생산성을 높일 수 있지만 나머지 절반은 핵심 과업을 자동화하여 노동수요를 감소시킬 가능성이 있다고 주장한다.

실제로 멀티모달 AI의 발전은 예술가, 디자이너, 성우, 번역가 등 창의적 직업군의 업무방식을 바꾸고 있다. 긍정적으로는 반복적이고 기계적인 부분(예: 배경 이미지 생성, 기초 스케치)을 AI가 맡아주어 창작자는 더 고차원적인 창의적 작업에 집중할 수 있다. 그러나 부정적으로 보면, 일부 분야의 인력 수요 감소를 야기할 수 있다. 2023년 할리우드 작가·배우 조합의 파업은 대본 작성이나 배우의 목소리·영상 합성 등에 AI가 활용되면서 일자리 대체에 대한 우려가 현실화된 것을 보여준다.³⁴ 특히 미국에서는 FOBO(Fear Of Becoming Obsolete)라는 신조어가 등장할 만큼, 일반 노동자의 20% 이상이 자신의 직무가 기술로 대체될까 불안해한다는 설문조사도 있다.³⁵

하지만 새로운 기술은 동시에 신규 일자리도 창출할 수 있다. WEF(세계경제포럼)는 AI로 인해 완전히 새로운 분야의 일자리(예: AI 프롬프트 엔지니어, 데이터 커리큘럼 디자이너 등)가 생겨날 것이며, 다수의 기존 일자리는 AI로 업무 능력이 확대(augment)되어 오히려 생산이 늘어날 것이라고 전망한다.³⁶ 또한 AI의 업무자동화 수준이 높아질수록, 인간 노동자의 역할은 감독자(supervisor)나 창의적 설계자로 이동할 가능성이 크다고 보고 있다. 반복적이고 절차적인 일은 AI가 하고, 인간은 AI가 제대로 작동하는지 검수하거나 AI에 맡길 과제를 설계하는 쪽으로 역할이 변하

³⁴ <https://www.weforum.org/stories/2024/02/ai-creative-industries-davos/>(최종접속일: 2025. 10. 5).

³⁵ 각주 27 참조

³⁶ 각주 27 참조

는 것이다. 이는 노동자의 필요역량의 변화를 의미하며, 노동자들에게 디지털 도구 활용 능력과 고차원 문제해결 능력이 더욱 요구될 수 있음을 의미한다. 반면, AI가 어려워하는 비정형 업무나 대인관계 서비스 등의 가치는 상대적으로 상승할 가능성이 높다(Chui *et al.*, 2023). 이러한 변화에 적응하기 위해 기업은 노동자에게 재훈련(reskilling)을 제공해야 하고, 교육계는 AI 시대에 맞는 교과과정을 준비해야 한다.

결국, 생성형 AI는 대체재와 보완재로서 이중적 성격을 가지기 때문에 사회가 AI 활용에 대해 어떠한 전략을 취하느냐에 따라 노동시장에 대한 영향과 생산성 제고 효과가 상이할 것으로 판단된다. AI로 인한 산업의 변화는 인간 고유의 강점(독창성, 감수성 등)을 어떻게 활용할지에 따라 협업의 기회가 될 수도 있고, 갈등 요인이 될 수도 있다. 중요한 것은 산업계와 노동자가 AI 활용 전략을 함께 모색하여 어떻게 상호 가치보완적 관계를 구축하느냐에 달려 있다고 판단된다.

2. AI의 확산에 따른 노동소득 분배와 임금의 효과

당연하겠지만, 앞서 설명한 AI의 노동과업에 대한 대체나 보완은 결국 노동소득의 분배에 영향을 미치게 되어 있다. AI가 고속된 노동자의 역할을 확대시킨다면 이들의 임금은 더욱 상승할 것이고, 반복적 업무에 종사하는 노동자는 상대적으로 수요가 줄어 임금이 정체되거나 하락할 것이다. 실제 IMF는 AI 활용 능력이 있는 노동자는 생산성과 임금이 올라가지만, 그렇지 못한 노동자는 뒤처지는 임금 양극화가 우려된다고 주장한다.³⁷

또한 AI 도입으로 기업의 이윤이 늘면 자본소득 비중이 커져 노동소득 분배율이 낮아질 수 있고, 이는 불평등 심화로 이어질 수 있다. Acemoglu and Restrepo(2022)는 생성형 AI는 아니지만, 1980년대부터 2016년까지 40여 년간 미국의 임금불평등이 급격히 증가한 주된 원인은 기술발전에

37 <https://www.imf.org/en/Blogs/Articles/2024/01/14/ai-will-transform-the-global-economy-lets-make-sure-it-benefits-humanity>(최종접속일: 2025. 10. 5).

다른 자동화로 인한 노동대체에 있음을 보여준다. 특히 미국 노동자의 임금분포상 양극화는 저학력-저숙련 업무의 자동화와 고학력-고숙련의 상대적 非자동화에 기인한 것으로 분석한다. 특히 Acemoglu and Johnson (2023)에서는 현재의 AI 발전 경로가 노동보완적 혁신보다는 자동화 위주로 흐르고 있어, 기술진보의 과실이 노동자에게 고르게 돌아가지 않을 가능성이 있다고 경고한다.

그러나 Acemoglu(2024)는 AI의 영향을 받는 과업(tasks)은 이전의 자동화 기술(로봇, 전용 소프트웨어 등)에 비해 인구통계학적 그룹 전반에 걸쳐 더 고르게 분포될 것으로 예상함에 따라 AI의 발전이 이전 자동화 기술만큼 임금의 불평등을 악화시키지는 않을 것이라고 전망한다. 특히 AI로 인한 생산성 향상은 AI 노출집단의 임금 상승으로 이어지기 어렵다고 주장하는데, 노동-자본 요소 간 대체탄력성이 1보다 작기 때문에 노동생산성을 높이는 기술은 임금에는 미미한 영향을 주거나 노동소득분배율을 오히려 감소시킬 수 있다고 설명한다. 그러나 그렇다고 해서 임금분포의 불평등을 완화할 것이라고 보기도 어렵다. 왜냐하면 AI가 특정 과업에서 저숙련 노동자의 생산성을 향상시키더라도, 이로 인해 해당 과업의 가격이 하락하고 노동이 재배치될 때, 불평등이 증가할 수 있음을 배제하기 어렵기 때문이다.

따라서 생성형 AI의 경제적 혜택을 공정하게 분배하려면, 정책적으로 노동자 재교육, 사회안전망 확충, 그리고 기술개발 방향의 조정 등이 필요할 수 있다. 특히 AI가 노동자들에게 유리한 임금 및 분배 효과를 가져오기 위한 핵심 조건은 새로운 과업(new tasks)의 창출에 있다. 왜냐하면 새로운 노동집약적 과업이 창출될 때, 이는 임금상승을 통해 노동소득분배율을 높이고 자본과 노동 간의 격차를 줄일 수 있기 때문이다. 그러나 현재 AI 연구의 주된 초점은 노동자를 위한 새로운 과업을 창출하는 방향이 아니라 자동화 및 개인 데이터 수익화에 맞춰져 있다. 따라서 현재의 기술발전 방향으로서는 노동자들에게 큰 혜택을 제공하거나 임금불평등을 완화할 가능성이 낮을 수 있다(Acemoglu, 2024).

3. AI의 생산성 J-커브 가설: 보이지 않는 투자와 시차 효과

우리는 AI의 기술발전 및 확산이 거시경제에 미치는 영향에 대해서 다른 시각에서 바라볼 수도 있다. 즉, 새로운 기술이 도입될 때 생산성 통계에 즉각 나타나지 않는 역설, 즉 J-커브 가설이다. 예를 들어 컴퓨터 보급은 1980년대부터 시작되었으나, 1990년대 후반에 가서야 IT 혁신이 생산성 통계에 반영되었는데, 이러한 시차(delayed impact)를 설명하는 이론이 생산성 J-커브 가설이다. 이 가설에 따르면 범용기술(GPT)이 등장하면 초기에는 그 가능성에 대한 대규모 투자가 이루어지지만, 이때 투자의 상당 부분은 무형자산(intangible) 축적에 쓰이기 때문에 단기 생산성 지표에 잡히지 않거나 오히려 하락 요인이 될 수 있다(Bounfour *et al.*, 2025).

예를 들어 새로운 AI를 도입하면 하드웨어·소프트웨어 구매비용뿐 아니라 직원 재교육, 데이터 정비, 조직 프로세스 재설계 등에 막대한 비용과 시간이 들어가지만, 이런 활동은 당장 눈에 보이는 생산량 증가로 이어지지 않을 수 있다. 오히려 이행기에는 기존 업무 흐름이 방해받거나, 투자비용 탓에 생산성 지표가 정체/하락하는 현상이 나타날 수도 있다. 그러나 이러한 숨은 투자가 충분히 축적되고 조직에 학습효과가 쌓이면, 이후부터 생산성이 급격한 상승 국면을 맞이하게 된다. 이 모습이 마치 J자 형태로, 처음에 떨어졌다가 나중에 급상승하는 곡선을 그린다고 해서 J-커브라 한다(Bounfour *et al.*, 2025). Brynjolfsson *et al.*(2021)은 이러한 메커니즘이 실제 미국의 IT 생산성 통계에서 관찰된다고 입증하였다. 따라서 AI가 생산성에 미치는 영향에서도 유사한 패턴이 나타날 수 있음을 배제하기 어렵다.

현재(2020년대 중반)는 생성형 AI가 업무현장에 막 도입되기 시작한 초기 단계에 있다고 볼 수 있다. 많은 기업들이 다양한 프로젝트를 통해 AI를 접목하고 활용하고 있지만, 솔직히 거시적 생산성 지표에서는 아직 뚜렷한 상승세를 확인하기 어렵다. 실제로 미국의 한 설문조사에 따르면, 기업이사회의 80%가 생성형 AI 활용이 중요한 의제라고 대답했으나, 상

당수는 아직 재무성과로 연결되지 않는다고 답하였다.³⁸ 이는 AI 기술 자체의 문제라기보다, 기업조직이 이를 활용할 준비가 덜된 상태이기 때문일 수도 있다.

예를 들어 보이지 않는 투자에 대해서 설명하면, 우선 기업들은 AI를 도입하면서 데이터 자산 정비에 집중한다. 예컨대 은행이 AI를 활용하기 위해서는 수십 년간 쌓인 고객 데이터를 AI가 쓰기 좋게 정규화하고 오류를 바로잡는 작업이 선행되어야 한다. 제조업체도 매뉴얼, 도면 등을 디지털화하고 일관된 형식으로 변환해야 AI가 학습하는 데 유용할 수 있다. 이러한 데이터 클렌징 및 데이터베이스화 작업은 상당한 비용을 필요로 하나, 아직은 생산성에 직접적으로 영향을 미치지 않는 투자이다. 생산 프로세스 재설계도 마찬가지이다. 전통적으로 사람끼리 협업하던 프로세스에 AI를 투입하려면 업무 흐름을 재조정해야 한다. 어떤 단계에 AI를 쓰고, 산출물을 누가 검토하며, 오류 책임은 어떻게 할당할지 등을 정하는 생산관리 혁신이 필요하다. 이러한 생산 과정을 재설계하고 반영하는 동안에는 오히려 혼선이 생겨 단기적으로 생산성이 떨어질 수 있다. 인적자본 투자는 어떠한가? 직원들이 AI를 잘 활용하려면 교육훈련이 필요하며, 어떤 직원은 업무 재배치를 통해 AI와 협업하는 역할로 전환해야 할 수 있다. 이 또한 시간과 비용이 소요되는 작업이다. 이런 숨은 비용들은 전통적인 회계에서는 경상비로 처리되거나 자산으로 잡히지 않기에, 생산성 분모(투입)는 늘고 분자(산출)는 당장 늘지 않아 생산성 지표를 일시적으로 악화시킬 수 있다(Bounfour *et al.*, 2025). 그러나 이러한 투자가 성과로 나타나기 시작하면, 이후에는 상당한 생산성 상승이 나타날 수 있다. 역대 기술혁신(전기, 정보기술 등) 사례에서 보듯, 러닝 커브를 넘은 조직은 새로운 기술로 인해 비약적 생산성을 실현하였다.

생산성 J-커브 가설을 적용해 보면, 현재의 AI 투자 붐은 당장 1~2년 사이에 통계상 뚜렷한 생산성 증가로 나타나지 않을 수 있지만, 중장기적으로는 큰 폭의 생산성 향상이 나타날 가능성도 배제하기 어렵다.³⁹

38 https://events.ringcentral.com/events/agent-ai-moving-beyond-pilots-to-enterprise-impact/registration?utm_source=Disruptor(최종접속일: 2025. 10. 5).

Briggs *et al.*(2023)이나 Chui *et al.*(2023)이 추정한 AI의 경제적 효과(연평균 생산성 성장률 1.5%p, 전 세계 GDP 7% 추가 상승, 연 0.5~3.4%p 추가 노동생산성 상승 등)도 과도해 보일 수 있으나, 이러한 J-커브 가설을 일부 반영하여 추정된 것일 수 있다. 다만, 이러한 잠재력이 실현되려면 노동전환 관리와 인프라 투자가 필수적이다(Chui *et al.*, 2023). 단기적으로 실직하거나 역할이 바뀌는 노동자들에게 새로운 숙련기술을 제공하고 일자리 이동을 지원해야 하거나, 클라우드 컴퓨팅, 전력 공급 등 AI 활용에 필요한 인프라 시설에도 투자가 따라야 한다. 이러한 보완투자와 정책 대응은 AI에 대한 초기 투자가 본격적인 생산성 및 경제성장으로 나타나 J-커브의 우상향 부분에 진입하는 데 도움을 줄 수 있을 것이다.

반대로, 필요한 보완조치 없이 AI 도입만 서둘렀을 경우, 생산성 향상 효과가 낮은 “그저 그런 자동화(so-so automation)”에 머무를 수 있다는 경고도 있다. 특히 Acemoglu and Johnson(2023)은 피상적인 자동화는 기업 이윤은 늘릴지 몰라도 경제 전반의 총요소생산성(TFP)에는 기여하지 못하며, 노동자 실직만 초래할 위험이 있다고 지적한다. 대표적인 사례로 마트의 셀프계산대를 들며, 이는 계산원을 줄였으나 소비자가 그 일을 떠안게 된 것일 뿐 생산성 혁신으로 이어지지는 않았다고 설명한다. 이런 유의미하지 않은 자동화를 피하고 진정한 생산성 혁신으로 나아가려면, AI를 활용해 완전히 새로운 부가가치 창출 작업을 개발하거나, 노동자의 한계생산성을 높여주는 방향으로 기술을 써야 한다고 강조한다. 다시 말하면 AI를 자동화 도구로만 쓸 것인가 확장 도구로 쓸 것인가에 따라 J-커브의 폭과 형태가 달라질 수 있음을 유의할 필요가 있다.

제3절 맺음말: AI 기술 진화와 경제적 가치

지금까지 생성형 AI의 발전사를 여러 단계로 구분하여 살펴보고, 각

39 <https://www.brookings.edu/articles/machines-of-mind-how-generative-ai-will-power-the-coming-productivity-boom/>(최종접속일: 2025. 10. 5).

단계에서의 기술 특징과 경제적 의미를 살펴보았다. 트랜스포머의 등장으로 시작된 기반모형 혁명은 인간 의도 학습을 거쳐 사용자 친화적 AI를 탄생시켰고, 이내 긴 문맥 처리와 에이전트화를 통해 보다 자율적이고 복잡한 업무 수행이 가능해졌다. 이어 멀티모달 통합으로 인간의 다양한 감각 영역을 아우르며 콘텐츠 생산의 지평을 넓혔고, 산업계에는 범용 플랫폼 대 특화모형의 AI 전략 분화가 진행되고 있다.

AI의 경제적 의미와 관련해서는 노동을 대체 혹은 보완할 수 있는가와 더불어 노동소득분배와 임금분포에 미칠 수 있는 영향에 대해서 논의하였다. 마지막으로 생산성 J-커브 관점에서 AI 기술 확산의 경제적 성과가 지금 당장은 성과를 보일 수 없으나, 일정한 시차를 두고 점차 가시화될 가능성도 살펴보았다.

생성형 AI가 일반목적기술(*general-purpose technology*: GPT)의 하나로써, 과거 증기기관이나 전기가 그랬던 것처럼 경제 전반에 미칠 파급효과와 잠재력은 무시 못할 수준임이 자명하다. 이는 지식노동자의 업무 효율화, 신규 서비스 개발, 소비자 경험 향상 등을 통해 이루어질 가능성이 크다. 특히 Chui *et al.*(2023)은 고객지원, 마케팅, 소프트웨어 개발, R&D와 같은 고부가가치 분야에서 전체 효과의 75%가량이 나타날 것으로 예상할 정도이다. 나아가 AI가 새로운 제품과 시장을 창출할 수 있다면, 이 보고서에서 설명하지 못한 2차 파급효과까지 고려할 때 영향은 훨씬 커질 수도 있다.

그러나 노동시장 측면에서는 업무의 재편과 인간 역할의 변화가 불가피할 수 있다. 반복적이고 예측 가능한 업무는 상당 부분 자동화되어 일자리 감소 압력으로 작용할 수 있지만, 동시에 신규 일자리와 과업이 생겨날 수도 있다(Acemoglu and Johnson, 2023). 중요한 것은 교육과 직업훈련의 대응이며, 평생학습체계를 강화하여 노동자가 AI 시대의 새로운 역할을 수행할 수 있도록 지원해야 한다는 것이다. 또한 AI로 인한 소득분배 불평등 가능성을 완화하기 위해, 사회안전망 보완과 함께 노동자가 기술개발 방향에 목소리를 낼 기회를 마련하는 등의 정책 논의도 필요할 수 있다.⁴⁰ 가령 Acemoglu and Johnson(2023) 등은 노동친화적 AI 개발을

유도하기 위해 세제 개편(자동화 투자에 대한 세제혜택 축소 등)이나 거버넌스 개선을 제안하기도 했다.

한편, 생산성 J-커브 가설이 실현된다면, 우리는 현재 겪고 있는 전 세계적인 생산성 둔화 현상을 AI가 극복시켜 주는 새로운 성장 국면을 맞이할 가능성도 있다. 1990년대 IT 버블 이후 디지털 투자 붐이 10여 년간의 생산성 황금기(미국의 사례)를 이끈 것처럼, 2020년대 중반 이후 AI로 인한 TFP(총요소생산성) 상승 가능성을 완전히 배제할 수는 없다. 이는 인플레이션 억제, 실질소득 증대, 재정건전성 개선 등 광범위한 경제적 호재를 가져올 수도 있다.⁴¹ 다만, 이러한 장밋빛 시나리오는 자동적으로 실현되는 것이 아니라, 기술의 책임 있는 도입과 보완투자를 전제로 한다. 다시 말해 AI로 인한 자동 성장은 없으며, 인간의 제도적 노력과 선택이 미래의 모습을 결정지을 가능성이 높다.

결론적으로, 생성형 AI의 발전은 기술사적으로도 경제사적으로도 중요한 전환기에 해당할 것이다. 지금 이 순간에도 모형의 능력이 향상되고 있고, 기업과 사회는 이에 대응하느라 분주하다. 기술적 혁신 단계마다 새로운 기회와 도전이 나타났듯이, 향후에도 AI 안전성, 규제, 국제협력, 일자리의 질 향상 등 넘어야 할 산이 많다. 하지만 과거 혁신들이 결국엔 인류의 부와 복지 향상으로 귀결되어 왔던 것을 돌이켜볼 때, 생성형 AI 역시 올바른 활용과 제어를 통해 사회적 번영을 이끌 수 있을 것으로 판단한다. 우리가 해야 할 일은 기술발전의 궤적을 주시하며, 그 경제적 함의를 정확히 파악하고 선제적으로 대응책을 마련하는 것이다. 그럴 때 비로소 생성형 AI는 인간을 대체하는 위협이 아니라 인간을 돕는 파트너로서, 새로운 도구의 시대를 여는 중요한 열쇠가 될 것이라고 생각된다.

40 각주 37 참조

41 각주 39 참조

제3장

AI 자동화: 경제성을 중심으로

본 장에서는 AI가 직업별·과업별 수준에서 어느 정도까지 인간 노동을 대체하거나 보완할 수 있는지를 체계적으로 분석한다. 보다 구체적으로는, 한국의 거시경제 환경과 노동시장 구조를 전제하고, 각 직업에 포함된 세부 수행과업(task description)이 AI 기술에 얼마나 노출되어 있는지, 그리고 그러한 기술적 가능성이 실제로 경제적 측면에서 실현 가능한지까지 단계적으로 평가한다. 이를 통해, AI가 단순히 할 수 있는 것에 머무르지 않고, 실제로 기업이 도입할 유인이 있는지를 구분함으로써, 기술 가능성과 경제적 채택 사이의 간극을 정량적으로 보여주는 것이 본 장의 핵심 목적이다.

$$\begin{aligned} \text{향후 10년 AI에 의한 TFP 증가율} &= \{\text{AI에 노출된 GDP 비중} \\ &\times \text{AI의 경제적 수익성이 있는 과업 비중}\} \times \text{제3장} \\ &\times \text{AI로 인한 생산성 향상} \\ &\times \text{AI에 노출된 노동소득분배율} \end{aligned}$$

이를 위해 먼저 한국고용직업분류(KECO)를 기준으로, 임금직업포털(Workpedia)에 수록된 537개 직업의 수행직무기술서를 활용하여 총 6,824개의 단위과업을 추출한다. 각 단위과업은 과업대상(object)과 과업행위(doing)로 분해한 뒤, 과업의 결과측정 가능성(objective outcome

measurability), 과업의 데이터 가용성(data availability and quality), 과업의 맥락 의존성(context dependence), 과업을 위한 인간의 창의성·판단 필요성(human judgment necessity), 과업의 에이전트화 가능성(agentability) 등 다섯 가지 차원을 중심으로 AI 자동화 및 보완 가능성을 확률적으로 계산한다. 이러한 지표를 결합하여 과업 단위의 AI 노출도와 자동화·보완 가능성을 도출하고, 이를 다시 직업·기업규모 수준으로 집계함으로써, 한국 노동시장에서 어떤 유형의 직무가 AI에 상대적으로 취약하거나, 반대로 보완을 통해 생산성 향상 여지가 큰지를 비교·분석한다.

다음으로, 본 장에서는 이러한 기술적 노출도를 실제 경제성 분석으로 연결한다. Thompson *et al.*(2024)에서 제시된 AI 도입 비용·편익 분석틀과 Svanberg *et al.*(2024)의 AI 비용구조를 바탕으로, 한국 기업의 현실적인 임금수준, 데이터 구축비용, 모형 학습·운영 비용 등을 반영한 과업 단위의 경제성 비용을 계산한다. 특히 고용직업분류, 기업규모별로 인건비와 AI 도입비용을 비교하여, 어떤 과업이 어떤 유형의 기업에서 경제적으로 자동화에 노출되는지를 식별하고, 그에 따라 실제로 AI 대체·보완의 영향을 받을 것으로 예상되는 종사자의 비중을 추정한다.

마지막으로, 과업 단위에서 도출된 AI 자동화 가능성(노출도)과 경제성 결과를 거시지표와 연계하여, AI 도입이 TFP(총요소생산성)과 노동소득 비중, 직업에 미치는 잠재적 영향을 평가하기 위한 기초자료로 사용한다. 따라서 본 장은 이후 연구에서 전개될 생산성·고용·분배 효과분석의 기반을 제공함과 동시에, 정책결정자가 직업·과업 수준에서 어떤 영역에 대한 재교육·전환지원, 데이터 인프라 구축, 규제 정비가 필요한지 판단하는 데 필요한 실증적 근거를 제시하고자 한다.

제1절 AI 자동화 가능성 추정

1. AI 자동화 가능성의 개념

가. 기존 문헌에서의 AI 자동화 가능성·노출도 개념

최근 생성형 AI와 노동시장 연구에서는 AI 자동화 가능성(automation potential) 혹은 AI 노출도(exposure)라는 개념을 중심으로, AI 기술이 직무·과업에 미치는 잠재적 영향을 정량화하려는 시도가 빠르게 진행되고 있다. 이들 연구는 대부분 직업이 아니라 그 직업을 구성하는 과업(task)을 기본 단위로 삼고, 각 과업이 현재 혹은 가까운 미래의 AI 기술에 의해 어느 정도 영향을 받을 수 있는지, 즉 노출되는지 혹은 자동화가 가능한지를 확률 혹은 비율의 형태로 측정한다.

대표적으로 Eloundou *et al.*(2024)은 대규모 언어모형(LLM)이 과업수준에서 노동에 미치는 잠재적 영향을 평가하기 위해 노출도(exposure)라는 개념을 명시적으로 정의한다. 이들은 미국 O*NET의 작업활동과 세부 과업을 단위로 삼고, 인간 전문가 평가와 GPT-4 자체평가를 결합한 방법을 통해 LLM 또는 LLM 기반 소프트웨어가 해당 과업의 수행시간을 최소 50% 이상 줄이면서 품질을 유지·개선할 수 있는지를 기준으로 노출 여부를 판단한다. 여기서 노출도는 노동 대체(substitution)와 보완(complementarity)을 구분하지 않고, 단지 LLM이 해당 과업 수행에 실질적인 영향을 미칠 수 있는 기술적 잠재력(technical potential)으로 해석된다. 이 방법론의 장점은 LLM의 실제 성능과 전문가 판단을 결합해 과업·기술 적합도를 비교적 직접적으로 측정한다는 점이며, 단점은 평가가 특정 시간의 모형·인터페이스(예: GPT-4, 채팅형 UI)에 고정되어 있어 기술발전·도입방식 변화에 따라 지표의 갱신이 필요하다는 점과 50% 시간 단축이라는 기준이 임의적일 수 있다는 점이다.

Felten *et al.*(2023)은 이를 보다 넓은 직업·산업·지역 수준으로 확장

하기 위해 AI Occupational Exposure(AIOE) 지표를 개발하고, 이후 생성형 AI 환경에 맞춰 직업별 노출도 분포의 이질성을 분석한다. 이 방법은 O*NET이 제공하는 직무·기술 능력과 AI가 상대적으로 잘 수행할 수 있는 기능(언어모형·이미지 생성 등)을 연결하고, 그 결과를 활용해 직업별 AI 노출도를 계산한다. 장점은 우선, 특정 AI 모형에 국한되지 않고 AI 기술이 잘하는 기능 vs 직업이 요구하는 기능이라는 보다 안정적인 구조를 사용한다는 점이다. 그리고 AIOE가 이후 IMF, OECD, 개별 국가 연구(예: 한국·미국 산업 노출도 분석)에서 범용적으로 활용 가능한 데이터베이스로 구축되었다는 점이다. 반면, 한계는 O*NET 서술과 기술 리스트 간의 텍스트 유사도에 크게 의존하기 때문에 실제 작업조직·도구 사용방식 같은 맥락이 충분히 반영되기 어렵고, 직업 능력을 기반으로 추상적으로 분석하기 때문에 특정 작업이 실제로 어떻게 대체되는지에 대한 구체적인 메커니즘을 설명하기 어렵다는 점이다.

Webb(2020)은 특정 기술(예: 소프트웨어, 산업용 로봇, AI)에 대한 노출도를 평가하기 위해 특허 텍스트와 직업·과업 텍스트 매칭이라는 방법을 제시한다. 구체적으로는, 특허 명세서에 나타나는 동사·명사 표현이 O*NET 직무기술서에 등장하는 과업설명과 얼마나 겹치는지를 측정하여, 각 직업이 특정 기술에 얼마나 많이 노출되어 있는지를 계량한다. 이후 과거 기술(소프트웨어, 로봇)에 대해 노출도가 높았던 직업들이 실제로 고용·임금 감소를 겪었는지를 검증함으로써, 해당 노출도 지표의 예측력을 확인한다. 이 접근법의 장점은 우선, 특허 텍스트라는 기술 측면의 공식 기록을 활용해 다양한 기술별 노출도를 일관된 방식으로 측정할 수 있고, 과거 사례를 통해 노출지표와 실제 노동시장 결과 간의 상관관계를 확인했다는 점이다. 다만, 특허에 포착되지 않는 비공개·오픈소스·내부 개발 기술은 반영하기 어렵고, LLM·생성형 AI처럼 범용 소프트웨어·서비스 형태로 확산되는 기술은 특허 텍스트와 실제 과업구조 간의 괴리가 커질 수 있다는 한계가 있다.

이러한 미시적 노출도 지표는 이후 거시·정책 분석의 핵심 입력값으로 사용된다. OECD의 Filippucci *et al.*(2025)은 개별 실험·현장 연구에

서 관측된 작업자 수준 성과개선 효과와 Eloundou식 과업노출도(share of tasks exposed to AI), 그리고 부문별 AI 채택률(adoption rate)을 결합해, 다부문 일반균형모형에서 향후 10년간 AI가 노동생산성·TFP에 미치는 기여를 시뮬레이션한다. 여기서 노출도는 현재 또는 가까운 미래의 AI가 성과개선을 가져올 수 있는 과업의 비중이라는 기술적 잠재력에 해당하며, 실제 성장 효과는 채택 속도와 보완투자 정도에 의해 크게 제약될 수 있음을 강조한다. IMF의 Pizzinelli *et al.*(2024)은 Felten *et al.*(2023)의 AIOE를 바탕으로, 직업이 AI에 많이 노출되면서도 AI와의 보완성이 높은지(high exposure-high complementarity), 아니면 주로 대체되는지(high exposure-low complementarity)를 구분하여 노동이동과 소득분포를 분석한다. 이러한 접근의 장점은 노출도(impact potential)와 보완성(complementarity)을 분리해 고노출은 고위험이라는 단순 구도를 피한다는 점이며, 반면 한계는 보완성 지표가 여전히 전문가 판단과 직무 서술에 기반해 추정된다는 점이다.

Acemoglu(2024)도 새로운 노출도 지표를 직접 추정하기보다는, 기존 연구에서 제공하는 과업노출도와 비용절감률을 거시적 충분통계(sufficient statistics)로 사용하는 이론적 틀을 제시한다. 그는 과업기반 생산함수와 Hulten 정리를 응용하여, AI로 인해 영향을 받는 과업의 GDP 비중과 해당 과업에서의 평균 비용절감률이 주어지면, AI의 TFP 기여를 근사할 수 있음을 보인다. 이때 과업노출도는 Eloundou 모형의 LLM 기반 노출지표를 의미한다. 다만, Acemoglu(2024)는 이는 쉽게 배울 수 있는 과업(easy-to-learn task)에 기반하기 때문에 추정이 어려운 과업(hard-to-learn, context-dependent tasks)의 성과를 과대추정하여 장기 효과를 과대평가할 수 있다고 지적한다. 장점은 노출도·비용절감 추정치를 하나의 거시적 구조 안에서 통합할 수 있다는 점이며, 한계는 노출도 자체의 측정오차와 기술·제도·조직 변화의 불확실성이 모두 충분통계에 흡수된다는 점이다.

Aghion and Bunel(2024)도 Acemoglu(2024)와 기본적으로 같은 구조 안에서 AI의 거시적 효과를 분해할 때, 첫 번째 항인 노출된 과업의 GDP

비중은 Eloundou *et al.*(2024), Felten *et al.*(2023), Webb(2020) 등에서 제시한 다양한 노출도 추정치를 활용하며, 두 번째 항인 경제성이 맞는 과업 비중은 Svanberg *et al.*(2024)처럼 비용·규모를 고려한 경제성 지표를 통해 보정한다. 이 접근의 장점은 기술적 노출과 경제적 채택 가능성을 명시적으로 분리해 성장 효과를 구성한다는 점이고, 한계는 각 항목이 서로 다른 데이터·가정에 기초하기 때문에 불확실성이 누적된다는 점이다. OECD(2024)의 성장 시나리오 역시 이러한 구조를 따르며, 노출도-채택률-성과개선의 조합을 통해 낙관·중간·비관의 범위를 제시한다.

종합하면, 기존 문헌의 AI 자동화 노출도 개념은 대체로 다음과 같은 공통 구조를 갖는다. 첫째, 단위(unit)는 직업이 아니라 직업을 구성하는 세부 과업 혹은 활동(O*NET DWA, work activity, task)을 기본 단위로 삼는다. 둘째, 기술적 기준은 현재 혹은 가시적 미래의 AI 기술이 인간 수행 시간·비용을 일정 비율 이상 절감하면서 품질을 유지·개선할 수 있는지에 기반하며, 이는 LMM 판단(Eloundou 모형), 텍스트 매칭(Felten, Webb 모형), 특허·실험자료 등 다양한 방식으로 구현된다. 셋째, 집계 방식은 과업별 노출 여부 또는 노출 확률과 과업의 중요도, 시간 비중, 임금 비중 등을 가중치로 사용하여 직업·부문·국가 수준으로 합산한다.

본 장에서 사용하는 AI 자동화 가능성 지표는 이러한 기존 문헌의 흐름, 특히 Eloundou *et al.*(2024)의 LLM 기반 과업노출도 개념을 출발점으로 하되, 한국의 직업·수행직무 구조와 데이터 환경에 맞추어 결과측정 가능성, 데이터 가용성, 맥락 의존성, 판단·창의 필요성, 에이전트 용이성이라는 5대 지표를 과업 단위에서 추정한다는 점에서 차별성을 갖는다. 다시 말해, 과업 중심 기존 연구가 AI에 기술적으로 노출된 과업인가를 하나의 이진 혹은 단일 점수로 요약했다면, 본 연구는 과업의 AI 노출도를 다차원으로 분해하여, 어떤 과업이 측정·데이터 측면에서 자동화에 유리한지, 반대로 맥락·판단·에이전트 구현 제약으로 인해 자동화가 어려운지를 동시에 파악할 수 있는 구조를 제시한다. 이는 이후 절에서 다루는 경제성 분석과 연계될 때, 기술적 노출-제약 요인-경제성을 보다 정교하게 연결할 수 있는 노출기제로 기능한다.

나. 본 연구의 AI 자동화 가능성 지표의 개념적 정의

본 연구는 임금직업정보시스템(임금직업포털, Workpedia)에 수록된 한국고용직업분류(KECO)의 수행직무기술서(task description)를 바탕으로, 각 직업 i 에 속한 세부 과업 j 에 대해 AI 자동화 가능성을 확률값 형태의 지표로 정의한다. 이러한 과업 단위 자동화 가능성은 다음의 다섯 가지 핵심 차원, 즉

1. 결과측정 가능성(M_{ij})(measurability),
2. 데이터 가용성 및 품질(D_{ij})(data availability and quality),
3. 맥락 의존성(C_{ij})(context dependence),
4. 인간의 창의성 · 판단 필요성(J_{ij})(human judgment necessity),
5. 과업의 에이전트화 가능성(A_{ij})(agentability),

으로 구성되며, 이들 지표를 결합하여 다음과 같은 형태의 과업별 AI 자동화 가능성 지표(지수)를 정의한다.

$$AI\ score_{ij} = M_{ij} \times D_{ij} \times (1 - C_{ij}) \times (1 - J_{ij}) \times A_{ij}.$$

여기서 각 지표는 0과 1 사이의 값으로 정규화되어 있으며, 값이 클수록 해당 차원에서 AI 자동화 가능성이 높음을 의미한다. 특히 여기서 AI 자동화 가능성이란 기업 내 AI 시스템이 실질적으로 구현될 조건이 동시에 만족될 확률을 의미한다. 따라서 과업 j 가 AI로 대체 · 보완될 실질적 구현 가능성을 요약한 지표로 이해하는 것이 좋다.

1) 결과측정 가능성(M_{ij})

과업 j 의 산출물과 성과가 객관적인(혹은 정량적, 시각적) 지표로 측정 가능한지를 나타낸다. 예를 들어 서류의 오탈자 검사와 같이 정답 · 오답이 명확히 정의되는 과업은 M_{ij} 값이 높게 정의된다. 반대로 조직 내 갈등 중재처럼 결과를 객관적으로 계량화하기 어려운 과업은 M_{ij} 값이 낮아진다. Acemoglu(2024)가 배우기 어려운 과업(hard-to-learn tasks)을 맥락이 복

잡하고 객관적 결과지표가 부재한 과업으로 규정하면서, 그러한 과업은 AI 학습과 자동화가 어렵다고 지적하는데, 본 연구의 M_{ij} 지표는 이러한 문제의식을 과업수준에서 명시적으로 수치화한 것이라고 해석할 수 있다.

2) 데이터 가용성 및 품질(D_{ij})

과업 j 를 자동화하기 위해 필요한 입출력 데이터가 충분한 양과 품질로 존재하는지를 나타낸다. 기존에 디지털 기록이 축적된 업무(콜센터 상담 기록, 표준화된 민원 처리 이력 등)는 높은 D_{ij} 값을 가질 수 있다. 그러나 반대로 오프라인, 비구조화 환경에서 수행되어 데이터 축적이 거의 없는 과업은 낮은 값을 가진다. Svanberg *et al.*(2024)이 AI 시스템 구축 비용에서 데이터 수집과 학습 컴퓨팅 비용을 핵심 요소로 다루는 것과 마찬가지로, 본 연구는 D_{ij} 를 통해 기술적 실현 가능성과 경제적 비용구조를 동시에 제약하는 요소로 사용한다.

3) 맥락 의존성(C_{ij})

노동자가 과업을 수행하는 데 있어 높은 수준의 상황 맥락, 비정형 정보, 암묵지에 의존하는 정도를 나타낸다. 과업의 결과가 설사 객관적이라 하더라도 환경·상황적 맥락(environmental context)에 따라 다르게 측정될 수 있음을 의미한다. 동일한 규정이라도 개별 사례의 맥락에 따라 중요한 변수가 달라지는 업무, 현장 상황에 따라 즉각적 상황 파악을 요구하는 업무는 C_{ij} 가 높다. 규정·절차가 충분히 표준화되어 있으며, 동일 입력에 대해 유사한 출력을 반복하는 과업은 C_{ij} 가 낮다. 기존 노출도 연구들이 주로 현재 LLM이 해당 과업에서 50% 시간 절감이 가능한지를 기준으로 노출 여부를 판정하는 반면, 본 연구는 그 배경에 있는 맥락 의존성을 별도의 축으로 분리하여, 비슷한 과업이라도 맥락 의존성이 높으면 자동화 가능성이 구조적으로 제한받도록 설계하였다.

4) 창의성·판단 필요성(J_{ij})

과업 j 가 인간의 고유한 창의성, 도덕적·전문적 판단, 책임 있는 의사

결정을 요구하는 정도를 나타낸다. 전략 수립, 복합적인 이해관계 조정, 법·윤리적 책임이 수반되는 의사결정 등은 J_{ij} 가 높다. 반면, 이미 상위 의사결정에서 정해진 규칙을 적용하는 수준의 업무는 J_{ij} 가 낮다. Pizzinelli *et al.*(2023)의 보완성 지표가 AI와 노동의 관계를 보완 vs 대체의 관점에서 구분한다면, 본 연구의 J_{ij} 는 과업수준에서 인간 판단의 비대체성을 직접적으로 모형화한다는 점에서 좀 더 미시적인 개념이라 생각할 수 있다.

5) 에이전트화 가능성(A_{ij})

과업 j 가 소프트웨어 에이전트 또는 자동화된 워크플로우 형태로 구현·배포되기 용이한지를 판단하는 지표이다. 예를 들어 API 호출, 데이터베이스 조회, 문서 생성 등 일련의 디지털 작업을 순차적으로 수행할 수 있는 과업은 A_{ij} 가 높다. 반대로, 물리적 이동, 대면 상호작용, 복잡한 조직 내 권한 구조와 긴밀히 연결된 과업은 에이전트화가 어렵고, A_{ij} 값이 낮게 평가된다. 이는 Chui *et al.*(2023)이 기술적 자동화 잠재력과 별도로 솔루션 통합(integration)·채택(adoption) 시점을 모형화하는 것과 유사한 문제의식을, 과업수준에서 에이전트화 가능성이라는 형태로 내재화한 것이라고 볼 수 있다.

이 다섯 지표를 곱의 형태로 결합한 $AI\ score_{ij}$ 는, 어느 한 축이라도 결정적으로 취약한 과업은 전체 자동화 가능성이 크게 낮아지는 구조를 갖게 만든다. 예를 들어 결과측정이 가능하고(M_{ij} 높음), 데이터도 풍부하며(D_{ij} 높음), 맥락 의존성과 판단 필요성이 낮더라도(C_{ij} , J_{ij} 낮음), 해당 과업이 물리적 수행과 강하게 결부되어 있거나 에이전트화가 어려운 업무($A_{ij} \approx 0$)라면 AI 자동화 가능성은 낮아지게 된다. 이는 단순히 “LLM이 이 일을 잘하는가?”라는 질문을 넘어, “이 과업을 AI 시스템으로 구성·운영하는 것이 기술적으로 가능하고 조직 내에서 구현 가능한가?”를 함께 묻는 구조이다. 즉, 과업에 대한 AI 자동화의 필수조건들(5대 지표

들이 상호 보완재라는 경제학적 직관과도 부합한다.

이와 같은 설계는 기존 문헌과 다음과 같은 점에서 연속성과 차별성을 동시에 가진다. 우선 기존 문헌과의 연속성 측면에서, Eloundou *et al.* (2024), OECD(2024), Chui *et al.*(2023) 등과 마찬가지로, 본 연구 역시 과업 단위에서 AI가 해당 과업 수행에 미치는 잠재적 영향을 확률적 지표로 정의하고, 이를 과업·직업·산업 단위로 집계하는 구조를 취한다. Acemoglu(2024), Aghion and Bunel(2024)이 거시모형에서 사용하는 AI에 노출된 과업의 비중을 구성하기 위한 기초 지표로 해석할 수 있다.

그러나 본 연구의 AI 자동화 가능성은 여러 측면에서 차별성을 가진다. 우선, 기존 연구의 노출도는 대체로 성능 기준(예: 50% 시간 절감) 중심인 반면, 본 연구는 그 이면의 데이터·맥락·판단·에이전트화를 분해하여 별도의 지표로 명시한다. 두 번째, Aghion and Bunel(2024)과 Svanberg *et al.*(2024)의 AI 노출도와 경제성 구분처럼, 기술적 가능성과 경제성을 분리하는 전통을 따르되, 본 연구는 경제성을 결정하는 일부 구조적 제약(측정 가능성, 데이터, 에이전트화)을 기술적 자동화 가능성 지표 내부에 내생적으로 포함시키고 있다. 또한 Pizzinelli *et al.*(2023)의 보완성 개념과 같이 AI가 일자리에 미치는 영향의 방향을 직업수준에서 구분하는 대신, 본 연구는 과업수준에서 맥락·판단 지표(C_{ij} , J_{ij})를 통해 AI 보완·대체 구조의 기초를 제공한다.

나아가, 이러한 과업별 자동화 가능성 지표는 이후 직업수준의 노출도로 집계된다. 예를 들어 직업 i 의 AI 자동화 가능성 지수(지표)는

$$AIex_i = \sum_{j \in \mathfrak{J}(i)} \omega_{ij} AIscore_{ij},$$

와 같이 정의할 수 있으며, 여기서 ω_{ij} 는 과업 j 가 직업 i 에서 차지하는 시간 비중 혹은 임금 비중을 나타낸다. 이때 $AIex_i$ 는 기존 문헌의 AI 노출도(exposure to AI) 개념과 직접적으로 대응되며, 제2절에서 다룬 경제성 분석에서는 여기에 Svanberg *et al.*(2024) 및 Thompson *et al.*(2024)의 비용모형을 결합하여 경제적으로 실제 자동화가 선택될 과업과 직업을

식별하게 된다.

정리하면, 본 연구의 AI 자동화 가능성 개념은 기존 문헌에서 정립된 과업기반 AI 노출도의 개념을 유지하면서, 한국의 직업·과업 데이터 구조와 AI 도입 환경을 반영하여 측정 가능성-데이터-맥락-판단-에이전트화라는 다섯 축으로 분해·정교화한 지표체계이다. 더불어, 이후에는 경제성 분석 및 거시적 파급효과 분석으로 자연스럽게 연결될 수 있도록 설계된 기술적-구조적 자동화 가능성 지표라고 요약할 수 있다.

2. AI 자동화 가능성 추정 방법론

가. 한국고용직업분류(KECO) 기준 수행직무기술서 수집 및 분해

1) 직업 관련 자료 수집 대상과 범위

본 연구는 한국 노동시장에서 AI 자동화에 노출될 가능성이 높은 과업(task)을 식별하기 위해 한국고용직업분류(KECO)를 기준으로 임금직업포털시스템(Workpedia)이 제공하는 직업별 직무기술 자료를 활용하였다. 구체적으로, Workpedia의 [직업정보/분류별 검색] 메뉴에서 1차분류-2차분류-세분류 단계의 분류체계를 차례로 탐색하여, 총 537개 세분류 직업에 대한 정보를 일괄 수집하였다. 각 직업에 대해 수집된 주요 항목은 다음과 같다.

1. 직업 요약 설명: 해당 직업의 핵심 역할과 주요 업무 범위를 1~2문장으로 요약한 서술
2. 수행직무(과업기술) 목록: 직업 i 에 속한 세부 수행직무(과업) j 를 나열한 항목으로, 각 수행직무는 통상 한 문장 단위의 서술로 제공
3. 임금 및 고용 관련 자료: 평균 연봉,⁴² 고용전망, 직업 만족도 등
4. 직능수준 등 요구역량: 한국고용직업분류상 직능수준⁴³

42 임금직업포털에 따르면 임금정보는 직업당 평균 30명의 제작자를 대상으로 실시한 설문 조사 결과로, 제작자의 자기보고에 근거한 통계치(2023년 기준)이다.

이 중 본 장에서 AI 자동화 가능성을 분석하는 데 핵심이 되는 것은 수행직무(과업기술서) 항목이다. 직업 i 는 N_i 개의 수행과업으로 구성되어 있으며, 각 과업 j 는 한 문장으로 기술된 텍스트 τ_{ij} 로 관측된다. 전체 표본에서 수행직무 문장은 약 4,200여 개 수준이며, 이후 단계에서 이를 보다 일반화된 과업 단위로 정리한다.

2) 과업기술서의 과업대상(object)-과업행위(verb) 분해

Workpedia의 수행직무 문장은 하나의 과업만을 기술하는 경우도 있으나, 상당수는 여러 개의 과업이 순차적으로 결합된 복합문장의 형태를 띤다.⁴⁴ 예를 들어 직업분류가 「건설·채굴관리자」인 경우 다음과 같은 수행직무를 생각할 수 있다.

43 직능수준별 임직 요구조건은 부록을 참고

44 Workpedia(최종접속일: 2025. 10. 5)에서는 수행직무문장에 대해 다음과 같이 설명한다. “직무담당자가 직무의 목적을 완수하기 위하여 수행하는 구체적인 작업(task) 내용을 작업순서에 따라 서술한 것이다. 단, 공정의 순서를 파악하기 어려운 경우에는 작업의 중요도 또는 작업빈도가 높은 순으로 기술하였다. 작업을 수행하면서 수반되는 작업요소(task element)는 직무를 기술하는 데 필요한 것이라면 포함한다. 직무의 특징적인 작업을 명확히 하기 위하여 작업자가 사용하는 도구·기계와 관련시켜 작업자가 무엇을, 어떻게, 왜 하는가를 정확하게 표현하되 평이한 문체로 이해하기 쉽게 기술하였다. 작업과 작업요소는 상대적인 개념으로 어떤 직업에서는 작업요소인 활동이 다른 직업에서는 작업(task)이 될 수 있고 또 어떤 근로자에게는 하나의 직무가 될 수 있으므로 직무특성에 따라 적절히 판단하였다. 문장기술의 통일성을 확보하기 위하여 조사자는 다음의 원칙을 고려하여 수행직무를 기술하였다.

1. 해당 작업원이 주어진 때는 주어를 생략하나, 다른 작업원이 주어진 때에는 주어를 생략하지 않는다.
2. 작업의 본질을 표현하는 동사와 그것을 규정하는 수식어를 적절히 사용하여 문장을 완성한다. 직무의 특성이 나타나지 않는 일반적인 문장은 가급적 피한다.
3. 문체는 항상 현재형으로 기술한다. 즉, “.....한다” “.....이다”의 형식이 된다.
4. 작업의 내용을 기술할 때 추상적인 언어는 사용하지 않는다.
5. 문체는 간결한 문장으로 한다.
6. 내용기술은 시간적 순서(작업순서)에 의해 작성한다.
7. 전체를 정확히 파악하여 중요한 내용을 모두 기술한다.
8. 주된 직무보다 빈도나 중요도는 낮으나 수행이 가능한 작업에 대해서는 “수행직무”에서 “~하기도 한다.”로 표현한다. “~하기도 한다.”라는 문장은 이 직업에 종사하는 사람이 가끔 이런 작업을 수행할 것이라는 의미가 아니라 다른 사업체에 있는 이 직업에 종사하는 사람이 일반적으로 수행하거나 수행 가능한 작업을 나타낸다.
9. 외래어의 정확한 이해를 위해 원어(原語)를 함께 표기한다.”

인력, 장비 및 사용되는 기술이 적정한지 판단하고 생산현장의 효율성을 평가한다.

표면적으로는 하나의 문장이지만, 실제로는 다음과 같이 두 개의 핵심 과업이 포함되어 있다.

1. 첫 번째 과업: 과업대상(object): 인력, 장비 및 사용되는 기술의 적정성
과업행위(verb): 판단
2. 두 번째 과업: 과업대상(object): 생산현장의 효율성
과업행위(verb): 평가

이와 같이, 과업기술서 문장 τ_{ij} 를 그대로 하나의 과업으로 취급할 경우, 문장 내에 결합된 복수의 과업이 동일한 노출도 지표를 공유하게 되어 세밀한 분석이 어렵고, 문장 길이와 복잡성이 증가할수록 AI 자동화 가능성 평가의 단위가 불명확해지는 문제가 발생한다.

따라서 본 연구는 각 수행직무 문장 τ_{ij} 를 과업대상(object)과 과업행위(verb)의 짝(pair)으로 분해하여,

$$\tau_{ij} \rightarrow \{(o_{ij1}, v_{ij1}), (o_{ij2}, v_{ij2}), \dots, (o_{ijk_{ij}}, v_{ijk_{ij}})\},$$

형태의 과업대상-과업행위(object-verb pair) 집합으로 변환하였다. 여기서 o_{ijk} 는 과업의 대상으로서 명사구(예: 생산현장의 효율성), v_{ijk} 는 그 대상에 대한 행위 동사(예: 평가하다)를 의미하며, k_{ij} 는 수행직무(과업기술) 문장 τ_{ij} 에서 추출된 단위과업의 수이다. 실제 분석에서는, 유사·중복 표현을 정리하고 동일한 의미를 갖는 조합을 통합하는 과정을 거쳐, 전체 4,206개의 수행직무 문장을 6,824개($= \sum_i \sum_j k_{ij}$)의 고유한 단위과업(object-verb) 조합으로 표준화하였다. 이렇게 표준화된 단위과업 조합은 이후 단계에서 AI 자동화 가능성 지표($AI\ score_{ij}$)를 추정하는 기본 단위가 된다(필요시 j 를 object-verb 조합 단위로 재해석).⁴⁵

45 수행직무기술서(과업기술서)의 object-verb 분해 작업은 수작업으로 수행할 경우 시간과

이와 같은 object-verb 분해는 다음과 같은 이유에서 필수적이다. 우선 과업 단위에서의 일관성 확보이다. 직업별 수행직무 문장은 기본적인 작성규칙이 존재하더라도 작성자에 따라 길이, 구조, 세부 기술수준이 크게 상이하다. 이를 그대로 분석에 사용할 경우 과업 간 비교 가능성이 떨어진다. 따라서 object-verb 조합으로 표준화함으로써, 무엇을 대상으로 어떤 행위를 하는가라는 공통된 구조로 과업을 재표현하여 직업 간 비교를 용이하게 하였다. 두 번째는 AI 기술 특성과의 정합성을 고려하였다. 최신 AI 시스템(특히 LLM 및 멀티모달모형)은 입력대상(object)의 유형과 모달리티, 그리고 요구되는 행위(생성, 변환, 판단 등)에 따라 성능과 도입 가능성이 크게 달라진다. object-verb 구조는 이러한 대상-행위-모달리티 연결고리를 명시적으로 드러내어, 이후 5대 지표 추정 및 경제성 분석에서 유연하게 활용할 수 있도록 하였다. 마지막으로 수행직무기술서의 중복 제거 및 집계 효율성 제고를 위해서이다. 서로 다른 직업에 속한 과업이라도 고객 문의 내용 파악-답변 제공, 계약 조건 검토-문서 작성 등 본질적으로 동일한 object-verb 조합을 공유하는 경우가 있다. object-verb 단위로 표준화하면 동일한 조합에 대해 한 번만 AI 자동화 가능성을 평가한 뒤, 이를 여러 직업·과업에 공통 적용할 수 있어 추정 효율성과 일관성을 동시에 확보할 수 있다. 이와 같은 이유로, 본 연구는 직업 i -수행직무 문장 τ_{ij} 정보를 (직업 i , 단위과업 j) 수준의 object-verb 조합으로 재구성한 후, 이 과업 단위를 중심으로 AI 자동화 가능성을 정량화한다.

나. AI 자동화 가능성 5대 지표 추정 방법

본 소절에서는 과업 (i, j) 단위의 AI 자동화 가능성 지표(M_{ij} , D_{ij} , C_{ij} , J_{ij} , A_{ij}) 및 종합지표 $AI_{score_{ij}}$ 를 실제로 어떻게 추정했는지에 관한 구체적인 절차와 규칙을 설명한다. 추정 과정은 크게 (1) object·모달리티·verb 유형 분류, (2) LLM 기반 5대 지표 추정, (3) 규칙 기반 보정 및

인력이 과도하게 소요되기 때문에, 본 연구에서는 생성형 AI API(이후 모든 분석에서 GPT-5.1 계열 LLM을 사용)를 활용하여 자동화하였다.

최종 $AI score_{ij}$ 산출의 세 단계로 구성된다.

1) 과업대상(object) 유형, 모달리티, 과업행위(verb) 유형 분류

먼저, 앞 절에서 object-verb 분해를 통해 얻은 각 과업 (i,j) 의 object와 verb를 세 가지 축에서 정형화하였다. 이는 이후 5대 지표를 LLM으로부터 추정할 때, 일관된 prior 정보로 활용하기 위한 선행 작업이다.

과업대상(object)의 대상형식 분류: object o_{ij} 는 의미와 대상의 성격에 따라 네 가지 유형으로 분류하였다(표 3-1). 이 분류는 AI 학습·추론의 대상이 무엇인지를 명시적으로 드러내는 역할을 한다. 예를 들어 정보객체는 이미 디지털화된 경우가 많아 데이터 수집과 결과측정이 상대적으로 용이하므로, 이후 단계에서 D_{ij} , A_{ij} 를 높게, M_{ij} 도 verb 유형에 따라 상향 조정하는 방식으로 사용된다. 반대로 인적대상이나 추상/지식/환경은 맥락·판단 요소가 강해 C_{ij} , J_{ij} 가 구조적으로 높게 나타나도록 설계하였다.

과업대상의 모달리티(modality) 분류: object가 다루는 정보의 형식에 따라 각 과업에 다음과 같은 모달리티를 부여하였다.

모달리티 분류를 별도로 둔 이유는, 멀티모달 AI 기술의 성숙도와 데이터 구축비용 구조가 모달리티별로 크게 다르기 때문이다. 텍스트 기반 과업은 LLM 기술이 이미 상용화 단계에 와 있고, 데이터 구축·학습 비용도 비교적 낮다. 이러한 개념은 추후 경제성 분석에 사용되는 비용구조에서도 반영된다. 이미지·영상·음성은 대형 비전·음성모형의 성능은 높지만, 라벨링·저장·컴퓨팅 비용이 크기 때문에, D_{ij} 와 A_{ij} 추정 시 데이터가 이미 존재하는 영역과 향후 구축 가능성만 있는 영역을 구분할 필요가 있다. 따라서 본 연구에서는 과업대상(object)의 모달리티가 정의되지 않은 과업의 경우, LLM을 호출하지 않고 보수적으로 ($M_{ij}=0$, $D_{ij}=0$, $C_{ij}=1$, $J_{ij}=1$, $A_{ij}=0$)를 부여하여 $AI score_{ij}=0$ 으로 처리하였다. 이는 모달리티조차 명시할 수 없는 과업은, 최소한 현 단계에서는 AI 자동화 가능성이 거의 없다고 판단한 것이다.

<표 3-1> 과업대상(object type) 분류

대상형식(object_type)	예 시	5대 지표와의 관계(직관적 방향)
정보객체	문서, 데이터, 보고서, 계정, 전자기록 등	M, D, A는 높게, C, J는 낮거나 중간
인적대상	고객, 환자, 학생, 동료, 상사, 민원인 등	대체로 C, J 상향, M, D, A 제약
추상/지식/환경	규정, 법령, 정책, 시장상황, 조직문화 등	현재 시점의 M, D, A는 제한, “10년 내 실현 가능성” 관점에서 평가
복합/프로세스/시스템	생산공정, 물류시스템, 프로젝트, 조직 운영 등	모듈화 여부에 따라 M, D, A는 편차, C, J는 중간 이상

자료: 저자 작성.

<표 3-2> 과업대상의 모달리티

모달리티(object_modality)	예 시
텍스트	문서 검토, 이메일 처리, 보고서 작성
이미지	X-ray · 사진 판독, 시각검사
영상	내시경 · CCTV 영상 판독
음성	통화 내용 파악, 상담 녹취 분석
텍스트+이미지	보고서+도면, 기사+사진 등
텍스트+영상	자막+영상 콘텐츠 검토 등
텍스트+음성	콜센터 상담(스크립트+통화) 등
텍스트+이미지+영상/음성	복합 미디어 기반 업무
N/A(분류 불가)	모달리티 분류가 어려운 경우

자료: 저자 작성.

과업행위(verb)의 업무 흐름 기반 유형 분류: verb v_{ij} 는 업무 프로세스 상 기능에 따라 다음 10개 범주로 분류하였다.

한 과업이 여러 범주에 동시에 속하는 경우(예: 자료를 분석하여 개선 방안을 기획하고 보고한다)에는, verb의 집합 형태로 복수 범주를 모두 기록하였다. 이 verb 범주 정보는 이후 맥락 의존성(C_{ij})과 판단 · 창의성 필요성(J_{ij})에 대한 prior를 설정하는 데 핵심적으로 사용된다.

<표 3-3> 과업행위의 유형 분류

verb 범주	예 시
정보수집	자료 조사, 요구 파악, 정보 탐색 등
기록저장	입력, 등록, 저장, 기록 등
정리가공	정리, 집계, 계산, 분류, 변환 등
확인점검	검토, 점검, 검사, 모니터링 등
분석판단	분석, 평가, 진단, 해석 등
기획결정	기획, 계획 수립, 의사결정 등
작성보고	문서 작성, 보고서 작성, 보고 등
협소통	협상, 상담, 안내, 조정, 설득 등
지휘운영	지시, 감독, 관리, 운영, 배분 등
물리작업	설치, 운반, 정비, 조작, 청소 등 물리적 작업 등

자료: 저자 작성.

2) LLM 기반 5대 지표 추정과 prior의 결합

위와 같이 분류된 정보를 바탕으로, 각 과업 (i,j) 에 대해 LLM (GPT-5.1)을 호출하여 $(M_{ij}, D_{ij}, C_{ij}, J_{ij}, A_{ij})$ 를 추정하였다. 이때 LLM에 전달한 정보는 크게 세 부류이다.⁴⁶ 만약 여러 verb 범주가 동시에 있을 때는 맥락·판단 부담이 가장 큰 범주 기준으로 prior를 설정하였다. 이는 하나의 과업이 기획결정·지휘운영을 동시에 포함할 때, 단순 평균보다는 가장 어려운 쪽에 맞춰 자동화 가능성을 보수적으로 평가하기 위한 선택이다.

시스템 프롬프트에서는, 위와 같은 C, J prior를 LLM에 제공한 뒤 1) C, J 는 prior 값 주변에서 ± 0.2 범위 내에서 조정할 것, 2) object_type과 object_modality에 따라 M, D, A 의 일반적인 범위를 제시할 것을 명시하였다. 예를 들어 object_type이 정보객체인 경우 M, D, A 는 대체로 0.6~0.9 범위, object_type이 추상/지식/환경인 경우에는 현재 시점이 아니

⁴⁶ 본 연구처럼 LLM에 과업정보를 넣고 과업 단위의 AI 노출도(exposure)를 직접 수치화한 연구는 Eloundou *et al.*(2024)이다. 그 외 Aghion and Bunel(2024), Acemoglu(2024), Svanberg *et al.*(2024), Briggs *et al.*(2023), Chui *et al.*(2023), OECD(2024) 등은 이 LLM-기반 노출지표를 가져다가 거시성장·생산성·고용 분석에 사용한 2차 연구들이라고 이해할 필요가 있다.

<표 3-4> LLM 프롬프트 정보 요약

정보 구분	정보 내용																																															
과업 기본 정보	- job_title, job_desc: 직업명과 직무 요약 - sentence: 원문 수행직무 문장 - object, verb: 해당 과업의 대상·행위 - task_id: 과업 식별자																																															
분류 결과 정보	- object_type: 정보객체, 인적대상, 추상/지식/환경, 복합/프로세스/시스템 - object_modality: 텍스트, 이미지, 영상, ..., N/A - verb_categories: 아래 10개 범주 중 해당되는 항목 리스트																																															
verb 기반 M, C, J prior 정보	<table><tr><th>verb 범주</th><th>M prior</th><th>C prior</th><th>J prior</th></tr><tr><td>정보수집</td><td>0.9</td><td>0.3</td><td>0.2</td></tr><tr><td>기록저장</td><td>1.0</td><td>0.2</td><td>0.1</td></tr><tr><td>정리가공</td><td>0.9</td><td>0.3</td><td>0.3</td></tr><tr><td>확인점검</td><td>0.8</td><td>0.5</td><td>0.4</td></tr><tr><td>분석판단</td><td>0.6</td><td>0.6</td><td>0.8</td></tr><tr><td>기획결정</td><td>0.5</td><td>0.7</td><td>0.9</td></tr><tr><td>작성보고</td><td>0.7</td><td>0.5</td><td>0.6</td></tr><tr><td>협의소통</td><td>0.2</td><td>0.9</td><td>0.8</td></tr><tr><td>지휘운영</td><td>0.2</td><td>0.6</td><td>0.8</td></tr><tr><td>물리작업</td><td>0.3</td><td>0.3</td><td>0.2</td></tr></table>				verb 범주	M prior	C prior	J prior	정보수집	0.9	0.3	0.2	기록저장	1.0	0.2	0.1	정리가공	0.9	0.3	0.3	확인점검	0.8	0.5	0.4	분석판단	0.6	0.6	0.8	기획결정	0.5	0.7	0.9	작성보고	0.7	0.5	0.6	협의소통	0.2	0.9	0.8	지휘운영	0.2	0.6	0.8	물리작업	0.3	0.3	0.2
	verb 범주	M prior	C prior	J prior																																												
	정보수집	0.9	0.3	0.2																																												
	기록저장	1.0	0.2	0.1																																												
	정리가공	0.9	0.3	0.3																																												
	확인점검	0.8	0.5	0.4																																												
	분석판단	0.6	0.6	0.8																																												
	기획결정	0.5	0.7	0.9																																												
	작성보고	0.7	0.5	0.6																																												
	협의소통	0.2	0.9	0.8																																												
	지휘운영	0.2	0.6	0.8																																												
물리작업	0.3	0.3	0.2																																													

자료: 저자 작성.

라 향후 10년 안에 결과추정·데이터 가용성·에이전트화가 1에 도달할 확률 관점에서 M , D , A 를 평가하도록 하였다.⁴⁷ 응답값은 원칙적으로

⁴⁷ 본 연구에서는 현시점의 기술수준만을 기계적으로 반영한 정태적 지표라기보다, 향후 10년 내 실현 가능성을 전제로 한 준동적(semi-dynamic) 평가로 설계하였다. 구체적으로 결과추정 가능성(M), 데이터 가용성(D), 에이전트 가능성(A)은 “현재 AI가 가능한가”가 아니라 “향후 10년 안에 결과추정/데이터 가용성/에이전트화 가능성이 1에 도달할 확률”의 관점에서 평가하도록 프롬프트를 구성하였다. 따라서 본 연구는 현재 시점의 기술을 그대로 연장한 것이 아니라, 향후 기술발전을 반영한 평가체계를 채택한 것으로 이해할 수 있다. 더욱이 향후 시나리오 분석에서는 모달리티가 정의된 단위과업의 경우 10년 후 AI score가 1에 수렴하는 것으로 가정하였으며, 이는 기술적 측면에서 해당 단위과업들이 장기적으로는 대부분 자동화 가능 상태에 도달하는 것을 전제한 것이다. 이러한 점에서 본 연구의 AI score는 기술의 발전 경로를 반영하지 않은 정태적 추정이라기보다는, 기술발전의 불확실성을 허용하면서도 과업별 자동화 가능성을 체계적으로 평가하기 위한 기준으로 해석하는 것이 타당하다.

0.05~0.95 구간의 실수로 요청하였으며, 0과 1은 극단적 경우에만 사용하도록 규칙을 부여하였다. 이는 LLM 특유의 주관적 편차를 줄이고, 후속 계산 여지를 확보하기 위한 설계이다.

3) 규칙 기반 보정 및 최종 *AI score* 계산

LLM에서 일차적으로 반환된 ($M_{ij}, D_{ij}, C_{ij}, J_{ij}, A_{ij}$) 값을 그대로 사용하지 않고, 몇 가지 규칙 기반 보정을 거쳐 최종지표로 사용하였다. 이는 경제학적 직관과 기술적 제약을 반영하여 지표를 정돈하기 위한 단계이다.

정보객체(object_type = 정보객체)에 대한 M, D, A 보정: 정보객체는 이미 디지털 인프라 위에서 생성·저장·처리되고 있는 경우가 많아, 데이터 가용성과 에이전트화 가능성 측면에서 기술적 제약이 상대적으로 적다. 이를 반영하여, 코드에서는 object_type이 정보객체인 과업에 대해 $D_{ij} = 1, A_{ij} = 1$ 로 변환하였다. 동시에, 결과측정 가능성 M 는 verb 유형별 prior에 따라 재조정하였다. 만약 복수 범주가 있을 경우, 마찬가지로 최댓값을 사용하였다. 그렇게 조정한 이유는 우선, 정보객체를 대상으로 하는 기록·정리·확인·집계 과업은 결과(정확도, 누락 여부 등)를 명확하게 측정할 수 있다는 점에서 M 이 구조적으로 높다. 또한 기획·결정·지휘·협의를 등은 정보객체를 다루더라도 결과의 정답·오답을 명확히 정의하기 어렵기 때문에 M 을 상대적으로 낮게 유지하였다. 즉, LLM이 개별 문맥에 따라 M 을 자유롭게 조정하되, 정보객체에 대해서는 측정 가능성이 구조적으로 높다는 prior를 강하게 반영함으로써 지표 간 상대적 일관성을 확보하려고 하였다.

추상/지식/환경(object_type = 추상/지식/환경)에 대한 보정: 추상·지식·환경 대상 과업의 경우, 코드에서는 별도의 변환 없이 LLM 추정값을 그대로 사용하였다. 대신 시스템 프롬프트에서 현재 시점의 수준이 아니라 향후 10년 안에 해당 지표가 1에 수렴할 확률로 해석하도록 지시함으로써, 현재 데이터가 부족하더라도 제도·인프라 변화로 충분히 데이터화·측정 가능성이 생길 수 있는 영역(예: 정책 집행 데이터, 행정 데이터

통합)을 어느 정도 반영할 수 있게 하였다. 그렇게 함으로써 AI의 거시경제 기여분석에서 향후 10년 동안의 AI 도입 시나리오에 활용할 계획이다.

object_modality 非정의 과업에 대한 보수적 처리: 앞서 언급했듯이, object_modality가 정의되지 않은 과업에 대해서는 LLM 호출 자체를 생략하고 ($M_{ij}=0, D_{ij}=0, C_{ij}=1, J_{ij}=1, A_{ij}=0$)을 부여하였다. 이는 모달리티조차 명확히 정의할 수 없는 과업은 적어도 본 연구에서 사용하는 데이터·방법론하에서는 AI 자동화 가능성을 평가할 수 있는 정보가 충분치 않다는 보수적 판단에 따른 것이다.⁴⁸

최종 AI score 계산: 이상의 절차를 거쳐 산출된 ($M_{ij}, D_{ij}, C_{ij}, J_{ij}, A_{ij}$)를 이용하여 각 과업 (i, j)의 AI 자동화 가능성 종합지표를 계산하였다.

$$AI score_{ij} = M_{ij} \times D_{ij} \times (1 - C_{ij}) \times (1 - J_{ij}) \times A_{ij}.$$

모든 지표가 [0,1] 범위 내 값을 갖도록 설계되어 있으므로, $AI score$ 역시 0~1 사이의 값을 갖는다. 이때 구조적으로 하나의 요소라도 매우 낮거나(예: 데이터가 전혀 없음), 반대로 맥락·판단 필요성이 극도로 높은 과업은, 곱(multiplication)의 구조에 의해 자연스럽게 $AI score$ 가 0에 가깝게 수렴한다. 이는 본 연구가 여러 측면에서 동시에 AI 자동화에 유리한 과업을 선별하는 데 초점을 두고 있음을 반영하는 설계이다.

요약하면, 본 연구의 5대 지표 추정 방법론은 object유형·모달리티·verb범주를 통해 구조적 prior를 먼저 설정하고, LLM을 활용하여 과업별 맥락 정보를 반영한 미시적 조정을 한 뒤, 정보객체·모달리티 미정의 과업 등에서 경제학적·기술적 직관에 부합하도록 규칙 기반 보정을 수행하는 3단계 절차를 따른다. 이를 통해, 단순히 LLM의 직관만으로 점수를 매기는 것을 피하고, 직업·과업 데이터의 구조와 AI 기술·경제성에 대한 사전 지식을 반영한, 재현 가능한 지표체계를 구축하고자 하였다. 결국 본 연구는 Eloundou *et al.*(2024)의 LLM 기반 과업노출도 추정 접근을 계승하되, 단일 scalar 평가 대신 M, D, C, J, A 다섯 차원으로 구조화

48 모달리티가 정의되지 않은 Object는 대부분 “활동, 운영, 업무, 협의, 훈련, 이동, 교육, 작업, 문제, 현장”과 같이 범위가 매우 넓고 추상적인 개념으로 구성되어 있다.

하여, AI 노출도의 원인을 분해·해석할 수 있는 구조적 노출도 지표를 제시한다.

3. AI 자동화 가능성 분석 결과

가. 한국고용직업분류상 과업구조와 기본 특성

본 연구의 AI 자동화 지표는 한국고용직업분류(KECO)를 기준으로 총 537개 세분류 직업에 대해 수집한 수행직무기술서 4,206개 문장을 (object-verb) 조합으로 정제하여 6,824개 단위과업으로 분해한 후 산출되었다. 이에 대한 기초통계는 한국고용직업 대분류별로 <표 3-5>에 정리하였다.

우선 직업별 과업구조를 보면, 연구·공학기술직과 설치·정비·생산직, 경영·사무·금융·보험직이 직업 수와 단위과업 수에서 가장 큰 비중을 차지한다. 예를 들어 연구·공학기술직은 112개 직업, 1,395개 단위과업으로 구성되어 있으며, 설치·정비·생산직(92개 직업, 1,255개 단위과업)과 함께 전체 표본 내에서 기술·전문직 중심의 과업이 상당한 비중을 차지함을 보여준다. 반면, 농림어업직은 직업 수는 10개로 많지 않지만 단위과업 수는 194개로 직업당 평균 과업 수가 19개에 달해, 상대적으로 소규모 직업군에 다양한 과업이 혼재되어 있다는 특징을 보인다.

임금과 직능수준 분포를 보면, 보건·의료직, 경영·사무·금융·보험직, 연구·공학기술직이 평균 직능수준 5 전후와 함께 평균 연봉 5.6~6.5천만원 수준으로 가장 높게 나타난다. 반면, 농림어업직, 미용·여행·숙박·음식·경비·청소직, 건설·채굴직은 평균 직능수준 2~3, 평균 연봉 2.8~3.7천만원으로 상대적으로 저숙련·저임금 직군에 해당한다.

이러한 기초통계는 이후 AI 자동화 지표를 해석하는 데 중요한 배경을 제공한다. 본 연구의 과업 단위 데이터는 단순히 서비스·생산직에 치우쳐 있지 않고, 고숙련 전문직·사무직·연구개발직까지 폭넓게 포함하고 있기 때문에, 기존 문헌에서 논의되는 고숙련·고임금 지식노동과 저

<표 3-5> 한국고용직업 대분류에 따른 과업 및 기초통계량

고용직업 대분류	직업 수	과업 문장 수	단위 과업 수	직업당 평균 단위과업 수	평균 직능 수준	평균 연봉 (천만원)
건설·채굴직	24	184	303	13	2	3.7
경영·사무·금융 ·보험직	84	547	885	11	5	5.9
교육·법률· 사회복지·경찰· 소방직 및 군인	33	274	443	13	5	4.2
농림어업직	10	118	194	19	2	3.0
미용·여행·숙박 ·음식·경비· 청소직	45	342	558	12	2	2.8
보건·의료직	39	319	521	13	5	6.5
설치·정비· 생산직	92	763	1,255	14	3	3.5
연구직 및 공학기술직	112	884	1,395	12	5	5.6
영업·판매·운전 ·운송직	36	299	505	14	3	4.1
예술·디자인· 방송·스포츠직	62	476	765	12	5	3.5
합계 및 평균	537	4,206	6,824	13	4	4.6

자료: 임금직업포털(<https://www.wagework.go.kr/pt/index.do>, 최종접속일: 2025. 10. 15)을 바탕으로 저자 작성.

숙련 대면서비스의 이중구조를 한국 자료에서도 검증할 수 있는 기반이 된다.

나. 한국의 과업기술에 따른 AI 자동화 가능성

본 연구에서 단위과업 기준으로 AI 모달리티가 정의되지 않는 과업, 즉 AI 자동화 가능성이 0인 과업은 4,463개로 전체 단위과업의 65% 수준이다. 그러나 분석한 고용직업분류 537개 직업 가운데, 단위과업 기준 평균 AI 자동화 지표(AI_{score})가 1% 이상인 직업은 약 72%(384개)로 나타

난다. 또한 최소 한 개 이상의 단위과업에서 0이 아닌 AI 자동화 지표를 갖는, 즉 일부라도 AI에 의해 자동화될 여지가 있는 직업은 전체의 약 90%(482개)에 이른다. 이는 한국 노동시장에서 상당수의 직업이 텍스트·이미지·수치정보 등 AI가 처리 가능한 모달리티에 기술적으로 노출되어 있음을 의미한다. 그러나 평균 자동화 지표의 기준을 10% 이상으로 상향하면 해당 직업 비중은 14%(77개)로 급격히 감소한다. 이는 과업의 표면적 형태만으로는 AI 자동화 가능성이 높아 보이더라도, 실제 업무 수행에 필요한 맥락 이해, 창의적 문제 해결, 도덕적·책임적 판단이 반영될 경우 완전한 대체가 가능한 과업은 상대적으로 제한적임을 시사한다. 다시 말해, 다수의 직업이 AI에 부분적으로 노출되어 있으나, 전면적 자동화가 가능할 정도로 높은 노출도를 보이는 직업은 노동시장 전체에서 소수에 불과하다는 점이 확인된다.⁴⁹

본 연구에서는 특히 *AI score*를 두 개의 차원으로 분해하여 단위과업의 특성을 설명하고자 한다. 첫 번째는 $M \cdot D \cdot A$ 로 정의되는 AI 구현 지표로, 결과의 측정 가능성(M), 데이터 가용성(D), 에이전트 구조로의 설계 용이성(A)을 곱한 값이다. 이는 특정 과업에 대해 AI 시스템을 실제로 구축·운영할 수 있는 기술·데이터·프로세스 여건이 얼마나 갖추어져 있는지를 요약한 지표로 해석한다. 두 번째는 $(1 - C) \cdot (1 - J)$ 로 정의되는 규칙화 지표로, 맥락 의존성(C)과 판단·창의 필요성(J)이 낮을수록(즉, $(1 - C)$, $(1 - J)$ 가 클수록) 값이 커진다. 따라서 규칙화 지표는 인간의 암묵적 맥락과 고급 판단으로부터 얼마나 자유로운지, 규칙·알고리즘으로 얼마나 잘 대체·규정할 수 있는지를 나타내는 지표라고 볼 수 있다. 두 지표는 모두 0에서 1 사이의 값을 가지며, 본 분석에서는 0~0.5 구간을 상대적으로 낮은 수준, 0.5~1 구간을 상대적으로 높은 수준으로 구분한다. AI 구현 지표와 규칙화 지표가 모두 높은 과업(0.5~1, 0.5~1)은 데이터·시스템 여건이 양호하고 규칙화도 잘되는 AI 완전대체 가능 과업에 해당한다. 반대로 두 지표가 모두 낮은 과업(0~0.5, 0~0.5)은 AI가 들어갈

49 *AI score*의 분포는 부록을 참조.

인프라도 부족하고, 들어가더라도 사람이 하는 방식을 규칙으로 포착하기 어려운, 현재로서는 대체·보완 가능성이 거의 없는 영역이다. 구현 지표는 높으나 규칙화 지표는 낮은 과업(0.5~1, 0~0.5)은 AI가 정보수집·정리·시뮬레이션·초안작성 등에서 강한 보완재로 작동하는 고속련 과업으로 해석되며, 반대로 구현 지표는 낮고 규칙화 지표는 높은 과업(0~0.5, 0.5~1)은 비교적 규칙적이지만 데이터·시스템 측면에서 제약이 큰 단순 물리·현장 작업 등으로, LLM·멀티모달 기반 AI보다는 전통적 기계화·로봇화가 더 중요한 영역으로 이해할 수 있다.

이러한 기준으로 전체 6,824개 단위과업을 분류한 결과는 <표 3-6>과 같다. 먼저 AI 구현 지표만 놓고 보면, 0~0.5 구간에 속하는 과업이 5,710개(84%)이고 0.5~1 구간이 1,114개(16%)로, 기술·데이터·프로세스 여건의 관점에서 볼 때 AI를 구현하기 좋은 과업은 전체의 약 6분의 1 수준에 그친다. 규칙화 지표는 좀 더 보수적인데, 0~0.5 구간이 6,518개(96%), 0.5~1 구간이 306개(4%)로 나타나, 인간의 맥락·판단에서 상당 부분 자유로운, 즉 규칙화가 잘되는 과업은 전체의 4% 정도에 불과한 것으로 나타났다. 두 지표를 동시에 보면 네 개의 영역으로 나뉘는데, 첫째, AI 구현 지표와 규칙화 지표가 모두 낮은 과업(0~0.5, 0~0.5)은 5,633개로 전체의 83%를 차지한다. 이는 대부분의 과업이 현시점에서 볼 때 AI가 쉽게 구현되기도 어렵고, 규칙으로 포착하기도 어려운 복합적인 인간 과업이라는 것을 보여준다. 둘째, AI 구현 지표는 낮으나 규칙화 지표가 높은 과업(0~0.5, 0.5~1)은 77개(1%)에 불과하다. 이 영역은 규칙적이지만 데이터·시스템 기반이 약한 단순 물리·현장 작업의 비중이 크고, LLM 중심의 AI보다는 기계·로봇 기술이 더 중요한 영역으로 판단된다. 셋째, AI 구현 지표는 높고 규칙화 지표는 낮은 과업(0.5~1, 0~0.5)은 885개로 전체의 13%를 차지하며, 데이터·시스템 측면에서는 AI를 도입할 여건이 좋지만 최종 의사결정·책임은 인간의 고급 판단으로 남아 있어 AI의 보완성이 높은 고속련 과업으로 볼 수 있다. 넷째, AI 구현 지표와 규칙화 지표가 모두 높은 AI 완전대체 과업 영역(0.5~1, 0.5~1)은 229개로 전체의 약 3%에 불과하다. 다시 말해, 데이터와 시스템 여건이 충분하고

<표 3-6> AI score의 AI 구현 지표 및 규칙화 지표 분해(단위:과업 수)

		AI 구현 지표(M · D · A)						
		0~0.5	0.5~1	합계		0~0.5	0.5~1	합계
규칙화 지표 (1-C) · (1-J)	0~0.5	5,633	885	6,518		83%	13%	96%
	0.5~1	77	229	306		1%	3%	4%
합계		5,710	1,114	6,824		84%	16%	100%

자료: 임금직업포털(<https://www.wagework.go.kr/pt/index.do>, 최종접속일: 2025. 10. 15)을 바탕으로 저자 작성.

과업 자체도 규칙화가 잘되어 있어 경제성만 맞으면 AI가 인력을 상당 부분 대체할 수 있는 과업은 전체 중 극히 일부라는 것이다. 이런 분포는, 한국 직업 · 과업 구조에서 AI가 가져올 변화가 광범위한 전면적 대체라기보다는, 일부 영역의 강한 자동화와 더 넓은 영역에서의 부분적 보완 · 업무 재편으로 나타날 가능성이 크다는 점을 시사한다.

1) 직업 중분류 수준에서 본 AI 자동화 가능성이 높은 상위 직종

다음으로 한국고용직업 중분류 수준에서, 각 AI 자동화 5대 지표의 상위 순위에 해당하는 직종을 <표 3-7>에서 정리하였다. 표에 따르면, 여러 지표에서 공통적으로 상위권에 등장하는 중분류 직종은 다음과 같이 요약할 수 있다.

연구개발 및 공학기술직: 이들 직종은 대부분의 지표에서 반복적으로 상위에 등장한다. 이들 직종의 과업대상은 주로 설계도, 소프트웨어 코드, 실험 · 시험 데이터, 공정 모니터링 정보 등 디지털 정보객체로 구성되어 있고, 업무가 표준화된 워크플로와 시스템 위에서 수행되기 때문에 결과측정이 용이하고 데이터 축적이 잘 이루어질 가능성이 높은 것이 반영된 것이다. 이는 고도의 전문성을 요하지만, 동시에 모형 기반 예측 · 최적화 · 설계 지원에 매우 적합한 영역이라는 점을 시사한다.

경영 · 행정 · 사무직: 이들 직종은 데이터 가용성 및 에이전트화 가능성 측면에서 높은 값을 보이면서 AI score가 가장 높아, 평균적으로 AI 자동화가 가장 많이 될 직종으로 판단된다. 이는 경영 · 행정 · 사무 과업이

<표 3-7> 한국고용직업 중분류에 따른 AI 자동화 지표별 상위 순위

상위 순위	결과측정 가능성(M)	데이터 가용성 및 품질(D)	맥락 의존성(C)	창의성 · 판단 필요성(J)	에이전트화 가능성(A)	AI score
1	건설 · 채굴직, 연구개발직 및 공학기술직	건설 · 채굴직, 연구개발직 및 공학기술직	경호 · 경비직	사회복지 · 종교직	건설 · 채굴직, 연구개발직 및 공학기술직	경영 · 행정 · 사무직
2	금융 · 보험직	경영 · 행정 · 사무직	음식 서비스직	경찰 · 소방 · 교도직	경영 · 행정 · 사무직	운전 · 운송직
3	인문 · 사회과학 연구직	인문 · 사회과학 연구직	농림어업직	경호 · 경비직	금융 · 보험직	영업 · 판매직
4	경영 · 행정 · 사무직	금융 · 보험직	사회복지 · 종교직	음식 서비스직	인문 · 사회과학 연구직	예술 · 디자인 · 방송직
5	자연 · 생명과학 연구직	영업 · 판매직	건설 · 채굴직	농림어업직	영업 · 판매직	금융 · 보험직
6	영업 · 판매직	자연 · 생명과학 연구직	경찰 · 소방 · 교도직	건설 · 채굴직	예술 · 디자인 · 방송직	건설 · 채굴직, 연구개발직 및 공학기술직
7	예술 · 디자인 · 방송직	예술 · 디자인 · 방송직	미용 · 예식 서비스직	관리직(임원 · 부서장)	자연 · 생명과학 연구직	청소 및 기타 개인서비스직
8	법률직	법률직	스포츠 · 레크리에이션직	스포츠 · 레크리에이션직	법률직	법률직
9	제조, 연구개발직 및 공학기술직	제조, 연구개발직 및 공학기술직	돌봄 서비스직(간병 · 육아)	미용 · 예식 서비스직	제조, 연구개발직 및 공학기술직	화학 · 환경설치 · 정비 · 생산직
10	정보통신 연구개발직 및 공학기술직	교육직	관리직(임원 · 부서장)	금속 · 재료설치 · 정비 · 생산직	교육직	섬유 · 의복 생산직

자료: 저자 작성.

전사 시스템(ERP, 회계, 인사, CRM 등)에 깊이 의존해 데이터가 풍부할 뿐 아니라 최상위 관리직과는 다르게 창의 · 판단 필요성과 맥락 의존성이 상대적으로 높지 않기 때문인 것으로 해석된다.

사회복지 · 종교직, 경호 · 경비직 등 대면서비스 직종: 이들 직종은 맥락 의존성과 인간 판단 필요성이 높게 평가되어 C와 J가 크게 나타났다.

즉, 기술적으로는 감정분석, 일정관리, 서류작성 등 일부 과업에서 AI의 보조를 받을 가능성이 있으나, 전반적인 직무는 대인 상호작용, 신뢰 형성, 돌봄 등 고도의 비정형 활동으로 구성되어 있어 완전 자동화보다는 보완의 역할에 머무를 가능성이 높음을 시사한다.

요약하면, 연구개발·공학·정보통신, 경영·행정·사무와 같이 디지털 정보 처리와 규칙 기반 의사결정이 많은 직군에서 AI 자동화 가능성이 높게 나타나는 반면, 대면서비스·돌봄·보건·사회복지 등 인간 상호작용 중심 직군에서는 맥락·판단 지표가 높게 나타나 기술적 자동화 여지가 제한된다는 점을 보여준다. 이러한 형태는 OECD(2025)가 AI에 의한 생산성 향상은 지식집약적·디지털화된 업무에서 먼저 나타나며, 대면서비스·돌봄 영역에서는 보완적 사용과 서비스 질 개선의 형태로 나타날 가능성이 크다고 지적한 것과 일정 부분 일치한다고 할 수 있다.

2) AI 자동화 가능성이 높은 상위 직업

<표 3-8>의 세분류, 즉 개별 직업수준에서 각 지표별 상위 10개 직업을 살펴보면 좀 더 미시적인 특징이 드러난다.

결과측정 가능성(M) 상위 직업: 이들 직업의 공통점은 산출물이 명확히 정의된 디지털 정보 형태라는 점이다. 예를 들어 속기 결과, 전산입력 데이터, 도면·그래픽 파일, 번역문, 회계장부·통계표 등은 모두 정량·정형화된 산출물로, AI가 생성한 결과물에 대한 품질 평가 기준을 설정하기가 상대적으로 용이하다. 따라서 과업의 결과측정 가능성이 높게 나타나며, 이는 AI 학습 및 운영에서 성과 측정 및 피드백 루프 구축이 쉬운 영역임을 의미한다.

데이터 가용성(D) 상위 직업: 도서관 자료, 전산입력 데이터, 회계·통계 시스템, 문서관리 시스템 등은 이미 디지털 데이터가 대량으로 축적되어 있는 분야이다. 이러한 직업에서 수행되는 단위과업은 과거 데이터 축적이 충분하고 추가 데이터 확보도 비교적 용이하므로, 데이터 용이성이 높게 나타났다. 이는 Briggs *et al.*(2023)이 서류처리·행정·법률·

<표 3-8> 한국고용직업 세분류에 따른 AI 자동화 지표별 상위 순위

상위 순위	결과측정 가능성(M)	데이터 가용성 및 품질(D)	1-맥락 의존성(C)	1-창의성 · 판단 필요성(J)	에이전트화 가능성(A)	AI score
1	영상그래픽 디자이너	사서	전산자료 입력원 및 사무보조원	전산자료 입력원 및 사무보조원	사서	전산자료 입력원 및 사무보조원
2	속기사	전산자료 입력원 및 사무보조원	사서	사서	전산자료 입력원 및 사무보조원	속기사
3	전산자료 입력원 및 사무보조원	속기사	속기사	속기사	관세사	영상그래픽 디자이너
4	제도사 (캐드원)	관세사	영상그래픽 디자이너	영상그래픽 디자이너	속기사	고객상담원
5	번역가	영상그래픽 디자이너	매장계산원 및 요급정산원	매장계산원 및 요급정산원	영상그래픽 디자이너	사서
6	통계사무원	통계사무원	제도사 (캐드원)	통계사무원	통계사무원	택배원
7	회계사무원	제도사 (캐드원)	통계사무원	고객상담원	제도사 (캐드원)	매장계산원 및 요급정산원
8	경영기획 사무원	고객상담원	관세사	제도사 (캐드원)	고객상담원	보건의료정보 관리사
9	건설자재 시험원	경영기획 사무원	회계사무원	관세사	번역가	부동산중개인
10	고객상담원	번역가	번역가	번역가	경영기획 사무원	자재 · 구매 사무원

자료: 저자 작성.

회계 · R&D 등 화이트칼라 영역에서 AI에 대한 노출과 잠재비용 절감 효과가 특히 클수 있다고 지적한 것과도 방향성이 어느 정도 일치한다.

1-맥락 의존성(C), 1-창의 · 판단 필요성(J) 상위 직업: 1-C와 1-J 지표는 각각 맥락 의존성과 창의 · 판단 필요성의 반대 값이므로, 상위 순위에 위치한다는 것은 맥락 · 판단 의존도가 상대적으로 낮다는 것을 뜻한다. 여기서도 전산자료입력원 및 사무보조원, 사서, 속기사, 제도사, 통계 · 회계 사무원 등 사무 · 정보처리 중심 직업이 상위에 위치한다. 이러한 직무는 규정 · 템플릿 · 전산시스템이 명확하고, 업무 흐름이 비교적 표준화되

어 있어 개별 상황에 따라 판단을 크게 달리할 여지가 적다. 이 때문에 AI가 비교적 안정적으로 대체하거나, 최소한 반복적 부분을 상당 부분 자동화할 수 있는 영역으로 해석된다.


에이전트화 가능성(A) 및 종합 $AI\ score$ 상위 직업: 여기서 상위 직업들은 크게 두 가지 특징이 눈에 띈다. 우선 백오피스·정보처리 직무가 주를 이룬다. 전산자료입력, 각종 통계·회계·경영기획, 도면·그래픽 제작, 도서·자료 관리 등은 이미 디지털 시스템(ERP, 회계시스템, CAD, 도서관 시스템 등)을 기반으로 운영된다. 따라서 이러한 직무는 LLM이 API를 통해 기존 시스템과 연동되거나, 자동화된 워크플로(예: 입력-검증-보고서 생성)를 설계하기 용이하므로 A 가 높게 나타난다. 두 번째는 거래·물류·고객접점 직무이다. 고객접점 직무의 경우 앞서 대면서비스업의 특성으로 맥락 의존성이나 창의성·판단 필요성이 높을 수 있지만, 매장계산·요금정산, 택배·물류, 자재·구매, 고객상담, 부동산 중개, 보건 의료정보 관리 등은 개별 거래·사건 단위로 프로세스가 반복되고, 데이터가 전산시스템에 자동 기록되는 구조를 가진다. 이 경우 AI 에이전트가 주문·결제·배달·문의 응대 등 프로세스의 상당 부분을 자동화하거나, 인간작업자를 실시간으로 보조하는 형태의 사용이 가능하기 때문에 지표가 높게 나온 것으로 판단된다.

종합지표인 $AI\ score$ 는 M , D , $(1-C)$, $(1-J)$, A 를 모두 곱해 산출되므로, 산출물 측정 및 데이터 가용성이 높고, 맥락 및 인간 판단 의존성이 상대적으로 낮으며, 시스템 연동이 용이한 직업이 상위에 집중된다. 이러한 형태는 Eloundou *et al.*(2023), Goldman Sachs(Briggs *et al.*, 2023), Chui *et al.*(2023) 등에서 공통적으로 보고되는 전문·행정·사무·콘텐츠 생산 영역의 높은 LLM 노출도와 상당히 유사하다.

3) 직능수준·연봉수준별 AI 자동화 가능성

[그림 3-1]은 직능수준(LEVEL 1~8)과 연봉 구간별로 단위과업 기준 평균 AI 지표 및 최종 AI 자동화 가능성을 제시한다. 몇 가지 특징적인 형태를 확인할 수 있는데, 우선 직능수준이 높아질수록 M , D , A 가 전반적

[그림 3-1] 직능수준·연봉수준별 평균 AI 자동화 지표



주: 단위과업 기준 단순 평균값.

으로 상승하는 것을 확인할 수 있다. 특히 저숙련 단순노무·서비스 직무(LEVEL 1~2)에 비해, 중간 숙련의 기능·사무·기술직(LEVEL 3~5), 그리고 고숙련 전문직·연구직(LEVEL 6 이상)에서 결과측정 가능성(M)과 데이터 가용성(D), 에이전트화 가능성(A)의 평균이 뚜렷하게 높다. 이는 고숙련 직무일수록 업무가 디지털 문서, 통계 데이터, 설계·코드, 전문 지식 데이터베이스 등 정보객체를 중심으로 조직되어 있고, 전산시스템 기반으로 업무 프로세스가 구조화되어 있기 때문으로 판단된다.

다른 측면에서는, 맥락 의존성(C)과 판단의 필요성(J)은 중간 숙련에서 상대적으로 낮고, 최고 직능수준으로 올라갈수록 높아지는 것을 확인할 수 있다. 이는 고위관리자 및 최고 숙련 전문가의 업무가 전략적 결정, 복잡한 이해관계 조정, 윤리적·법적 책임이 수반되는 판단을 포함하기 때문에, AI가 완전히 대체하기보다는 보조 역할에 머무를 가능성이 크다는 점을 의미한다. 이 점은 Acemoglu(2024)가 AI를 자동화 기술로만 볼 경우 고숙련 의사결정 영역의 한계까지 과대평가하게 된다고 지적한 논 의와도 맞닿아 있다.

마지막으로 연봉수준별로는 아주 뚜렷한 경향을 찾기 어려워 보인다. 전반적으로 연봉수준이 상승할수록 M , D , A 가 상승하는 모습을 보이나, $1-C$, $1-J$ 와 결합하면서, 최종적인 AI 자동화 가능성이 단조적으로

높아지는 모습을 보이지 않는다. 다만, 연봉 1억 3천만원 이상인 그룹에서는 *AI score*가 빠르게 높아지는데, 세부 자료를 살펴본 결과, 항공조종사 및 의사 집단의 특정 과업들이 반영된 결과인 것을 확인하였다. 따라서 일반적인 경향이라고 결론 내리기는 어려워 보인다. 이는 Goldman Sachs(Briggs *et al.*, 2023)가 고임금 전문·행정·관리직에서 AI 노출도가 높다는 점을 강조하면서도, 최상위 의사결정 영역에서는 인간의 역할이 장기간 유지될 가능성을 언급하여, 양 요인을 동시에 고려한 본 연구의 AI 자동화 가능성 지표와 유사하다고 볼 수 있다. 다만, Acemoglu(2024)는 AI 노출도가 전방위적으로 연봉·학력에 상관없이 영향을 미치고 있다고 주장한다.

다. 경제적 시사점

위의 표와 그림에서 드러난 경향을 종합하면, 한국 노동시장에서 AI 자동화 가능성이 높은 영역은 (1) 디지털 정보 기반의 사무·분석·연구 개발 과업, (2) 표준화된 프로세스를 가진 거래·물류·고객서비스 과업에 집중되어 있다. 반면, (3) 대면돌봄·사회복지·현장서비스·고위관리·정책결정 등 고도의 맥락·판단이 요구되는 영역은 기술적으로 AI에 노출되어 있음에도 불구하고, 완전 자동화보다는 보완의 역할이 중심이 될 가능성이 높다.

이는 기존 문헌 전반에서 공통적으로 제기되는 의견, 즉 AI가 전통적 단순 반복 노동의 기계적 대체라기보다, 지식·정보 기반 사무직 업무의 재구성 및 전문직 업무의 분해·재조합을 통해 생산성을 끌어올릴 것이라는 전망과 상당히 부합한다. 동시에, 본 연구의 5대 지표 구조를 통해 각 과업의 기술적 노출도와 잠재적인 자동화 난이도를 보다 미시적으로 분해함으로써, 향후 경제성 분석과 거시적 파급효과(노동 재배치, 임금 구조 변화, TFP 상승 경로 등)에 대한 보다 정교한 분석이 가능하다는 점도 의의가 있다.

제2절 AI 자동화의 경제성 분석

1. AI 자동화의 경제성 도입

가. AI 자동화의 경제성 개념

초기의 AI 연구들은 주로 어떤 직무·과업이 AI에 기술적으로 노출되어 있는가에 집중하였다. 그러나 최근 문헌은 단순노출도를 넘어, 어떤 과업이 실제로 비용 대비 이익이 나서 도입될 것인가, 즉 경제성이 있는 자동화 범위를 구분하는 방향으로 진화하고 있다. 이때 경제성의 개념은 대체로 다음과 같은 부등식으로 표현된다. 과업 j 에 대해,

$$\text{AI 자동화 구축} \cdot \text{운영비용} < \text{자동화에 의한 인건비 절감액}$$

이 조건을 만족하는 과업만이 수익성 있는 자동화(profitably automated) 혹은 경제적으로 매력적인 자동화(cost-effective automation)의 집합에 포함된다.

Svanberg *et al.*(2024)은 이 논리의 대표적인 연구이다. 이 논문은 컴퓨터 비전(Computer Vision: CV) 기능을 사례로 각 과업에 대해 필요 성능 수준을 설정하고, Thompson *et al.*(2024)의 모형을 이용해 그 성능에 도달하는 CV 시스템의 총비용(데이터 수집, 모형설계·학습, 인프라 구축, 운영·유지비)을 추정한 다음, 과업별 작업량·임금수준과 비교하여 어떤 과업이 경제적으로 자동화할 가치가 있는지를 판별한다. Thompson *et al.*(2024)은 CV 시스템의 비용을 초기 고정비(개발·데이터 구축·배포), 성능에 의존하는 학습비용(데이터·컴퓨팅), 과업 처리량에 비례하는 운영비(추론·스토리지·유지보수)로 분해하는 비용함수를 제시한다.

두 논문의 핵심 메시지는 다음과 같다. 어떤 과업은 기술적으로는 CV로 대체가 가능하지만, 데이터가 비싸거나, 처리 건수가 적거나, 임금이 낮으면 AI 시스템을 구축해도 투자비를 회수하기 어렵다. 따라서 AI 노출도(exposure)와 경제적으로 매력적인 과업(economically attractive tasks)

의 집합은 상당히 다르다는 것이다. 즉, 그들은 기술적 노출도만으로는 실제 자동화 범위를 과대평가하게 되며, 경제성 개념을 도입해야 진짜 의미 있는 AI 자동화 가능 과업이 무엇인지 식별할 수 있다는 점을 강조한다.

이러한 AI 자동화의 경제성 개념을 거시경제학에 끌어들이는 논문들이 있다. Acemoglu(2024)와 Aghion and Bunel(2024)이 대표적이다. Acemoglu(2024)는 과업기반(task-based) 거시모형에서 AI의 영향을 모형화하면서, AI가 경제 전체에 미치는 TFP 효과는 단순히 노출된 과업의 비중이 아니라 실제로 AI로 대체되는, 즉 비용 대비 이익이 나는 과업의 비중에 의해 결정된다고 본다. 이 논문은 수익성 있게 대체되는 과업(profitably replaced tasks)의 비중과 평균 비용절감률이 TFP(총요소생산성) 증가 효과를 결정하는 충분통계(sufficient statistics) 역할을 한다는 것을 보여주며, 보수적인 가정을 둘 경우 향후 10년간 미국 TFP 연평균 증가분이 약 0.066%p에 그칠 수 있다고 추정한다. 이에 비해 Aghion and Bunel(2024)은 동일한 과업기반 틀을 사용하면서, 보다 낙관적인 비용절감과 도입범위를 가정하여 훨씬 높은 TFP 성장기여(연 0.6~1%p 수준)를 제시한다. 이들은 노출 과업(exposed tasks)과 수익성 있는 자동화 과업(profitably automated tasks)을 명확히 구분하고, 후자에 대해 더 큰 비용절감률과 빠른 도입을 가정하여, AI가 성장률을 유의하게 끌어올릴 수 있다고 본다. 두 논문 모두 공통적으로, 기술적으로 가능한 과업 전체가 아니라, 일반 기업의 입장에서 비용 대비 이익이 발생하는 과업의 부분집합만이 실제로 경제에 반영된다는 점을 전제로, 이 부분집합의 크기와 비용절감률을 통해 거시적 성장 효과를 추정한다.

OECD(2024)는 다양한 미시연구에서 추정된 개별 활동 단위의 성과 향상치와 AI 노출도 지표, 그리고 향후 도입 속도 시나리오를 결합하여, 향후 10년간 AI가 TFP에 기여할 수 있는 범위를 모의실험한다. 이때 AI 도입률은 단순히 기술수준이 아니라, 투자비용(시스템 구축·전환 비용), 조직 재설계 비용, 인력 재배치·교육비 등의 경제적 제약에 의해 결정되는 것으로 간주한다. IMF(Pizzinelli *et al.*, 2023)는 주로 직업·과업 단위 노출도(exposure)를 계산하지만, 노출도가 단지 상한선(upper bound)일 뿐

이며, 실제 자동화와 노동시장 충격은 임금수준, 제도, 기업의 채택비용 등에 의해 크게 축소될 수 있음을 명시적으로 언급한다. Chui *et al.*(2023)은 먼저 직무·활동별 기술적 자동화 잠재력(technical automation potential)을 산출하고, 이후 국가별 임금수준, 도입비용, 규제·조직 리스크 등을 반영하여 경제적으로 실현 가능한 자동화 시나리오를 제시한다. 특히 저임금 국가에서는 동일한 기술이 존재하더라도 절대 인건비가 낮기 때문에 자동화의 경제성이 떨어져 도입 속도가 느릴 것으로 가정한다.

이들 문헌을 종합하면, 거시경제적 관점에서 AI 자동화의 경제성은 다음과 같은 의미를 갖는다. AI 자동화에 노출된 과업 전체(exposed tasks) 중에서, AI 시스템 구축·운영 비용을 상회하는 비용절감 및 생산성 향상을 실현할 수 있는 과업(경제적으로 수익성 있는 과업)의 비중이 최종적으로 TFP·GDP·고용구조에 반영된다는 것이다. 즉, AI의 기술적 잠재력과 실제 거시경제적 성과 사이에는 경제성 필터(economic viability filter)가 존재하며, 이 필터의 강도(비용, 임금, 제도, 조직)가 강할수록 기술적 낙관론 대비 실현되는 효과는 작아질 수 있다.

나. 본 연구의 AI 자동화 경제성 개념

본 연구 역시 위의 문헌들과 마찬가지로, 기술적 자동화 가능성과 경제적 자동화 가능성을 명확히 구분한다. 제1절에서 정의한 과업 단위 AI 자동화 가능성 지표인 $AI_{score_{ij}}$ 는 각 직업·과업 (i, j)가 기술적으로 어느 정도 AI에 의해 자동화·보완될 수 있는지를 측정하는 지표이다. 그러나 $AI_{score_{ij}}$ 가 높다고 해서, 해당 과업이 항상 모든 기업에서 경제적으로 도입되는 것은 아니다. 저임금·소규모 기업에서는 동일 과업이라도 자동화를 통해 절감되는 인건비가 적어, Svanberg *et al.*(2024)에서 보듯이 투자비를 회수하기 어려울 수 있다. 반대로 고임금·대규모 기업에서는 상대적으로 더 많은 과업이 경제성 기준을 충족하게 된다.

따라서 본 연구는 Svanberg *et al.*(2024), Thompson *et al.*(2024), Acemoglu(2024), Aghion and Bunel(2024), OECD(2024), Chui *et al.*(2023)

등이 제시한 것과 같은 경제성 필터를 한국 노동시장 자료에 맞게 구현하여, 먼저 $AI\ score_{ij}$ 를 이용해 AI 단순노출과 기술적으로 AI 구현 가능한 과업집합을 정의하고, 여기에 AI 시스템 구축·운영 비용 모형과 직업별 임금·과업시간 구조를 결합하여, 실제로 경제성이 있는 AI 자동화 과업집합(경제적 AI 자동화)을 추정하는 것을 목표로 한다.

보다 구체적으로, 본 연구의 경제성 분석은 다음과 같은 구조를 갖는다. **1) 과업 단위 AI 시스템 비용:** Svanberg *et al.*(2024), Thompson *et al.*(2024)을 바탕으로, 과업 j 에 적합한 AI 시스템(LLM·멀티모달 등)의 비용을 고정비용(시스템 구현 및 유지 비용), 성능 의존비(데이터·학습·재학습비용), 규모 의존비(운영·API 호출·추론 비용)로 분해한다. **2) 과업 단위 노동비용:** 한국고용직업분류 기반 직업 i 에 대해, 임금 w_i 와 과업 j 가 차지하는 과업 비중 ω_{ij} (또는 이를 근사하는 지표)를 이용하여 과업 j 를 인간이 수행할 때의 단위당 비용을 추정한다. **3) 경제성 판단:** AI 시스템의 총비용과 AI 시스템으로 전환했을 때 절감되는 인건비를 비교한다. 특히 일정 기간(5년) 동안의 현재가치 기준으로 AI가 더 싸고/좋은 경우를 경제성 충족 과업으로 정의한다.

마지막으로, 경제성이 있는 과업집합에 해당하는 직업·산업의 고용·임금 비중을 합산하여 한국에서 기술적으로는 AI에 노출되어 있으나, 경제성 기준까지 만족하는 과업이 차지하는 고용·GDP 비중이 어느 정도 인지, 어떤 직업군·산업에서 경제성 장벽이 특히 높은지를 분석한다. 이는 Acemoglu(2024), Aghion and Bunel(2024), OECD(2024) 등에서 핵심 모수로 사용하는 수익성 있는 자동화 과업(profitably automated tasks)의 비중을 한국 자료에 맞춰 추정하는 작업이라고 볼 수 있다.

본 연구의 AI 자동화 경제성 개념을 기존 문헌과 비교하면 차별점과 공통점이 분명하다. 우선, Svanberg *et al.*(2024), Thompson *et al.*(2024)처럼 AI 시스템 비용을 구조적으로 분해하고 노동비용과 비교하여 경제성 여부를 판단한다는 점과 Acemoglu(2024), Aghion and Bunel(2024), OECD(2024), Chui *et al.*(2023)처럼 기술적 노출도(exposure)와 경제성이 있는 자동화(adoption)를 분리하고, 후자를 거시성장 및 생산성 분석의 핵심 요

인으로 본다는 점이 비슷하다. 차이점은 기존 연구의 경제성 개념이 주로 단일 노출지표(technical exposure)와 비용·임금의 함수로 표현되는 반면, 본 연구는 개별 과업의 특성인 M, D, C, J, A 라는 다차원 지표를 활용하여 AI 자동화 비용의 세부 요인들을 명시적으로 연결한다. 따라서 왜 어떤 과업은 경제성이 높고, 다른 과업은 낮은지를 훨씬 세분화된 방식으로 해석할 수 있다. 또한 기존 Svanberg · Thompson 모형이 주로 컴퓨터 비전이라는 특정 기술군을 대상으로 한 반면, 본 연구는 LLM · 멀티모달모형을 포함한 보다 광범위한 AI 시스템을 상정하고, 과업대상(object)의 모달리티(텍스트 · 이미지 · 영상 · 음성 등)와 과업의 기밀성/산업 특성 등을 고려하여 AI 자동화 비용을 계산한다.

요약하면, 본 절에서 정의하는 AI 자동화의 경제성은 기존 문헌의 개념을 그대로 계승하면서도, 과업 단위의 특성을 데이터, 관리비용, 모달리티, 기밀성, 데이터 가용성 등 세부적으로 분류하여 경제성을 산출하고, 한국의 직업·임금 구조와 결합하여 한국에서 기술적으로 가능한 과업 중 실제로 경제성이 있는 과업이 어느 정도인가를 계량적으로 제시하는 것을 목표로 한다.

2. AI 자동화의 경제성 분석 방법론

가. AI 시스템 비용 C_j^M

1) AI 시스템 비용구조

Svanberg *et al.*(2024)은 CV 과업에 대해, AI 시스템의 비용을 초기 고정비(시스템 구축 · 통합), 성능 의존비(목표 정확도에 도달하기 위한 데이터 · 학습비용), 규모 의존비(운영량에 비례하는 추론 · 유지비용)로 분해하고, 이를 시스템 유효기한 L 년 동안 할인해 합산하는 구조를 제시한다.

본 연구는 이 구조를 그대로 계승하여, 과업 j 에 대한 모형 기반 AI 시스템 비용(C_j^M)을 다음과 같이 정의한다(기업 인덱스는 단순화를 위해 생략한다).

<표 3-9> AI 시스템 구축비용 정리

비용항목 및 기본 모수	설 명
$C^{\text{구축}}$	AI 시스템 초기 구축비(설계·개발·통합)
$C^{\text{유지}}$	연간 유지보수·업그레이드에 필요한 인건비(고정)
$C_j^{\text{데이터}}$	초기 데이터 비용
$C_j^{\text{계산}}$	목표 성능을 달성하기 위한 초기 학습(트레이닝) 계산비용
$C_j^{\text{운영}}$	연간 운영(추론)비용
K_j	연간 재학습 횟수(모형 재학습 주기)
L	투자비 회수 기간(5년)
d	연간 할인율(5%)
m	하드웨어 기술발전에 따른 비용의 할인율(22%)
λ	재학습 데이터 비율(20%)

주: Svanberg *et al.*(2024)의 모형을 저자가 수정.

$$C_j^M = C^{\text{구축}} + C_j^{\text{데이터}} + C_j^{\text{계산}} + \sum_{t=0}^{L-1} \left\{ \frac{C^{\text{유지}} + \lambda C_j^{\text{데이터}} K_j}{(1+d)^t} + \frac{C_j^{\text{운영}} + C_j^{\text{계산}} K_j}{((1+d)(1+m))^t} \right\},$$

여기서 비용항목 및 기본 모수들은 <표 3-9>에 정리한다.

m 을 분모에 추가하는 것은 하드웨어 효율성 기준을 반영한 것으로 Svanberg *et al.*(2024)의 22%를 그대로 차용한다. 또한 Svanberg 모형에서 제시된 기본 모수들(예: L , d 등)은 딥러닝 기반 CV 시스템의 경제성 분석에서 널리 쓰이는 관행적인 값으로, 본 연구도 이를 그대로 차용하였다. 마지막으로 λ 는 초기 학습 데이터 대비 재학습 데이터 규모를 결정하는 모수로 20%를 가정하였다. 이는 Pham and Sun(2024)에서 제시한, 원 학습데이터의 20%를 사용하는 continual learning 설정을 참고한 것으로, 해당 논문에서도 이를 낙관적인(optimistic) 시나리오로 고려하고 있다.⁵⁰

2) 데이터 구축비용: $C_j^{\text{데이터}}$

데이터 라벨링 비용 $p_j^{\text{데이터}}$: 본 연구에서는 수행과업 j 의 AI 자동화

50 Li *et al.*(2025)에서는 적절한 데이터를 선택하면 LLM을 fine-tuning하는 데 전체 데이터의 0.7%로도 충분하다고 분석한다.

구축을 위한 학습 데이터의 기본 단위를 1건의 데이터 라벨링 비용이자 데이터 구입비용으로 간주하고, 다음과 같이 정의한다.

$$p_j^{\text{데이터}} = w_j \cdot h_j \cdot \phi_j \cdot x_{\text{mod},j} \cdot x_{\text{sec},j} \cdot x_{D,j}.$$

여기서 데이터 라벨링의 가격을 결정하는 요인들은 <표 3-10>에 정리한다. 이렇게 정의된 $p_j^{\text{데이터}}$ 는 Svanberg · Thompson 모형의 데이터당 단가 개념을 한국 노동시장과 본 연구의 AI 노출도 지표(D_{ij} , 모달리티, 기밀성 등)에 맞게 구조화한 것이다.

필요 학습 데이터 라벨링 수 $f(a_j, b_j, c_j)$: 과업 j 의 AI 자동화 시스템 구축을 위해 필요한 데이터 라벨링 수는 다음과 같이 정의된다.

$$f(a_j, b_j, c_j) = 10^{\left(\frac{\log_{10}(1-a_j) + 0.81 - 0.62 \cdot b_j - 0.61/9.94 \cdot \max\{0, \log_2(c_j/4)\}}{-0.123 \cdot 3.8} + 2.1 \right)},$$

여기서 a_j 는 해당 과업을 AI가 수행하는 데 있어 필요한 최소한의 목표 정확도를 의미하며, b_j 는 AI가 해당 과업에서 출력하는 결과 값의 복잡도(텍스트 길이, 필드 개수, 세그멘테이션 복잡도 등)를 의미한다. 마지막으로 c_j 는 해당 과업에서 AI가 구분해야 할 클래스(범주) 수를 의미한다.

f 자체는 Thompson *et al.*(2024)이 사용한 성능-데이터량 간 로그선형 관계(일종의 power-law)를 변형하여, 정확도 목표 a_j 가 높을수록, 출력복잡도 b_j 가 클수록, 클래스 수 c_j 가 많을수록 필요 데이터량이 기하급수적으로 증가하도록 구성하였다. 다만, 내부 상수는 베이스라인 작업에서 $10^3 \sim 10^6$ 개의 라벨링 수 범위가 나오도록 조정하였다. 이는 너무 작거나 과도한 데이터량을 피하기 위해 최근 AI 및 데이터 관련 시장에 형성되어 있는 실무적 학습 데이터량을 고려한 것이다.⁵¹ 이에 따라 시스템 구축에

⁵¹ CV 실무가이드에서는 학습 기반 과업에서 클래스당 1,000장 수준을 경험적으로 제시하며, 프로덕션 모형은 수백에서 수천장으로 확장되는 경우가 많다고 설명한다. 또한 LLM 미세조정(fine-tuning)에서도 과업특화 데이터는 통상 수천 개의 라벨된 예제를 사용한다는 가이드가 있다(<https://encord.com/blog/choose-the-best-data-guide-computer-vision>: 최종접속일: 2025. 10. 5). 또한 대표적인 소규모 학습 fine-tuning 모형인 Alpaca는 52,000개의 예제규모를 가지고 있다. 한편, 대규모 범용 벤치마크인 ImageNet은 약 120만 훈련이미

<표 3-10> 데이터 라벨링 가격 요인 분해

데이터 라벨링 가격 요인	설 명	
w_j	라벨링을 수행하는 인력의 시급	
	직능수준	반영 내용
	≤ 4	2025년 한국 최저임금(10,030원)을 사용 - 단순 · 반복적 라벨링은 저숙련 아르바이트/외주 인력으로 수행 가능하다는 가정
	≥ 5	해당 과업을 수행하는 직업의 평균 시급(Workpedia 기반)을 사용 - 전문지식이 필요한 라벨링(예: 의료영상, 법률 문서)은 실제 업무 담당자가 라벨링한다는 보수적 가정
h_j	1건 라벨링에 소요되는 시간(시간 단위) - LLM 추정	
ϕ_j	데이터 관리 · 품질검사(QA) · 톨 비용 등 오버헤드 계수	
	직능수준	반영 내용
	1~2	1.2(간단 관리)
	3~5	1.3(기본)
$x_{\text{mod},j}$	모달리티 계수(텍스트 · 이미지 · 영상 등 데이터 형태에 따라 라벨링 복잡도 차이를 반영)	
	모달리티	반영 내용
	텍스트	1.0
	이미지	1.2
	음성	1.5
	영상	2.0
	텍스트+이미지, 텍스트+음성	1.8
	텍스트+영상	2.2
	텍스트+이미지+영상/음성	2.4
$x_{\text{sec},j}$	기밀성/산업 특성 계수 - LLM 추정	
	과업대상 판단 기준	반영 내용
	일반 데이터(교육자료 · 공개 문서 등)	1.0
	민감 데이터(거래자료, 비공개 실적, 고객 · 근로자 개별 정보 등)	1.5
$x_{D,j}$	데이터 가용성 D_{ij} 를 반영한 계수	
	판단 기준	반영 내용
	$D_{ij} \geq 0.8$	0.8(이미 풍부한 데이터가 있어 추가 데이터는 비교적 싸게 확보 가능)
	$0.5 \leq D_{ij} < 0.8$	1.0(중간 수준)
	$D_{ij} < 0.5$	1.3(데이터가 희소 · 산발적이라 확보 비용이 증가)

자료: 저자 작성.

지(라벨)를 제공하며, COCO는 1.5백만 객체라벨을 포함하는 등, 복잡한 과업에서는 10^6 단위 라벨규모가 관측된다(<https://cocodataset.org/>, 최종접속일: 2025. 10. 5).

필요한 데이터 비용은 $C_j^{\text{데이터}} = p_j^{\text{데이터}} \cdot f(a_j, b_j, c_j)$ 로 계산된다.

3) LLM 기반 모수 추정 규칙

$p_j^{\text{데이터}}$, f 를 완전히 수작업으로 설정하는 것은 6천여 개 과업에 대해 비현실적이므로, 본 연구는 LLM(GPT-5.1)을 사용하여 모수들을 규칙 기반으로 자동 추정하였다.⁵²

라벨링 시간 h_j : LLM은 직업명(job_title), 과업대상(object), 모달리티(object_modality), 과업행위의 범주(verb_cat_list)를 종합적으로 보고, 과업의 라벨링 난이도를 4단계로 다음과 같이 분류한다.⁵³

<표 3-11> 라벨링 시간

단계	예 시	h_j 시간
1	단순 텍스트 태깅, 키워드 여부, 단일 이미지 분류	0.003h(약 11초)
2	이미지 1~2개 객체 bounding box, 짧은 텍스트 QA · 요약 평가	0.01h(36초)
3	다중 객체 · 세그멘테이션, 길이 있는 텍스트 · 오디오 클립 라벨링	0.03h(1분 48초)
4	의료영상 판독, 법 · 금융 문서 정밀 검토 등 전문 판단 필요	0.1h(6분)

자료: 저자 작성.

과업의 정확도 a_j , 복잡도 b_j , 클래스 수 c_j : LLM은 각 과업의 설명(직업명(job_title), 과업대상(object), 과업행위(verb) 범주 등)을 읽고, <표 3-12>의 규칙에 따라 후보 값 중 하나를 선택한다. 이렇게 개별 과업에 대해 통일된 스케일로 추정함으로써, 과업 간 비교 가능한 데이터 요구량을 산출할 수 있도록 설계하였다.

⁵² Svanberg *et al.*(2024)은 데이터 가격을 추정하기 위해 설문조사를 시행하였으나, 데이터 가격대의 범위가 매우 넓고, 설문문항도 단순하여 본 연구에서 해당 방법론을 사용하기는 어려운 것으로 판단하였다.

⁵³ 구체적인 라벨링 시간은 아래의 웹페이지를 참조하기 바란다(최종접속일: 2025. 10. 15). (<https://pmc.ncbi.nlm.nih.gov/articles/PMC11102897/>, <https://arxiv.org/pdf/2207.00810>, <https://calvin-vision.net/wp-content/uploads/Publications/bearman16eccv.pdf>)

<표 3-12> 학습 데이터량 결정 요인

모수	추정 규칙	
a_j	직능수준과 과업 위험도(의료·금융·안전·규제 관련 여부 등)에 따라 0.75~0.99 사이의 이산값 세트에서 선택	
	위험 기준	반영 내용
	저숙련·저위험 과업	0.75~0.88
	중간 수준	0.90~0.97
	고숙련·고위험 과업	0.98~0.99
b_j	출력구조 복잡도를 1.0~1.5 범위의 이산값에서 선택	
	출력 복잡도 기준	반영 내용
	단순 이진/단일 라벨	1.00~1.05
	짧은 요약·복수 태그	1.10~1.20
	세그멘테이션·장문 보고서 등 고복잡	1.30~1.50
c_j	과업이 구분해야 할 클래스 수를 1~400 사이 정수로 설정	
	클래스 구분 기준	반영 내용
	단순 예/아니오	2
	3~4단계 등급	3, 4
	5~10개 유형	5, 10 등
	복잡 코드 체계	20, 50, 100 등

자료: 저자 작성.

재학습 주기 K_j : 마지막으로, 매년 재학습 빈도는 1) 과업 위험도(High/Medium/Low), 2) 데이터 변동성(Very stable / Seasonal / Fast-changing), 3) 직능수준에 따라 LLM이 규칙 매트릭스를 이용해 {0, 1, 2, 4, 6, 12} 중에서 선택하도록 하였다. 예를 들어 규정·법령 기반의 매우 안정적이고 고위험인 과업은 연 1~2회 재학습, 고객 행동·이상거래 탐지처럼 빠르게 변하는 고위험 과업은 연 6~12회 재학습을 기본으로 한다. 이는 Svanberg *et al.*(2024)이 데이터 분포 변화 및 운영 리스크를 고려해 재학습비용을 포함시킨 구조를 과업별 위험·변동성 지표로 체계화한 것이라고 이해할 수 있다.

4) 계산(학습)비용 $C_j^{\text{계산}}$

Svanberg *et al.*(2024), Thompson *et al.*(2024)은 필요(데이터량 × 모형 크기 × Epoch)로 총학습 FLOPs⁵⁴를 계산하고, 이를 GPU의 FLOPs/h로

나눈 후 GPU 렌탈가격(p^{GPUh})을 반영하여 계산(학습)비용을 산출하는 방식을 사용하였다. 본 연구는 이 구조를 그대로 따르되, LLM·멀티모달모형에 적합한 모수를 설정하여

$$C_j^{계산} = \frac{f(a_j, b_j, c_j) \cdot 2 \cdot Model\ Connections \cdot 3 \cdot Epochs}{GPU\ FLOPs/h} \cdot \frac{p^{GPUh}}{U}$$

로 정의한다. 여기서 각 모수들은 <표 3-13>과 같이 가정한다. 이 식을 통해, 각 과업에 필요한 데이터량과 모형크기·학습조건을 일정하게 유지했을 때의 초기 계산(학습)비용을 일관된 기준으로 산출할 수 있다.⁵⁵

<표 3-13> AI 학습비용 모수

모수	설 명
Model Connections	10 ⁸ : 중형 LLM의 유효 파라미터 수(또는 attention 연결 수)에 상응하는 규모
Epochs	50: Svanberg-Thompson 모형의 기준과 유사하게, 고정된 Epoch 수를 가정하여 비교 가능성 확보
GPU FLOPs/h	10 ¹⁸ : NVIDIA H100 (TF32 Tensor Core) 기준 성능을 시간당 연산량으로 환산한 값
p^{GPUh}	3,968원: 주요 클라우드 및 전문 GPU 렌탈 업체의 평균 가격 USD 3에 최근 3년 평균 원/달러 환율(1,323원)을 반영 ⁵⁶
U	GPU 사용률(85%)

주: Svanberg *et al.*(2024)의 모형을 저자가 수정.

5) 운용(추론) 비용 $C_j^{운용}$

운용비용은 Svanberg *et al.*(2024)에서 제시된 (연간 GPU 사용시간 × GPU 단가) 구조를 그대로 따르되, 대규모 LLM을 여러 과업·종사자가

54 FLOPs(플롭스)는 FLoating point Operations Per Second의 약자로, 컴퓨터나 프로세서가 1 초에 수행할 수 있는 부동소수점 연산의 수를 나타내는 성능 측정 단위이다(Google AI).
55 본 연구에서는 하드웨어의 발전으로 인해 한계 학습비용의 수준이 매우 낮아졌기 때문에 시스템 초기 학습비용과 재학습비용에 차이가 없는 것으로 가정하였다.
56 2025년 기준 H100 렌탈 가격은 전문 GPU 클라우드(예: RunPod, Vast.ai, GMI 등)에서 대략 1.5~3달러/h 수준, 주요 하이퍼스케일 클라우드(AWS, GCP, Azure 등)에서 4~10달러/h 수준으로 보고되고 있다. 이에 따라 전문 GPU 클라우드와 하이퍼스케일 클라우드를 혼합적으로 활용하는 현실적인 기업도입 상황을 반영한 평균값으로 3달러/h를 가정한다.

공유한다는 점을 반영해 상대적으로 단순화된 형태로 정의하였다.

$$C_j^{\text{응용}} = \frac{p^{GPUh}}{U} \cdot 40 \cdot 50 \cdot \omega_{ij},$$

여기서 40은 주당 근로시간 40시간을, 50은 연간 근로주 50주를, ω_{ij} 는 직업 i 의 과업 j 가 노동시간에서 차지하는 비중(직업 내 과업들은 균등하게 취급)으로 계산하였다. Svanberg *et al.*(2024)은 Vision 시스템 기준으로 직원 수에 비례한 GPU 필요량을 따로 고려하지만, 본 연구는 H100급 LLM서버 1대가 수많은 직무·과업을 동시에 처리할 수 있다는 점을 반영하여, 직원 수를 직접적으로 반영하지 않고 과업시간 비중만을 통해 상대적 규모만 반영하였다.

6) 시스템 구축·유지 고정비용 $C^{\text{구축}}$, $C^{\text{유지}}$

마지막으로, AI 시스템 구축 및 유지에 필요한 고정 인건비는 Svanberg *et al.*(2024)이 제시한 1개의 과업을 자동화하기 위한 프로젝트 팀 구성(IT아키텍트, 개발자, 분석가 등) 구조를 그대로 따르되, 개발시스템이 기반모형(foundation model) 위에서 fine-tuning이나 에이전트화하는 것을 가정하여, CV 시스템을 처음부터 개발하는 경우(Svanberg *et al.*, 2024)에 비해 필요 인력 수를 약 절반 수준으로 축소하였다.

구체적으로, 시스템 구축비용($C^{\text{구축}}$)은 IT아키텍트 3명(100%), 응용 SW 개발자 2명(80%), 업무분석가 1명(5%)이 6개월 동안 투입된다고 가정하고, 각 직무별 월평균 임금은 「2025년 적용 SW기술자 평균임금 공표」(한국소프트웨어산업협회)에서 제공하는 임금표를 사용하였다.⁵⁷ 이를 합산하여 약 2억 5,200만원 수준의 시스템 구축비를 산정하였다. 시스템 유지비용($C^{\text{유지}}$)은 응용 SW 개발자 2명(30%), 업무분석가 1명(1.42%)이 연간 유지보수·운영지원에 투입되는 것으로 가정하고, 동일한 임금 통계를 사용하여 연간 약 5,100만원 수준의 유지비용을 반영하였다.⁵⁸

57 <https://www.sw.or.kr/site/sw/ex/board/List.do?cbIdx=304>(최종접속일: 2025. 10. 15).

58 Svanberg *et al.*(2024)은 구축비용은 176만달러, 유지비용은 24만달러로 추정하고 있다. 본

나. 과업의 1인당 노동비용 C_{ij}^H

AI 시스템 비용 C_j^M 와 비교되는 기준은, 해당 과업을 사람이 수행할 때 기업이 부담하는 노동비용의 현재가치이다. Svanberg *et al.*(2024)은 CV 과업 j 에 대해, 특정 기업 l 에서 그 과업을 수행하는 전체 노동자집단에 대한 인건비 총액의 현재가치를 계산하였지만, 본 연구는 이 구조를 과업당 1인 기준으로 단순화하여 직업 i , 과업 j 에 대한 1인당 과업 노동비용의 현재가치로 다음과 같이 정의한다.

$$C_{ij}^H = \sum_{t=0}^{L-1} \frac{w_i \cdot r \cdot \omega_{ij}}{(1+d)^t},$$

여기서 w_i 는 임금직업포털(Workpedia)에 보고된 직업 i 의 연간 평균임금(연봉), ω_{ij} 는 직업 i 의 연간 노동시간(또는 연봉) 중 단위과업 j 가 차지하는 비중이다. 해당 직업의 과업기술서(task description)를 object-verb 단위과업으로 분해한 뒤, 단위과업 수 $\sum_{s_{ij}} k_{ij}$ 로 연봉을 균등분할하는 방식으로 근사한 것이다.⁵⁹ r 은 임금에 대비한 기업의 총노동비용 비율로, 본 연구에서는 2022~24년 「기업체노동비용조사」 결과를 이용하여 임금 대비 총노동비용 비율의 3년 평균이 약 1.26임을 추정하고, 이를 공통 모수로 사용한다.⁶⁰

다. AI 자동화의 경제성 판단

본 연구에서는 경제성 판단을 기업 내 최소 필요 인원수(minimum viable headcount) 관점에서 재정의한다. 즉, AI 시스템 1개를 구축할 때

연구의 구축 및 유지 비용은 Svanberg *et al.*(2024) 비용 대비 10%, 15% 수준이다.

⁵⁹ Svanberg *et al.*(2024)이 사용하는 과업 비중 v_{ij} 개념과 구조적으로 동일하지만, 미국 O*NET의 task importance 점수를 이용하는 대신, 우리는 과업 분해된 object-verb pair 개수를 기반으로 과업 비중을 근사한다는 점에서 차이가 있다.

⁶⁰ https://kosis.kr/statHtml/statHtml.do?orgId=118&tblId=DT_118N_ENTN041&conn_path=I3 (최종 접속일: 2025. 10. 15).

필요한 비용 C_j^M 를 기준으로, 과업 j 를 수행하는 인원이 몇 명 이상일 때 AI 도입이 인건비보다 유리한지 계산하는 방식이다. 이를 위해, 앞 절에서 정의한 1인당 과업 노동비용 C_{ij}^H 를 사용하여, 과업 j 에 대한 최소 필요 인원수 임계값(threshold)을 다음과 같이 정의한다.

$$n_{ij}^* = \frac{C_j^M}{C_{ij}^H}.$$

즉, $n_{li} \geq n_{ij}^*$ 이면, 해당 기업 l 은 과업 j 에 대해 AI 시스템 도입이 인건비 대비 경제적으로 유리한 상황(또는 최소한 손익분기점 근처)에 도달했다고 판단한다. 그 반대이면, 기업의 규모 부족으로 AI 시스템 구축비를 회수하기 어려운 경우로 분류한다.⁶¹

본 연구의 경제성 판단에서 중요한 문제는 기업 내에서 특정 과업 j 가 포함된 직무 i 를 수행하는 인원수 n_{li} 를 관측하거나, 최소한 근사하는 것이다. Svanberg *et al.*(2024)은 기업규모와 직종분포를 통합한 통계자료를 활용하였으나, 직종별 기업 내 인원 비중이 직접 관찰되지 않아, 여러 추가 가정과 보정 절차를 통해 추정해야 했다. 그로 인해 개별 기업에 대한 정확도가 떨어지고, 특히 중소기업·서비스업 등에서 직무구조가 단순하지 않다는 점이 간과되었다.

한국의 경우, 고용노동부 「직종별사업체노동력조사」에서 표본조사로 사업체별·직종별·규모별 현원이 제공된다.⁶² 본 연구는 2024년 하반기, 2025년 상반기 자료에서 고용직업분류(소분류) 코드별 현원 정보를 이용하여 경제성 판단을 수행한다. 즉, 조사자료의 한 관측치는 (사업체 l -직업 i -현원 n_{li}) 조합(반기당 약 37만건)이며, 여기에 해당 직업 종사자 수 n_{li} 가 기록돼 있으므로 앞에서 계산한 과업별 임계값 n_{ij}^* 와 비교하여, $n_{li} \geq n_{ij}^*$ 인 사업체-직업 조합을 과업 j 에 대해 AI 자동화가 경제성을 갖는 사업체로 식별한다.

⁶¹ n_{ij}^* 의 분포는 부록을 참조

⁶² <https://mdis.mods.go.kr/index.do>(최종접속일: 2025. 10. 15).

3. AI 자동화의 경제성 분석 결과

경제성 분석은 고용노동부의 사업체노동력조사 자료의 한계로 한국고용직업분류 세분류(537개)를 소분류 직업군으로 집계한 뒤, 하나의 소분류 직업군을 하나의 직업으로 간주하여 수행하였다. 구체적으로는, 소분류 안에 포함된 세분류 직업들의 단위과업(object-verb pair)을 모두 합쳐 한 직업이 수행하는 과업집합으로 보고, 연봉 또한 소분류 내 세분류 직업의 연봉을 합산한 값으로 정의하였다. 이는 동일 소분류 내에서 과업들이 어느 정도 상호 대체·공유될 수 있다는 현실적인 가정을 반영한 것으로, 경제성이 다소 과대평가될 여지는 있으나, Svanberg *et al.*(2024)이 논의하는 AI-as-a-service 시나리오(하나의 AI 시스템이 동일 직업군 안에서 광범위하게 서비스되는 경우)와 유사한 설정으로 해석할 수 있다.

가. 직업별 AI 자동화의 경제성

이러한 설정하에서, 각 직업군에 대해 AI 기술 단순노출 기준(*AI score*가 1에 수렴하였다는 가정) 경제성 비중과 AI 자동화 가능성(*AI score*)을 반영한 경제성 비중을 각각 계산하였다. AI 기술 단순노출 기준 직업 경제성 비중은 직업 i 를 고용한 전체 사업체들 고용인원수 대비 경제성 있는 고용인원의 과업 비중의 합으로 정의된다.

$$\frac{\sum_l \sum_j \omega_{ij} \cdot n_{li} \cdot 1(n_{li} \geq n_{ij}^*)}{\sum_l n_{li}}$$

이는 향후(대략 10년) AI 기술이 급속히 발전하여 모달리티가 정의된 과업이 모두 기술적으로 자동화 가능하다고 가정하고, 그중에서 AI 시스템 비용이 인간 노동비용을 하회하는 과업들이 전체 고용인원 중 어느 정도 비중을 차지하는지를 의미한다.

AI 자동화 가능성(*AI score*)을 반영한 직업 경제성 비중은 직업 i 를

고용한 전체 사업체들 고용인원수 대비 경제성에 자동화의 실질적 구현 가능성을 고려한 고용인원의 과업 비중의 합으로 정의한다.

$$\frac{\sum_l \sum_j \omega_{ij} \cdot n_{li} \cdot 1(n_{li} \geq n_{ij}^*) \cdot AI_{score_{ij}}}{\sum_l n_{li}}$$

이는 동일한 구조에서 각 과업에 대해 추정된 AI 자동화 가능성을 추가 가중치로 곱하여, 기술적 불확실성과 맥락·판단·에이전트화 제약을 반영한 실효적 경제성 비중을 측정한다.

직업군별 AI 자동화의 경제성 상·하위 순위를 보면, AI 기술 단순노출 기준 상위 직업군은 금융·보험 영업원(54.3%), 정보보안 전문가(49.0%), 자연과학 연구원 및 시험원(48.0%), 자동차 및 제품영업원(39.5%), 정부·공공 행정 사무원(37.7%) 등으로 나타난다. 이 직업들은 공통적으로 (1) 디지털 정보객체를 다루는 과업 비중이 높고, (2) 텍스트·수치·기록 데이터 기반 업무가 많으며, (3) 반복적인 정보처리·보고·확인/점검 과업이 상당 부분을 차지한다는 특징을 갖는다. 따라서 기술적 관점에서 보면, LLM·검색·RPA(robotic process automation)⁶³·에이전트 등을 결합한 AI 시스템이 상당 규모의 과업을 자동화할 수 있는 여지가 크며, 일정 수준의 AI 시스템 구축비용이 들더라도 기업 입장에서는 노동비용 절감 효과가 크게 나타나 경제성이 높게 평가된다.

그러나 AI 자동화 가능성을 반영하면 순위와 수준이 상당 부분 달라진다. 같은 표에서 정보보안 전문가의 경제성 비중은 13.6%로 여전히 가장 높지만, 금융·보험 영업원은 8.4%, 자동 조립라인·산업용 로봇 조작용은 7.4%, 안내·고객상담·통계·비서·사무보조 및 기타 사무원은 6.4%, 정부·공공 행정 사무원은 6.1% 수준으로 떨어진다. 이는 단위과업 차원에서 볼 때, 동일 직업 안에서도 (i) 결과측정이 명확하고 데이터

63 RPA란 소프트웨어 로봇을 이용해 반복적이고 규칙 기반의 업무를 자동화하는 기술로, 데이터 복사/붙여넣기, 시스템 로그인, 보고서 작성 등 단순 업무를 사람이 하는 것처럼 수행하여 생산성 향상과 비용절감, 에러 감소 효과를 가져온다(Google AI).

<표 3-14> AI 자동화의 경제성 상위 직업군

AI 자동화 경제성 상위 순위	AI 기술 단순노출		AI 자동화 가능성 반영	
	직업군	경제성 비중	직업군	경제성 비중
1	금융·보험 영업원	54.3%	정보보안 전문가	13.6%
2	정보보안 전문가	49.0%	금융·보험 영업원	8.4%
3	자연과학 연구원 및 시험원	48.0%	자동 조립라인·산업용 로봇 조작원	7.4%
4	자동차 및 제품영업원	39.5%	안내·고객상담·통계· 비서·사무보조 및 기타 사무원	6.4%
5	정부·공공 행정 사무원	37.7%	정부·공공 행정 사무원	6.1%
6	대학교수 및 강사	34.7%	금속관련 기계·설비 조작원	5.7%
7	인문·사회과학 연구원	32.9%	검침·주차관리 및 기타 서비스 단순 종사자	5.6%
8	항공기·선박· 열차 객실 승무원	32.7%	발전·배전 장치 조작원	5.5%
9	자동 조립라인·산업 용 로봇 조작원	30.0%	항공기·선박·철도 조종사 및 관제사	5.5%
10	통신·방송송출 장비 기사	28.1%	택배원 및 기타 운송 종사자	5.5%

자료: 저자 작성.

축적이 쉬운 과업과, (ii) 맥락 의존성과 판단 필요성이 높은 과업이 혼재해 있다는 사실을 반영한다. 전자의 과업만이 $AI\ score$ 가 높게 나와 경제성 판단에서 실제 자동화로 이어질 가능성이 큰 반면, 후자의 과업은 기술적 노출은 존재하더라도 자동 대체의 가능성이 낮아 경제성 기여도가 제한적이기 때문에 실효적 경제성이 하락한 것으로 해석할 수 있다.

하위 직업군을 보면 이러한 패턴이 더 분명하다. 수의사, 정부·공공 행정 전문가, 임업 종사자, 어업 종사자, 의복 제조원 및 수선원, 영양사, 사회복지사 및 상담사, 미용 서비스원, 주방장 및 조리사, 작물재배 종사

<표 3-15> AI 자동화의 경제성 하위 직업군

AI 자동화 경제성 하위 순위	AI 기술 단순노출		AI 자동화 가능성 반영	
	직업군	경제성 비중	직업군	경제성 비중
1	수의사	0.0%	어업 종사자	0.0%
2	정부·공공 행정 전문가	0.0%	영양사	0.0%
3	임업 종사자	0.0%	정부·공공 행정 전문가	0.0%
4	어업 종사자	0.0%	임업 종사자	0.0%
5	의복 제조원 및 수선원	0.0%	수의사	0.0%
6	영양사	0.0%	의복 제조원 및 수선원	0.0%
7	사회복지사 및 상담사	0.1%	의회의원·고위공무원 및 기업 고위 임원	0.0%
8	미용 서비스원	0.2%	사회복지사 및 상담사	0.0%
9	주방장 및 조리사	0.2%	미용·여행·숙박·음식 ·경비·청소 관리자	0.0%
10	작물재배 종사자	0.4%	주방장 및 조리사	0.0%

자료: 저자 작성.

자 등은 AI 기술 단순노출 기준에서도 경제성 비중이 0.0~0.4%에 불과하며, AI 자동화 가능성을 반영하면 대부분 0%에 가깝다. 이 직업들은 (1) 현장 물리작업 비중이 높거나, (2) 대면서비스·정서적 돌봄·상담 등 고도의 인간 상호작용이 필요하고, (3) 과업 성과를 정량적으로 측정하기 어렵거나, (4) 데이터 수집 자체가 윤리·법제도 측면에서 제약되는 분야라는 공통점을 갖는다.

경제학적으로 보면, 이러한 결과는 다음의 함의를 갖는다. 첫째, 단순한 AI 기술 노출도와 경제적으로 선택될 자동화 사이에는 큰 격차가 존재한다. 직업수준에서 모달리티 기준 노출도를 보면 상당수의 직업이 AI에 의해 대체될 수 있을 것처럼 보이지만, 실제로는 과업별 실질 AI 자동화 가능성과 시스템 구축비용을 고려할 때 경제성이 확보되는 과업·직업은 상대적으로 제한적이다. 이는 Acemoglu(2024)가 강조하는 바와 같이, 자동화 기술의 잠재력을 곧바로 현실의 대체 효과로 등치시키기 어

렵다는 점과 정확히 맞닿아 있다. 둘째, 경제성이 높은 직업은 고숙련·고임금의 디지털·지식 노동에 집중되어 있다. 이는 Aghion and Bunel (2024), OECD(2024), Chui *et al.*(2023), Briggs *et al.*(2023) 등이 공통적으로 지적하는, 금융·전문서비스·ICT 등 지식집약 서비스 부문에서 AI 도입에 따른 노동수요 조정과 생산성 향상이 동시에 발생할 수 있다는 전망과 일치한다. 반면, 대면서비스·돌봄·요식·미용·농림어업 등은 기술적 노출이 일부 존재하더라도 경제성 기준에서 대규모 자동화가 일어나기 어렵다는 점에서, 앞으로도 인간 노동의 비중이 유지될 가능성이 크다.

나. 산업별 AI 자동화의 경제성⁶⁴

산업별 분석에서는 직업-산업 매트릭스를 이용하여 각 산업 내에서 경제성이 있는 과업이 전체 고용인원 가운데 어느 정도 비중을 차지하는지를 측정하였다. AI 기술 단순노출 기준 산업 경제성 비중은 산업 q 내 모든 고용인원수 대비 경제성 있는 고용인원의 과업 비중의 합으로 정의된다.

$$\frac{\sum_l \sum_i \sum_j \omega_{ij} \cdot n_{li} \cdot 1(n_{li} \geq n_{ij}^*)}{\sum_l \sum_i n_{li}} = Eco(ex)_q$$

향후(대략 10년) AI 기술이 발전하여 모달리티가 정의된 과업이 모두 자동화 가능하다고 가정한 것이다.

또한 AI 자동화 가능성을 반영한 산업 경제성 비중은 산업 q 내 모든 고용인원수 대비 경제성에 자동화 가능성(실질적인 AI 구현 가능성)을 고려한 고용인원의 과업 비중의 합으로 정의된다.

⁶⁴ 고용노동부의 사업체노동력조사에서는 농업, 임업, 어업, 공공행정·국방 및 사회보장 행정 업종은 제외되어있다.

$$\frac{\sum_l \sum_i \sum_j \omega_{ij} \cdot n_{li} \cdot 1(n_{li} \geq n_{ij}^*) \cdot AI score_{ij}}{\sum_l \sum_i n_{li}} = Eco(sc)_q$$

산업별 AI 자동화의 경제성 상위 산업을 보면, AI 기술 단순노출 기준으로는 보험 및 연금업, 항공 운송업, 광업지원 서비스업, 금융 및 보험관련 서비스업, 연구개발업, 정보서비스업, 코크스·연탄 및 석유정제품 제조업, 우편 및 통신업, 담배 제조업, 방송업 등이 상위권을 차지하며, 해당 산업 고용의 20~40% 안팎이 경제성이 있는 과업인 것으로 나타난다. 이들 산업은 (1) 정보처리·모니터링·통제·보고 등의 디지털 과업 비중이 높고, (2) 대규모 데이터 축적과 시스템 기반 업무가 일반화되어 있으며, (3) 인건비 수준이 높아 AI 시스템 구축비용 대비 절감 효과가 크게 나타나기 쉬운 공통적 특성을 갖는다.

그러나 AI 자동화 가능성, 즉 실질적인 AI 구현 가능성을 반영하면 비

<표 3-16> AI 자동화의 경제성 상위 산업

AI 자동화 경제성 상위 순위	AI 기술 단순노출		AI 자동화 가능성 반영	
	산업	경제성 비중	산업	경제성 비중
1	보험 및 연금업	39.6%	항공 운송업	6.5%
2	항공 운송업	35.5%	보험 및 연금업	6.4%
3	광업 지원 서비스업	31.1%	담배 제조업	6.0%
4	금융 및 보험관련 서비스업	29.2%	코크스, 연탄 및 석유정제품 제조업	5.2%
5	연구개발업	28.9%	금융 및 보험관련 서비스업	4.9%
6	정보서비스업	25.7%	광업 지원 서비스업	4.5%
7	코크스, 연탄 및 석유정제품 제조업	24.6%	정보서비스업	4.4%
8	우편 및 통신업	22.8%	육상 운송 및 파이프라인 운송업	4.4%
9	담배 제조업	21.9%	사업 지원 서비스업	4.0%
10	방송업	21.2%	우편 및 통신업	3.8%

자료: 저자 작성.

중이 많이 축소된다. 항공 운송업, 보험 및 연금업, 담배 제조업, 코크스·연탄 및 석유정제품 제조업, 금융 및 보험관련 서비스업, 광업지원 서비스업, 정보서비스업, 육상 운송 및 파이프라인 운송업, 사업지원 서비스업, 우편 및 통신업 등이 상위권을 유지하지만, 각 산업 내 경제성 비중은 대략 4~7% 수준에 머문다. 이는 산업 내에서 AI에 노출된 과업이 상당한 비중을 차지하더라도, 실제로는 (i) 맥락·판단·책임성이 강조되는 과업, (ii) 복잡한 조직·규제 환경과 연결된 과업, (iii) 물리적 설비 운용과 안전이 결부된 과업 등이 여전히 인간 중심으로 남아 있을 가능성이 크다는 점을 반영한다.

반대로, 하위 산업을 보면 음식점 및 주점업, 비연료 비금속 광물 광업, 하수·폐기물·분뇨 처리업, 가구 제조업, 가죽·가방·신발 제조업, 목재 및 관련 제품 제조업, 펄프·종이 및 종이제품 제조업, 섬유제품 제조업 등 노동집약적 제조·서비스 업종에서 경제성 비중이 1% 미만 수준에 머무르는 것으로 나타난다. AI 자동화 가능성을 반영하면 이 값은 거의 0에 수렴하며, 일부 인쇄·기록매체 복제, 펄프·종이, 기타 운송장비 등에서만 0.2~0.3% 수준의 경제성 비중이 관측된다. 이들 산업은 저임금·단순·육체 노동 비중이 높고, 추가적인 AI 도입이 가져올 한계비용 절감 효과가 제한적이라는 점에서, Svanberg *et al.*(2024)에서 보여준 제조업에서의 추가적인 AI 투자 대비 수익률이 생각보다 높지 않을 수 있다는 분석과도 상통한다.

다. 기존 연구와의 비교 및 함의

이상의 직업·산업별 경제성 분석 결과는 여러 문헌과 비교했을 때 몇 가지 공통점과 차별성을 동시에 보여준다. 첫째, AI 노출·경제성의 고집중이라는 점에서는 Briggs *et al.*(2023), Chui *et al.*(2023) 등과 유사하다. 이들 연구 역시 AI에 의한 자동화 잠재력이 금융·전문서비스·ICT·R&D, 그리고 일부 고임금 사무·영업직에 집중되어 있음을 보여준다. 본 연구에서도 금융·보험 영업원, 정보보안 전문가, 연구원, 항공·통신

<표 3-17> AI 자동화의 경제성 하위 산업

AI 자동화 경제성 하위 순위	AI 기술 단순노출		AI 자동화 가능성 반영	
	산업	경제성 비중	산업	경제성 비중
1	음식점 및 주점업	0.3%	비금속광물 광업; 연료용 제외	0.0%
2	비금속광물 광업; 연료용 제외	0.3%	음식점 및 주점업	0.0%
3	하수, 폐수 및 분뇨 처리업	0.5%	가죽, 가방 및 신발 제조업	0.1%
4	가구 제조업	0.6%	하수, 폐수 및 분뇨 처리업	0.1%
5	가죽, 가방 및 신발 제조업	0.7%	목재 및 나무제품 제조업; 가구 제외	0.1%
6	목재 및 나무제품 제조업; 가구 제외	0.7%	가구 제조업	0.1%
7	펄프, 종이 및 종이제품 제조업	1.0%	기타 제품 제조업	0.2%
8	섬유제품 제조업; 의복 제외	1.0%	인쇄 및 기록매체 복제업	0.2%
9	인쇄 및 기록매체 복제업	1.1%	펄프, 종이 및 종이제품 제조업	0.2%
10	기타 제품 제조업	1.1%	섬유제품 제조업; 의복 제외	0.3%

자료: 저자 작성.

· 정보서비스업 등에서 경제성 비중이 상대적으로 높게 나타나, 지식집약 서비스 부문이 AI 도입의 선도 영역이 될 가능성을 시사한다.

둘째, 단순노출과 실질 경제성의 괴리를 명시적으로 측정했다는 점에서 Acemoglu(2024)와 문제의식이 통한다. Acemoglu(2024)는 기술적 가능성만을 근거로 자동화 효과를 과대평가하는 것을 비판하면서, 실제 도입에는 데이터·조직·규제·책임·판단구조 등 다양한 제약이 작동한다고 강조한다. 본 연구에서 AI 기술 단순노출 기준과 *AI score*를 반영한 경제성 기준 사이의 큰 격차, 특히 상위 직업군조차 경제성 비중이 5~15% 수준으로 축소되는 결과는 이러한 점을 양적 지표로 뒷받침한다고 판단

된다.

셋째, 보완·재배치 효과의 여지에 관한 함의도 분명하다. Aghion and Bunel(2024)과 OECD(2024)는 AI가 일부 과업을 자동화하는 동시에 다른 과업·직업을 신설하거나 고도화함으로써 장기성장과 TFP 개선에 기여할 수 있다고 본다. 본 연구의 결과는 단기적으로 경제성이 높은 과업·직업이 경제 전체에서 아직 제한적인 비중을 차지하고 있음을 보여주며, 이는 대규모 고용 축소보다는 특정 직업·산업 내에서의 과업의 구조조정과 직무 재설계가 중심이 될 가능성을 시사한다. 다시 말해, 금융·보험·정보서비스·운송·에너지 등 일부 산업에서 AI 도입과 함께 생산성 향상이 나타나는 한편, 돌봄·교육·요식·미용·농림어업 등 인간 중심 산업에서는 AI가 보조도구·의사결정 지원 시스템으로 기능하면서 노동의 질과 생산성을 높이는 방향의 보완효과가 더 중요해질 수 있다.

정리하면, 본 장의 경제성 분석 결과는 (i) AI 자동화의 경제성이 직업·산업 간에 매우 이질적으로 분포하며, (ii) 기술적 노출도에 비해 실제 경제성이 있는 과업 비중은 제한적이고, (iii) 그럼에도 특정 고임금·디지털 집약 부문에서 의미 있는 자동화가 진행될 수 있음을 보여준다. 이는 거시적으로 볼 때, 단기에는 부분적·선택적 자동화와 과업 재구성을 통해 점진적인 생산성 향상이 나타나고, 중장기에는 인적자본·제도·조직혁신과 결합될 경우 보다 큰 성장 효과가 구현될 수 있다는 가능성을 보여 준다.

제3절 AI 자동화의 거시경제적 의미

1. AI 자동화의 영향을 받는 경제규모

가. 산업별 AI 자동화의 영향을 받는 종사자 및 매출액 비중

앞 절에서 직업·과업 단위로 추정된 경제성이 있는 AI 자동화 과업

<표 3-18> AI 자동화의 영향을 받는 상위 산업별 종사자 규모

AI 영향 종사자 상위 순위	AI 기술 단순노출		AI 자동화 가능성 반영	
	산업	종사자 수	산업	종사자 수
1	교육 서비스업	223,850	육상운송 및 파이프라인 운송업	45,889
2	육상운송 및 파이프라인 운송업	161,051	사업지원 서비스업	35,993
3	사업지원 서비스업	140,888	사회복지 서비스업	20,203
4	전문 서비스업	110,122	보건업	20,158
5	보건업	97,327	교육 서비스업	17,550
6	연구개발업	89,799	전문 서비스업	15,882
7	출판업	82,532	보험 및 연금업	13,140
8	보험 및 연금업	81,066	출판업	13,090
9	사회복지 서비스업	80,585	소매업; 자동차 제외	11,777
10	건축기술, 엔지니어링 및 기타 과학기술 서비스업	77,169	전자부품, 컴퓨터, 영상, 음향 및 통신장비 제조업	11,656
전 산업 합계		2,060,900 (8.1%)		363,904 (1.4%)

자료: 저자 작성.

비중을 산업 단위로 집계한 결과, 한국경제에서 AI 자동화가 영향력을 행사할 수 있는 잠재 규모를 종사자 수와 매출액 기준으로 파악할 수 있다. 국가데이터처 「전국사업체조사」(2023년)를 활용하여 산업별 종사자와 매출을 결합한 결과,⁶⁵ AI 기술에 단순노출된 과업 중 경제성이 있는 과업에 종사하는 인력은 전체 종사자의 약 8.1%, 약 206만명으로 추정된다. 반면, 본 연구에서 추정한 AI 자동화 가능성을 반영하여 실효적으로 자동화될 가능성이 있는 과업만을 고려하면, 영향을 받는 종사자는 전체의

65 https://kosis.kr/statHtml/statHtml.do?orgId=101&tblId=DT_1K52D08&conn_path=I3(최종접속일: 2025. 10. 15).

<표 3-19> AI 자동화의 영향을 받는 상위 산업별 매출액 비중

AI 영향 매출액 상위 순위	AI 기술 단순노출		AI 자동화 가능성 반영	
	산업	매출액 비중	산업	매출액 비중
1	보험 및 연금업	1.2%	보험 및 연금업	0.20%
2	금융업	1.1%	금융업	0.18%
3	금융 및 보험 관련 서비스업	0.8%	금융 및 보험 관련 서비스업	0.14%
4	전자부품, 컴퓨터, 영상, 음향 및 통신장비 제조업	0.7%	전자부품, 컴퓨터, 영상, 음향 및 통신장비 제조업	0.11%
5	도매 및 상품 중개업	0.6%	코크스, 연탄 및 석유정제품 제조업	0.11%
6	코크스, 연탄 및 석유정제품 제조업	0.5%	전기, 가스, 증기 및 공기조절 공급업	0.09%
7	연구개발업	0.5%	도매 및 상품 중개업	0.08%
8	전기, 가스, 증기 및 공기조절 공급업	0.4%	자동차 및 트레일러 제조업	0.07%
9	자동차 및 트레일러 제조업	0.4%	창고 및 운송관련 서비스업	0.06%
10	전문 서비스업	0.3%	육상운송 및 파이프라인 운송업	0.06%
전 산업 합계		10.5% (916조원)		1.8% (159조원)

자료: 저자 작성.

약 1.4%, 약 36만명 수준으로 크게 줄어든다. 매출액 기준으로는, AI 단순노출·경제성 기준으로 전 산업 매출의 10.5%(약 916조원), AI 자동화 가능성을 반영하면 1.8%(약 159조원) 정도의 매출이 경제적으로 AI 자동화의 영향을 받을 것으로 추정된다.⁶⁶

산업별 상위 순위를 살펴보면, 종사자 수 기준으로는 AI 기술 단순노출·경제성을 기준으로 교육 서비스업(약 22만명), 육상운송 및 파이프라인 운송업(약 16만명), 사업지원 서비스업(약 14만명), 전문 서비스업, 보건업, 연구개발업, 출판업, 보험 및 연금업, 사회복지 서비스업, 건축기술

⁶⁶ 2023년 전 산업 매출액 규모는 약 8,696조원이다.

· 엔지니어링 및 기타 과학기술 서비스업 등이 상위 10개 산업을 구성한다. *AI score*를 반영했을 때는 육상운송 및 파이프라인 운송업, 사업지원 서비스업, 사회복지 서비스업, 보건업, 교육 서비스업, 전문 서비스업, 보험 및 연금업, 출판업, 소매업, 전자부품·컴퓨터·통신장비 제조업 등이 상위에 위치한다.

이 결과는 몇 가지 특징을 보여준다. 우선, 교육·보건·사회복지와 같은 공공·사회 서비스산업이 종사자 기준 상위권에 반복적으로 등장한다. 이들 산업은 개별 과업의 AI 자동화 가능성은 제한적일 수 있으나, 전체 고용규모가 크기 때문에 영향을 받는 인원수 측면에서는 거시경제적으로 중요한 비중을 차지한다. 특히 교육 서비스업은 AI 단순노출 기준 종사자 수에서 1위, AI 자동화 가능성 기준에서도 5위를 기록하여, 향후 교육 현장에서 AI 보조도구의 확산이 노동수요·직무구조에 적지 않은 변화를 가져올 수 있음을 시사한다.

둘째, 금융·보험·연구개발·전문 서비스·정보통신 제조업 등 고부가가치 산업은 매출액 기준에서 특히 높은 비중을 차지한다. AI 단순노출 기준으로는 보험 및 연금업(1.2%), 금융업(1.1%), 금융 및 보험관련 서비스업(0.8%), 전자부품·컴퓨터·통신장비 제조업(0.7%), 도매 및 상품 중개업, 코크스·연탄 및 석유정제품 제조업, 연구개발업, 전기·가스·증기·공기조절 공급업, 자동차·트레일러 제조업, 전문 서비스업 등이 상위 10위를 구성하며, AI 자동화 가능성을 반영한 경우에도 보험 및 연금업, 금융업, 금융 및 보험관련 서비스업, 전자부품·컴퓨터·통신장비 제조업, 코크스·연탄 및 석유정제품 제조업, 전기·가스 공급업, 도매 및 상품 중개업, 운송관련 제조업 및 서비스업 등이 상위에 위치한다.

요약하면, 고용 측면에서는 교육·보건·사회복지·운송·사업지원 서비스 등 대규모 서비스산업, 매출 측면에서는 금융·보험·에너지·정유·전자·도매 등 고부가가치 산업이 AI 자동화의 경제적 영향을 상대적으로 크게 받을 것으로 예상된다. 그러나 AI 자동화 가능성을 고려하면 전체 종사자의 1.4%, 매출의 1.8% 수준으로 축소된다는 점에서, 단기적으로는 경제성이 있는 AI 자동화의 거시경제적 파급효과가 일부 산업·

과업에 국한된다는 보수적인 그림이 그려진다.

나. 직업별 AI 자동화의 영향을 받는 근로자 및 임금 규모

직업 단위에서는 2024년 고용노동부 「고용형태별근로실태조사」의 표준직업분류에 따른 근로자 수와 임금자료를 활용하여, AI 자동화가 영향을 미치는 근로자 수와 임금 비중을 추정하였다.⁶⁷ AI 기술 단순노출·경제성 기준으로는, 전체 임금근로자 가운데 약 11.7%(약 142만명)가 경제성이 있는 AI 자동화 과업에 종사하고 있는 것으로 추정된다. AI 자동화 가능성을 반영하면 이 비중은 약 2.2%(약 26만명) 수준으로 줄어든다. 임금 기준으로 보면, 단순노출·경제성 기준으로 전체 임금의 12.9%, AI 자동화 가능성을 반영하면 2.2% 정도의 임금이 실질적으로 AI 자동화의 영향권에 있는 것으로 나타난다.

직업군별 상위 순위를 보면, AI 단순노출·경제성 기준으로는 경영 관련 사무원(31만명), 영업 종사자(14만명), 돌봄 및 보건 서비스 종사자(8.5만명), 컴퓨터 시스템 및 소프트웨어 전문가(7만명), 전기·전자공학 기술자 및 시험원, 건축·토목 공학 기술자, 간호사, 기계·로봇공학 기술자, 고객 상담 및 기타 사무원, 대학교수 및 강사 등이 상위 10개 직업군을 차지한다. *AI score*를 반영하면, 경영 관련 사무원(5.5만명), 돌봄 및 보건 서비스 종사자(2.5만명), 영업 종사자(2만명), 고객 상담 및 기타 사무원(1.6만명), 간호사(1.4만명), 자동차 운전원, 컴퓨터 시스템 및 소프트웨어 전문가, 전기·전자공학 기술자, 비서 및 사무 보조원, 건축·토목 공학 기술자 순으로 상위 직업군이 구성된다.

임금 비중 상위 직업군도 유사한 구성을 보인다. AI 단순노출·경제성 기준으로는 경영 관련 사무원(3.0%), 영업 종사자(1.3%), 전기·전자공학 기술자 및 시험원(0.9%), 컴퓨터 시스템 및 소프트웨어 전문가(0.7%), 기계·로봇공학 기술자 및 시험원, 건축·토목 공학 기술자 및 시험원, 간

67 https://kosis.kr/statHtml/statHtml.do?orgId=118&tblId=DT_118N_PAYM41&conn_path=I3(최종집속일: 2025. 10. 15).

<표 3-20> AI 자동화의 영향을 받는 상위 직업별 근로자 규모

AI 영향 직업군 상위 순위	AI 기술 단순노출		AI 자동화 가능성 반영	
	직업군	근로자 수	직업군	근로자 수
1	경영 관련 사무원	310,730	경영 관련 사무원	54,619
2	영업 종사자	141,812	돌봄 및 보건 서비스 종사자	24,589
3	돌봄 및 보건 서비스 종사자	84,560	영업 종사자	19,688
4	컴퓨터 시스템 및 소프트웨어 전문가	69,947	고객 상담 및 기타 사무원	16,135
5	전기·전자공학 기술자 및 시험원	65,674	간호사	14,440
6	건축·토목 공학 기술자 및 시험원	57,397	자동차 운전원	10,953
7	간호사	53,574	컴퓨터 시스템 및 소프트웨어 전문가	10,563
8	기계·로봇공학 기술자 및 시험원	46,630	전기·전자공학 기술자 및 시험원	9,541
9	고객 상담 및 기타 사무원	44,735	비서 및 사무 보조원	8,364
10	대학교수 및 강사	40,798	건축·토목 공학 기술자 및 시험원	6,261
전직업 합계		1,423,361 (11.7%)		264,139 (2.2%)

자료: 저자 작성.

호사, 대학교수 및 강사, 돌봄 및 보건 서비스 종사자, 금융 및 보험 전문가 등이 상위 10개 직업군을 형성한다. AI 자동화 가능성을 반영하면, 경영 관련 사무원(0.5%), 영업 종사자(0.2%)를 중심으로, 전기·전자공학 기술자, 간호사, 컴퓨터 시스템 및 소프트웨어 전문가, 고객 상담 및 기타 사무원, 돌봄 및 보건 서비스 종사자, 자동차 운전원, 건축·토목 공학 기술자, 주조 및 금속가공 관련 기계 조작원 등이 각 0.1% 수준의 임금 비

<표 3-21> AI 자동화의 영향을 받는 상위 직업별 임금 비중

AI 영향 직업군 상위 순위	AI 기술 단순노출		AI 자동화 가능성 반영	
	직업군	임금 비중	직업군	임금 비중
1	경영 관련 사무원	3.0%	경영 관련 사무원	0.5%
2	영업 종사자	1.3%	영업 종사자	0.2%
3	전기·전자공학 기술자 및 시험원	0.9%	전기·전자공학 기술자 및 시험원	0.1%
4	컴퓨터 시스템 및 소프트웨어 전문가	0.7%	간호사	0.1%
5	기계·로봇공학 기술자 및 시험원	0.5%	컴퓨터 시스템 및 소프트웨어 전문가	0.1%
6	건축·토목 공학 기술자 및 시험원	0.5%	고객 상담 및 기타 사무원	0.1%
7	간호사	0.5%	돌봄 및 보건 서비스 종사자	0.1%
8	대학교수 및 강사	0.3%	자동차 운전원	0.1%
9	돌봄 및 보건 서비스 종사자	0.3%	건축·토목 공학 기술자 및 시험원	0.1%
10	금융 및 보험 전문가	0.2%	주조 및 금속가공 관련 기계 조작원	0.1%
전직업 합계		12.9%		2.2%

자료: 저자 작성.

중을 차지한다.

이 결과는 다음과 같은 시사점을 준다. 첫째, AI 자동화의 경제적 영향은 고임금, 중·고숙련 사무·기술·전문직에 상대적으로 집중되어 있다. 영향 받는 근로자 비중(2.2%)에 비해 임금 비중(2.2%)이 비슷하거나 다소 높은 것은, AI 자동화가 특히 임금수준이 높은 직업군에서 먼저 경제성을 갖추고 있다는 뜻이다. 이는 Goldman Sachs(Briggs *et al.*, 2023)가 사무·전문·관리직에서 AI에 의한 노동비용 절감과 생산성 향상이 크게 나타날 것이라고 전망한 것과 동일한 방향성이다.

둘째, 돌봄·보건 서비스 종사자와 간호사 등 고도의 대인서비스 및 전문성을 요구하는 직업군도 상위권에 등장한다는 점이 특징적이다. 이들 직업군의 과업 중 상당 부분은 환자·이용자 기록 정리, 일정·투약

관리, 기초적인 모니터링과 보고 등 정보처리 중심 과업으로, AI에 의한 부분 자동화·보조의 여지가 크다. 그러나 동시에 직접돌봄·상담·위기 대응·윤리적 판단 등 AI 대체가 어려운 과업도 함께 포함되어 있어, 전체 직무가 전면 자동화되기보다는 (업무 일부의 자동화+ 전반적 업무 재구성) 형태로 전개될 가능성이 크다. 이는 Aghion and Bunel(2024)이 주장하는, AI에 기술적으로 노출된 과업과, 경제적으로 자동화되기보다는 보완적 활용이 이루어지는 과업을 구분해야 한다는 논지와도 일치한다.

2. 기존 문헌과의 비교 및 경제학적 의의

본 연구는 AI 기술 단순노출(모달리티 기준)과 AI 자동화 가능성(실질적 AI 구현 가능성)을 비용 비교를 통한 경제성 분석과 결합하여, 한국경제에서 단기적으로 경제성이 있는 AI 자동화가 영향을 미칠 수 있는 고용·임금·매출 비중을 하향식으로 추정하였다. 그 결과, (i) 산업 기준으로는 종사자 1.4%, 매출 1.8%, (ii) 직업 기준으로는 근로자 2.2%, 임금 2.2% 수준의 경제가 실질적인 AI 자동화의 영향권에 있는 것으로 나타났다.

이를 다른 기존 연구의 추정치와 비교하면 다음과 같은 특징을 확인할 수 있다. 우선, 수준 측면에서 본 연구의 추정치는 보수적 하단(lower bound)에 가까운 추정이라고 볼 수 있다. 이는 Acemoglu(2024)의 보수적인 시나리오에 보다 가까운 추정치로, 기술적 노출도나 잠재 가치(Chui *et al.*, 2023; Briggs *et al.*, 2023 등)가 가리키는 장기 기대효과와는 상당한 거리가 있음을 보여준다. 다만, Svanberg *et al.*(2024)은 CV 과업에 한정하고, 개별 기업 단위의 최소규모, 높은 정확도, 데이터 비용을 보수적으로 반영한 결과, 미국 비농업 보수의 0.4%만이 현재 비용구조에서 경제성이 있는 것으로 추정한다. 반면, 본 연구는 멀티모달·LLM 기반 과업 전체를 대상으로, 직업군 단위의 플랫폼화 시나리오와 기술발전에 따른 비교적 낮은 데이터·계산(학습)비용을 가정하여, 한국경제 전체 임금의 약 2.2%가 경제성이 있는 AI 자동화의 영향권에 있는 것으로 분석하

였다.

방법론 측면에서는 본 연구는 (i) AI 자동화 5대 지표(M, D, C, J, A)에 기반한 $AI\ score$, (ii) 과업별 AI 시스템 구축·운영 비용(C_j^M)과 1인당 인건비(C_{ij}^H)의 비교라는 두 단계의 필터를 적용하였다. 그 결과, AI 기술적 노출 기준으로는 상당한 규모의 고용·매출·임금이 AI에 노출되어 있지만, 실제 경제적으로 자동화가 선택될 과업·직업·산업은 훨씬 제한적임을 확인하였다. 이는 기술적 가능성만을 근거로 자동화 효과를 과대평가하는 오류를 피하려는 시도로 이해할 수 있으며, Acemoglu(2024)가 설명하는 쉬운 과업 對 어려운 과업(easy-to-learn vs hard-to-learn tasks), 맥락·결과측정의 제약, 데이터·조직·규제·판단의 병목을 정량화하기 위한 좀 더 세밀한 접근방법으로 해석할 수 있다.

거시경제적 영향 측면에서 직업·산업별 분포를 보면, AI 자동화 경제성은 경영 관련 사무원, IT·공학기술자, 영업·고객상담, 돌봄·보건 서비스, 간호사와 같은 중·고속런 서비스·전문직과, 금융·보험·정보통신·연구개발·에너지·정유와 같은 고부가가치 서비스·제조업에 집중되어 있다. 이는 Chui *et al.*(2023)이 생성형 AI의 경제적 가치가 주로 고객 운영, 마케팅·세일즈, 소프트웨어 엔지니어링, 제품·R&D에 집중된다고 분석한 결과와, Briggs *et al.*(2023)이 사무·법률·건축·엔지니어링·비즈니스 서비스에서 큰 노동시간 대체 가능성을 제시한 것과 유사하다. 따라서 한국에서도, AI 자동화의 1차적인 거시경제적 파급효과는 저임금 단순노무의 대규모 대체가 아니라, 중·고속런 사무·전문 서비스의 업무구조 재편과 생산성 향상을 통해 나타날 가능성이 크다는 점이 확인된다.

3. 정책적 시사점

위의 분석을 종합하면, 한국에서 AI 자동화의 거시경제적 의미는 다음 다섯 가지 축에서 이해할 수 있으며, 그에 상응하는 정책적 대응이 요구된다.

가. 단기적으로는 “선택적·부분적 자동화”에 초점

현재 추정으로는, 경제성이 있는 AI 자동화가 직접적으로 영향을 미치는 고용·임금·매출 비중이 2% 수준에 머문다. 이는 대규모 고용 충격 보다는, 특정 산업·직업에서의 부분적 자동화와 과업 재구성이 핵심 이슈가 될 것임을 시사한다. 교육·보건·사회복지·운송·경영사무·IT·영업·고객상담 등, 상위 표에 등장하는 직업·산업군을 중심으로 직무 재설계, 재교육·전환교육(reskilling) 프로그램, 작업조직·성과평가 시스템의 개선을 선제적으로 설계할 필요가 있다. 이는 OECD(2024)가 강조하는 AI 도입의 생산성 효과를 극대화하기 위해서는 인적자본·조직·규제의 보완적 투자(complementary investments)가 필수라는 메시지와도 일치한다.

나. 중장기적으로는 “보완적 AI 활용”과 “새로운 과업 창출” 유도

본 연구의 결과는, 많은 과업이 기술적으로 AI에 노출되어 있음에도 불구하고 경제성이 있는 완전 자동화는 제한적이라는 점을 보여준다. 이는 곧 정책적으로 노동대체형 AI보다는 노동보완형·전문가 시스템형 AI를 확산시키는 방향이 장기성장과 고용안정을 동시에 달성하는 데 유리하다는 의미이기도 하다. Aghion and Bunel(2024)은 적절한 정책이 뒷받침될 경우, AI가 성장과 고용을 동시에 늘릴 수 있다고 주장하는데, 이를 위해서는 (i) 의료·교육·돌봄·공공서비스 등에서 AI를 활용한 서비스 질 개선, (ii) 중소기업·지방기업에 대한 AI 도입 지원과 데이터·클라우드 인프라 보급, (iii) 신산업·신직업 창출을 촉진하는 규제 샌드박스·혁신 친화적 규제체계가 필요하다.

다. 분배·불평등·사회적 대화에 대한 선제 대응

경제성이 있는 AI 자동화가 주로 고임금, 중·고숙련 사무·전문직에

집중된다는 점은, 단순히 저임금 노동의 대체 문제가 아니라 중산층·전문직 내부의 직무·임금 구조 재편 문제가 핵심이 될 수 있음을 의미한다. Briggs *et al.*(2023)과 Chui *et al.*(2023) 역시 AI가 백오피스·전문서비스·관리직의 업무구조를 크게 변화시킬 것으로 전망한다. 이에 따라 직업별 상위 리스트에 반복적으로 등장하는 경영 관련 사무원, IT·공학기술자, 영업·고객상담, 돌봄·보건 서비스, 간호사 등을 중심으로, 선제적으로 노사정 차원의 직무전환·재교육, 임금구조 조정, AI 활용 가이드라인(업무 범위, 책임·책무 분담, 데이터 보호·윤리 기준)에 대한 사회적 대화가 필요하다.

라. 데이터·조직·규제 인프라에 대한 전략적 투자

본 연구에서 경제성이 낮게 추정된 많은 과업·산업은, 실제로는 해당 산업의 규모의 경제 부족으로 기업규모 제한, 데이터 부족, 결과측정의 어려움, 책임·규제의 불확실성 때문에 AI 도입이 제약되고 있을 가능성이 크다. OECD(2024)는 법적 책임과 규제의 불확실성이 생산적인 AI 도입을 가로막는 주요 요인 중 하나라고 지적한다. 따라서 공공부문과 전략산업을 중심으로 표준화된 데이터 인프라·공공 데이터셋 구축, AI 도입에 따른 책임 분담, 민형사 책임·보험·감독 체계를 명확히 하는 법·제도 정비, 기업 내부의 데이터 거버넌스 및 머신러닝운영·AI 리스크 관리체계 구축을 지원하는 정책이 병행되어야 한다.

마. 거시적 관점에서의 기대 관리

끝으로, 본 연구가 제시하는 GDP 2~3%(임금 비중 기준) 수준의 경제성이 있는 AI 자동화의 영향 비중은 AI에 대한 과도한 낙관이나 비관을 경계해야 한다는 점을 시사한다. 단기적으로는 일부 산업·직업에서 의미 있는 생산성 향상과 과업 재구성이 나타나겠지만, Acemoglu(2024)가 강조하듯이 어려운(hard-to-learn) 과업과 제도·조직적 제약을 감안하면,

거시적 생산성·성장 효과는 점진적·부분적으로 실현될 가능성이 크다. 동시에, Aghion and Bunel(2024)과 OECD(2024)가 제시하는 바와 같이, 적절한 보완투자와 제도설계가 뒷받침될 경우, 이러한 초기 효과가 장기적인 생산성 도약으로 이어질 수 있는 잠재력도 존재한다. 한국의 정책 선택은 바로 이 보수적 현재와 잠재적 미래 사이의 경로를 어떻게 설계 하느냐에 달려 있다고 볼 수 있다.

제4장

AI가 기업생산성에 미치는 영향

본 장에서는 기업수준에서 AI 활용이 생산성에 미치는 영향을 실증적으로 추정한다. 기존 문헌은 생성형 AI를 포함한 디지털 기술이 생산 과정에 미치는 영향을 주로 과업(task) 단위의 시간 단축, 오류 감소, 산출물 품질 개선과 같은 미시적 지표로 측정해 왔다. 예컨대 글쓰기·요약·분석·코딩 등 지식노동 과업에서 AI 보조도구를 제공할 때 처리시간이 줄고 성과가 개선되는 결과가 반복적으로 보고되며(Noy and Zhang, 2023; Peng *et al.*, 2023; Dell'Acqua *et al.*, 2023; Haslberger *et al.*, 2025), 이러한 미시적 효율성 증가는 기업 입장에서는 인건비 절감 또는 동일 인력으로 더 많은 산출을 생산하는 형태로 나타날 수 있다. 아울러 금융·산업 전반의 디지털 전환과 연계된 생산성 파급을 논의하는 연구(Gambacorta *et al.*, 2024) 및 기업 현장에서의 AI 활용이 업무 프로세스, 조직역량을 통해 성과로 전이되는 메커니즘을 다룬 연구(Brynjolfsson *et al.*, 2023)는 과업 효율성에서 기업성과로의 연결이 단순한 자동화 효과만이 아니라 보완적 투자와 학습, 확산의 결과임을 시사한다.

본 연구는 이러한 문헌의 통찰을 차용하되, 분석 단위를 과업이 아닌 기업으로 옮겨 국내 기업 패널자료를 활용한다는 점에서 차별성이 있다. 구체적으로 국가데이터처의 기업활동조사 설문을 기반으로 기업별 AI 활용 여부 및 관련 특성을 구축하고, 앞선 장에서 산출한 산업별 AI 자동화

경제성 지표를 결합하여, 기업이 처한 외생적 ‘AI 활용강도’ 충격을 활용한다. 이를 통해 AI 도입이 기업의 1인당 매출액 및 고용규모에 미치는 영향을 고정효과 패널 도구변수(IV) 모형과 성향점수매칭(Propensity Score Matching: PSM) 분석 등 준실험적 식별 전략으로 추정한다. 특히 AI 도입은 기업의 내생적 의사결정에 따라 시점과 강도가 상이하므로, 도입 전후의 비교에서 발생할 수 있는 선택편의와 동시적 충격을 통제하는 것이 핵심이며, 본 장은 이를 위한 표본 구성과 식별 가정, 강건성 점검을 체계적으로 제시한다.

$$\begin{aligned} \text{향후 10년 AI에 의한 TFP 증가율} &= \text{AI에 노출된 GDP 비중} \\ &\times \text{AI의 경제적 수익성이 있는 과업 비중} \\ &\times \{\text{AI로 인한 생산성 향상}\}_{\text{제4장}} \\ &\times \text{AI에 노출된 노동소득분배율} \end{aligned}$$

마지막으로 제4장의 추정 결과는 단순한 기업성과 분석에 그치지 않고, 이후에 수행할 향후 10년간 AI에 의한 TFP 증가율 계산을 위한 핵심 모수(생산성 증대 효과)로 활용된다. 즉, 미시 실증에서 확인한 기업수준 생산성 효과를 거시모형의 입력값으로 연결함으로써, AI 확산이 경제 전체의 성장·생산성에 미치는 정량적 함의를 도출하는 기반을 마련한다.

제1절 AI 활용 현황

1. 기업활동조사에 따른 AI 활용률

국가데이터처의 「기업활동조사」는 상용근로자 50인 이상이면서 자본금 50억원 이상인 기업을 모집단으로 하는 전수조사로, 2024년 조사 기준 총 14,922개 기업을 대상으로 이루어졌다. 이러한 표본설계의 특성상 중소·영세 기업보다는 일정 규모 이상의 중대형 기업에 초점이 맞추어져 있으며, 고정 표본을 상당 부분 유지하는 패널 구조이기 때문에 2017년

<표 4-1> AI 활용률(부문별)

(단위: %)

연도	제품(서비스) 개발	생산공정	판매목적	마케팅 전략	조직관리	AI 활용 전체
2017	1.1	0.1	0.0	0.2	0.0	1.4
2018	1.8	0.3	0.3	0.3	0.1	2.7
2019	1.9	0.3	0.4	0.3	0.2	3.1
2020	2.2	0.4	0.3	0.4	0.2	3.4
2021	2.5	0.5	0.4	0.3	0.1	3.8
2022	2.9	0.5	0.4	0.3	0.2	4.3
2023	3.7	0.8	0.6	0.5	0.5	6.1
생성형 AI 기여 (%p) (2023년과 2022년의 차이)	0.8	0.3	0.3	0.2	0.2	1.8

자료: 국가데이터처, 「기업활동조사」.

부터 2023년까지의 AI 활용 추이를 일관된 기준으로 파악할 수 있다는 장점이 있다.⁶⁸

기업활동조사 통계를 이용하여 2017~23년 기간 동안 AI 활용률의 변화를 살펴보면, 전체 AI 활용률은 2017년 1.4%에서 2023년 6.1%로 약 4.7%p 상승하였다. 세부 활용 부문은 제품(서비스) 개발, 생산공정, 판매목적, 마케팅 전략, 조직관리 등 다섯 개 영역으로 나뉘는데, 이 가운데 2017년 기준 가장 높은 활용률을 보이는 부문은 제품(서비스) 개발(1.1%)이며, 생산공정(0.1%), 판매목적(0.0%), 마케팅 전략(0.2%), 조직관리(0.0%)는 모두 1% 미만의 미미한 수준에 머물러 있다. 이는 초기에는 AI가 주로 R&D 및 신제품·서비스 기획을 지원하는 보조도로 활용되었음을 시사한다.

이후 2018~20년에 걸쳐 모든 부문에서 AI 활용률이 완만하게 상승하는데, 제품(서비스) 개발은 2018년 1.8%, 2019년 1.9%, 2020년 2.2%로 꾸준한 증가세를 보인다. 같은 기간 생산공정은 0.3~0.4% 수준, 판매목적과

⁶⁸ 기업활동조사에서 4차 산업혁명 기술 관련(AI 포함) 설문은 2017년부터 시작되었다.

마케팅 전략은 각각 0.3~0.4% 수준으로 소폭 증가하고, 조직관리 역시 0.1~0.2%로 점차 활용이 이루어지는 것으로 나타난다. 2021년에는 제품(서비스) 개발 2.5%, 생산공정 0.5%, 판매목적 0.4%, 마케팅 전략 0.3%, 조직관리 0.1%로, 전 부문에서 점진적인 확산이 이루어지지만 여전히 전체 AI 활용률은 3.8% 수준에 머물러 있어, 대다수 기업에서는 AI가 아직 본격적인 생산성 향상 도구라기보다는 일부 선도기업의 선택적 도입 단계에 있음을 의미한다.

주목할 점은 2022년에서 2023년으로 넘어가는 구간이다. <표 4-1>에 따르면 2023년 전체 AI 활용률은 6.1%에 이르며, 2022년 대비 증가분(생성형 AI 기여분)이 1.8%p로 제시된다. 부문별로는 제품(서비스) 개발 0.8%p, 생산공정 0.3%p, 판매목적 0.3%p, 마케팅 전략 0.2%p, 조직관리 0.2%p가 1년 사이에 증가한 것으로 나타난다. 이는 2022년 말 이후 본격적으로 확산된 생성형 AI 도구(대화형 LLM, 코드 생성, 문서 작성 지원 등)가 단순한 시범 도입을 넘어 실제 업무 프로세스 속으로 빠르게 녹아들면서, 특히 제품(서비스) 개발과 마케팅·판매 지원, 내부 문서·보고서 작성·정리 등의 백오피스 과업에 빠르게 활용되기 시작했음을 보여준다. 다만, 현재의 설문수준으로는 단순한 생성형 AI 계정구독인지 해당 기업의 과업에 특화된 AI 시스템 도입인지 명확하지는 않다.

이러한 흐름을 기업규모별로 나누어 보면, [그림 4-1]에서 제시된 바와 같이 종사자 250인 이상 대기업의 AI 활용률이 250인 미만 기업에 비해 현저히 높은 것으로 파악된다. 전체 활용률 기준으로 대기업이 중소·중견 기업에 비해 수배 수준의 활용률을 보이며, 제품(서비스) 개발과 마케팅, 조직관리 등 지식집약적·관리적 과업에서 격차가 특히 크게 나타난다. 이는 AI 도입에 필요한 데이터 인프라, 클라우드 및 GPU 자원, 전문 인력 확보 등 고정비 성격의 비용을 감당할 수 있는 기업일수록 기술 도입에 유리하다는 점을 시사한다. 제3장에서 분석한 바와 같이 AI 자동화의 경제성은 구축·학습 비용 대비 절감 가능한 노동비용, 그리고 과업의 플랫폼화 가능성 등에 의해 결정되는데, 규모의 경제를 확보할 수 있는 대기업일수록 이러한 경제성이 상대적으로 높게 나타날 가능성이 크다.


<표 4-2> 산업별 AI 활용률(2023년 기준)

(단위: %)

업종	제품(서비스) 개발	생산공정	판매 목적	마케팅 전략	조직 관리	AI 활용 전체
농업, 임업 및 어업	0.0	0.5	0.0	0.0	0.0	0.5
광업	0.0	0.0	0.0	0.0	0.0	0.0
제조업	1.2	0.6	0.2	0.1	0.1	2.2
전기, 가스, 증기 및 공기조절 공급업	2.7	5.0	0.0	0.0	2.5	10.2
수도, 하수 및 폐기물 처리, 원료 재생업	0.2	0.2	0.0	0.0	0.0	0.4
건설업	0.8	0.5	0.2	0.2	0.5	2.2
도매 및 소매업	1.1	0.1	0.4	0.5	0.1	2.3
운수 및 창고업	0.3	0.1	0.0	0.1	0.2	0.7
숙박 및 음식점업	0.3	0.1	0.1	0.4	0.0	0.9
정보통신업	13.0	0.3	1.9	0.6	0.4	16.2
금융 및 보험업	6.1	0.8	0.4	2.4	0.9	10.7
부동산	0.1	0.1	0.0	0.0	0.0	0.2
전문, 과학 및 기술 서비스업	3.0	0.3	0.2	0.3	0.2	4.0
사업시설 관리, 사업 지원 및 임대 서비스업	1.2	0.0	0.2	0.3	0.1	1.9
교육 서비스업	6.9	0.2	0.5	0.9	0.2	8.6
보건업 및 사회복지 서비스업	0.7	0.0	0.7	0.7	0.0	2.2
예술, 스포츠 및 여가관련 서비스업	0.0	0.0	0.0	0.0	0.1	0.2
협회 및 단체, 수리 및 기타 개인 서비스업	0.5	0.0	0.3	0.0	0.0	0.8

자료: 국가데이터처, 「기업활동조사」.

[그림 4-1] AI 활용률: 기업규모별(250인 미만·이상)



자료: 국가데이터처, 「기업활동조사」.

또 다른 특징은 AI와 기타 4차 산업혁명 기술의 동시·선후 도입 관계이다. 2017~23년 동안 4차 산업혁명 기술(IoT, 클라우드, 빅데이터, 모바일, 블록체인, 3D 프린팅, 로봇, AI, AR·VR 등)을 한 번이라도 활용한 기업은 누적 4,968개로 집계된다. 이 가운데 AI보다 다른 기술을 먼저 활용하기 시작한 기업은 518개이며, 4차 산업혁명 관련 기술을 활용하면서도 아직 AI를 도입하지 않은 기업은 3,449개, 반대로 AI 기술을 다른 기술과 동시에 또는 더 먼저 도입한 기업은 1,001개로 나타난다. 즉, 4차 산업혁명 기술 활용 기업 중 약 20% 정도만이 AI를 다른 기술과 동시에 혹은 선도적으로 도입하고 있으며, 나머지는 인프라 성격의 디지털 기술(예: 클라우드, 빅데이터 등)을 먼저 구축한 뒤 후행적으로 AI를 도입하거나, 아예 AI 도입을 미루고 있는 것으로 해석된다. 이는 제3장에서 도출한, AI 자동화의 경제성은 높지만 그 효과가 최대화되기 위해서는 클라우드·데이터 등 보완적 기술·자본에 대한 선행 투자와 결합되어야 한다는 분석과 일치한다.

마지막으로 산업별 AI 활용률을 살펴보면, 2023년 기준 제조업의 전체 AI 활용률은 2.2%로, 제품(서비스) 개발 1.2%, 생산공정 0.6% 등 실물 생산과 밀접한 영역에서 주로 활용이 이루어지고 있다. 반면, 전기·가스·증기 및 공기조절 공급업의 전체 활용률은 10.2%에 달하며, 제품(서비스)

개발과 생산공정뿐 아니라 조직관리에서의 활용 비중도 상대적으로 높다. 교육 서비스업 역시 제품(서비스) 개발 6.9%를 중심으로 전체 8.6%의 활용률을 보여, AI를 활용한 교육콘텐츠 개발, 학습관리 및 평가 지원 등이 이미 상당 부분 확산되고 있음을 시사한다. 농업·임업·어업, 광업, 일부 개인서비스업 등에서는 활용률이 1% 미만에 머무르는 등 산업 간 격차가 매우 큰 것으로 나타나며, 특히 정보통신업, 금융 및 보험업, 전기·가스·증기 및 공기조절 공급업, 교육 서비스업 등은 제3장에서 분석한 AI 자동화의 경제성 비중이 가장 높은 상위 산업과 일치한다는 점에서, 경제성이 높은 산업에서 실제 AI 활용률도 높다는 직관을 뒷받침한다.

요약하면, 기업활동조사에 기반한 AI 활용률 분석은, 첫째, 2017~21년에는 완만한 확산에 그쳤으나 2022~23년에 생성형 AI의 등장을 계기로 도입 속도가 뚜렷이 가속화되고 있으며, 둘째, 도입은 대기업, 디지털 집약 산업에 편중되어 있고, 셋째, AI는 아직 생산공정 자동화보다는 제품(서비스) 개발과 백오피스 업무 지원에 집중되어 있음을 보여준다. 이는 이후 패널분석에서 기업의 AI 활용 여부와 4차 산업혁명 기술 활용 여부를 함께 고려하여, AI 단독 효과와 다른 디지털 기술과의 상호작용 효과를 분리해 추정할 필요가 있음을 시사한다.

2. AI 활용 현황: 기업정보화통계조사

기업활동조사는 비교적 규모가 큰 기업을 대상으로 하는 전수조사라는 장점이 있으나, AI 활용의 세부 목적·유형·미활용 사유에 관한 정보는 제한적이다. 이러한 한계를 보완하기 위해, 본 소절에서는 과학기술정보통신부가 실시하는 「기업정보화통계조사」 결과를 활용하여 AI 활용의 목적과 방식, 미이용 이유 등을 보다 세분화하여 살펴본다. 이 조사는 전국의 종사자 수 10인 이상 민간부문의 모든 기업체(213,266개)를 모집단으로 하는 표본조사(약 12,500개)이다.⁶⁹

⁶⁹ 본 연구에서는 기업정보화통계조사를 이용한 기업정보화통계집(2024)을 재인용한다.

기업정보화통계조사에 따르면 2023년 기준 전체 AI 기술 및 서비스 활용률은 30.5%로, 기업활동조사에서 동일 연도에 관측되는 6.1%보다 상당히 높은 수준이다. 이는 첫째, 기업정보화통계조사가 종사자 10인 이상으로 모집단을 확대한 반면, AI 활용 여부에 대한 질문과 응답 방식이 보다 포괄적(예: 클라우드 기반 AI 기능 포함)이라는 점, 둘째, 정보화 관련 질문에 자발적으로 응답하는 기업들이 디지털 기술 친화적일 가능성이 높다는 점 등에 기인한 것으로 해석된다.

업종별로는 금융 및 보험업의 AI 기술 및 서비스 활용률이 52.4%로 가장 높고, 정보통신업이 49.5%, 교육 서비스업이 48.7%로 뒤를 잇는다. 이들 산업은 데이터 축적과 디지털 인프라 수준이 높고, 무형자산·소프트웨어 비중이 큰 대표적인 디지털 집약 산업으로, 제3장에서 도출한 AI 자동화 경제성 지표에서도 상위 그룹에 속하는 산업들이다. 반면, 일부 전통 제조업이나 개인서비스업, 농림수산업 등에서는 활용률이 상대적으로 낮은 것으로 나타나, 디지털 격차가 AI 활용 격차로 직결되고 있음을 보여준다. 기업규모 측면에서도 종사자 250인 이상 기업체의 AI 활용률은 63.3%로, 보다 작은 규모의 기업에 비해 현저히 높는데, 이는 앞 절에서 확인한 기업활동조사 결과와도 일치한다.

AI 기술 및 서비스의 구체적 이용 유형을 보면, “이미지 인식, 이미지 처리 등”이 69.7%로 가장 높은 비중을 차지하고, 그다음으로 “의사결정 지원”(48.8%), “문서작성 및 정보 수집”(34.0%), “업무자동화 지원”(25.5%) 순으로 나타난다. 이는 현재 기업들이 AI를 활용하는 대표적인 영역이 컴퓨터 비전, 의사결정 보조, 문서 요약·작성, 반복 업무 자동화 등이라는 점을 보여주며, 기존 연구에서 확인된 생성형 AI의 생산성 효과 분석과도 부합한다. 예를 들어 Noy and Zhang(2023)은 글쓰기 과업에서 LLM 도입 시 생산성이 평균 37% 향상되고 품질이 개선된다고 보고하고 있으며, Brynjolfsson *et al.*(2023) 역시 고객상담 업무에서 AI 도입으로 처리 건수와 고객 만족도가 유의하게 개선된다고 분석한다. 이러한 실증 결과는 우리나라 기업들이 문서·고객응대·의사결정 지원 영역에서 AI를 적극 활용하고 있다는 통계와 자연스럽게 연결된다.

AI 활용 목적에 대한 응답을 보면, “기업 보안”이 66.3%로 가장 높은 비중을 차지하며, 다음으로 “회계 및 재무관리”(28.9%), “마케팅 및 판매”(24.8%), “비즈니스 관리 프로세스 또는 관리 조직화”(23.7%) 순으로 나타난다. 특히 기업 보안 관련 응답률은 부동산업에서 86.5%, 전기 등 공기조절 공급업·수도 및 원료 재생업에서 86.3%, 건설업에서 81.8%로 매우 높은 수준을 보인다. 이는 사이버 공격, 랜섬웨어, 중요 인프라 보호 등 보안 이슈가 심각해지면서, AI가 공격 탐지, 이상 징후 감시, 위협 분석 등 보안 관련 과업에서 핵심 도구로 활용되고 있음을 보여준다. 회계·재무·마케팅·조직관리 영역에서도 AI가 계정 분류, 이상 거래 탐지, 타겟 마케팅, 수요 예측, 인력 배치 등 다양한 과업을 지원하고 있으며, 이는 제3장에서 구축한 과업수준의 AI 자동화 가능성 지표에서 정보수집·기록저장·정리가공·작성보고 등 디지털화된 사무·지식 과업의 자동화 가능성이 높게 평가된 결과와 일치하는 것이다.

AI 기술 및 서비스 이용 형태에 관한 통계를 보면, “상용 소프트웨어 또는 시스템 구매”가 69.4%로 가장 높은 비중을 차지하며, “외부 공급업체와 계약하여 이용”(21.8%), “상용 소프트웨어 또는 시스템을 자체적으로 수정하여 이용”(13.4%) 등이 뒤를 잇는다. 산업별로 보면 상용 소프트웨어 또는 시스템 구매방식은 건설업(83.1%), 수리 및 기타 개인 서비스업(82.1%)에서 특히 높게 나타나며, 외부 공급업체와의 계약을 통한 이용은 농림수산업(30.5%), 사업시설관리·사업지원 및 서비스업(26.6%)에서 상대적으로 높은 비중을 보인다. 이는 많은 기업들이 AI를 완전한 자체 개발보다는 SaaS(Software-as-a-Service) 혹은 외부 솔루션 형태로 도입하고 있음을 시사하며, 고성능 GPU·모형 학습 인프라를 직접 구축하는 방식보다는 클라우드 기반 API·플랫폼을 활용하는 것이 현실적인 선택임을 보여준다.

한편, AI 기술 및 서비스 미이용 이유로는 “인프라 및 인력 부재”가 30.5%로 가장 높은 비중을 차지하고, “경제적 비용 부담”(28.9%), “서비스(기술)의 복잡성”(22.9%)이 그 뒤를 잇는다. 산업별로 보면 경제적 비용 부담이 정보통신업(56.9%), 보건업 및 사회복지 서비스업(50.6%)에서

높게 나타나고, 인프라 및 인력 부재는 보건업 및 사회복지 서비스업(48.3%), 정보통신업(46.2%), 예술·스포츠 및 여가관련 서비스업(37.9%)에서 상대적으로 높은 비중을 보인다. 디지털 집약 산업인 정보통신업에서조차 AI 미이용의 주된 이유로 비용 부담과 인력·인프라 부족이 지목된다는 점은, AI 도입에 필요한 고정비 및 운영비가 여전히 상당한 진입 장벽으로 작용하고 있음을 의미한다. 제3장에서 검토한 Svanberg *et al.* (2024)과 OECD(2024)의 분석에서도, AI 시스템의 구축·학습·운영 비용이 특히 중소기업에는 상당한 부담이 되며, 이런 비용구조가 AI 확산 속도를 제약할 수 있다는 점이 반복적으로 지적된다.

정리하면, 기업정보화통계조사에 기반한 분석은, 첫째, AI 활용률이 기업활동조사보다 높은 수준으로 나타나지만 이는 조사설계와 질문방식의 차이에 상당 부분 기인하며, 둘째, 금융·정보통신·교육 등 디지털 집약 산업과 250인 이상 대기업에서 활용률이 가장 높고, 셋째, 현재 AI는 이미징 인식, 의사결정 지원, 문서작성, 보안 등 특정 과업 영역에서 집중적으로 활용되고 있으며, 넷째, 미이용 이유로 인프라·인력 부족과 비용 부담이 가장 중요하게 지적된다는 점을 보여준다. 이러한 특징은 이후 패널 분석에서 AI 도입 효과를 추정할 때, 산업·규모·디지털 인프라 수준에 따른 이질성을 체계적으로 통제해야 함을 시사한다.

3. AI 활용 현황의 정책적 함의

앞서 살펴본 바와 같이, 우리나라 기업의 AI 활용은 산업·규모·과업 유형에 따라 뚜렷한 이질성을 보인다. 정보통신업, 금융 및 보험업, 전기·가스·증기 및 공기조절 공급업, 교육 서비스업 등에서는 AI 자동화의 경제성이 높게 추정되었고(제3장), 실제 AI 활용률 역시 다른 산업에 비해 두드러지게 높은 반면, 전통 제조업, 개인서비스업, 보건·사회복지 등 일부 산업에서는 경제성 잠재력이 존재함에도 불구하고 도입률이 낮은 잠재력-활용 간 괴리가 관찰된다. 이러한 미스매치는 향후 AI 관련 정책설계에서 중요한 출발점이 된다.

더불어, 생성형 AI가 상용화되기 전부터 시작된 조사를 바탕으로 분석한다는 것을 감안하면 본 장에서 사용하는 AI 개념은 보다 포괄적으로 정의할 필요가 있다. 즉, 기업활동조사는 설문지에서 AI를 “인간의 학습 능력과 추론능력, 지각능력, 자연언어의 이해능력 등을 컴퓨터 프로그램으로 실현한 기술”로 정의하고 있으며, 이는 분류·예측 알고리즘, 규칙 기반 시스템, 기계학습 등을 모두 포함하는 비교적 넓은 개념이다. 물론 제2장과 제3장은 트랜스포머·생성형 AI 등 최근 기술을 중심으로 과업 자동화와 경제성을 논의하지만, 기본적으로 데이터를 활용하여 인지·추론·예측·생성 기능을 수행하는 범용 소프트웨어 기술이라는 점에서 기업활동조사의 정의와 본질적으로 상충하지 않는다. 다만, 실증분석에서 2023년 이전 시점에서는 기업들이 도입한 AI가 특정 과업에 특화된 알고리즘·모델에 가까울 수 있는 반면, 제2장·제3장에서 다루는 AI와 2023년에 도입한 AI 시스템은 보다 범용적인 에이전트형 AI까지 포함하는 것으로 해석하는 것이 타당하다. 이에 본 보고서의 정량적 결과는 당시 기업들이 실제로 도입하여 운영 중인 AI 시스템을 대상으로 한 분석이며, 생성형 AI, 멀티모달 에이전트 등 최신 기술과 그 이전의 기술까지 포함하여, 기술적 범위가 더 넓다는 점을 전제로 분석의 결과를 해석할 필요가 있다.

또한 기존 연구와 비교하면, 우리나라의 AI 활용수준은 대체로 OECD 주요국과 유사한 범위에 위치한 것으로 판단된다. OECD의 기업수준 AI 조사에 따르면, 2023년 기준 EU 회원국의 AI 활용 기업 비중은 전체 기업의 약 8% 수준이며, 정보통신업 등 디지털 집약 산업에서는 20~30% 수준으로 높게 나타난다(OECD, 2025). 우리나라 기업활동조사 기준 AI 활용률 6.1%는 이러한 국제 비교에서 중위권에 해당하며, 기업정보화통계조사 기준 30.5%라는 수치는 보다 포괄적인 정의를 사용한 결과로 볼 수 있다. 다만, OECD(2024)는 AI가 생산성에 미치는 효과가 일부 선도기업에 집중될 위험이 크며, 후발·저생산성 기업과의 격차를 심화시킬 수 있다는 점을 강조한다. 우리나라에서도 대기업, 디지털 집약 산업에 AI 도입이 집중되고 있다는 점에서, 유사한 생산성 격차 확대 문제가 나타

날 가능성이 크다.

우리나라 기업자료를 기반으로 한 본 연구의 분석은 기존 연구와 직접적으로 연결된다. 첫째, 제3장에서 구축한 AI 자동화의 경제성 지표는 정보통신업, 금융·보험업, 전기·가스·증기 및 공기조절 공급업, 교육 서비스업 등에서 높은 값을 보였고, 본 절에서 살펴본 실제 AI 활용률 역시 이들 산업에서 뚜렷이 높게 나타났다. 이는 기술적·경제적 잠재력이 높은 산업에서 실제 도입도 선도적으로 진행된다는 사실을 확인해 주며, 향후 거시생산성 효과도 이러한 산업을 중심으로 나타날 가능성이 크다는 점을 시사한다. 둘째, AI 활용의 주요 목적이 기업 보안, 회계·재무, 마케팅, 조직관리 등 백오피스 및 관리 기능에 집중되어 있다는 점은, Acemoglu(2024)가 지적한 것처럼 단기적으로는 업무 효율화, 시간 절감 중심의 그저 그런 자동화(so-so automation)에 머물 가능성이 있음을 의미한다. 이에 비해 Noy and Zhang(2023), Brynjolfsson *et al.*(2023), Peng *et al.*(2023), Dell'Acqua *et al.*(2023), Haslberger *et al.*(2025), Gambacorta *et al.*(2024)은 개별 기업·과업 수준에서 AI 도입이 노동시간 단축, 오류 감소, 고객응대 품질 개선 등을 통해 유의한 생산성 향상을 가져온다는 실증 결과를 제시하고 있다. 본 연구에서 기업수준의 패널자료를 이용해 AI 활용 여부를 내생적으로 취급하고, 산업별 AI 경제성 지표와 AI 도입 등을 도구변수(instrument variables: IV)로 활용하여 1인당 매출액 등에 대한 영향을 추정하는 것은, 이러한 기존 실증연구와 직접 비교 가능한 한국 사례를 제시한다는 점에서 의미가 있다.

따라서 정책적 함의는 다음과 같이 정리할 수 있다. 첫째, 현재 AI 미이용의 가장 큰 이유로 인프라·인력 부재와 비용 부담이 지적된다는 점을 고려할 때, 클라우드·GPU·데이터 인프라에 대한 접근비용을 낮추고, AI 활용역량을 갖춘 인력을 양성·공급하는 정책이 중요하다. 특히 보건·사회복지, 예술·스포츠·여가, 일부 서비스업 등에서 인프라·인력 부족이 두드러진 만큼, 이러한 산업을 대상으로 한 맞춤형 지원이 필요하다. 둘째, 4차 산업혁명 기술을 이미 활용하고 있으나 AI를 도입하지 않은 기업(3,449개)과, 다른 기술을 먼저 도입한 후 AI를 후행적으로 도

입한 기업(518개)은, 클라우드·빅데이터 등 디지털 인프라와 AI를 결합할 경우 잠재적 시너지 효과가 매우 클 수 있다. 따라서 클라우드·데이터·AI를 통합한 패키지형 지원, 산업별 AI 레퍼런스 모형⁷⁰ 보급 등을 통해 이들 기업의 도입 장벽을 낮추는 정책이 필요하다. 셋째, AI 도입 효과가 특정 산업·대기업에 집중될 경우 생산성·임금 격차가 확대될 수 있으므로, 중소기업과 후발 산업을 대상으로 한 공공 데이터, 오픈소스 모형, 공동 GPU 인프라 제공 등 공공 디지털 인프라 정책을 통해 격차를 완화할 필요가 있다. 넷째, 본 연구에서 추정할 1인당 매출액 기준 생산성 효과는 단기적인 매출·효율성 향상에 초점을 두고 있으므로, 향후 고용, 임금, 직무 재편, 노동시간 등 분배·고용 측면을 함께 분석하여, Acemoglu(2024)가 제기한 성장과 분배 사이의 긴장을 국내 데이터로 검증하는 후속연구가 요구된다.⁷¹

70 AI 레퍼런스 모델(AI Reference Model)은 인공지능 시스템을 설계, 구축 및 운영할 때 표준이 되는 프레임워크나 아키텍처 가이드라인을 의미한다(Google AI).

71 본 연구에서는 AI가 기업생산성에 미치는 영향을 추정함에 있어 1인당 부가가치 대신 1인당 매출액을 생산성 지표로 사용하는 것이 타당하다고 본다. 이론적으로 생산성은 부가가치 기준이 보다 순수한 개념으로 이해되지만, 기업수준 자료에서 부가가치는 매출에서 중간투입을 차감하는 과정에서 산업별·기업별 회계관행과 중간투입 항목 구성의 이질성 등으로 측정오차가 크게 발생할 소지가 있으며, 특히 서비스업·플랫폼 산업에서는 중간투입과 부가가치의 경계가 불분명한 경우가 많다. 이에 비해 1인당 매출액은 재무제표상의 매출과 상용근로자 수라는 비교적 안정적이고 일관된 항목에 기반하기 때문에, 종속변수 측정오차를 줄이고 패널·IV·PSM 분석의 계수 안정성을 높일 수 있다는 점에서 실증적으로 우월하다. 더욱이 기존 AI 생산성 연구를 보면, Noy and Zhang(2023), Peng *et al.*(2023) 등은 과업당 산출량·소요시간·품질 점수, Brynjolfsson *et al.*(2023), Gambacorta *et al.*(2024), Dell'Acqua *et al.*(2023) 등은 시간당 처리 건수, 코드 산출량, 과업 완료율과 같은 과업 단위 산출물을 종속변수로 사용하고 있어, 이들 지표는 본질적으로 해당 과업이 만들어내는 산출물(output)을 측정하는 것에 가깝지 부가가치까지 계산하는 것은 아니다. 이러한 과업수준 결과가 기업 전체로 집계될 때, AI의 직접 효과는 특정 과업집합에서 산출량이나 처리 속도를 높여 총매출을 증가시키거나 동일 매출을 더 적은 인력으로 달성하게 만드는 방식으로 나타나므로, 기업 단위에서는 1인당 매출액이 과업수준 연구와 가장 자연스럽게 연결되는 지표라 할 수 있다. 반대로 부가가치를 종속변수로 두면 AI가 중간투입 절감과 마진개선을 통해 원가구조를 개선하는 효과는 확대해서 포착할 수 있고, AI가 신제품·서비스 출시, 품질 개선에 따른 수요 확대, 맞춤형 가격·마케팅 전략을 통해 매출규모 자체를 확대시키는 채널은 과소평가되거나 부분적으로만 반영될 수 있다는 한계가 있다. 요컨대 1인당 매출액은 생산성, 수요, 품질, 가격 전략의 변화를 함께 포착하는 포괄적 성과지표로서, AI 도입이 특정 과업의 시간절감뿐 아니라 매출 확대와 시장구조 변화까지 동반하는 현실을 반영하기에 적합하며, 부가가치

결국, 우리나라 기업의 AI 활용 현황은 경제성이 높은 산업·대기업 중심의 점진적 확산이라는 점에서 국제적 추세와 유사하지만, 미이용 이 유와 산업별·규모별 격차를 고려할 때 정책개입 여지가 상당히 크다. 본 장의 후속 절에서는 이러한 활용 현황을 바탕으로, AI 도입이 실제로 1인당 매출액, 고용규모 및 총매출 등에 어떤 영향을 미쳤는지, 그리고 그 효과가 산업·기업의 활용 분야 등에 따라 어떻게 달라지는지를 패널분석 등을 통해 정량적으로 평가하고자 한다. 이는 AI 자동화의 기술적·경제적 가능성(제3장)과 실제 기업생산성 효과(제4장)를 연결함으로써, AI가 우리 경제의 성장·생산성·분배에 미치는 영향을 보다 거시적으로 이해하는 데 기여할 것으로 판단된다.

제2절 실증분석 방법론

1. 기업활동조사 자료를 이용한 패널분석

본 절에서는 앞선 절에서 살펴본 우리나라 기업의 AI 활용 현황을 토 대로, AI 도입이 기업생산성에 미치는 효과를 정량적으로 추정하기 위한 실증분석 방법론을 설명한다. 특히 국가데이터처의 기업활동조사 패널자료를 활용하여, AI 활용 여부가 상용근로자 1인당 매출액, 고용규모, 매출액 등에 어떤 영향을 미쳤는지를 고정효과 모형과 도구변수(IV)를 결합한 패널분석으로 추정한다. 이 과정에서, 기존의 과업 단위 생산성 연구들이 주로 실험자료나 국지적 패널자료를 이용하여 과업시간 절감 또는 단위 시간당 산출 증가를 식별한 것과 달리, 본 연구는 전수에 가까운 기업 단위 행정자료를 이용해 기업수준 노동생산성(1인당 매출액), 고용

기준만을 사용할 경우 이러한 다층적인 효과를 놓칠 위험이 존재하므로, 본 연구와 같이 기업 단위에서 AI 생산성을 추정할 때 1인당 매출액을 종속변수로 선택하는 것은 기존 문헌과 데이터 특성을 고려할 때 충분히 정당화될 수 있다고 판단된다. 더불어, 본 연구의 기초분석에서 이미 1인당 부가가치를 분석하였고, 정성적으로 분석 결과가 동일하였음을 밝힌다.

규모 조정 및 총매출이라는 보다 거시적인 결과변수에 초점을 둔다는 점에서 차별성을 갖는다.

본 연구의 종속변수는 생산성을 대표하는 로그(상용근로자 1인당 매출액), 고용수준을 나타내는 로그(상용근로자 수) 그리고 로그(매출액)이다. 기업활동조사에서 매출액과 상용근로자 수는 비교적 안정적으로 측정되는 핵심 재무·고용 지표이므로, 로그 변환을 통해 분포의 비대칭성을 완화하고, 계수의 해석을 백분율 차이로 단순화할 수 있다. 예를 들어 로그(상용근로자 1인당 매출액)를 종속변수로 두고 AI 활용 여부 더미의 계수를 추정하면, 해당 계수는 AI를 활용한 기업과 활용하지 않은 기업의 1인당 매출액 수준 차이(%)로 해석할 수 있다. 이는 Dell'Acqua *et al.* (2023), Noy and Zhang(2023), Brynjolfsson *et al.*(2023) 등이 보고한 시간당 처리량 증가나 과업당 소요시간 감소와 개념적으로 대응되지만, 개별 과업 단위가 아니라 기업 전체의 산출과 고용이 동시에 조정된 결과를 반영한다는 점에서 보다 장기적이고 포괄적인 생산성 지표라고 할 수 있다.

내생변수 벡터 Z_{it} 는 기업 i 가 t 기에 AI를 활용하고 있는지 여부를 나타내는 이진변수 AI_{it} 와 클라우드, 빅데이터, 로봇, IoT, 모바일, AI 기술 등 4차 산업혁명 기술 활용 여부를 포괄하는 이진변수 $IR4_{it}$ 로 구성된다. $IR4_{it}$ 는 AI_{it} 를 포함하는 상위 개념의 기술 활용 변수로, 기업이 직접 AI를 도입하지 않았더라도 클라우드 인프라, 빅데이터 분석, 로봇 자동화, 플랫폼 기반 서비스 등을 통해 간접적으로 AI의 영향을 받을 수 있는 기술 환경을 통제하기 위한 목적에서 포함된다.⁷² 실제로 기업활동조사 자료에서는 AI를 도입한 기업이 다른 4차 산업혁명 기술도 동시에 활용하는 경우가 많으며, 이 경우 단순히 AI 더미만 사용하면 이미 디지털 인프라와 조직역량이 우수한 기업이 선택적으로 AI를 도입해 더 높은 생산성

72 본 연구는 보다 정석적인 접근으로 $IR4$ 를 AI를 제외한 기술로 재정의하고 AI , $IR4$, $AI \times IR4$ 를 동시에 포함하는 상호작용 모형을 고려할 수 있다. 그러나 본 연구의 기초분석에서 내생변수 수가 증가함에 따라 유효한 도구변수(IV)를 충분히 확보하지 못하였고, Weak IV 문제로 인해 추정의 안정성이 낮아지는 한계가 확인되었다. 이에 본 연구에서는 거시효과 분석에 사용할 모수로서 해석 가능성과 식별의 안정성을 우선하여 현재의 모형을 채택하였으며, 보다 정교한 상호작용 모형의 추정은 향후 연구과제로 남겨둔다.

을 달성하는 상황을 과대추정할 위험이 존재한다. 반대로, 생산성이 낮거나 매출 정체를 겪는 기업이 이를 만회하기 위한 전략으로 AI를 도입하는 경우에는 AI 계수가 과소추정될 가능성도 있다. 이러한 양방향 내생성 가능성을 완화하기 위해 본 연구는 도구변수를 활용한 2단계 최소자승법(2SLS)을 도입한다.

구체적으로, 1단계 회귀식은 다음과 같이 설정된다.

$$Z_{it}' = IV_{it}'\alpha_0 + X_{it}'\beta_0 + \mu_i + \mu_t + \nu_{it}. \quad (4.1st)$$

여기에서 Z_{it} 는 앞서 언급한 AI 및 4차 산업혁명 기술 활용 여부 벡터이며, IV_{it} 는 도구변수 벡터, X_{it} 는 통제변수 벡터, μ_i 는 기업 고정효과, μ_t 는 연도 고정효과, ν_{it} 는 교란항이다. 2단계 회귀식은

$$Y_{it} = \widehat{Z}_{it}'\alpha_1 + X_{it}'\beta_1 + \eta_i + \eta_t + \epsilon_{it}, \quad (4.2nd)$$

로 정의하며, 여기서 Y_{it} 는 로그(상용근로자 1인당 매출액) 혹은 로그(상용근로자 수)와 같은 생산성 관련 종속변수이다. 1단계에서 도구변수에 의해 예측된 $\widehat{Z}_{it}$ 를 2단계 식에 대입함으로써, AI 및 4차 산업혁명 기술 활용 여부의 내생성을 완화한 상태에서 그 효과(계수 α_1)를 추정한다.

도구변수 벡터 IV_{it} 는 크게 두 축으로 구성된다. 첫째, 2022년 12월에 공개된 생성형 AI의 상용화 충격이 2023년을 기준으로 산업별로 상이하게 반영된 정도를 나타내기 위해, 본 연구는 경제성이 있는 AI 자동화 가능 과업의 산업별 비중을 이용한다. 구체적으로, 2023년에 1의 값을 갖는 시점 더미 I_{2023} 와 이전 장에서 추정된 산업 q 의 AI 자동화 경제성 지표 $Eco(ex)_q$ 를 곱한 $IV_i^{(1)} = I_{2023} \times Eco(ex)_q$ 를 도구변수로 사용한다. 이 변수는 동일한 산업에 속한 기업들이 2023년에 공유하는 생성형 AI 파급가능성의 크기를 반영하되, 개별 기업의 AI 도입 의사결정에는 직접 등장하지 않는 외생적 충격이라는 점에서 관련성(relevance)과 외생성(exogeneity)을 동시에 기대할 수 있다.

둘째, 기업수준의 AI 도입률을 이용한 leave-one-out 형태의 도구변수

($IV_{it}^{(2)}$)를 구성한다.⁷³ 전체 관측치에서 해당 기업을 제외한 AI 활용률,

$$\frac{\sum AI_{mt} - AI_{it}}{n_t - 1} \times I_{-2023},$$

해당 기업이 속한 지역(r) · 산업(q) 집단을 제외한 AI 활용률,

$$\frac{\sum AI_{mt} - \sum_{rq} AI_{it}}{n_t - n_{rq}} \times I_{-2023},$$

그리고 해당 지역(r) · 산업(q) 내부에서 관측기업을 제외한 AI 활용률,

$$\frac{\sum_{rq} AI_{mt} - AI_{it}}{n_{rq} - 1} \times I_{-2023}$$

등 여러 후보를 고려하며, 이들 중 약한 도구변수(Weak IV) 조건을 통과한 변수를 최종 모형에 포함한다. 이러한 leave-one-out 구조는 개별 기업의 AI 도입 여부가 집단 평균 도입률을 결정하는 반사(reflection) 문제를 완화하는 데 목적이 있다.

독립변수 벡터 X_{it} 는 기업규모와 재무구조, 혁신역량, 지역 · 산업 특성 등을 통제하기 위해 구성된다. 구체적으로 로그(총자산), 로그(종사자 수), 상용근로자 수와 임시 · 일용 근로자 수의 합, 로그(영업비용)과 같은 기본 재무 · 투입 변수와, 특허권 보유 건수(1,000으로 나눔), 연구개발(R&D) 외주 여부 등의 혁신 관련 변수를 포함한다. 또한 상장 코드, 시도 지역, 산업 대분류, 연도 더미변수를 통해 지역별 · 산업별 · 시계열적 공통 충격을 통제하며, 종속변수의 전기 값(Y_{it-1})을 독립변수로 포함함으로써 생산성의 동학과 부분적 조정비용을 반영한다. 이와 같은 통제구조는 Brynjolfsson *et al.*(2023)이나 Gambacorta *et al.*(2024)이 개별 기업 또는 팀 수준에서 기간 고정효과와 개인 고정효과를 이용해 이질성을 통제한

⁷³ AI 영향률이 지역의 고용에 미치는 영향을 분석하는 한요셉(2023)의 도구변수 설계와는 차이가 있다.

방식과 유사한 논리이지만, 본 연구는 전국 단위 행정 패널자료를 활용해 지역·산업 더미를 포함하고 있다는 점에서 다른 형태라고 볼 수 있다.

이제 본 연구의 분석 모형을 기존 문헌과 비교해 보면, 공통점과 차이점을 보다 명확히 확인할 수 있다. Dell'Acqua *et al.*(2023)은 컨설턴트의 복잡한 과업(제품 혁신, 전략 분석, 경영 문제 해결 등)에 대해 GPT-4 기반 도구 접근 여부를 무작위로 할당하고, 품질 점수, 과업 완료율, 소요시간, 정답률 등의 지표를 이용해 생산성 효과를 추정하였다. Noy and Zhang(2023)은 대학 교육을 받은 전문직 종사자의 중급 작문 과업에 ChatGPT를 도입하여 소요시간과 출력 품질의 변화를 측정하였고, Peng *et al.*(2023)은 GitHub Copilot의 접근 여부가 코딩 과업의 완료시간과 성공률에 미치는 영향을 분석하였다. Brynjolfsson *et al.*(2023)은 고객 상담원의 대화형 AI 도우미 도입이 시간당 처리 건수, 평균 처리시간, 이직률 등에 미치는 영향을 이중차분법(DID)과 고정효과 모형으로 추정하였으며, Gambacorta *et al.*(2024)은 CodeFuse LLM을 도입한 개발자의 코드 산출량과 수용률 변화를 성향점수매칭(PSM)과 이중차분법(DID)을 결합하여 분석하였다. Haslberger *et al.*(2025)은 텍스트 기반 사무 과업 전반을 대상으로 ChatGPT 사용 여부가 과업시간과 성과 점수에 미치는 영향을 국소적 평균 처치 효과 추정(LATE)으로 추정하였다. 이들 연구의 공통점은 모두 AI 도입 여부 또는 접근 여부를 주요 독립변수로 두고, 시간당 산출, 과업당 소요시간, 품질 점수와 같은 생산성 관련 지표를 종속변수로 설정했다는 점이다. 반면, 대부분 무작위 실험(randomized controlled trial: RCT)이나 특정 조직 내부의 단계적 도입 데이터를 이용하여, 비교적 단기간의 과업 단위 효과를 식별하는 데 초점을 맞추고 있다.

이에 비해 본 연구는 첫째, 분석 단위가 과업(task)이 아니라 기업(firm)이라는 점에서 근본적인 차이를 가진다. 기존 연구의 과업 단위 생산성 효과는 해당 과업이 수행되는 조직 환경과 다른 보완·대체 투입요소를 완전히 통제하기 어렵다는 한계를 가지며, 동시에 조직 차원의 스케일업 효과(예: AI 도입 이후 신규 프로젝트 확대, 시장 확장, 조직 재편)를 충분히 반영하지 못한다는 특징이 있다. 반대로, 기업 단위 1인당 매출액과

고용규모를 종속변수로 사용하는 본 연구는 AI 도입이 특정 과업뿐 아니라 기업 전반의 사업구조, 인력 배치, 자본집약도, 시장전략 등을 통해 축적되는 효과를 포착할 수 있다. 또는 AI 자동화가 과업별로 적용될 때 과업 단위별로 경제적 효과가 상이하기 때문에 기업 단위 분석에서는 오히려 AI 도입의 경제적 효과가 미약할 수도 있다. 둘째, 기존 문헌의 다수는 무작위 실험 설계 또는 자연실험 구조를 활용하여 내생성을 통제한 반면, 본 연구는 관측자료에 기반한 패널분석이므로 도구변수 설정이 핵심적인 식별 전략이 된다. 산업별 AI 자동화 경제성 지표와 leave-one-out AI 도입률을 결합한 도구변수는, 한편으로는 생성형 AI 기술의 외생적 과급 경로를, 다른 한편으로는 동일 집단 내 다른 기업들의 도입행태를 활용함으로써, 개별 기업의 관측되지 않은 생산성 충격과 구별되는 변동을 확보하려는 시도이다. 셋째, 본 연구는 AI 활용 여부와 더불어 4차 산업혁명 기술 활용 여부를 동시에 고려하여, AI 효과 추정에서 디지털 인프라와 기술역량의 수준을 명시적으로 통제한다. 이는 AI를 포함한 광의의 디지털 기술군을 하나의 처치로 다루는 대신, AI와 非AI 4차 산업혁명 기술을 구분함으로써 순수한 AI 기여분을 식별하려는 시도라는 점에서, AI를 하나의 광범위한 기술 카테고리로 통합하여 분석하려는 시도와도 차별화된다.

요약하면, 본 소절에서 제시된 기업활동조사 자료 기반 패널분석 방법론은 기존 과업 단위 생산성 연구들과 동일하게 AI 도입 여부와 생산성 지표 사이의 인과효과를 식별한다는 공통점을 가지면서도, 분석 단위를 기업수준으로 끌어올리고, 도구변수 기반의 패널 IV 모형을 도입함으로써 보다 거시적·장기적인 관점에서 AI가 기업생산성에 미치는 영향을 평가한다. 또한 제3장에서 구축한 산업별 AI 자동화 경제성 지표를 도구변수로 활용함으로써, 경제성이 높은 산업에서 실제 AI 활용률이 높은가라는 기술·경제성 분석과 AI 활용이 1인당 매출액, 고용 및 매출액에 어떤 효과를 가져오는가라는 실증분석을 하나의 일관된 계량모형 안에서 연결한다는 점에서, 기존 문헌과는 차별적인 기여를 갖는다고 판단한다.

2. Propensity Score Matching을 이용한 분석

본 소절에서는 앞서 제시한 패널 IV 모형을 보완하기 위하여, 성향점수매칭(Propensity Score Matching: PSM) 후 패널분석과 더불어 차분모형을 결합한 보조 분석 방법론을 설명한다. PSM 분석은 AI 활용 기업과 미활용 기업 간에 관측 가능한 특성의 분포를 최대한 유사하게 맞춘 뒤, 도입 전후 시점별로 1인당 매출액과 고용의 경로 등을 비교함으로써, 패널 IV 분석에서 얻어진 추정치가 특정 함수형태 가정이나 도구변수 선택에 과도하게 의존하지 않는지를 검증하는 역할을 한다. 다시 말해, 본 소절의 PSM 분석은 관측 공변량(Covariate)에 기반한 선택편의 제거를 전제로 한 준실험적(semiparametric) 접근법인 반면, 앞 절의 패널 IV 분석은 도구변수를 통한 내생성 교정이라는 구조적 접근법에 가깝다고 볼 수 있다. 두 방법론이 서로 다른 식별 전략에 기반하면서도 유사한 방향의 결과를 보인다면, AI 도입이 기업생산성에 미치는 효과에 대한 인과적 해석의 설득력이 강화될 수 있다.

먼저 PSM 분석의 기본 설계는 기업별 AI 도입 시점의 비동시성(staggered adoption)을 명시적으로 고려하는 데서 출발한다. 기업활동조사 패널에서 각 기업 i 의 AI 활용 여부 AI_{it} 가 0에서 1로 처음 전환되는 연도를 $first\ AI_i$ 라 하고, 분석 기간 내에 한 번이라도 AI를 도입한 기업을 처리집단(treated) 후보로 정의한다. 이때 도입 이후 다시 $AI_{it} = 0$ 으로 되돌아가는 사례는, AI 도입이 일시적 시험 도입인지, 구조적 도입인지 구분하기 어렵고, 도입 시점을 명확히 정의하기 어렵다는 점에서 분석에서 제외한다. 특히 $first\ AI_i \in \{2018, \dots, 2023\}$ 인 기업을 처리집단(treated) 후보로, 분석 기간 동안 한 번도 $AI_i = 1$ 을 기록하지 않은 기업을 대조군(never-treated) 후보로 설정한다.⁷⁴

이후 성향점수 추정은 도입 연도별 위험집단(risk set)을 기준으로 수행

74 본 연구는 PSM 분석에서 4차 산업혁명 기술을 활용하나 AI 기술을 활용하지 않는 기업은 제외한다.

된다. 기준연도 $t_0 \in \{2018, \dots, 2023\}$ 마다 해당 연도에 처음 AI를 도입한 기업($first\ AI_t = t_0$)을 코호트(cohort) t_0 의 처리집단으로, 같은 시점까지 AI를 도입한 적이 없는 대조군 기업을 해당 코호트의 대조군 후보로 구성한다. 여기서 중요한 점은 성향점수의 공변량(독립변수)을 도입 직전 연도, 즉 $t_0 - 1$ 기의 기업 특성으로 한정한다는 점이다. 이는 PSM의 기본 가정인 처리할당의 조건부 독립성(conditional independence assumption)을 도입 직전의 정보에 기반하여 최대한 만족시키기 위함이다. 구체적으로, 코호트 t_0 에 대해 다음과 같은 이진 처치변수 $T_l^{t_0}$ 를 정의한다.

$$T_l^{t_0} = \begin{cases} 1 & \text{if 처리군} \\ 0 & \text{if 대조군} \end{cases}$$

이때 성향점수는 도입 직전 연도 $t_0 - 1$ 에 관측되는 공변량(통제변수) 벡터 $X_{l_{t_0-1}}$ 를 이용하여

$$E_{t_0}[X_{l_{t_0-1}}] = \Pr(T_l^{t_0} = 1 | X_{l_{t_0-1}})$$

으로 정의되며, Logit 모형

$$\text{Logit}(E_{t_0}[X]) = X\gamma^{t_0}$$

을 통해 추정된다. $X_{l_{t_0-1}}$ 은 패널분석과 마찬가지로 전기의 로그(상용근로자 1인당 매출액), 로그(총자산), 로그(종사자 수: 상용근로자 수와 임시·일용근로자 수의 합), 로그(영업비용)과 같은 기본 재무·투입 변수와, 특허권 보유 건수(1,000으로 나눔), 연구개발(R&D) 외주 여부와 함께, 상장 코드, 시도 지역, 산업 대분류의 범주형 더미를 포함시킨다. 이는 기업규모, 재무지표, 혁신활동, 기업유형, 지역·산업구조 등 관측 가능한 이질성을 충분히 반영함으로써 동일 코호트 내에서 AI를 도입한 기업과 도입하지 않은 기업이 도입 이전까지 매우 유사한 궤적을 가져왔다는 조건을 최대한 충족시키기 위한 선택이다.

성향점수 추정 이후 실제 매칭 단계에서는, 각 코호트마다 처리기업

$T_l^{t_0} = 1$ 와 성향점수가 유사한 대조군 기업을 하나씩 선택한다. 또한 공통 지지(common support) 영역 밖에 위치하는 관측치는 제외하여, 처리집단과 대조군의 성향점수 분포가 중첩되는 영역에서만 매칭이 이루어지도록 설계한다. 이 과정을 통해, 코호트별로 도입 직전 특성 측면에서 유사하지만, 실제로는 AI를 도입했는지 여부만 다른 기업쌍을 구성하게 되며, 각 대조군 기업은 여러 처리기업과 매칭될 수 있으므로 매칭 횟수를 반영한 가중치를 부여한다. 구체적으로 처리기업에는 1을, 대조군 기업에는 해당 기업이 매칭에 사용된 횟수를 가중치로 부여하여 평균처리효과(average treatment effect on the treated: ATT)를 추정하도록 한다.

추정식은 두 가지 범주로 나뉜다. 우선,

$$Y_{lt}^{t_0} = \sum_{k=0}^3 \delta_k D_{lk}^{t_0} + X_{lt}'\beta + \lambda_l + \lambda_t + \epsilon_{lt}, \quad (4.PSM1)$$

$$D_{lk}^{t_0} = 1 \{T_l^{t_0} = 1, t - t_0 = k\}, \quad k = 0, 1, 2, 3,$$

여기서 $Y_{lt}^{t_0}$ 는 코호트 t_0 기준으로 복제된 패널에서의 기업 l , 연도 t 의 종속변수, 그리고 기업-코호트 고정효과(기업이 여러 코호트에 복제되었음을 반영), 연도 고정효과, X_{lt} 는 패널분석과 마찬가지로 총자산, 종사자 수, 영업비용, 특허, 연구개발 위탁 여부 등의 시점별 통제변수이며, δ_k 는 도입 후 k 년 시점에서의 처치효과를 나타낸다. 이 회귀식은 가중치를 이용한 가중 최소제곱으로 추정된다. 이때 δ_k 는 AI를 도입한 기업과 같은 코호트 내 대조군 기업을 PSM으로 정렬했을 때, 도입 전 $k = -1$ 에 비해 도입 후 k 년 시점에서 1인당 매출액 로그가 얼마나 더 높게(또는 낮게) 변화했는가를 의미한다.

둘째, 종속변수가 기본적으로 로그값이기 때문에 성장률 혹은 변화율에 해당하는 차분을 종속변수로 두고, 유사한 형태의 이중차분(DID) 모형을 추정한다.

$$Y_{it}^{t_0} - Y_{it-1}^{t_0} = \sum_{k=0}^3 \theta_k D_{ik}^{t_0} + X_{it}'\gamma + \lambda_t + \lambda_i + u_{it}, \quad (4.PSM2)$$

여기서 $k=0$ 에 해당하는 θ_0 는 AI 도입연도의 성장률에 대한 처치효과 (도입 직후 급격한 변화)를, $\theta_1, \theta_2, \theta_3$ 는 도입 후 1~3년 동안의 성장률 효과를 각각 나타낸다. 이로써 AI 도입이 생산성과 고용에 미치는 동태적 영향을 동시에 평가할 수 있다.

이러한 회귀모형 외에도, 각 도입기간 k 에 대해 매칭된 표본에서 단순 평균 차이를 추정하는 방식으로 보완한다. 즉, k 가 주어진 상태에서 도입 기업과 대조군 기업의 종속변수의 평균 차이를 ATT 가중치를 이용한 회귀분석으로 추정함으로써, 이벤트 스터디 회귀에서 얻은 δ_k, θ_k 와 비교한다. 이 절차는 회귀모형의 함수형태 가정에 대한 민감도를 점검하는 데 유용하며, 특히 성향점수가 매우 유사한 기업들로 구성된 소규모 근방에서의 국소 평균 처리 효과를 보다 직관적으로 해석할 수 있다.

이상의 PSM-DID 접근법은 앞 절의 패널 IV 모형과 몇 가지 중요한 측면에서 대비된다. 첫째, 패널 IV 모형은 전체 표본에서 시간에 따라 변하는 AI 도입 여부와 생산성의 관계를 구조적으로 추정하며, 산업별 AI 경제성 지표와 leave-one-out 도입률을 도구변수로 활용하여 관측되지 않은 생산성 충격과 AI 도입의 내생적 상관성을 교정한다. 반면, PSM-DID는 도구변수를 사용하지 않고, 도입 직전의 관측 공변량에 조건한 선택편의를 제거하는 것을 목표로 한다. 둘째, 패널 IV는 도입 시점의 이질성과 이벤트 시점별 동태 효과를 명시적으로 모델링하지 않는 대신, 평균적인 계수 α_1 을 추정하는 반면, PSM-DID는 코호트별 위험집단을 구분하고 도입 후 시간 k 를 도입함으로써 도입 직후와 도입 이후 1~3년의 효과를 구분해서 식별한다. 셋째, 패널 IV는 전체 기간의 정보를 최대한 활용한다는 장점이 있지만, 도구변수의 설계와 강도(weak IV 문제)에 민감한 반면, PSM-DID는 상대적으로 모형 가정이 단순한 대신 도입 직전 시점까지의 관측 공변량이 모든 선택편의를 설명한다는 강한 조건을 전제로 한다. 따라서 두 방법이 서로 다른 전제와 식별 전략하에서 유사한 방향성

과 규모의 결과를 보여줄 경우, AI 도입 효과에 대한 추정이 특정 방법론에 국한되지 않는 보다 견고한(econometrically robust) 결과임을 의미하게 된다.

요약하면, 본 소절에서 제시한 PSM 분석은 2018~23년 사이에 단일·비가역적 AI 도입을 경험한 기업들을 도입연도별 코호트로 구분한 뒤, 도입 직전 연도의 재무·고용·혁신특성 및 지역·산업구조를 기준으로 대조군 기업과 성향점수매칭하여, 도입 전후 4년(도입 전 1년, 도입 후 3년)의 생산성과 고용의 동태적 차이를 추정하는 방법론이다. 이는 앞서 제시한 기업 고정효과와 도구변수에 기반한 패널분석 결과를 보완하고, AI 도입이 1인당 매출액, 고용, 총매출액에 미치는 효과를 다양한 식별 전략하에서 교차검증하는 역할을 수행함으로써, 본 장에서 제시하는 실증 결과의 신뢰도를 제고하거나 강건성을 검증한다.

제3절 실증분석 결과

1. 패널 IV 분석

표본 기간은 AI 활용 여부에 대한 설문이 처음 도입된 2017년부터 최신 자료가 제공되는 2023년까지이며, 이 가운데 연속적으로 최소 5개 연도의 관측치가 존재하는 기업만을 분석에 포함하였다. 이는 중간에 신규로 진입하거나 일시적으로만 조사에 포착된 기업들이 패널 추정치에 미치는 영향을 최소화하고, 기업 고정효과 모형과 도구변수 추정에서 요구되는 시계열 변동성을 확보하기 위한 조치이다. 또한 2017년 시점에 이미 AI를 활용하고 있는 것으로 응답한 기업은 표본에서 제외하였다. 이들 기업의 경우 AI 도입 시점이 설문 이전에 발생하였을 가능성이 크기 때문에, 도입 전후 비교를 통해 AI 활용 효과를 식별하려는 본 연구의 목적에 부합하지 않기 때문이다.

먼저 <표 4-3>은 2017~23년 분석 표본에 대한 주요 변수의 기초통계량

<표 4-3> 주요 변수 기초통계량(2017~23년)

변수	관측치 수	평균	표준 편차	최소	최대
로그(상용근로자 1인당 매출액)	75,279	5.8	1.1	-2.3	13.7
로그(상용근로자 수)	75,314	5.0	1.1	1.6	11.7
로그(매출액)	75,280	10.8	1.5	0	19.2
로그(총자산)	75,311	10.9	1.6	4.9	20.1
로그(종사자 수)	75,314	5.0	1.1	1.6	11.7
로그(영업비용)	75,313	10.8	1.5	4.7	19.0
특허권 보유 건수/1,000	75,314	0.03	0.5	0.0	39.8
연구개발 외주 여부	75,314	0.1	0.2	0.0	1.0

자료: 국가데이터처, 「기업활동조사」.

을 제시한다. 로그(상용근로자 1인당 매출액)의 평균은 5.8, 표준편차는 1.1로, 기업 간 노동생산성의 분산이 상당히 크다는 점을 보여준다. 최솟값은 -2.3, 최댓값은 13.7로, 일부 기업에서는 매출액 대비 상용근로자 수가 매우 작아 극단적인 고생산성이 관측되는 반면, 반대의 경우도 적지 않음을 시사한다. 로그(상용근로자 수)와 로그(종사자 수)의 평균은 모두 5.0으로, 이는 표본 기업의 규모가 대체로 중견기업 이상임을 의미한다. 로그(매출액), 로그(총자산)과 로그(영업비용)의 평균은 각각 10.8, 10.9, 10.8이며, 표준편차가 1.5~1.6 수준이라는 점을 고려하면 총매출, 자산과 비용 측면에서도 기업 간 이질성이 뚜렷하다. 특허권 보유 건수/1,000은 평균이 0.03에 불과하지만 최댓값이 39.8까지 분포해, 혁신역량에 있어서도 일부 특허집중형 기업이 존재함을 알 수 있다. 연구개발 외주 여부 더미는 평균 0.1로, 전체 기업 중 약 10% 정도가 국내외 기관에 연구개발을 위탁하고 있음을 보여준다. 이러한 기초통계량은 이후 패널 IV 분석에서 AI 활용과 생산성 간 관계를 추정할 때, 통제변수로 포함되는 기업 규모·투입구조·혁신활동이 상당한 변이를 제공하고 있음을 보여주는 배경 정보로 해석할 수 있다.

본 소절에서 사용하는 패널 IV 모형은 제4장 제2절에서 제시한 식 (4.2nd)에 기초한다. 종속변수로는 로그(1인당 매출액), 로그(상용근로자

수), 로그(매출액)를 각각 사용하며, 핵심 설명변수로 AI 활용 여부 더미 AI_{it} 와 4차 산업혁명 기술 활용 여부 더미 $IR4_{it}$ 가 포함된다. 여기서 $IR4_{it}$ 는 AI를 포함한 IoT, 클라우드, 빅데이터, 모바일, 로봇, AR/VR 등 광의의 4차 산업혁명 기술 활용 여부를 나타내는 변수로 정의되어 있다. 따라서 $AI_{it}=1$ 인 기업은 반드시 $IR4_{it}=1$ 이지만, 역은 성립하지 않는다. 회귀식에 두 변수를 동시에 포함할 경우, 기준집단은 AI와 4차 산업혁명 기술을 모두 사용하지 않는 기업이며, $IR4_{it}$ 의 계수는 4차 산업혁명 기술을 사용하는 기업집단과 기준집단 간 차이를, AI_{it} 의 계수는 동일하게 4차 산업혁명 기술을 사용하되 동시에 AI를 활용하는 기업집단과 4차 산업혁명 기술을 활용하는 기업집단 간 차이를 의미한다. 따라서 어떤 기업이 AI를 포함한 4차 산업혁명 기술을 모두 활용하는 경우와 아무런 4차 산업혁명 기술도 사용하지 않는 기업 간의 차이는 두 계수의 합 $\alpha_1^{AI} + \alpha_1^{IR4}$ 로 해석된다. 실제 보고서에서는 이 합을 $AI + IR4$ 로 표기하여, AI 활용 효과의 경제적 크기를 % 변화율로 제시하고 있다.

AI 활용 여부는 기업의 내생적 경영 결정이기 때문에, 단순 회귀분석이나 고정효과 추정치는 AI 활용의 인과효과가 아니라 생산성이 높은 기업이 AI를 먼저 도입한 결과일 수 있다는 선택편의(selection bias)에 노출된다. 이를 보완하기 위해 본 연구는 앞 절에서 논의한 바와 같이, 해당 기업을 제외한 AI 도입률(leave-one-out AI adoption rate)을 도구변수로 사용한다. 이 변수는 개별 기업의 도입 여부에서는 제외된(leave-one-out) 집단 평균 도입률로 정의되어, 개별 기업의 우발적인 생산성 충격과는 독립적이면서, 기술·규제·인력공급 환경을 공유한다는 점에서 AI 도입 결정에 강하게 영향을 미친다는 장점을 가진다. 부록에서 제시한 약한 도구변수 검정 결과에 따르면, 이러한 leave-one-out AI 도입률이 다른 도구변수 후보에 비해 유일하게 Kleibergen-Paap rk F 통계량 10을 상회하는 등 Stock-Yogo 기준을 충족하여, 약한 도구변수 문제는 크게 우려되지 않는 것으로 확인된다.

<표 4-4>는 종속변수를 로그(1인당 매출액)으로 둔 패널 IV 추정 결과

<표 4-4> 패널 IV 분석: 로그(1인당 매출액)

로그(1인당 매출액)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
<i>AI</i>	-0.21	0.03	-0.28	0.04
<i>IR4</i>	0.39	0.02	0.49	0.04
전기($t-1$)	0.06	0.00	0.22	0.00
로그(총자산)	-0.01	0.50		
로그(종사자 수)	-0.70	0.00		
로그(영업비용)	0.95	0.00		
특허권 수/1,000	-0.02	0.09		
연구개발 외주 여부	-0.02	0.04		
상장 고정효과	Y			
산업 고정효과	Y			
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	63,620		63,623	
<i>AI + IR4</i>	0.18 (20%)	0.01	0.20 (23%)	0.05

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.

자료: 국가데이터처, 「기업활동조사」.

를 요약한다. 모형 (1)은 총자산, 종사자 수, 영업비용, 특허권 수, 연구개발 외주 여부 등 기업의 규모 및 투입구조를 통제하고, 상장 더미, 기업 고정효과, 산업 고정효과, 연도 고정효과를 모두 포함한 사양이다. 모형 (2)는 내생변수와 기업·연도 고정효과만을 포함하여, 보다 간결한 구조에서 도구변수의 강건성을 점검하기 위한 사양이다. 모형 (1)의 결과를 보면, *AI*의 계수는 -0.21로 추정되어 음(-)의 값을 가지며, p-value는 0.03으로 5% 수준에서 통계적으로 유의하다. 반면, *IR4*의 계수는 0.39로 양(+)의 값을 가지며, p-value는 0.02로 역시 유의하다. 두 계수의 합 *AI + IR4*는 0.18로, 로그선형 모형에서 지수함수를 적용하면, AI를 포함한 4차 산업혁명 기술을 활용하는 기업의 상용근로자 1인당 매출액이 아무 기술도 사용하지 않는 기업에 비해 약 20% 높은 것으로 해석할 수 있다.⁷⁵

모형 (2)에서는 *AI*의 계수가 -0.28, *IR4*의 계수가 0.49로 추정되며, 두 계수의 합은 0.20으로 약 23%의 생산성 제고 효과를 시사한다. 통제변수 구성이 달라짐에도 불구하고 *AI* 활용 효과의 크기와 방향이 유사하게 나타난다는 점은, 본 연구의 주된 결론이 특정 사양에 과도하게 의존하지 않음을 보여준다.

흥미로운 점은 *AI* 계수 자체가 음(-)의 값을 가진다는 사실이다. 이는 클라우드·빅데이터·로봇 등 다른 4차 산업혁명 기술을 사용하는 기업과 비교할 때, *AI*를 도입한 기업의 1인당 매출액이 오히려 낮다는 것을 의미한다. 반면, *IR4* 계수는 양(+)의 값을 가지므로, 4차 산업혁명 기술을 도입한 기업집단은 전통적 기술수준에 머무르는 기업에 비해 높은 생산성을 누리고 있다. 이러한 결과는 두 가지 해석을 가능하게 한다. 첫째, 다른 4차 산업혁명 기술만을 도입한 기업은 이미 상당한 디지털 전환과 운영 혁신을 이룬 상태에서 *AI* 이전 단계의 효율성 향상을 충분히 달성했을 수 있다. 이때 *AI* 도입은 기존 효율성 수준이 높은 기업에 추가적인 한계효과를 상대적으로 작게 제공하여, *AI* 계수가 음(-)으로 나타날 수 있다. 둘째, *AI*를 도입한 초기 단계에서는 데이터 인프라 구축, 알고리즘 튜닝, 조직 내 업무 재설계 등 선행 투자가 집중되기 때문에, 단기적으로는 비용 증가와 생산성 변동성이 발생할 수 있다. 즉, *AI*의 음(-)의 계수는 4차 산업혁명 기술 활용 기업 내부에서의 *AI* 초기 도입비용과 조정 과정을 반영하는 것으로 해석할 수 있으며, *AI*의 효과는 IT 기반 기술을 포함한 인프라 도입 전체를 기준으로 평가해야 한다는 점을 시사한다.

<표 4-5>는 종속변수를 로그(상용근로자 수)로 둔 경우의 패널 IV 추정 결과를 제시한다. 모형 (1)에서 *AI* + *IR4*의 합은 -0.06으로, 지수함수를 적용하면 *AI*를 포함한 4차 산업혁명 기술 활용 기업의 상용근로자 수가 기준집단에 비해 약 5% 정도 낮은 것으로 추정된다. p-value는 0.15로 10% 수준에서는 통계적으로 유의하지 않지만, 계수의 부호와 크기는 *AI* 도입이 노동 수요를 다소 축소시키는 방향으로 작용할 수 있음을 시사한다.

75 종속변수가 로그값이기 때문에 지수(exponential)함수를 사용하여 추정값을 %로 시산.

<표 4-5> 패널 IV 분석: 로그(상용근로자 수)

로그(상용근로자 수)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
<i>AI</i>	0.07	0.18	0.28	0.00
<i>IR4</i>	-0.12	0.16	-0.48	0.00
전기($t-1$)	0.07	0.00	0.35	0.00
로그(총자산)	0.04	0.00		
로그(종사자 수)	0.69	0.00		
로그(영업비용)	0.07	0.00		
특허권 수/1,000	0.01	0.06		
연구개발 외주 여부	0.01	0.27		
상장 고정효과	Y			
산업 고정효과	Y			
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	63,673		63,676	
<i>AI+IR4</i>	-0.06 (-5%)	0.15	-0.20 (-18%)	0.01

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.

자료: 국가데이터처, 「기업활동조사」.

모형 (2)에서는 $AI + IR4$ 의 합이 -0.20으로 추정되는데, 이는 상용근로자 수가 약 18% 감소하는 것에 해당하고, p-value가 0.01로 1% 수준에서 유의하다. 즉, 보다 단순한 모형에서는 AI를 포함한 4차 산업혁명 기술 도입이 기업의 고용규모를 통계적으로 유의하게 축소시키는 것으로 나타난다.

이를 앞서 살펴본 1인당 매출액 결과와 결합하면, AI 도입은 노동생산성 향상과 고용 감소라는 두 채널을 통해 작동하고 있음을 알 수 있다. 특히 모형 (1)과 모형 (2) 모두에서 전기 $t-1$ 의 종속변수가 0.06~0.07 수준의 양(+)의 계수를 가지는데, 이는 매출·고용이 상당한 자기지속성을 갖고 있음을 보여준다. 그럼에도 불구하고 AI 관련 변수의 계수가 추가적으로 유의한 효과를 갖는다는 점은, 단지 과거 성과의 경로의존성만으로는

<표 4-6> 패널 IV 분석: 로그(매출액)

로그(매출액)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
<i>AI</i>	-0.13	0.08	-0.05	0.66
<i>IR4</i>	0.25	0.06	0.10	0.65
전기($t-1$)	0.03	0.01	0.48	0.00
로그(총자산)	0.04	0.00		
로그(종사자 수)	-0.01	0.18		
로그(영업비용)	1.04	0.00		
특허권 수/1,000	-0.01	0.17		
연구개발 외주 여부	-0.01	0.08		
상장 고정효과	Y			
산업 고정효과	Y			
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	63,620		63,623	
<i>AI + IR4</i>	0.12 (13%)	0.04	0.04 (4%)	0.64

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.
 자료: 국가데이터처, 「기업활동조사」.

설명되지 않는 구조적 변화가 발생하고 있음을 의미한다.

<표 4-6>은 종속변수를 로그(매출액)으로 변경하여 추정한 결과이다. 모형 (1)에서 *AI + IR4*의 합은 0.12로, 이는 AI를 포함한 4차 산업혁명 기술을 도입한 기업의 총매출액이 기준집단에 비해 약 13% 높은 것을 의미한다. 앞서 1인당 매출액 분석에서 제시된 20% 생산성 향상과 비교해 볼 때, 1인당 매출액 증대 효과의 약 65%는 총매출 증가에 기인하고, 나머지 35%는 고용규모 축소의 결과로 해석할 수 있다. 즉, AI 도입은 단순히 기존 인력을 대체하여 비용을 절감하는 데 그치지 않고, 새로운 제품·서비스 제공, 고객 맞춤형 마케팅, 운영 효율성 제고 등을 통해 매출 자체를 확장하는 역할을 어느 정도 수행하고 있다고 볼 수 있다. 반면, 모형 (2)에서는 *AI + IR4*의 합이 0.04(약 4%)로 추정되지만, p-value가

0.64로 통계적으로 유의하지 않다. 이는 통제변수 구성이 단순화될수록 AI와 매출 간 관계의 추정치가 불안정해질 수 있음을 보여주며, 총매출 측면에서는 기업규모와 비용구조, 특허 보유 등 통제변수를 충분히 포함하는 것이 중요함을 시사한다.

<표 4-7>과 <표 4-8>에서는 다른 4차 산업혁명 기술을 활용하는 기업을 표본에서 제외한 후, 순수하게 AI 활용 여부만을 기준으로 재추정한 결과를 제시한다. 종속변수를 1인당 매출액과 상용근로자 수로 각각 두고 추정한 결과, AI 활용 계수는 어느 사양에서도 통계적으로 유의하지 않았다. 이는 아직까지 AI를 단독으로 도입하는 것만으로는 생산성과 고용에 뚜렷한 변화를 가져오기 어렵고, IoT·클라우드·빅데이터 등 디지털 인프라 및 프로세스 혁신과 결합될 때 비로소 의미 있는 성과가 발생할 수 있다는 점을 시사한다. 다시 말해, AI는 다른 4차 산업혁명 기술을 대체하는 독립적인 생산요소라기보다는, 그 위에서 작동하는 범용기술(*general-purpose technology*)의 성격을 갖고 있으며, 실질적인 생산성이 향상되기 위해서는 데이터 수집·저장·처리 체계, 클라우드 기반 운영 환경, 디지털화된 생산·판매 프로세스가 선행되어야 한다는 정책적 함의를 제공한다.

<표 4-9>에서는 제조업과 도소매업을 중심으로 한 주요 산업별 패널 IV 분석 결과를 요약한다.⁷⁶ 제조업의 경우 $AI + IR4$ 의 합이 0.22로 추정되어, AI를 포함한 4차 산업혁명 기술을 도입한 제조기업의 상용근로자 1인당 매출액이 도입하지 않은 기업에 비해 약 25% 높은 것으로 나타난다. 동시에 제조업에서의 고용규모 효과는 통계적으로 유의하지 않거나 0에 근접해, 매출액 증가(약 23%)가 대부분 생산성 향상을 설명하는 것으로 해석된다. 이는 제조업에서의 AI 활용이 주로 공정 자동화, 품질 관리, 예지정비 등 생산 효율성 제고와 수율 개선을 통해 산출량을 확대하는 방향으로 작동하지만, 아직까지는 상용근로자 수를 급격하게 축소시키는 단계까지는 도달하지 않았음을 의미한다. 반면, 도소매업에서는 1인당

76 제조업과 도소매업만 패널 IV 분석 결과가 안정적이어서 결과를 제시한다.

<표 4-7> 패널 IV 분석(4차 산업혁명 기술 제외): 로그(1인당 매출액)

로그(1인당 매출액)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
<i>AI</i>	0.01	0.19	-0.01	0.54
전기($t-1$)	0.07	0.00	0.22	0.00
로그(총자산)	-0.02	0.13		
로그(종사자 수)	-0.67	0.00		
로그(영업비용)	0.95	0.00		
특허권 수/1,000	0.00	0.75		
연구개발 외주 여부	0.00	0.69		
상장 고정효과	Y			
산업 고정효과	Y			
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	45,845		45,848	

자료: 국가데이터처, 「기업활동조사」.

<표 4-8> 패널 IV 분석(4차 산업혁명 기술 제외): 로그(상용근로자 수)

로그(상용근로자 수)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
<i>AI</i>	-0.01	0.24	0.00	0.87
전기($t-1$)	0.07	0.00	0.33	0.00
로그(총자산)	0.04	0.00		
로그(종사자 수)	0.67	0.00		
로그(영업비용)	0.07	0.00		
특허권 수/1,000	0.01	0.17		
연구개발 외주 여부	0.00	0.67		
상장 고정효과	Y			
산업 고정효과	Y			
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	45,882		45,885	

자료: 국가데이터처, 「기업활동조사」.

<표 4-9> 주요 산업별 패널 IV 분석의 주요 결과

	로그(1인당 매출액)		로그(상용근로자 수)		로그(매출액)	
	제조	도소매	제조	도소매	제조	도소매
$AI + IR4$	0.22 (25%)	0.84	0.00 (0%)	-0.60	0.21 (23%)	0.23
p-value	0.01	0.54	1.00	0.54	0.01	0.56

주: 1) 지수(exponential)함수를 사용하여 추정값을 %로 시산.

2) 모형 (1)의 추정 결과.

자료: 국가데이터처, 「기업활동조사」.

매출액, 고용, 매출액 어느 변수에서도 $AI + IR4$ 계수가 유의하지 않은데, 이는 도소매업에서의 AI 활용이 아직 초기 단계이거나, 온라인·오프라인 채널 통합, 고객 데이터 분석 등에서의 효과가 충분히 가시화되지 않았을 가능성을 시사한다.

마지막으로 <표 4-10>에서는 AI 활용 분야별 패널 IV 분석 결과를 제시한다. 연구개발, 생산공정, 판매목적, 마케팅, 조직관리 등 다섯 가지 활용 분야마다 $AI + IR4$ 의 합을 제시하고 있는데, 전반적으로 1인당 매출액에 대한 효과는 16~28% 범위에서 유의한 양(+)의 값을 보인다. 특히 제품 및 서비스 판매를 위한 AI 활용의 경우 1인당 매출액이 약 28% 증가하고, 상용근로자 수는 약 9% 감소하는 것으로 추정되며, 총매출액은 약 16% 증가한다. 이는 AI가 판매·유통 과정에서 가격설정, 재고관리, 수요예측, 추천 시스템, 챗봇 상담 등 다양한 영역에 활용되면서, 동일한 인력으로 더 많은 매출을 창출하거나, 동일 매출을 더 적은 인력으로 달성하게 만드는 효율성 향상 효과를 가져옴을 보여준다. 연구개발과 생산공정, 마케팅, 조직관리 분야에서도 1인당 매출액과 매출액의 계수는 11~19% 수준의 양(+)의 값을 가지며, 고용 계수는 -4%에서 -6% 범위의 음(-)의 값을 보이지만 통계적 유의성은 상대적으로 낮다. 이는 AI가 다양한 기능 영역에서 점진적으로 생산성 향상을 이끌고 있으나, 고용조정은 판매 영역과 같이 직접적인 수요·매출 확대가 가능한 분야에서 먼저 나타나고 있음을 시사한다.

종합하면, 본 소절의 패널 IV 분석 결과는 다음과 같은 결론을 제공한다

<표 4-10> AI 활용 분야별 패널 IV 분석의 주요 결과

로그(1인당 매출액)	연구개발	생산공정	판매목적	마케팅	조직관리
AI+ IR4	0.17 (19%)	0.15 (16%)	0.25 (28%)	0.16 (17%)	0.17 (19%)
p-value	0.04	0.04	0.02	0.05	0.03
로그(상용근로자 수)					
AI+ IR4	-0.04 (-4%)	-0.04 (-4%)	-0.09 (-9%)	-0.06 (-6%)	-0.06 (-6%)
p-value	0.36	0.31	0.09	0.18	0.17
로그(매출액)					
AI+ IR4	0.12 (13%)	0.10 (11%)	0.15 (16%)	0.10 (11%)	0.12 (12%)
p-value	0.06	0.07	0.07	0.13	0.06

주: 1) 지수(exponential)함수를 사용하여 추정값을 %로 시산.
2) 모형 (1)을 사용한 추정 결과.
자료: 국가데이터처, 「기업활동조사」.

다. 첫째, leave-one-out AI 도입률을 도구변수로 사용한 결과, AI를 포함한 4차 산업혁명 기술 활용 기업의 상용근로자 1인당 매출액은 약 20% 수준으로 유의하게 높으며, 이는 총매출 증가(약 13%)와 고용 감소(약 5%)라는 두 채널을 통해 실현된다. 둘째, AI를 다른 4차 산업혁명 기술과 분리하여 단독 효과만 추정할 경우, 생산성과 고용에 대한 유의한 효과는 발견되지 않는다. 이는 AI가 클라우드·빅데이터·IoT 등과 결합된 통합 디지털 전환의 일부로서 작동할 때 가장 큰 성과를 낸다는 점을 뒷받침한다. 특히 빅데이터나 클라우드 같은 4차 산업혁명 기술은 이미 정형화된 대량의 노동을 대체하는 단계에 안착한 반면, AI는 아직 새로운 일자리 창출과 전문인력 채용이라는 긍정적 효과가 노동대체 효과와 팽팽하게 맞서고 있는 초기 단계이기 때문에 기존 ICT의 고용 감소 효과가 상대적으로 더 크게 관찰된 것으로 판단된다. 셋째, 제조업과 판매목적 AI 활용 분야에서 특히 큰 생산성 제고 효과가 관측되는데, 이는 향후 정책설계 시 산업별·기능별로 차별화된 지원 전략이 필요함을 시사한다. 이러한 결과는 다음 절에서 제시하는 PSM 기반 분석과 상호 보완적으로

해석될 수 있으며, 제4장 전체의 결론으로 이어지는 AI 활용이 한국 기업의 생산성 구조를 어떻게 재편하고 있는지에 대한 실증적 근거를 제공한다.

2. PSM 분석

본 소절에서는 PSM을 활용한 분석 결과를 정리하고, 앞서 제시한 패널 IV 분석 결과와의 비교를 통해 AI 활용이 기업생산성에 미치는 영향을 종합적으로 해석한다. PSM 분석의 목적은 AI 외 다른 4차 산업혁명 기술을 동시에 활용하는 기업을 대조군에서 배제함으로써, 가능한 한 순수한 AI 활용 효과에 근접한 추정치를 얻는 데 있다. 이를 위해 우선 2018~23년 사이에 AI를 처음 도입한 기업을 처리집단으로 정의하고, 분석 기간 동안 한 번도 AI를 도입하지 않은 기업 중에서 재무규모, 인력규모, 특허 및 연구개발 외주 여부, 산업·지역 특성 등이 유사한 기업을 성향점수(propensity score)에 기반하여 매칭하였다. 이후 매칭된 표본에 대해서만 패널회귀와 이중차분(DID) 모형을 적용함으로써, AI 도입 전후의 생산성과 고용의 궤적을 비교하였다.

먼저 <표 4-11>과 <표 4-12>를 보면, 이벤트 시간 더미 $D_0 \sim D_3$ 계수를 통해 AI 도입 시점($k=0$)과 도입 후 1~3년($k=1,2,3$)에 걸친 효과를 식별하고 있다. 1인당 매출액의 경우 모형 (1)에서 D_0 계수는 약 0.02(약 3%)로 추정되나 통계적으로 유의하지 않고, 이후 $D_1 \sim D_3$ 는 -2~-5% 수준의 음(-)의 계수로 나타나지만 이 역시 유의하지 않다. 반면, 상용근로자 수에 대한 모형 (2)를 보면, D_1 계수는 약 0.10(11%)으로 1% 수준에서 유의하고, D_2 와 D_3 역시 각각 약 13%, 20% 수준의 양(+)의 계수로 나타나면서 10% 혹은 1% 수준에서 통계적으로 유의하다. 이는 PSM 이후 표본에서는 AI를 도입한 기업의 고용규모가 도입 직후부터 일정 시차를 두고 증가하는 경향이 있으며, 이러한 고용 확대가 1인당 매출액의 통계적 유의성을 희석시키는 방향으로 작용할 가능성을 시사한다. 요약하면, 매칭 이

<표 4-11> PSM 후 패널 분석: 로그(1인당 매출액)

로그(1인당 매출액)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
D_0	0.02 (3%)	0.18	0.01 (1%)	0.63
D_1	-0.03 (-3%)	0.26	-0.05 (-5%)	0.29
D_2	-0.02 (-2%)	0.63	-0.03 (-3%)	0.66
D_3	-0.05 (-5%)	0.36	-0.03 (-3%)	0.65
전기($t-1$)	0.02	0.50		
로그(총자산)	0.02	0.77		
로그(종사자 수)	-0.74	0.00		
로그(영업비용)	0.88	0.00		
특허권 수/1,000	-0.03	0.18		
연구개발 외주 여부	0.01	0.75		
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	1,052		1,097	

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.
자료: 국가데이터처, 「기업활동조사」.

<표 4-12> PSM 후 패널 분석: 로그(상용근로자 수)

로그(상용근로자 수)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
D_0	-0.02 (-2%)	0.12	0.04 (4%)	0.12
D_1	0.00 (0%)	0.91	0.10 (11%)	0.01
D_2	-0.02 (-2%)	0.57	0.12 (13%)	0.07
D_3	0.01 (1%)	0.74	0.18 (20%)	0.01
전기($t-1$)	0.01	0.81		
로그(총자산)	0.03	0.22		
로그(종사자 수)	0.72	0.00		
로그(영업비용)	0.09	0.06		
특허권 수/1,000	0.01	0.36		
연구개발 외주 여부	-0.01	0.60		
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	1,053		1,097	

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.
자료: 국가데이터처, 「기업활동조사」.

후의 패널 분석에서는 1인당 매출액 수준에서 뚜렷한 생산성 효과가 드러나기보다는, AI 도입기업이 비도입기업에 비해 고용을 확대하는 방향의 조정이 일부 관측된다고 해석할 수 있다.

다음으로 <표 4-13>을 살펴보면, 매출액 수준 측면에서는 보다 직관적인 생산성 향상이 관찰된다. 로그(매출액)에 대한 모형 (2)에서 D_0 계수는 약 0.05(5%)로 5% 수준에서 통계적으로 유의하며, 이후 D_3 계수는 0.15(16%) 수준까지 확대되지만 유의수준은 10%에 근접하는 정도에 그친다. 이는 AI 도입 이후 매출규모가 시간의 경과에 따라 점진적으로 확대되는 경향을 보여주지만, 표본 수가 감소하고 매칭 과정에서 처리집단과 대조집단의 동태가 제한되면서 통계적 검정력은 다소 낮아졌음을 의미한다.

반면, 1인당 매출액의 차분에 대한 이중차분(DID) 모형에서는 전반적으로 계수의 크기가 -2~+8% 범위에 머물고 p-value가 0.2 이상인 경우가 많아, 성장률 측면에서는 유의한 차이를 확정적으로 제시하기 어렵다. 그룹에도 불구하고 계수의 부호를 보면, AI 도입기업의 1인당 매출액 증가율이 대체로 대조군보다 빠른 방향을 보이며, 특히 도입 시점 주변에서 소폭의 양(+)의 효과가 관측되는 점은 앞선 패널 IV 분석에서 확인된 생산성 향상 방향성과 일치한다.

고용과 매출 증가율 측면에서의 PSM-DID 결과는 <표 4-15>와 <표 4-16>에서 확인할 수 있다. 상용근로자 수의 경우, 도입 시점 주변의 계수는 -1%에서 -7% 사이의 음(-)의 값이지만 대부분 통계적으로 유의하지 않다. 이는 패널 IV 분석에서 관찰된 AI 도입기업의 고용 감소 혹은 정체라는 결과와 방향은 유사하나, PSM 표본에서는 매칭을 통해 규모·산업·지역이 유사한 기업만을 비교함에 따라 고용 조정 효과의 순수 크기가 축소되었을 가능성을 시사한다. 매출액 증가율에 대해서는 도입 시점 이후 3년까지 대부분 0~13% 범위의 양(+)의 계수로 추정되지만, p-value가 0.1~0.8 사이에 분포하여 통계적 유의성은 제한적이다. 요컨대 PSM-DID 분석에서는 1인당 매출액과 매출액 성장률 모두에서 AI 도입기업이 대조군에 비해 조금 더 빠르게 성장하고, 고용 증가율은 상대적

<표 4-13> PSM 후 패널 분석: 로그(매출액)

로그(매출액)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
D_0	0.00 (0%)	0.80	0.05 (5%)	0.04
D_1	-0.04 (-4%)	0.04	0.05 (6%)	0.26
D_2	-0.04 (-4%)	0.21	0.09 (9%)	0.15
D_3	-0.04 (-4%)	0.26	0.15 (16%)	0.07
전기($t-1$)	0.01	0.88		
로그(총자산)	0.05	0.37		
로그(종사자 수)	-0.02	0.57		
로그(영업비용)	0.97	0.00		
특허권 수/1,000	-0.01	0.19		
연구개발 외주 여부	0.00	0.88		
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	1,052		1,097	

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.
 자료: 국가데이터처, 「기업활동조사」.

<표 4-14> PSM 후 DID 패널 분석: 로그(1인당 매출액) 차분

d로그(1인당 매출액)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
D_0	0.03 (3%)	0.42	0.02 (2%)	0.69
D_1	-0.02 (-2%)	0.76	0.01 (1%)	0.88
D_2	0.01 (1%)	0.87	0.08 (8%)	0.24
D_3	-0.02 (-2%)	0.85	0.06 (6%)	0.50
전기($t-1$)	-0.43	0.00		
로그(총자산)	-0.01	0.92		
로그(종사자 수)	-0.80	0.00		
로그(영업비용)	0.96	0.00		
특허권 수/1,000	-0.01	0.74		
연구개발 외주 여부	0.01	0.91		
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	977		1,052	

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.
 자료: 국가데이터처, 「기업활동조사」.

<표 4-15> PSM 후 DID 패널 분석: 로그(상용근로자 수) 차분

<i>d</i> 로그(상용근로자 수)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
D_0	-0.01 (-1%)	0.68	0.02 (2%)	0.52
D_1	-0.03 (-3%)	0.52	0.00 (0%)	0.93
D_2	-0.07 (-7%)	0.29	-0.02 (-2%)	0.75
D_3	0.00 (0%)	0.97	0.06 (6%)	0.48
전기($t-1$)	-0.49	0.00		
로그(총자산)	-0.04	0.38		
로그(종사자 수)	0.69	0.00		
로그(영업비용)	-0.04	0.55		
특허권 수/1,000	0.02	0.50		
연구개발 외주 여부	0.00	0.92		
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	977		1,053	

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.
 자료: 국가데이터처, 「기업활동조사」.

<표 4-16> PSM 후 DID 패널 분석: 로그(매출액) 차분

<i>d</i> 로그(매출액)	모형 (1)		모형 (2)	
	계수	p-value	계수	p-value
D_0	0.01 (1%)	0.59	0.04 (4%)	0.20
D_1	-0.05 (-5%)	0.23	0.01 (1%)	0.77
D_2	-0.06 (-6%)	0.37	0.06 (7%)	0.28
D_3	-0.02 (-2%)	0.77	0.12 (13%)	0.12
전기($t-1$)	-0.37	0.00		
로그(총자산)	-0.03	0.59		
로그(종사자 수)	-0.12	0.09		
로그(영업비용)	0.90	0.00		
특허권 수/1,000	0.01	0.85		
연구개발 외주 여부	0.01	0.87		
기업 고정효과	Y		Y	
연도 고정효과	Y		Y	
관측치 수	977		1,052	

주: 지수(exponential)함수를 사용하여 추정값을 %로 시산.
 자료: 국가데이터처, 「기업활동조사」.

<표 4-17> AI 도입 이후 기간별 회귀분석

로그(1인당 매출액)	k=0	k=1	k=2	k=3
treat	0.05 (5%)	-0.04 (-4%)	0.05 (5%)	0.01 (1%)
p-value	0.05	0.27	0.22	0.88
로그(상용근로자 수)				
treat	-0.01 (1%)	0.03 (3%)	-0.03 (13%)	0.00 (0%)
p-value	0.57	0.32	0.32	0.96
로그(매출액)				
treat	0.05 (5%)	-0.01 (-1%)	0.00 (0%)	-0.01 (-1%)
p-value	0.03	0.74	0.95	0.80
관측치 수	359	168	122	88

주: 1) 지수(exponential)함수를 사용하여 추정값을 %로 시산.

2) 통제변수로는 t-1기 종속변수, 총자산, 종사자, 영업비용, 특허권 수, 연구개발 외주 여부 등을 사용.

자료: 국가데이터처, 「기업활동조사」.

으로 낮다는 방향성은 유지되지만, 표본 규모와 매칭에 따른 정보 손실 때문에 통계적 유의성이 약화된 것으로 이해할 수 있다.

이러한 패널 및 DID 결과를 보다 직관적으로 보여주는 것이 <표 4-17>이다. 이 표는 도입 직전 연도($k = -1$)를 기준으로 도입연도($k = 0$)와 도입 후 1~3년($k = 1, 2, 3$)에 대해, 처치집단 더미(treat)의 계수를 각각 추정한 것이다. 1인당 매출액의 경우 도입연도 $k=0$ 에서 treat 계수는 0.05(5%)이며 5% 수준에서 통계적으로 유의하다. 이는 동일 코호트 내에서 PSM으로 매칭된 기업들을 비교할 때, 도입연도의 1인당 매출액 수준이 비도입기업보다 평균 5% 높은 수준으로 상승(jump)한다는 것을 의미한다. 이후 $k=1, 2, 3$ 에서는 계수의 부호가 -4%, +5%, +1% 등으로 불안정하지만, p-value가 0.22~0.88 수준으로 나타나 통계적으로 유의한 추가 효과는 확인되지 않는다. 전체 매출액에 대해서도 $k=0$ 에서 treat 계수는 0.05(5%)이며 5% 내외의 유의수준을 보이는 반면, 이후 기간에서는 계수가 0% 또는 -1% 수준으로 수렴하고 통계적으로 유의하지 않다. 상용근

로자 수는 전 기간에 걸쳐 계수 크기가 -1%에서 +3% 사이의 소규모 변동에 그치며, 모든 기간에서 통계적 유의성이 없다. 이 결과는 AI 도입이 기업의 생산성 수준(1인당 및 총매출 기준)에 대해 단기적으로는 명확한 수준 효과(level effect)를 가져오지만, 고용규모를 즉각적으로 조정하지 않으며, 중장기적으로는 매출 증가율의 추가적인 가속 효과가 뚜렷하지 않음을 시사한다.

이상의 PSM 분석 결과를 앞서 제시한 패널 IV 분석 결과와 비교하면, 두 방법론은 몇 가지 중요한 공통점과 차이점을 동시에 보여준다. 공통점부터 살펴보면, 첫째, 두 분석 모두 AI 도입이 1인당 매출액과 기업 전체 매출액에 미치는 효과가 양(+)의 방향이라는 점에서 결과가 일관적이다. 패널 IV 분석에서는 산업별 AI 자동화 경제성 지표와 leave-one-out AI 도입률을 도구변수로 사용하여 내생성을 통제한 결과, AI 활용 여부가 1인당 매출액을 대략 5~20%, 기업 매출액을 5~10% 수준에서 유의하게 증가시키는 것으로 나타난 바 있다. PSM-DID 분석에서도 계수의 통계적 유의성은 일부 기간에 한정되지만, 도입연도 기준 5% 내외의 생산성 수준 상승과 이후 기간의 매출 증가율 우위라는 방향성은 유지된다. 둘째, 고용 측면에서는 두 방법론 모두 AI 도입기업의 상용근로자 수가 대조군에 비해 크게 증가하지 않거나 일부 감소하는 경향이 관찰된다. 패널 IV 분석에서는 고용에 대한 계수가 대체로 0~10% 범위의 음(-)의 값을 갖는 시나리오가 현실적인 것으로 제시되었고, PSM 결과에서도 고용 증가율에 대한 명확한 양(+)의 효과는 발견되지 않는다(다른 통제변수를 사용하지 않은 모형 (2)만 예외). 이는 AI 도입이 주로 노동생산성 향상을 통해 매출 확대에 기여하는 반면, 고용수준은 단기적으로 크게 늘리지 않는다는 점에서 서로 보완적인 증거를 제공한다.

차이점 측면에서, 패널 IV 분석은 전체 패널을 활용하여 산업별 자동화 경제성 지표와 AI 도입률을 도구변수로 사용함으로써, 관측되지 않는 기업 특성이나 거시적 충격에 의한 내생성을 보다 강하게 통제한다는 장점이 있다. 반면, PSM 분석은 관측 가능한 공변량에 기초해 성향이 비슷한 대조군을 구성함으로써, 특히 AI 외 다른 4차 산업혁명 기술(IoT, 클

라우드, 빅데이터 등)을 활용하는 기업을 대조군에서 제외하고 순수한 AI 효과에 초점을 맞춘다는 장점이 있다. 이 때문에 PSM 이후의 추정치는 패널 IV 결과에 비해 효과 크기가 다소 작거나 유의성이 낮게 나타나지만, 이는 오히려 AI 자체의 순수 효과를 과대평가하지 않도록 하는 역할을 한다. 두 방법론의 추정치는 크기와 유의도의 차이가 있음에도 불구하고, 방향과 경제적 해석에서는 높은 수준의 일관성을 보이며 서로를 상호 검증하는 관계로 이해할 수 있다.

제4절 소 결

기존의 AI 거시경제 효과에 대한 연구들, 예컨대 Acemoglu(2024)와 Aghion and Bunel(2024), OECD(2024) 등은 주로 과업(task)수준의 노출도와 생산성 변화를 바탕으로 총생산(GDP)과 노동소득분배율에 미치는 장기적 효과를 추정한다. 이들 연구가 Brynjolfsson *et al.*(2021), Peng *et al.*(2023), Noy and Zhang(2023), Gambacorta *et al.*(2024), Dell'Acqua *et al.*(2023), Haslberger *et al.*(2023)과 같은 미시적 실험·현장연구에서 관측된 특정 과업의 생산성 향상(대략 10~55% 범위)을 입력값으로 사용하는 것과 달리, 본 연구는 한국의 기업수준에서 관측되는 1인당 매출액과 총 매출의 변화를 직접 추정한다는 점에서 차별성을 가진다. 과업 단위가 아니라 기업 전체를 단위로 할 경우, AI가 영향을 미치는 과업의 비중이 제한적이기 때문에, 개별 과업에서 관측되는 평균 30~50% 수준의 생산성 향상이 기업 전체 1인당 생산성(매출액)에서는 5~20% 수준으로 희석된다. 본 연구의 추정치는 바로 이러한 과업-기업 집계 과정을 실증적으로 보여주며, 거시모형에서 가정하는 AI 생산성 충격의 크기를 현실적인 범위로 제약하는 역할을 한다. 또한 본 연구는 제3장에서 구축된 직업·산업별 AI 자동화 경제성 지표와 결합함으로써, AI가 GDP에 미치는 영향을 계산할 수 있게 한다. 즉, 경제성 있는 과업이 전체 과업에서 차지하는 비중과 1인당 매출액에 대한 추정 효과를 결합하여, 근로자 1인당

생산성 향상이 거시경제에 미치는 영향을 산업별·경제 전체 차원에서 추정할 수 있다.

종합하면, 패널 IV 분석과 PSM-DID 분석을 통해 확인된 사실은 다음과 같이 정리할 수 있다. 첫째, AI 활용은 한국 기업의 1인당 매출액을 대략 5~20% 범위에서, 기업 전체 매출액을 5~10% 범위에서 증가시키는 것으로 보인다. 다만, 이러한 생산성 제고는 AI 활용만의 효과라기보다는 IoT, 빅데이터, 클라우드 등 ICT 관련 인프라 효과가 같이 반영된 결과라고 볼 수 있다. 둘째, 고용규모는 대부분의 모형에서 통계적으로 유의한 변화가 관측되지 않으나, AI 활용 분야별 분석 결과를 토대로 판단하면 최대 10% 이내의 감소 효과가 나타날 가능성이 있다. 셋째, 이러한 결과는 기존 연구들에서 보고된 과업수준 생산성 효과를 기업수준으로 집계했을 때 기대되는 크기와 대체로 정합적이다. 따라서 본 연구의 실증분석은 한국 경제에서 AI가 이미 유의미한 생산성 향상과 매출 확대를 가져오고 있으며, 고용에 대한 충격은 상대적으로 완만하다는 점을 뚜렷이 보여준다. 향후 거시모형을 활용한 시나리오 분석에서는, 본 연구에서 도출된 1인당 매출액 및 매출액 효과와 고용조정 범위를 기초모수(혹은 계수)로 사용함으로써, AI 확산이 향후 잠재성장률, 총요소생산성, 소득분배 구조에 미치는 장·단기 효과를 보다 현실적으로 평가할 수 있을 것이다.

제5장

AI가 거시경제에 미치는 영향

본 장은 제3장에서 구축한 AI 자동화·경제성 지표와 제4장에서 추정
한 AI 활용의 생산성 효과를 결합하여, 향후 10~15년간 AI 확산이 한국
경제의 총요소생산성(TFP) 그리고 장기적으로 고용·임금에 미치는 거시
적 파급효과를 분석하는 것을 목적으로 한다. 이를 위해 Acemoglu(2024)
와 Acemoglu and Restrepo(2022)가 제시한 과업기반 생산함수(task-based
production function)를 출발점으로 삼아, 산업·직종별로 이질적인 AI 노
출과 자동화 가능성을 반영하는 일반균형모형을 설정한다. 이 모형하에
서 AI 도입이 특정 과업의 단위비용(1인당 매출액)을 얼마나 감소(증가)
시키는지, 그리고 그러한 과업이 전체 경제에서 어느 정도의 경제적 비중
을 차지하는지를 결합하여, Hulten 정리(Hulten's Theorem)에 따라 산업별
생산성 충격을 가중합함으로써 TFP의 1차 근사 효과를 산출한다. Aghion
and Bunel(2024)과 OECD(2024)가 강조하듯이, 최근 AI 관련 거시분석은
이러한 과업기반 Hulten 방식을 중심으로 전개되고 있으며, 본 장 역시
제3·4장에서 도출한 한국의 지표를 이 틀에 일관되게 연결하는 것을 목
표로 한다.

그러나 Hulten의 1차 근사만으로는 구조 변화와 상대가격 조정, 중간재
네트워크 등으로 인해 발생하는 비선형 효과를 충분히 포착하기 어렵다
는 점도 잘 알려져 있다. Baqaee and Farhi(2019)의 이론과 이를 AI 맥락

에 적용한 OECD(2024), Filippucci *et al.*(2025)의 분석은, 산업 간 생산성 성장률과 최종수요·무역패턴의 이질성이 큰 경우 1차 근사가 TFP 상승을 과대추정할 수 있음을 보인다. 특히 Filippucci *et al.*(2025)은 AI로 인한 고생산성 부문과 저생산성 부문의 격차 확대, 이른바 바우몰(Baumol) 효과가 집계 생산성에 미치는 영향을 정량적으로 제시한다. 본 장에서는 이러한 논의를 참고하여, 먼저 한국경제의 산업별 AI 생산성 충격을 이용해 Hulten식 1차 근사에 따른 TFP 경로를 제시한 뒤, Baqaee and Farhi (2019)의 비선형 근사방식을 응용하여 구조 변화와 상대가격 조정을 부분적으로 반영한 TFP 경로를 비교함으로써, AI 확산으로 인한 거시적 생산성 이득이 어느 정도 범위 안에서 실현될 수 있는지를 평가한다.

$$\begin{aligned} \{\text{향후 10년 AI에 의한 TFP 증가율}\}_{\text{제3장}} &= \text{AI에 노출된 GDP 비중} \\ &\times \text{AI의 경제적 수익성이 있는 과업 비중} \\ &\times \text{AI로 인한 생산성 향상} \\ &\times \text{AI에 노출된 노동소득분배율} \end{aligned}$$

한편, AI 확산의 거시적 의미는 TFP 상승에만 국한되지 않고, 고용규모와 임금분포의 구조적 변화를 통해 분배에 중요한 함의를 갖는다. Acemoglu and Restrepo(2022)와 Acemoglu(2024)는 다부문·다집단 일반 균형모형과 전파행렬(propagation matrix)을 이용하여, 자동화 충격이 산업별 노동수요를 어떻게 변화시키고, 이것이 숙련도·직종·산업별 임금에 어떤 이질적 충격을 주는지를 정량적으로 제시하였다. 본 장에서는 이와 유사한 접근을 바탕으로, 제3장에서 구축한 직종·과업 단위 AI 자동화 지표표를 가지고 직종별 AI 충격을 구성하고, 직종별 장기 횡단면 IV 분석을 통해 장기 고용과 임금에 대한 효과를 추정한다. 특히 자동화 가능성이 높고 경제성이 있는 과업이 집중된 직종에서는 AI 도입 이후 노동수요가 상대적으로 더 크게 감소하고, 자본 및 AI 투입은 증가함에 따라 자본-노동 비율이 상승하는 한편 임금이 상대적으로 정체되거나 하락할 가능성이 크다. 반대로 AI와 보완적인 과업이 많은 직종에서는 생산성 상승이 오히려 임금과 고용을 지지할 수 있다.

이러한 이질적 충격은 산업·직무·과업 간 노동의 재배치와 임금분포의 변화로 이어져, 전체 임금소득불평등에 중요한 영향을 미친다. Acemoglu(2024)와 Aghion and Bunel(2024)은 AI가 장기적으로 성장률을 높이면서도 동시에 임금불평등을 심화시킬 가능성이 있음을 지적하며, AI 노출지표와 채택률, 노동소득분배율을 결합하여 성장·분배 효과를 동시에 평가한다. 본 장은 기존 문헌에서 제시된 분석을 한국경제에 적용하되, AI가 한국경제의 TFP 성장, 고용구조, 임금불평등에 미치는 장기적 영향을 통합적으로 제시한다. 이를 통해 본 장은 AI의 거시경제 효과를 단순한 낙관적 성장 시나리오가 아니라, 성장과 분배의 긴장관계 속에서 균형 있게 평가하고, 향후 노동시장·교육·산업 정책설계에 필요한 정량적 근거를 제공하는 것을 목표로 한다.

제1절 AI 도입 확산으로 인한 TFP 성장기여

1. 과업기반 경제모형

가. 일반균형모형

본 소절에서는 AI 도입의 거시효과를 TFP 경로 추정으로 설명하기 위한 과업기반(task-based) 거시모형을 설정한다. 경제는 이산시간 $t = 0, 1, 2, \dots$ 로 진행되며, 최종재는 완전경쟁하에서 생산되고 최종재 가격을 표준척도(Numeraire)로 둔다. 최종재 Y_t 는 연속된 과업산출 $y_t(j)$ 의 대체탄력성 불변(CES)의 함수로 생산된다고 가정한다. 과업지수 j 는 현시점 t 에 사용되는 과업의 범위 $\mathfrak{I}_t$ 안에서 정의된다. 다음의 형태를 기본으로 둔다.

$$Y_t = \left(\int_{j \in \mathfrak{I}_t} y_t(j)^{\frac{\sigma-1}{\sigma}} dj \right)^{\frac{\sigma}{\sigma-1}}, \quad \sigma \in (0, \infty), \quad \mathfrak{I}_t \equiv [\underline{\mathfrak{I}}_t, \overline{\mathfrak{I}}_t]. \quad (5.1)$$

여기서 σ 는 과업 간 대체탄력성이다.

각 과업 j 의 산출 $y_t(j)$ 는 노동투입 $\ell_t(j)$ 및 자본투입 $k_t(j)$ 로 생산된다. 기술적으로 자동화 가능한 과업의 집합은 $[\underline{\mathfrak{I}}_t, I_t] \subseteq [\underline{\mathfrak{I}}_t, \overline{\mathfrak{I}}_t]$ 로 표시하며, I_t 는 자동화의 외연범위(extensive margin)를 나타내는 경계(임계값)이다. 또한 각 요소별 과업의 생산효율성(task productivity technology)을 $\psi_L(j)$, $\psi_K(j)$ 로 두고, 총요소 생산효율성(factor-augmenting technology)은 각각 A_t^L , A_t^K 로 정의한다. 그러면 과업 생산함수는 다음과 같다.

$$y_t(j) = \begin{cases} A_t^L \psi_L(j) \ell_t(j) + A_t^K \psi_K(j) k_t(j), & j \in [\underline{\mathfrak{I}}_t, I_t] \\ A_t^L \psi_L(j) \ell_t(j), & j \in (I_t, \overline{\mathfrak{I}}_t] \end{cases} \quad (5.2)$$

더불어, 자본 중심 과업 대비 노동 중심 과업의 비교우위 가정으로 j 에 대해서 다음과 같이 단조증가한다고 가정한다.

$$\frac{\partial \psi_L(j)/\psi_K(j)}{\partial j} > 0$$

즉, 고지수 과업일수록 노동에 상대적으로 유리해지면서 주어진 상대가격하에서 낮은 지수 과업은 자본(즉, AI 관련 자본), 높은 지수 과업은 노동으로 배분되는 임계값(I_t) 구조가 성립한다.

과업의 완전경쟁하에서 과업을 수행하는 기업의 비용최소화를 통해 단위 생산비용은 다음과 같이 정의된다.

$$c_{jt}^K \equiv \frac{r_t}{A_t^K \psi_K(j)}, \quad c_{jt}^L \equiv \frac{w_t}{A_t^L \psi_L(j)}. \quad (5.3)$$

여기서 r_t 는 자본 1단위의 사용자비용으로, w_t 는 노동 1단위의 임금으로 정의된다. 또한 최종재 기업은 식 (5.1)을 만족시키도록 $\{y_t(j)\}_{j \in \mathfrak{I}_t}$ 를 선택하여 총비용을 최소화한다. 이러한 표준 CES 비용최소화로 과업의 수요는

$$y_t(j) = Y_t \left(\frac{p_{jt}}{P_t} \right)^{-\sigma}, \quad P_t \equiv \left(\int_{j \in \mathfrak{I}_t} p_{jt}^{1-\sigma} dj \right)^{\frac{1}{1-\sigma}} = 1 \quad (5.4)$$

로 정의된다. 과업 j 생산자는 식 (5.2)의 선형기술하에서 주어진 가격에 대해 비용최소로 투입을 선택한다. $j \in (I_t, \overline{\mathfrak{S}}_t]$ 에서는 노동만 가능하므로 단위비용이 식 (5.3)이고, 경쟁하에서 과업가격은

$$p_{jt} = c_{jt}^L, \quad (5.5)$$

로 결정된다. 과업 $j \in [\underline{\mathfrak{S}}_t, I_t]$ 에서는 자본이 완전대체(선형)로 결합되므로 비용최소는 더 낮은 단위비용 기술을 선택한다. 마찰이 없다면

$$p_{jt} = \min \{c_{jt}^L, c_{jt}^K\}. \quad (5.6)$$

로 결정된다. 과업 j 가 노동으로 생산하는 부분에서 요구되는 노동의 공급/수요, 그리고 자본의 공급/수요는 다음과 같다.

$$\ell_t(j) = \frac{y_t(j)}{A_t^L \psi_L(j)}, j \in (I_t, \overline{\mathfrak{S}}_t], k_t(j) = \frac{y_t(j)}{A_t^K \psi_K(j)}, j \in [\underline{\mathfrak{S}}_t, I_t], \quad (5.7)$$

$$\bar{n} = \int_{j \in \mathfrak{S}} \ell_t(j) dj, \bar{k} = \int_{j \in \mathfrak{S}} k_t(j) dj \quad (5.8)$$

일반균형 정의: 초기조건 $(A_0^L, A_0^K, \overline{\mathfrak{S}}_0, \underline{\mathfrak{S}}_0, I_0)$ 이 주어진 상태에서 경쟁균형은 $\{Y_t, \{y_t(j)\}, \{p_{jt}\}, w_t, r_t, I_t, \overline{\mathfrak{S}}_t, \underline{\mathfrak{S}}_t\}_{t \geq 0}$ 의 시계열로서 (i) 최종재 기업의 비용최소화 조건 식 (5.4), (ii) 과업생산자의 가격은 단위비용 조건 식 (5.5), (5.6), (iii) 노동 및 자본은 시장청산 조건 식 (5.7), (5.8)을 동시에 만족시킨다. 특히 일반균형이 존재하기 위해서는 노동·자본 간 비교우위의 단조증가와 함께 다음과 같은 조건이 만족되어야 한다.

$$\frac{A_t^L \psi_L(I_t)}{A_t^K \psi_K(I_t)} < \frac{w_t}{r_t} < \frac{A_t^L \psi_L(\overline{\mathfrak{S}}_t)}{A_t^K \psi_K(\underline{\mathfrak{S}}_t)}$$

위에서 설명한 과업기반 경제모형은 AI나 로봇 등 과업 자동화의 경제적 효과를 다양한 측면에서 설명하는 데 장점이 있다(Acemoglu, 2024). AI가 생산 경제에 미치는 영향은 크게 네 가지 경로를 통해 전달되는 것

으로 설명할 수 있다.

우선, 자동화된 과업의 외연적 확장($I_t \uparrow$)으로, 이는 AI가 인간에게 할 당되었던 과업을 기계나 알고리즘이 수행할 수 있도록 확장하는 과정을 의미한다. 생성형 AI가 단순 작문, 번역, 분류 업무를 맡거나 CV가 이미지 인식을 수행하는 것이 전형적인 사례라고 볼 수 있다.

두 번째는 과업 보완성 경로이며, AI가 노동자의 숙련도를 보강하여 기존 과업에서 성과를 개선하거나 노동생산성을 직접적으로 높이는 효과를 의미한다(특정 과업 j 의 $\psi_L(j) \uparrow$ 이나 $A_t^L \uparrow$). 특히 AI가 정형화된(routine) 하위과업(sub-task)을 자동화하여 인간이 더 고차원적인 활동에 전문화할 수 있도록 돕는 것처럼, 특정 하위과업의 자동화가 인간 노동에 대한 수요를 오히려 확대하는 결과로 이어질 수 있다.

세 번째 경로는 자동화의 심화(deepening of automation)로, 이미 자본집약적으로 수행되고 있는 과업에서 AI가 성능을 개선하거나 비용을 절감하는 기술적 진보를 의미한다(특정 과업 j 의 $\psi_K(j) \uparrow$ 이나 $A_t^K \uparrow$). 정보기술 보안의 강화나 자동화된 재고관리 및 품질제어 시스템의 효율화 등이 이 범주에 속할 수 있으며, 이는 노동의 직접적인 대체보다는 기존 자동화 설비의 생산성 제고에 집중된다고 설명할 수 있다.

마지막으로 AI가 인간이 비교우위를 갖는 새로운 노동집약적 과업이나 제품을 창출함(creation of new tasks)으로써 경제 전반의 과업 범위를 확장하는 역할을 수행할 수 있다($\bar{S}_t \uparrow$). 다만, 이러한 신규 과업 창출 과정에서는 사회적 후생을 증진하는 긍정적 측면뿐만 아니라, 딥페이크나 온라인 조작 등 사회적 가치가 음(-)인 소위 나쁜 과업(bad tasks)이 생성될 가능성도 공존하므로 유의할 필요가 있다(Acemoglu, 2024).

나. Hulten 정리(Hulten's theorem)의 근사

본 소절에서는 과업기반 경제모형에서 AI의 미시적 비용절감이 TFP(또는 생산성) 변화로 집계되는 근사(approximation)를 도출한다. 핵심은

과업가격지수 P_t 의 변화가 생산성 변화와 역의 관계에 있으며, 작은 변화에 대해 로그선형화하면 가중평균 형태가 된다는 점이다. 이는 Acemoglu(2024)가 강조하는 Hulten 정리의 변형과 동일한 논리이며, Aghion and Bunel(2024)의 ‘10년 TFP = (영향 과업의 GDP 비중) × (평균 비용절감)’도 이 근사의 직관적 표현에 해당한다.

식 (5.4)에서 정의된 과업가격지수 P_t 는 최종재 단위비용과 동치이며, 최종재 가격은 1로 둔다. 생산성(또는 실질 산출능력)을 보다 명시적으로 보여주기 위해, 기술이 주어졌을 때 동일한 투입으로 달성 가능한 최종재의 TFP_t 증가는 다음과 같이 주어진다.

$$d \ln TFP_t = dY \Big|_K = \int_{j \in \mathcal{S}_t} s_{jt} d \ln y_t(j) dj,$$

$$s_{jt} \equiv \frac{p_{jt} y_t(j)}{\int p_{mt} y_t(m) dm} = \frac{p_{jt} y_t(j)}{Y_t},$$

여기서 s_{jt} 는 직관적으로 과업의 GDP 부가가치 비중이 된다.

AI가 영향을 주는 것은 일반적으로 과업의 비용절감을 통한 생산성 증가로 요약되므로, 완전경쟁 과업 j 에서 AI로 인한 과업의 생산성 향상(비용 하락)을 $\pi_{jt}^L \equiv d \ln y_t(j) = -d \ln p_{jt} \geq 0$ 로 정의하면 자연스럽게,

$$d \ln TFP_t = \int_{j \in \mathcal{S}} s_{jt} \pi_{jt}^L dj \quad (5.9)$$

로 된다. 이 식이 본 장에서 사용하는 TFP를 추정하기 위한 기본적인 Hulten의 근사식이다.

다. AI 노출-경제성-생산성 향상(비용절감)-노동분배로의 분해

본 연구는 식 (5.9)에서 AI가 실제로 영향을 미치는 과업만 적분하면 된다. 문제는 실제 AI에 노출되거나 자동화 가능성이 있는 과업의 비중(E_j)과 그중 경제성이 있는(profitable) 과업의 비중(x_{jt})을 다시 분해해야

된다는 것이다. 그리고 AI 도입으로 인한 비용절감률은 다시 노동비용 절감률, 즉 $\alpha_{jt}\delta_{jt}^L (=1 \text{인당 노동비용절감률} \times \text{노동소득분배율})$ 로 구분하여 $\pi_{jt}^L = E_j x_{jt} \alpha_{jt} \delta_{jt}^L$ 로 정의하면,

$$d \ln TFP_t = \int s_{jt} E_j x_{jt} \alpha_{jt} \delta_{jt}^L dj \quad (5.10)$$

가 된다. 서론부터 지금까지 본 연구에서 사용한 형식(formula)은

향후 10년 AI에 의한 TFP 증가율 = AI에 노출된 GDP 비중
 × AI의 경제적 수익성이 있는 과업 비중
 × AI로 인한 생산성 향상
 × AI에 노출된 노동소득분배율

이다. 이를 모형의 식 (5.10)으로 다시 정리하면,

$$\Delta \ln TFP_{t \rightarrow t+10} \approx \sum_{\tau=t}^9 \sum_j^N s_{jt} E_j \tilde{x}_{j\tau} \alpha_j \delta_{jt}^L \quad (5.11)$$

이 된다. 여기서 $\tilde{x}_{j\tau}$ 는 AI의 경제적 수익성이 있는 과업 중 매년 채택되는 속도를 의미한다. 특히 본 연구는 다른 기존 문헌과의 상대적 비교를 위해 생성형 AI 상용화(2022년 말) 이후 10년간의 TFP 기여도를 추정하나, 실제 AI에 노출된 과업이 모두 자동화되는 시점은 Brynjolfsson *et al.* (2021)에서 제시하는 생산성 J-curve의 최저점 15년 전후에 달성하는 것으로 가정한다.⁷⁷

라. 다중산업 확장과 파급효과

Acemoglu(2024) 및 Aghion and Bunel(2024)은 전 산업의 AI 노출 과업 비중(전체 AI 노출 과업의 임금 비중을 사용)을 단일 변수로 사용하여 AI의 TFP 기여를 추정한다. 그러나 본 연구는 그들과는 다르게 산업별 TFP

⁷⁷ 연도별 AI 채택률을 추정하기 위한 구체적인 방법은 부록을 참고하기 바란다.

충격을 가중 합산하는 방식을 사용한다. 이때 가중치로 부가가치 비중이 아닌 Domar 가중치(산업별 총매출액/GDP)를 사용한다(Hulten, 1978). Domar 가중치를 사용하는 이유는 중간재의 효과를 반영하기 위해서다. 특히 부가가치 비중은 최종 재화의 가치만을 반영하지만, Domar 가중치는 중간재 생산 과정에서의 효율성 개선을 경제 전체로 파급하는 누적 효과를 포착한다. 즉, Domar 가중치의 합은 통상 1을 초과하는데, 이는 개별 산업의 생산성 향상이 공급망을 통해 경제 전반에 미치는 승수효과를 수학적으로 일관성 있게 연결한 것이다.

우선 경쟁적이고 규모에 대한 수익 불변(CRS)인 경제에서 미시 단위(기업·산업)의 TFP 변화가 GDP TFP에 미치는 효과를 식 (5.9)와 유사하게 다음과 같이 1차 근사로 표현할 수 있다.

$$\Delta \ln TFP_t = \sum_{q \in Q} \lambda_q d \ln A_q, \quad (5.12)$$

여기서 λ_q 는 명목 GDP에 대한 산업 q 의 총매출액 비중이며, $d \ln A_q$ 는 산업 q 의 TFP 충격이다. 식 (5.12)를 식 (5.11)을 이용하여 다중산업으로 확장하면,

$$\Delta \ln TFP_{t \rightarrow t+10} \approx \sum_{\tau=t}^9 \sum_q \lambda_{q\tau} \sum_j^N E_{qj} \tilde{x}_{qj\tau} \alpha_{qj} \delta_{qjt}^L \quad (5.13)$$

로 표현할 수 있다.

따라서 본 연구는 전 산업을 단일 노출도 지표로 축약하는 대신, 산업별 AI 노출·경제성·생산성 효과를 Domar 가중치로 집계함으로써, 중간재 네트워크를 통해 발생하는 승수효과(혹은 연쇄효과)와 산업구조 변화의 이질성을 보다 정교하게 반영한다. 다만, 본 접근법 역시 부문 간 상대가격 조정과 장기적인 고용·수요 재배치를 명시적으로 모형화하지는 못한다는 점을 유의할 필요가 있다. 즉, 본 연구의 결과는 실제로 산업 간 대체탄력성이 1보다 작고($\sigma < 1$), 서비스업처럼 AI 노출이 상대적으로 낮은 부문의 상대가격이 장기적으로 상승하면 Baumol(1967)이 지적한 비용질병(cost disease) 때문에 Filippucci *et al.*(2025)이 제시하는 Baumol

효과를 잡지 못하거나 Baqaee and Farhi(2019)의 정교한(비선형) 추정 대비 오차가 존재할 수 있음을 인식할 필요가 있다.⁷⁸

2. AI 도입의 확산으로 인한 총요소생산성(TFP) 개선

가. AI 확산의 시나리오별 TFP 기여도 경로

본 절에서는 앞서 도출한 식 (5.13)에 아래의 모수들을 적용하여 AI의 도입 확산으로 인한 TFP의 장기 기여를 추정한다.

(i) λ_{qt} 는 2024년 국가데이터처의 「전국사업체조사」의 중분류 산업별 매출액 및 한국은행의 명목 GDP를 이용하여 계산한다.

(ii) $\sum E_{qj} = E_q$ 는 본 연구의 제3장에서 추정한 AI 자동화 가능성(AI score)을 반영한 산업별 과업 비중과 AI에 노출된 산업별 과업 비중을 사용한다.

(iii) $\tilde{x}_{qj}$ 는 E_q 중 경제성 있는 과업이 연도별로 채택되는 비율로, 현재 기준 AI 기술의 자동화 가능성을 고려하여 제3장에서 추정한 $Eco(sc)_q/10$ 에서 시작하여 15년 후에는 누적 $Eco(ex)_q$ 에 도달하는 것으로 가정한다.

(iv) α_{qj} 는 본 연구의 제4장에서 추정한 AI 활용으로 인한 1인당 매출액 상승률을 일괄 적용한다. 특히 시나리오별 적용을 위해 제4장 패널 IV 분석 모형 (1)의 추정 결과인 20%를 Baseline으로 하고, 추정된 계수의 ± 1 표준오차(standard error)를 적용하여 Better인 경우와 Worse인 경우를 추정한다.

(v) 마지막 $\sum_j \omega_j \delta_{qjt}^L = \delta_{qt}^L$ 은 한국은행의 생산성 지표(제11차 한국표준 산업분류)의 중분류 산업별 노동소득분배율 3년(2022~24년) 평균을 사용한다.

78 Baumol의 비용질병은 생산성 향상이 어려운 서비스산업(교육, 의료, 예술 등)이 기술발전으로 생산성이 증가한 산업(제조업 등)의 임금수준을 따라가야 하는 상황으로 생산성은 그대로인데 비용과 가격만이 상승하여 오히려 매출 비중이 상승하는 현상을 말한다.

<표 5-1> AI 도입의 TFP 성장률 민감도 분석

(단위: %)

시나리오	Baseline	Better		Worse	
기술수준	생산성 20% 향상	AI 비용 50% 감소	생산성 향상: 29%(20%+S.E)	AI 비용 50% 증가	생산성 향상: 11%(20%-S.E.)
AI 자동화 가능성 반영	0.9	1.1	1.2	0.7	0.5
AI 노출 반영	5.4	7.0	7.4	4.5	3.3
AI 자동화 가능성 반영		1.2		0.5	
AI 노출 반영		7.4		3.3	
AI 노출 직무 100% 도입 시점	2038년	2038년		2038년	

자료: 국가데이터처, 「전국사업체조사」; 한국은행 경제통계시스템(최종접속일: 2025. 10. 25)을 바탕으로 저자 작성.

<표 5-1>은 위의 모수들을 적용한 AI 확산의 민감도를 분석하기 위한 시나리오별 TFP 성장률(%)이다. 기준이 되는 Baseline의 경우 AI 기술수준이 지금 그대로 유지된다면 15년간 TFP 성장률은 0.9%(연간 0.06%p)에 불과하다. 이는 Acemoglu(2024)의 추정치와 흡사하다. 그러나 AI의 기술이 빠르게 발전하여 현재 AI에 노출된 모든 과업 중 경제성 있는 과업들에 모두 AI가 도입된다면 15년간 5.4%(연간 0.36%p)의 TFP 개선을 기대할 수 있다.⁷⁹

특히 생산성(비용) 향상(절감)의 약화·강화를 시나리오로 고려하면, Better의 경우 15년간 최대 7.4%(연간 0.5%p)의 TFP 개선을, Worse의 경우에는 최소 0.5%(연간 0.04%p)만 개선될 수 있는 것으로 나타났다. 시나리오별로 좀 더 분석하면, TFP 개선의 민감도는 AI 비용보다는 생산성 향상 정도에 더 민감하게 움직이는 것을 확인할 수 있다. 이는 현재 기업 내 직종의 분포가 극단적으로 정의 왜도(positive skewness) 또는 오른쪽으로 치우친 분포를 가지기 때문에 AI 비용절감으로 인한 경제성을 확보하는 인원수(n_{ij}^*)의 임계값 감소가 실제 기업 내에 분포하는 해당 직종의

79 산업별 TFP 기여는 부록을 참고.

현원수(n_{li})보다 월등히 높기 때문에 AI 비용절감의 효과가 제한적이다.⁸⁰ 오히려 비용절감, 즉 생산성 향상은 AI를 도입한 모든 과업에 영향을 미치기 때문에 TFP 개선의 정도가 빠르게 향상되는 것을 알 수 있다. 더불어, 이는 AI 도입의 생산성 효과를 어떻게 가정하느냐에 따라 추정 결과가 많이 달라질 수 있음을 의미한다.


<표 5-1>은 AI에 노출되거나 자동화 가능성이 있는 과업 중 경제성이 있는 과업들이 모두 AI 시스템을 구축하였을 때의 TFP 기여로 저장(貯量, stock)의 개념이지만, [그림 5-1]은 유량(流量, flow)으로 $\tilde{x}_q$ 에 따른 연도별 TFP 성장기여도(%p) 경로를 보여준다. 특히 생성형 AI 상용화 초기인 2023년에는 AI의 자동화 가능성을 추정한 *AI score*를 반영하는 것이 가장 현실적일 것이다. 다만, 시간이 지날수록 AI 기술력은 빠르게 발전할 수 있기 때문에 15년 후에는 모달리티가 정의된 경제성 있는 모든 과업에 AI가 도입될 것이라고 가정하였다. 이러한 채택률 경로의 가정을 바탕으로 [그림 5-1]을 보면, 2023년에서 2026년에는 AI의 도입이 상대적으로 천천히 이루어지다가, 2028년에서 2030년에 가장 빠르게 AI의 도입률이 올라가고 이후에는 채택률이 유지되는 것으로 나타난다.⁸¹

이러한 성장 경로를 고려하면, Baseline에서 생성형 AI 상용화 후 AI로 인한 10년간 TFP 성장률은 2.3%(연간 0.23%p), Better의 경우는 3.5%(연간 0.35%p), 그리고 Worse의 경우에는 1.5%(연간 0.15%p)로 추정된다. 따라서 여러 가정 및 민감도를 고려하였을 때 현시점에서 가장 합리적인 AI에 의한 10년간 TFP 성장률 기여 범위는 1.5~3.5%일 것으로 판단된다. 이 중 72%인 1.1~2.5%p는 중간재의 공급망을 통한 AI 도입의 전후방 연쇄효과(linkage effect)이며, 나머지(0.41~95%p)는 최종재화에 대한 AI의

80 [부도 6]-[부도 8]을 참고하기 바란다.

81 앞서 제4장에서 보여준 설문조사를 통한 기업의 AI 도입률과 본 연구에서 가정한 채택률은 개념적으로 다르다. 설문조사에서는 AI의 활용에 대해서 업무자동화를 위한 AI 시스템 도입인지, 단순 생성형 AI의 활용(AI 계정 구입)인지 명확하지 않다. 본 연구에서 정의하는 AI 도입은 계정 구입 등 단순한 생성형 AI 계정의 활용이 아니라, 실제 과업 자동화를 위해 내부 시스템을 구축하거나 최소한 데이터 학습을 통해 업무에 특화된 생성형 AI 기능을 도입하는 경우를 의미한다.

[그림 5-1] AI 활용 확산으로 인한 15년간 TFP 성장기여도 경로



자료: 국가데이터처, 「전국사업체조사」; 한국은행 경제통계시스템(최종접속일: 2025. 10. 25)을 바탕으로 저자 작성.

기여이다. 마지막으로 한국 거시경제에 AI의 기여가 본격화되는 것은 AI 상용화 초기 5년보다는 2030년 이후에 뚜렷해질 것으로 판단된다.

끝으로, 본 연구의 10년 TFP 성장기여도 추정치를 기존 문헌과 비교해 보면 몇 가지 특징이 드러난다. Acemoglu(2024)는 동일한 Hulten 정리식에 매우 보수적인 모수(노출 과업 비중, 경제성 있는 과업 비중, 노동비용절감률, AI 노출 조정 노동소득분배율)를 대입하여 향후 10년간 TFP 상승분을 0.5~0.7% 수준, 연간 추가 성장률은 0.06%p 내외로 제시한다. 반대로 Aghion and Bunel(2024)은 동일한 과업기반 공식에 대해 노출도와 생산성 향상, 채택률에 보다 낙관적인 값을 부여하여 연평균 0.68%p, 최대 1%p를 넘는 추가 TFP 성장률을 제시한다. Filippucci *et al.*(2025)은 Acemoglu(2024)의 접근을 OECD 자료에 적용하되, 산출·소비 구조를 반영한 다부문 일반균형모형을 통해 Baumol 효과와 부문 간 재배치 제약을 고려한 결과, 10년 기준 연간 0.25~0.6%p의 TFP 상승, 노동생산성 기준으로는 0.4~0.9%p의 추가 성장률을 제시한다. 이에 비해 본 연구의 Baseline은 생성형 AI 상용화 이후 10년 동안 2.3%, 연간 0.23%p의 TFP

<표 5-2> AI의 거시경제 효과를 분석한 논문들의 가정 및 분석 결과

구분	Briggs <i>et al.</i> (2023)	Aghion and Bunel(2024)	OECD(2024)	Acemoglu (2024)	본 연구
생산성 이득/ 비용절감	30%	27~40%	30%	27%	20%
AI 노출 비중	66%	18.5~68%	12~50%	20%	17%
AI 도입률/ 경제성 비중	50%	23~80%	23~40%	23%	8~47%
연평균 TFP 성장기여도	1.0%p	0.68%p	0.25~0.6%p	0.064%p	0.23%p

자료: OECD(2024)의 Table 1 수정 인용 및 저자 작성.

성장기여도를 추정하고 있어, Acemoglu(2024)의 보수적 추정보다는 높지만 Aghion and Bunel(2024)이나 Filippucci *et al.*(2025)보다는 낮은 수준에 위치한다. Acemoglu(2024)의 경우 AI 노출을 CV만 고려하였으나, 본 연구는 AI 모달리티 전반을 고려하여 AI 자동화 가능성을 분석하였다. 다만, 본 연구가 개발한 AI 자동화 지표와 생산성 향상 계수(제3·4장)가 기존 문헌이 사용하는 미국·유럽 기준치에 비해 낮게 추정된 점이 전반적인 추정치를 낮춘 것으로 판단한다. 그러나 다른 문헌과는 다르게 산업별 Domar 가중치를 사용함으로써 제조·ICT·전문서비스 등 고노출 부문의 승수효과를 반영한 것은 합리적이라고 판단한다. 반면, 본 장의 모형은 Baumol 효과나 새로운 과업 창출(creation of new tasks)과 같은 추가 채널을 명시적으로 포함하지 않으므로, 본문에서 제시한 수치는 한국경제에서 AI가 가져올 장기 TFP 상한선이라기보다는 현재 가용한 실증 근거와 보수·낙관 시나리오를 종합했을 때 기대할 수 있는 합리적인 범위로 해석하는 것이 적절할 것으로 보인다.

나. Hulten 1차 근사의 한계

Baqae and Farhi(2019)는 본 연구에서 사용한 Hulten식 1차 근사가 미시적 충격이 작고 균등하게 분포된 상황에서는 유용하지만, 특정 부문에

대규모 생산성 충격이 집중되거나, 산업 간 대체탄력성이 낮고 공급망이 복잡한 경우에는 비선형 효과를 무시하여 TFP를 체계적으로 과대추정할 수 있음을 보여준다. 이들은 산업별 생산성 충격을 토대로 고차항을 포함하는 일반균형 탄력성을 비선형 함수로 추정함으로써, 공급망 연결성, 규모수익의 비정형성, 요소 재배치 제약 등을 포착하고자 하였다. Filippucci *et al.*(2025)은 이러한 방법론을 AI의 거시효과에 적용하여, 단일 Hulten 1차 근사가 제시하는 10년 기준 TFP 기여도가 대부분 일반균형과 비선형 집계를 고려할 경우 17~33% 정도 과대추정될 수 있음을 보인다. 특히 소비재 간 대체탄력성이 낮고, AI 생산성 충격이 특정 고부가 서비스 부문에 편중되며, 산업 간 노동의 재배치가 제약되는 상황에서 Baumol의 비용질병이 강화되어, 생산성이 높은 부문의 상대가격과 산출 비중이 빠르게 하락하는 메커니즘을 정량적으로 제시하였다.

본 연구는 아쉽지만, 투입-산출표와 가격·수량(매출액) 및 산업별 TFP 데이터의 기간이 충분하지 못해 Baqaee and Farhi(2019)의 비선형 추정을 수행하기 어려웠다. 다만, 한국생산성본부의 중분류 산업별 TFP와 국가데이터처의 「전국사업체조사」의 매출자료를 결합하여, 2017~21년 사이 TFP 성장률을 1차 근사와 비선형 근사로 각각 재구성한 후, 두 방식의 차이를 오차율의 형태로 평가하였다.⁸²

$$\Delta \ln TFP^{1차 근사} = \sum_q \lambda_{q2016} (\ln A_{q2021} - \ln A_{q2016}),$$

$$\Delta \ln TFP^{비선형} = \sum_q \sum_{t=2016}^{2020} \lambda_{qt} (\ln A_{qt+1} - \ln A_{qt}).$$

<표 5-3>에 따르면, 팬데믹이 포함된 2017~21년의 5년 동안 총산출 기준 TFP 성장률은 1차 근사로 3.01%, 비선형 근사로 2.88%로 추정되며, 두 값의 차이는 0.13%p, 오차율로 환산하면 약 5% 수준으로 나타난다. 이를 10년 기간으로 환산할 경우 누적 오차율은 약 10.3%로 추정되는데,

82 국가데이터처의 「전국사업체조사」의 경우 2016년부터 매출액을 조사하여 충분한 기간의 산업별 매출액 규모를 확보하기 어려웠다.

<표 5-3> TFP 성장률 추정 방법 비교(2017~21년, 총산출 기준)

(단위: %, %p)

1차 근사			비선형 근사			1차 근사-비선형 근사		
전체	비교역	교역	전체	비교역	교역	전체	비교역	교역
3.01	1.71	1.30	2.88	1.47	1.41	0.13 (5)	0.24 (16)	-0.11 (-8)

주: 괄호 안은 5년간 비선형 근사 대비 1차 근사의 오차율(%).

자료: 국가데이터처, 「전국사업체조사」; 한국생산성본부 홈페이지(최종접속일: 2025. 10. 25)를 바탕으로 저자 작성.

이는 Filippucci *et al.*(2025)이 G7 국가를 대상으로 보고한 17~33% 범위에 비해 낮은 값이다. 이러한 결과는 우리나라의 산업구조 및 수요구조가 전형적인 선진 서비스경제와는 상이하여, Baumol 효과가 TFP에 미치는 부정적 영향이 상대적으로 제한적일 수 있다는 점에서 시사하는 바가 있다.

좀 더 구체적으로 보면, 본 연구는 산업을 2016년 기준 수출수요에 의한 부가가치 유발 비중이 전 산업 평균(27.2%) 이상인 교역재산업(tradable)과 그 미만인 비교역재산업(non-tradable)으로 구분한 뒤, 두 집단별 TFP 성장률을 다시 1차 근사와 비선형 근사로 비교하였다. 그 결과, 비교역재산업에서는 5년간 비선형 추정치 대비 1차 근사 오차율이 16%로 나타나 Baqaee and Farhi(2019)와 Filippucci *et al.*(2025)이 강조한 방향과 유사한 과대추정이 확인된다. 반면, 교역재산업에서는 오히려 -8%의 오차율, 즉 1차 근사가 비선형 추정치에 비해 TFP 성장률을 과소추정하는 결과가 나타났다. 이는 Baumol 효과가 주로 내수 중심의 저생산성 부문에서 가격에 비탄력적인 수요와 임금동조성으로 인해 상대가격과 매출 비중이 상승하는 반면, 수출 중심의 고생산성 교역재산업에서는 생산성 향상이 역외 수요 확대와 시장점유율 상승으로 이어져, 상대가격 하락이 매출 비중의 급격한 하락으로 이어지지 않았다고 해석할 수 있다.

이러한 해석의 근거는 우선 Nordhaus(2006)가 미국 산업을 대상으로 Baumol 가설을 계량적으로 검증하면서 생산성 충격이 각 부문의 산출과 고용에 미치는 영향이 궁극적으로는 수요의 가격탄력성에 의해 결정된다

는 점과 일치한다. 즉, 가격탄력성이 높은 부문에서는 생산성 향상으로 상대가격이 하락해도 산출 증가가 더 크게 나타나 고용과 매출이 확대되지만, 탄력성이 낮은 부문에서는 상대가격 상승과 수요 위축으로 산출 비중이 줄어들어 Baumol 효과가 강화된다는 것이다. 한국경제처럼 IT 제조업과 일부 지식기반 서비스에서 수출 중심의 고생산성 산업이 큰 비중을 차지하는 경우, 이러한 부문들은 국내 수요 대신 세계시장의 수요탄력성을 주로 마주하게 되고, 생산성 향상이 상대가격 하락보다는 수출 확대와 글로벌 분업구조 내 재배치 확대를 통해 실현되기 때문에 Baumol 식의 구조 변화가 약화될 가능성이 있다.

또한 최근 서비스무역 연구에 따르면, 전통적으로 비교역재로 분류되어 온 상당수 고부가 서비스업종이 실제로는 제조업 못지않은 수준의 낮은 무역비용을 가지고 국제적으로 거래되고 있으며, 이러한 부문은 지역별 수요에 비해 생산이 특정 거점에 집중되고, 생산성 향상이 지역 간·국가 간 교역 흐름을 통해 곧바로 산출 확대와 임금 상승으로 이어지는 경향을 보인다는 것이다. Gervais and Jensen(2019)은 미국의 900여 개 제조·서비스 산업을 대상으로 지역 간 과잉공급지수와 무역비용을 추정한 결과, 소프트웨어, 비즈니스 서비스 등 일부 서비스업종은 전통적인 제조업과 유사한 수준의 낮은 무역비용과 높은 지리적 집중도를 보이는 반면, 진정한 비교역서비스는 세무대리, 소매, 건설과 같이 지역에 분산된 업종이라는 점을 보여준다. 이러한 결과는, 수출 중심의 고부가 서비스와 제조업이 결합된 경제에서는 고생산성 부문 상당수가 실질적으로 교역재로 작동하여, 생산성 격차에 따른 노동 재배치가 내수용 저생산성 서비스로만 흘러가지 않고, 외수(역외 수요)를 향한 확장으로 상당 부분 흡수될 수 있음을 시사한다. 한국경제에 대한 선행연구(Oh and Kim, 2015) 역시 비생산적 서비스 비중 확대와 Baumol 효과를 지적하면서도 제조업 및 일부 서비스의 수출 확대가 전체 성장 둔화를 완충해 온 측면을 함께 강조한다는 점에서 본 연구의 해석과 일치한다.

이러한 맥락에서 보면, 짧지만 우리나라 자료에서 추정한 1차 근사와 비선형 근사 간 TFP 성장률 오차율이 10년 기준 약 10% 수준에 머무르

는 것은, 첫째, 교역재 중심 산업에서 생산성 충격이 외수 확대로 이어져 Baumol식 구조 변화가 상대적으로 약하게 나타나고, 둘째, 고부가 서비스 중 상당 부분이 실질적인 교역재로 작동하여 전형적인 내수 서비스 중심 경제에 비해 저생산성 부문으로의 노동 재배치 압력이 덜하기 때문으로 해석할 수 있다. 반대로 비교역재산업에서는 Filippucci *et al.*(2025)이 OECD 국가에서 보여준 것과 유사하게 1차 근사가 비선형 추정치를 10% 이상 과대추정하고 있으며, 이는 국내 수요의 비탄력성과 규제·입지 등으로 인해 생산요소 재배치가 지연되는 전형적인 Baumol 효과의 패턴으로 이해할 수 있다.

마지막으로, 이러한 1차 근사의 오차구조는 AI 도입으로 인한 10년 TFP 성장기여를 해석할 때도 중요한 의미를 갖는다. 본 연구가 제시하는 AI의 10년 TFP 기여는 기본 시나리오에서 1.5~3.5% 수준으로 추정되며, 연평균 추가 성장률로 환산하면 0.15~0.35%p에 해당한다. 앞서의 비교에서 한국경제의 1차 근사 오차율이 약 10% 수준이라는 점을 감안하면, AI의 TFP 기여도 역시 교역재 중심 산업에서의 긍정적 효과를 고려하더라도 10년 기준으로 0.13~3.1%로 기존 추정치에 비해 약 10% 정도는 하향 조정될 여지가 있다. 그럼에도 불구하고 이는 여전히 Acemoglu(2024)가 제시하는 보수적인 추정치보다는 높고, Filippucci *et al.*(2025)의 G7 시나리오보다는 낮은 수준을 보인다. 다시 말해, 수출 중심의 산업구조와 높은 교역재 비중 덕분에 한국경제는 Baumol 효과에 따른 구조적 성장 둔화가 상대적으로 약화될 수 있으나, 내수 서비스 부문에서의 비선형 효과와 재배치 제약을 감안할 때, Hulten식 1차 근사가 제공하는 AI의 거시적 성장 효과는 경험적으로 약 10% 정도 과대추정될 수 있다는 결론을 내릴 수 있다. 다만, AI의 생산성 효과는 중간재 거래, 업무 재배치, 산업 간 연쇄적 파급효과를 통해 확산될 수 있으므로, Baumol 효과에 따른 조정폭을 기계적으로 최종 추정치에 반영하지는 않았다. 따라서 본문의 수치는 구조 변화와 전 산업 파급효과가 충분히 반영된 기준선 추정치로 해석할 필요가 있다.

제2절 AI 활용이 장기 고용 및 임금에 미치는 영향


AI와 자동화 기술의 확산이 장기적으로 노동시장에 미치는 영향은 최근 거시노동 경제학의 핵심 쟁점으로 부상하고 있다. 특히 Acemoglu and Restrepo(2018, 2022) 및 Acemoglu(2024)는 앞서 본 연구가 설명한 것처럼 생산을 과업(task)의 묶음으로 보는 관점을 도입하여, 새로운 기술이 기존의 노동이 수행하던 과업을 자동화할수록 해당 과업에 특화된 노동 수요와 임금이 구조적으로 감소할 수 있음을 이론 및 실증적으로 제시하였다. 이들 연구에 따르면, 자동화로 인한 생산성 제고와 신규 과업 창출이 충분히 크지 못한 경우, 장기균형에서 특정 직종·기술수준 집단에 대한 수요가 줄어들고, 임금불평등과 노동소득분배율 하락으로 이어질 수 있다. 따라서 AI의 확산이 향후 10년 이상에 걸쳐 고용과 임금의 수준·분포를 어떻게 재편하는지 평가하는 것은, 단기 경기변동을 넘어선 구조적 변화를 이해하기 위한 필수 과제가 된다.

본 연구는 고용노동부의 「고용형태별근로실태조사」의 한국표준직업분류 중분류 직종을 대상으로, 지난 10년(2014~24년) 동안 정형과업(定型課業, routine task) 비중이 높은 직종에서 실제로 고용규모와 시간당 실질임금이 어떻게 변화해 왔는지를 먼저 살펴본다. [그림 5-2]에서 확인되듯이, 직종별 정형과업 비중이 높을수록 고용증감률이 낮고, 임금상승률 역시 상대적으로 낮게 나타나는 뚜렷한 음의 관계가 관찰된다. 이는 단순한 상관관계에 불과하지만, 정보수집·기록저장·정리가공과 같이 규칙 기반으로 쉽게 전산화·기계화될 수 있는 과업이 지난 10년간 다양한 형태의 디지털 기술과 자동화 설비에 의해 대체되었을 가능성을 시사한다. 특히 직종 외부의 고용이 확대될수록 해당 직종의 고용이 감소하는 패턴은, 국내 노동시장에서도 자동화와 구조조정이 직종 간 재배치를 동반한 장기 균형조정으로 나타났음을 암시한다.

이러한 과거 10년의 경험을 바탕으로, 본 절에서는 10년의 장기 횡단면회귀와 도구변수 추정을 통해 얻은 계숫값을 이용하여 향후 10년간 경제성 있는 AI 자동화가 직종별 고용과 임금에 어떠한 영향을 미칠지 모

[그림 5-2] 직종별 시간당 임금 상승률 및 고용규모 증감률

(단위: %)



주: 추세선은 단순회귀선, 동그라미의 크기는 해당 직종의 고용규모 비중을 나타냄.
 자료: 고용노동부, 「고용형태별근로실태조사」 및 임금직업포털(최종접속일: 2025. 10. 25)을 바탕으로 저자 작성.

의실험적으로 평가한다. 구체적으로는 직종별 정형과업 비중과 경제성 있는 AI 자동화 가능 과업 비중을 과업기반 자동화 강도의 지표로 사용하고, 과거 자료에서 추정된 고용/임금 반응 계수를 장기 추세에 적용함으로써, AI 기술 확산이 현재의 직종구조를 어떤 방향으로 재편할지, 그리고 그 과정에서 어느 직종이 일자리 감소와 임금 정체에 더 취약한지를 정량적으로 제시하고자 한다. 이는 단순한 예측을 넘어, AI 자동화 시나리오들 간의 상대적 위험과 분배 효과를 비교하는 데 목적이 있다.

아울러 본 절에서는 노동시장 논의에서 자동화(automation)와 대체(substitution 또는 displacement)를 명확히 구분하고자 한다. 자동화는 기술이 기존에 인간이 수행하던 특정 과업을 수행하게 되는 현상으로, 직

업 전체가 사라지지 않더라도 작업방식의 변화와 효율성 제고를 통해 동일 산출을 더 적은 노동으로 달성하게 만드는 과정이다. 반면, 대체는 기술이 노동자의 역할 자체를 전면적으로 대신하여 해당 일자리(직무·직종)가 실질적으로 소멸하는 결과에 초점을 둔다. 동일한 자동화 수준이라도, 신규 과업창출과 직종 내 업무 재설계를 통해 노동이 다른 역할로 재배치될 경우에는 자동화는 진전되지만, 대체는 제한되는 균형이 가능하며, 반대로 구조조정과 인력감축 위주로 조정이 이루어질 경우에는 자동화가 곧 대체와 일자리 상실로 이어질 수 있다. 따라서 AI 기술 확산에 대한 정책 대응 역시, 자동화 자체를 막기보다는 어떤 조건·직종에서 자동화가 대규모 대체로 귀결되는지를 식별하고, 재교육·직종전환·사회안전망을 통해 대체위험이 높은 집단을 중심으로 완충장치를 설계하는 방향으로 차별화될 필요가 있다. 본 절의 분석은 이러한 정책적 논의를 뒷받침할 수 있도록, AI 기반 자동화가 장기적으로 한국 노동시장의 고용과 임금 구조에 미치는 영향을 직종 수준에서 체계적으로 정량화하는 것을 목표로 한다.

1. 분석방법론

장기 노동시장을 분석하기 위해서는 고용·임금 등의 상호 내생적 관계와 거시경제적 장기 추세를 어떻게 통제하느냐가 중요한 문제가 된다. 장기 노동시장에서 고용과 임금을 분석할 때 내생성 문제를 항상 고려해야 하는 이유는, 관측되는 변수들 사이의 관계가 단순한 일방향 인과가 아니라 상호결정적인 일반균형 과정의 산물인 경우가 많기 때문이다. 예를 들어 기술진보나 자동화 충격은 특정 직종의 고용과 임금에 영향을 미치지만, 동시에 임금수준과 고용조정이 다시 기업의 기술 도입 인센티브와 생산조직에 영향을 줄 수 있다. 또한 관측 불가능한 요인들, 예컨대 직종별 비가시적 숙련, 직업선택과 매칭의 질, 기업수준의 생산성 충격, 지역·산업별 정책과 규제 환경 등은 고용·임금과 설명변수(정형과업비중, AI 노출도, 산업구조 변화 등)에 공통으로 작용할 가능성이 높다.

이러한 요인들을 적절히 통제하지 못하면, 추정된 계수는 기술·자동화가 고용과 임금에 미치는 순수한 효과를 반영하기보다, 역인과관계(예: 임금상승이 자동화 투자와 직종 구성에 영향을 미치는 경우)와 누락변수 편의(예: 성장산업에 몰린 직종의 특성과 자동화 도입이 동시에 변하는 경우)가 섞인 결과가 된다. 특히 장기자료에서는 경기순환, 인구구조 변화, 교육·훈련 제도 변화 등이 함께 작동하기 때문에, 단순한 상관관계를 기술의 영향으로 해석할 유인이 크지만, 이 경우 정책적 함의가 심각하게 왜곡될 수 있다. 따라서 자동화·AI가 장기적으로 고용과 임금에 미치는 영향을 식별하기 위해서는, 도구변수 등 내생성에 대한 체계적인 식별 전략을 채택하여, 관측된 변화가 기술 충격의 결과인지, 아니면 기술 도입과 동시에 움직이는 다른 구조적 요인의 반영인지를 최대한 분리해내는 것이 필수적이다. 따라서 본 연구에서는 제3장의 패널 IV 분석과 비슷하지만, 장기 10년의 변화를 한 번에 추정하는 준구조적 횡단면 IV 분석(2SLS)을 수행한다. 왜냐하면 연도별 분석은 AI 충격 시점을 특정해야 하고, 2014년부터 2024년까지 한국경제에는 디지털 전환·플랫폼·코로나·반도체 경기 등 동시다발적 충격이 많아서 오히려 분석 결과의 해석이 불안정할 수 있을 것으로 판단되기 때문이다.⁸³

본 분석에서는 고용노동부 「고용형태별근로실태조사」에 나타난 2014~24년의 10년간 직종별 고용규모의 로그차분과 시간당 실질임금의 로그차분을 종속변수로 사용한다.⁸⁴ 2014~24년의 직종별 과업 자동화를 대표하는 변수로는 정형과업의 비중을 선택하였다. 특히 정형과업(routine task)은 제3장의 단위과업에서 과업행위(verb)가 정보수집·기록저장·정리가공에 해당하고, 과업대상(object)은 정보객체·추상/지식/환경으로 제한하여 과업이 반복·규칙·예상 가능하지만, 상대적으로 고난이도 AI 기능은 필요하지 않은 과업으로 정의하였다.⁸⁵ 이러한 정형과업 비중은

⁸³ 횡단면 분석일지라도 로그차분을 분석하면, 해당 직종이 가진 시간에 따라 변하지 않는 고유한 특성(time-invariant unobservables)은 차분 과정을 통해 제거된 것으로 간주할 수 있다.

⁸⁴ 시간당 임금은 생산 과정에서의 노동비용 측면에서 총산출물가지수를 이용하여 실질화하였다.

사전적으로 정의된 것으로 기술 도입에 따른 자동화를 직접적으로 측정하지는 않으나, 기술발전에 따른 자동화 가능성을 대리(proxy)할 수는 있을 것으로 판단된다.⁸⁶ 더불어, 직종 간 자동화 압력 혹은 과업대체(task displacement)의 파급효과(ripple effect)를 추정하기 위해 Acemoglu and Restrepo(2022)가 사용한 Inverted-Sigmoid 함수를 이용하여 직종 간 거리로 가중화된 정형과업의 비중을 생성하였다. 이 변수는 추후 고용 및 임금을 분석하는 데 독립변수 및 도구변수로 사용된다.

또한 기술 변화가 숙련·인구 집단별로 상이한 영향을 미친다는 숙련편향적 기술진보(Skill-Biased Technological Change: SBTC) 가설과 연관된 노동공급 측 구조를 요약하는 통제변수로 직종별 평균 연령, 성별, 학력 구성을 사용한다.⁸⁷ 다만, 이 변수들은 SBTC의 직접 측정치라기보다는, 직종별 숙련·생애주기·성별 구성이라는 공급 측 노동자의 이질성을 반영하면서 SBTC와 연관된 수요효과를 함께 대리하는 구성통제(compositional controls)라는 점을 유의하기 바란다. 그리고 마지막 통제변수로 직종 간 임금프리미엄을 통제하기 위해 2014년 시간당 임금의 로그값을 사용한다.

마지막으로 도구변수(IV)로는 세 변수를 사용하는데, 우선 앞서 설명한 정형과업 비중에 파급효과를 반영한 변수는 다음과 같이 정의된다.

$$\sum_j \frac{r_j^R}{(1 + \exp(|d_{ij}|))},$$

-
- 85 Webb(2020), 한국은행(한지우·오삼일, 2023)은 산업용 로봇지수, 소프트웨어 지수를 자동화 노출변수로 사용하였는데, 이들의 경우 본문에서 설명한 역인과관계(고용조정이 기술 개발 및 도입을 촉발)를 완전히 배제하기 어려울 것으로 판단된다.
- 86 TFP 추정에서는 *AI score*와 *Eco(sc)*를 사용하였으나, 고용·임금 분석에서는 정형과업 비중을 사용한 것은 두 지표의 역할이 다르기 때문이다. *AI score*와 *Eco(sc)*는 향후 AI 충격의 크기와 잠재 규모를 측정하는 지표로 사용되는 반면, 정형과업 비중은 생성형 AI 상용화 이전 기간(2014-24년)의 자동화 압력에 대한 노동시장 반응계수(준탄력도)를 식별하기 위한 대리변수이다. 따라서 본 연구는 과거 자동화 경험으로부터 추정한 고용·임금 준탄력계수를 제3장의 AI 노출·경제성 지표와 결합하여 미래 AI 확산의 장기 영향을 예측한다.
- 87 국가데이터처의 2013년 하반기 및 2024년 하반기 「지역별고용조사」 자료를 이용하여 평균값을 사용한다.

여기서 r_j^R 는 직종 j 의 정형과업 비중이며, d_{ij} 는 직종 i 와 j 의 거리이다. 따라서 가까운 거리, 특히 동일한 직종 대분류⁸⁸에 속해 있는 중분류 직종의 정형과업 비중은 옆 직종에 상당한 영향을 미칠 수 있도록 구조화한 변수이다.

두 번째 IV는 정형과업의 대체수요 압력뿐 아니라 보완적 생산성 효과, 신규 과업창출 및 정책적 변화 등의 노동수요 충격을 대리할 변수로, leave-one-out 방식으로 해당 직종이 속한 대분류 직종의 고용규모 변화(로그차분)를 사용한다.

$$\ln\left(\sum_{-i}^{\text{대분류}(i)} \text{고용}_{m2024}\right) - \ln\left(\sum_{-i}^{\text{대분류}(i)} \text{고용}_{m2014}\right).$$

마지막 세 번째 IV는 해당 직종을 제외한 나머지 직종들의 고용규모 변화(로그차분)를 사용하여 국가 전체의 경기 추세, 전반적인 산업구조의 변화 등 거시적인 노동 수요·공급 충격을 내재적으로 포착하고자 한다.

$$\ln\left(\sum_{-i}^{\text{전직종}} \text{고용}_{m2024}\right) - \ln\left(\sum_{-i}^{\text{전직종}} \text{고용}_{m2014}\right).$$

따라서 위의 IV들을 통해 별도의 거시 및 산업 성장률 변수가 없더라도 leave-one-out 변수가 해당 직종이 직면한 외부적 경제 환경을 대리하도록 한다. 특히 첫 번째는 해당 직종의 자동화 대체 충격, 두 번째는 주변 직종의 노동시장 충격, 세 번째는 거시산업적 노동시장 충격으로 분해하여 이해할 수 있다.

본 연구는 위의 종속변수들 및 독립(통제)변수들을 사용하여 다음과 같은 횡단면 IV 분석을 수행한다.

$$\ln \text{고용}_{i2024} - \ln \text{고용}_{i2014} = \mu_e + X_i^{E'} \beta_e + \nu_{ie}. \quad (5.E)$$

⁸⁸ 한국표준직업분류에 따르면 대분류는 관리자, 전문가, 사무원, 서비스직, 판매직, 농림어업 숙련자, 기능원, 생산직, 단순노무직 등으로 나뉜다. 따라서 같은 대분류에 속하는 직종은 산업이 다르더라도 숙련도가 비슷하고 과업의 성격이 유사할 수 있어 자동화의 압력을 공유할 수 있다.

식 (5.E)는 2014-24년 사이 직종별 고용 변화를 분석하는 횡단면 회귀식으로 정형과업 비중, leave-one-out 전체 고용규모 차분, 2014년 임금프리미엄, 연령·성별·학력을 독립변수로 사용하되, 아래의 임금식과는 다르게 IV를 사용하지 않는다. 이유는, 우선 이 식에서는 잠재적 내생성이 상대적으로 큰 변수(직종별 고용 변화)는 오른쪽이 아니라 왼쪽에 위치한다. 또한 해당 통제변수들은 모두 기준 시점(2014년)의 정태적 특성(정형과업 비중, 임금프리미엄, 연령·성별·학력 구성) 또는 해당 직종을 제외한 전체 고용조정의 집계지표(leave-one-out 고용차분)로, 분석기간 내 직종별 고용증가율에 비해 시간상 선행·외생적 성격이 강해, 어떤 초기 특성을 가진 직종이 10년간 더 많이 줄거나 덜 늘어났는가를 장기 재배치 패턴을 설명하는 데 초점을 두기 때문이다. 둘째로는 leave-one-out 고용차분은 개별 직종의 고용 변화를 설명하기 위해 사용되는 광의의 거시·구조적 충격지표로 해당 직종의 고용조정과의 동시 결정성이 상대적으로 약하므로, 별도의 도구변수 없이도 공통 충격을 통제하는 설명변수로 활용하는 것이 가능하다. 세 번째는 이 회귀식의 역할은 임금식에서 내생적 설명변수로 다루어지는 고용증감률을 도출·식별하기 위한 구조식을 추정하는 것이라기보다, 정형과업 비중과 초기 직종 특성이 장기 고용조정과 어떤 방향의 상관관계를 보이는지를 기술하고, 이후 AI 자동화의 대체시나리오에 사용할 준탄력도(계수)를 얻기 위한 실증적 단계이기 때문이다.⁸⁹

89 식 (5.E)에 2014년 임금프리미엄뿐 아니라 직종별 임금 변화율까지 추가로 포함할 필요성은 크지 않으며, 오히려 분석목적에 고려하면 제외하는 것이 더 적절할 수 있다. 식의 핵심 목적은 초기 시점의 직종 특성(정형과업 비중, 임금프리미엄, 연령·성별·학력 구성)과 외생적·거시적 수요지표(leave-one-out 고용 변화)가 향후 10년간의 고용조정에 어떤 방향의 상관관계를 갖는지를 파악하는 데 있다. 이때 임금 변화율은 고용 변화와 동일 기간에 동시에 결정되는 결과변수로, 동일한 수요·기술·제도 충격에 의해 함께 움직이는 내생변수이기 때문에 이를 설명변수로 포함할 경우, (i) 고용조정에 대한 기술·자동화 충격의 효과를 임금 경로를 통해 부분적으로 빼버리는 일종의 bad control 문제가 발생할 수 있고, (ii) 고용 변화와 임금 변화가 공통 충격에 의해 공동결정되는 동시방정식 구조에서 강한 내생성을 추가로 유입시킬 가능성이 크다. 반면, 2014년 임금프리미엄은 기준 시점의 직종별 생산성·숙련 프리미엄 및 장기 구조적 지위를 요약하는 정태적 지표로서, 평균회귀와 초기 직종 위상을 통제함으로써 이후 고용성장률과의 관계를 보다 안정적으로 식별하는 데 기여한다. 따라서 식 (5.E)에서 임금 변화율까지 통제변수로

다음으로 10년 임금 변화를 분석하는 횡단면 IV 분석은 다음과 같다.

$$Z_i^{E'} = \mu_1 + IV_i' \gamma_{w1} + X_i^{W'} \beta_{w1} + \nu_{i1}, \quad (5.W1)$$

$$\ln \text{임금}_{i2024} - \ln \text{임금}_{i2014} = \mu_2 + \widehat{Z}_i^{E'} \gamma_{w2} + X_i^{W'} \beta_{w2} + \nu_{i2}. \quad (5.W2)$$

위 식 (5.W1), (5.W2)는 2014~24년 직종(중분류) 임금 변화를 분석하기 위해 사용하는 2단계 최소자승법(2SLS)이다. 장기균형에서 임금과 고용이 공동결정된다는 점을 반영하여 설계되었다. 우선 종속변수는 직종별 10년 시간당 실질임금 변화이고, 핵심 설명변수는 동일 기간의 직종별 고용 변화와 정형과업 비중이다. 그러나 고용 변화는 임금수준, 직종 매력도, 기업의 기술 도입 결정을 통해 임금과 동시에 결정되는 전형적인 내생변수이다. 또한 정형과업 비중은 식 (5.E)와는 다르게 임금식에서는 임금 충격과 상관된 누락변수(예를 들어 직종별 비가시적 생산성, 노동조합력, 직종별 선호도)에 의해 편의가 발생할 가능성을 완전히 배제하기는 어렵다.⁹⁰ 이에 따라 1단계 식 (5.W1)에서는 우선 직종별 고용 변화를 내생변수로 두고, 필요할 경우 정형과업 비중까지 내생변수로 확장한 뒤, 2단계 식 (5.W2)에서 IV로부터 예측된 외생적 성분만을 사용하여 임금 변화의 반응계수를 추정한다. 이때 2014년 시간당 임금 로그값은 직종별 초기 임금프리미엄과 평균회귀를 통제하기 위한 지표로 포함되며, 평균 연령 · 성별 · 학력은 SBTC와 관련된 직종별 숙련 · 구성 요인을 반영하는 노동공급 통제변수로 사용되어, 자동화 · 고용조정 효과와 장기적 공급 구성 변화를 구분하는 역할을 한다.

사용하는 것은, 인과효과 식별 측면에서도, 이후 고용 변화와 임금 변화를 분리해 분석하려는 구조적 해석 측면에서도 바람직하지 않으며, 임금 변화율은 별도의 임금식에서 고용 변화 및 정형과업 비중의 결과로 해석하는 것이 이론적으로도 더 정합적이다.

⁹⁰ 식 (5.W2)에서는 10년 고용 변화가 명시적으로 내생변수로 들어가고, 고용조정과 정형과업 비중이 공통된 기술 · 수요 충격과 직종별 비가시적 생산성에 의해 동시에 결정될 가능성이 있기 때문에, 임금식의 계수는 고용식보다 강한 인과적 해석이 요구된다. 특히 정형과업 비중은 장기적으로 자동화 도입과 직무 재설계의 결과로 조정될 수 있고, 그 과정에서 임금수준 자체가 자동화 인센티브와 과업 구성 변화에 영향을 미칠 수 있어, 임금식에서 정형과업 비중이 임금 충격과 상관된 누락변수 편의를 야기할 가능성을 배제하기 어렵다.

IV로 사용하는 leave-one-out 전체 고용규모 차분과 leave-one-out 대분류(상위 직종군) 고용규모 차분은, 특정 직종을 제외한 나머지 노동시장에서 발생한 장기 수요·구조 충격을 요약한 지표로서, 개별 직종의 임금 충격에는 직접적으로 영향을 미치지 않으면서 그 직종의 고용조정 압력에는 강하게 작용하는 요인들이다. 이는 Acemoglu and Restrepo(2022)의 산업 구성 변동 요인(industry shifter)과 유사하게, 직종 외부에서 발생한 산업·직종군 수준의 성장·수축을 활용해 각 직종의 고용 변화를 도구화하는 전략이다. 아울러 정형과업 비중을 내생변수로 취급하는 확장 사양에서는, 직종 간 과급효과를 반영한 정형과업 비중(과업대체 압력의 ripple effect)을 추가 도구로 활용한다. 이는 유사 직종에서 자동화가 진전될수록 해당 직종에도 자동화 압력이 전이된다는 기술적 과급구조를 반영하되, 개별 직종의 임금 충격과는 비교적 독립적인 외생적 기술 압력으로 해석할 수 있기 때문에 정형과업 비중의 내생성을 완화하는 데 유용할 수 있다. 이러한 IV 구성과 초기임금·SBTC 통제를 결합함으로써, 2단계 식 (5.W2)에서 얻는 고용 변화 및 정형과업 비중에 대한 계수는 향후 AI 자동화에 의해 유도된 외생적 고용대체 압력과 자동화 취약성이 임금에 미치는 준구조적 효과로 사용할 수 있다.

2. 분석 결과

본 절에서는 앞서 제시한 장기 횡단면 IV 모형에 기초하여, 2014년부터 2024년까지 10년 동안 한국표준직업분류 중분류 직종을 대상으로 추정한 고용 및 임금 회귀모형의 실증 결과를 살펴본다. 본격적인 회귀분석에 앞서 <표 5-4>는 추정에 사용되는 주요 변수들의 기초통계량을 제시하고 있으며, 이는 이후 제시될 계수 해석이 어떤 데이터 분포를 전제로 하는지 이해하는 데 도움이 될 것이다. 직종별 로그(고용) 차분의 평균은 0.133, 표준편차는 0.390으로, 일부 직종에서는 10년간 고용이 100% 이상 증가한 반면(최대 1.13), 반대로 70% 이상 감소한 직종도 존재하는 등(-1.18) 중분류 수준에서 상당한 이질적 조정이 있었음을 보여준다. 로

<표 5-4> 주요 변수 기초통계량(로그값)

(단위: %)

변수	관측치 수	평균	표준편차	최소	최대
로그(고용) 차분	51	0.133	0.390	-1.18	1.13
로그(시간당 임금) 차분	51	0.261	0.130	-0.128	0.628
정형과업 비중	51	6.26	5.91	0	26.6
정형과업 비중(파급)	51	4.09	1.89	0.58	10.6
로그(직종 외 고용) 차분	51	0.279	0.006	0.254	0.295
로그(시간당 임금 ₂₀₁₄)	51	8.0	0.45	7.3	9.4
연령	51	44.4	5.23	35.2	59
성별	51	1.29	0.26	1	1.9
학력	51	3.92	0.80	2.6	5.9
고용 비중(2014)	51	1.96	3.53	0.01	22.9

주: 비중은 %.

자료: 고용노동부, 「고용형태별근로실태조사」, 「지역별고용조사」 및 임금직업포털(최종접속일: 2025. 10. 25).

로그(시간당 임금) 차분의 평균은 0.261, 표준편차는 0.130으로, 임금의 경우 전반적으로 완만한 상승 추세를 보이지만 직종 간 격차가 적지 않음을 확인할 수 있다.

정형과업 비중은 평균 6.26%, 표준편차 5.91%로, 일부 직종에서는 정형적 정보처리·기록저장·정리가공 과업이 거의 없는 반면(최소 0%), 다른 직종에서는 전체 과업의 4분의 1 이상이 정형과업으로 구성되어 있다(최대 26.6%). 정형과업 비중(파급)은 평균 4.09, 표준편차 1.89 수준이며, 이는 개별 직종의 내부 과업 구성뿐 아니라, 유사 직종에서 발생한 자동화 압력의 파급효과까지 반영한 네트워크형 자동화 취약성을 요약한다. 로그(직종 외 고용) 차분은 평균 0.279로 분산이 매우 작아, 전체 노동시장 또는 장기 고용 성장률이 비교적 고르게 분포해 있음을 시사한다. 로그(시간당 임금₂₀₁₄)의 평균은 약 8.0, 표준편차 0.45로, 기준 시점 임금 프리미엄과 직종 간 초기생산성 격차를 반영한다. 연령, 성별, 학력 변수는 각각 직종별 평균 연령(44.4세), 남성 비중지표(평균 1.29: 남성 1, 여성 2), 교육수준(평균 3.92: 초대졸 3, 대졸 4 사이에 위치)을 나타낸다.

마지막으로 2014년 고용 비중은 각 직종이 전체 취업자에서 차지하는 비중을 의미하며, 평균 1.96%, 최대 22.9%로 나타나, 일부 대규모 직종이 전체 고용구조를 지배하고 있음을 보여준다. 따라서 본 연구는 2014년 직종별 고용 비중을 회귀식의 설명변수로 포함하는 것이 아니라, 분석 전반에서 사용되는 가중치로 활용한다. 이는 전체 고용에서 차지하는 비중이 큰 직종일수록 거시적 관점에서 고용·임금 구조에 미치는 실질적 영향이 크다는 점을 반영하기 위한 것으로, 각 직종의 관측값에 2014년 고용 비중을 가중함으로써, 추정된 계수가 모든 직종을 동일하게 본 평균 효과가 아니라 고용규모를 고려한 집계적(aggregate) 효과에 더 근접하도록 설계한 것이다. 다시 말해, 본 절의 분석에서 제시되는 계수들은 소규모 직종의 변동에 의해 과도하게 좌우되기보다는, 많은 근로자를 고용하고 있는 주요 직종들의 장기적 고용·임금 조정 추세를 보다 잘 반영하는 방향으로 추정되며, 이러한 가중 설정은 AI 기반 자동화가 한국 전체 노동시장에 미치는 거시적 파급효과를 평가한다는 본 장의 목적과도 일치한다.

<표 5-5>는 2014~24년 사이 중분류 직종별 고용 로그차분을 종속변수로 한 횡단면 회귀분석 결과를 보여준다. 통계적으로 유의한 계수를 보면, 정형과업 비중이 1%p 높을수록 10년 고용증감률은 대략 1.5~1.8%p 낮다는 의미로 해석할 수 있다. 직종 간 파급효과를 반영한 정형과업 비중을 사용할 경우 통계적으로 유의한 계수는 -0.030 전후로 커지는데, 이는 유사 직종에서 자동화가 진전될수록 해당 직종의 고용도 추가로 압박을 받는다는 점을 시사한다. 곧, 파급효과 지표가 1%p 높은 직종은 10년 고용성장률이 약 3%p 낮은 것으로 추정되어, 개별 직종의 내부 과업구조뿐 아니라 직종 간 공급망을 통한 자동화 압력의 전이가 장기 고용조정에 중요한 역할을 하고 있음을 보여준다. 직종 외 전 고용 로그차분 계수는 -20 내외로 개별 직종의 평균 고용 비중이 2% 정도인 것을 고려하면, 직종 외 전 고용 변화가 1bp(0.01%p) 증가하면 개별 직종의 고용은 2%p 정도 감소하거나 덜 늘어나는 것으로 해석할 수 있다.

<표 5-6>은 동일 기간 직종별 시간당 임금의 10년 로그차분을 종속변

<표 5-5> 직종별 고용규모 10년 로그차분에 대한 횡단면 분석⁹¹

	모형 (1)		모형 (2)		모형 (3)		모형 (4)	
	계수	p-value	계수	p-value	계수	p-value	계수	p-value
정형과업 비중	-0.012	0.18	-0.018	0.05	-0.015	0.02	-0.016	0.01
직종 외 전 고용 로그차분			-22.0	0.00	-21.8	0.00	-20.8	0.00
로그(임금 ₂₀₁₄)					-0.197	0.02	-0.383	0.00
연령							0.000	0.92
성별							-0.110	0.32
학력							0.088	0.09
관측치 수	51		51		51		51	
파급효과 (ripple effect)								
정형과업 비중	-0.035	0.20	-0.039	0.05	-0.030	0.04	-0.030	0.05

주: 2014년부터 2024년까지의 누적 변동을 분석.
자료: 고용노동부, 「고용형태별근로실태조사」, 「지역별고용조사」 및 임금직업포털(최종접속일: 2025. 10. 25).

<표 5-6> 직종별 시간당 임금 10년 로그차분에 대한 횡단면 분석

	모형 (1)		모형 (2)		모형(3)		모형(4)	
	계수	p-value	계수	p-value	계수	p-value	계수	p-value
정형과업 비중	-0.0051	0.13	-0.0060	0.06	-0.0046	0.05	-0.0036	0.27
고용 로그차분			-0.076	0.08	-0.126	0.00	-0.118	0.06
로그(임금 ₂₀₁₄)					-0.150	0.00	-0.115	0.15
연령							0.0028	0.43
성별							0.016	0.81
학력							-0.0037	0.92
관측치 수	51		51		51		51	
파급효과 (ripple effect)								
정형과업 비중	-0.011	0.12	-0.014	0.04	-0.0095	0.06	-0.0071	0.26

주: 2014년부터 2024년까지의 누적 변동을 분석.
자료: 고용노동부, 「고용형태별근로실태조사」, 「지역별고용조사」 및 임금직업포털(최종접속일: 2025. 10. 25).

91 추정계수의 절댓값이 크지 않아 지수함수를 사용하여 시산하지 않는다.

수로 한 단순 OLS 결과를 제시한다. 정형과업 비중의 계수는 모형에 따라 -0.005에서 -0.006 정도로 추정되는데, 이는 정형과업 비중이 1%p 높은 직종의 경우 10년 누적 임금상승률이 약 0.5~0.6%p 낮다는 의미이다. 파급효과를 반영한 정형과업 비중을 사용할 경우 계수는 -0.011~0.014 수준으로 커져, 유사 직종에서의 자동화 압력까지 고려하면 임금상승률은 약 1.1~1.4%p 낮아졌음을 시사한다. 고용 로그차분의 계수는 -0.076에서 -0.126 사이의 음의 값으로 추정되어, 10년 동안 고용이 더 많이 늘어난 직종일수록 평균 임금상승률은 오히려 낮게 나타나는 경향을 보여준다. 이는 고용이 빠르게 증가한 직종이 상대적으로 낮은 임금의 신규 진입자를 많이 흡수했거나, 반대로 고용이 정체·감소한 직종에서는 잔존자 효과와 직종 프리미엄 유지로 평균임금이 상대적으로 상승했을 가능성을 반영한다. 초기 임금수준(로그 임금₂₀₁₄)의 계수가 음(-)인 점도, 고임금 직종일수록 이후 10년 동안 임금상승률이 상대적으로 낮아지는 조건부 수렴형태와 일치한다.

<표 5-7>은 임금을 횡단면 IV(2SLS)로 추정한 결과로, 직종별 10년 고용 변화를 내생변수로 두고 leave-one-out 전체 및 대분류 고용 변화를 IV로 사용한다. 고용 로그차분의 계수는 -0.061에서 -0.077 수준으로, 단순 OLS보다 절댓값이 작고 통계적 유의성도 약해지지만, 여전히 외생적 고용 확대가 임금상승률을 일부 억제하는 방향임을 시사한다. 10년 동안 고용이 10% 더 증가한 직종의 임금상승률은 약 0.6~0.8%p 낮아지는 정도의 탄력으로 해석할 수 있다. 한편, 정형과업 비중의 계수는 -0.0059에서 -0.0041 수준으로 OLS 결과와 유사한 크기이며, 일부 모형에서는 10% 수준에서 유의하다. 이는 고용의 내생성을 IV로 보정한 이후에도, 정형과업 비중 1%p 차이가 여전히 약 0.4~0.6%p 정도의 임금상승률 격차와 연관되어 있음을 의미하며, 자동화 취약성이 임금과 고용에 동시에 작용하는 공통 충격의 결과만은 아니라는 점을 뒷받침한다.

<표 5-8>은 한 걸음 더 나아가 직종별 고용 변화와 정형과업 비중을 모두 내생변수로 처리하고, 파급효과를 반영한 정형과업 비중과 leave-one-out 고용변수들을 IV로 사용하는 횡단면 분석 결과를 제시한다.⁹² 여

<표 5-7> 직종별 시간당 임금 10년 로그차분에 대한 횡단면 IV 분석

	모형 (1)		모형 (2)		모형 (3)		모형 (4)	
	계수	p-value	계수	p-value	계수	p-value	계수	p-value
정형과업 비중	-	-	-0.0059	0.06	-0.0041	0.07	-0.0019	0.53
고용 로그차분 (IV)			-0.061	0.24	-0.077	0.08	-0.019	0.80
로그(임금 ₂₀₁₄)					-0.140	0.00	-0.059	0.43
연령							0.0025	0.49
성별							0.0020	0.97
학력							-0.030	0.45
관측치 수	51		51		51		51	

주: 2014년부터 2024년까지의 누적 변동을 분석.

자료: 고용노동부, 「고용형태별근로실태조사」, 「지역별고용조사」 및 임금직업포털(최종접속일: 2025. 10. 25).

<표 5-8> 직종별 시간당 임금 10년 로그차분에 대한 횡단면 IV 분석: 파급효과

	모형 (1)		모형 (2)		모형(3)		모형(4)	
	계수	p-value	계수	p-value	계수	p-value	계수	p-value
정형과업 비중 (IV)	-0.0063	0.08	-0.0069	0.04	-0.0041	0.09	-0.0016	0.59
고용 로그차분 (IV)			-0.061	0.23	-0.077	0.07	-0.020	0.79
로그(임금 ₂₀₁₄)					-0.140	0.00	-0.059	0.41
연령							0.002	0.48
성별							0.002	0.97
학력							-0.030	0.43
관측치 수	51		51		51		51	

주: 2014년부터 2024년까지의 누적 변동을 분석.

자료: 고용노동부, 「고용형태별근로실태조사」, 「지역별고용조사」 및 임금직업포털(최종접속일: 2025. 10. 25).

기서 정형과업 비중(IV)의 계수는 -0.0041에서 -0.0069 수준으로, 1%p 더 높은 정형과업 비중을 가진 직종의 10년 임금상승률이 약 0.4~0.7%p 낮

92 IV의 약한 도구 검정(Weak IV) 및 과식별(Overidentification) 검정에 대한 통계는 부록을 참고하기 바란다.

다는 점을 보여준다. 파급효과 지표를 도구로 활용함으로써, 정형과업이 많은 직종이 자동화 압력을 더 많이 받는다는 구조를 이용해 정형과업 비중의 외생적 변동을 추출한 결과, 그 크기는 OLS·단순 IV와 유사하게 되 통계적 유의성이 일부 모형에서 오히려 강화되는 양상을 보인다. 이는 직종 내부 과업 구성뿐 아니라, 유사 직종에서의 자동화 파급효과까지 고려한 정형과업 비중의 외생적 부분이 장기 임금상승률을 유의하게 끌어내리고 있음을 시사하며, AI 기반 자동화가 향후 심화될 경우 정형과업에 많이 의존하는 직종의 임금 경로가 상대적으로 더 불리할 수 있음을 암시한다. 고용 로그차분의 계수는 <표 5-7>과 유사하게 음(-)이지만 유의성이 약해, 임금과 고용 간의 음의 상관관계는 주로 직종 간 구성효과와 자동화 취약성의 차이에서 비롯되고, 고용조정 그 자체의 외생적 충격은 임금에 제한적 영향을 미친다는 해석이 가능하다.

추가적으로 본 연구에서 추정한 정형과업 비중에 대한 준탄력계수가 임금식보다 고용식에서 절댓값이 더 크게 추정된 것은, 장기 노동시장 조정에서 자동화 압력이 임금보다 고용에 먼저, 그리고 더 강하게 작용하는 구조적 특성을 반영한 결과로 이해할 수 있다. 우선, 정형과업 비중이 높은 직종은 정보수집·기록저장·정리가공 등 규칙 기반 과업의 비중이 크기 때문에, 지난 10년 동안 전산화·소프트웨어·로봇 등 기존 기술뿐 아니라 생성형 AI 상용화 전 본격화된 플랫폼화·빅데이터·클라우드 등으로도 상대적으로 쉽게 대체될 수 있었던 영역에 해당한다. 이 경우 기업은 생산성을 유지하거나 높이기 위해 우선 해당 과업에 투입된 인력규모를 줄이거나 신규 채용을 억제하는 방식으로 조정을 하는 것이 일반적일 수 있으며, 이는 직종별 고용증감률에서 직접적인 음(-)의 영향으로 나타난다.⁹³ 반면, 임금은 직종 내 이질적 업무 구성, 정규·비정규 및 근속연수 차이, 임금경직성과 노사관계, 최저임금·호봉제 등 제도적 요인에 의해 조정 속도와 폭이 제약되기 때문에, 동일한 자동화 충격이라도 고용에서처럼 선형적으로 반영되지 않고 부분적으로 상쇄되는 경향

93 제4장 패널 IV 분석에서 4차 산업혁명 기술 도입만 놓고 보면 고용에서 부정적인 영향이 더 두드러지는 것을 확인할 수 있다.

을 보일 수 있다.

또한 임금식에서는 장기적으로 직종 내 구성효과와 SBTC 관련 요인이 자동화의 직접효과를 상당 부분 흡수하는 점도 준탄력계수 차이를 키우는 요인이다. 예를 들어 정형과업 비중이 높은 직종에서 고용이 감소하는 과정에서 저숙련·저임금 인력이 먼저 이탈하고, 상대적으로 숙련도가 높은 잔존 노동자만 남는 경우, 평균임금은 자동화 압력에도 불구하고 일정 부분 유지되거나 오히려 상승할 수 있다. 이때 고용식에서는 정형과업 비중이 높은 직종일수록 고용이 더 빠르게 줄어드는 음의 관계가 그대로 반영되지만, 임금식에서는 동일한 정형과업 비중이 (고용 축소 + 잔존자 효과 + 초기 임금프리미엄 및 SBTC 통제)와 함께 결합되면서 자동화의 순수 임금효과가 희석될 수 있다. 즉, 고용은 자동화 충격이 작동하는 1차적인 조정 변수인 반면, 임금은 재배치·구성·제도를 통해 조정되는 2차적·완충적 변수의 성격이 강하기 때문에, 정형과업 비중에 대한 준탄력계수가 고용에서 더 가파른(절댓값이 큰) 형태로 추정될 수 있는 것이다.

3. AI 자동화가 향후 10년 일자리 대체 및 임금에 미치는 영향


본 절에서는 앞서 추정한 정형과업 자동화에 따른 고용 및 임금의 준탄력계수를 활용하여, 향후 AI 기반 자동화가 직종별 일자리와 임금에 미칠 잠재적 부정적 영향을 정량적으로 평가하고, 그 결과가 전체 임금 소득 분포와 지니계수에 어떤 변화를 가져올지를 살펴보고자 한다. 분석의 핵심은 2014~24년 동안 관측된 장기 고용·임금 조정 추세를 바탕으로, 동일한 구조적 관계를 AI 자동화 및 기술 노출 시나리오에 적용함으로써, 기술진보가 직종별 고용 축소와 임금 경로의 이질성, 그리고 임금 불평등의 변화로 어떻게 연결될 수 있는지를 모의실험하는 데 있다.

[그림 5-3]은 이러한 시나리오 분석의 출발점으로, 가로축에 직종별 기존 정형과업 비중을 두고 세로축에는 제3장에서 구축한 AI자동화(AI


[그림 5-3] 정형과업 비중과 AI 자동화 가능 과업 및 AI 노출 과업 비중

(단위: %)

(a) 정형과업과 AI score 반영 과업



(b) 정형과업과 AI 노출 과업



주: 실선은 45도선, 점선은 각 점도의 추세선.
 자료: 임금직업포털(최종접속일: 2025. 10. 10)을 바탕으로 저자 작성.

score) 가능 과업 비중과 AI 노출 과업 비중을 배치한 산점도를 보여준다. 패널(a)에서 파란 점은 기술적 가능성만을 반영한 AI 자동화 가능 과업 비중, 회색 점은 경제성(profitability)까지 고려한 AI 자동화 가능 과업 비중을 나타낸다. 파란 산점도와 추세선이 전반적으로 45도선 위쪽에 위치하여, 경제성을 고려하지 않을 경우 현시점에서 AI가 기술적으로 자동화할 수 있는 과업 비중이 전통적 의미의 정형과업 비중보다 높은 수준에 있음을 보여준다. 반면, 회색 산점도와 추세선은 45도선에 근접하거나 일부 구간에서 그 아래에 위치하여, 실제 비용·수익 측면에서 AI가 대체 가능한 과업은 기술적 잠재력에 비해 상당 부분 제약을 받고 있음을 보여준다. 패널(b)에서는 파란 점이 AI 노출 과업 비중, 회색 점이 경제성까지 고려한 AI 노출 과업 비중을 나타내는데, 두 경우 모두 추세선이 45도선 위에 위치하고, 특히 파란 추세선은 정형과업 비중보다 훨씬 높은 수준으로 형성되어 있다. 이는 모달리티가 정의된, 즉 텍스트·이미지·코드 등 데이터 기반 과업은 기존의 정형과업 범주를 넘어 훨씬 넓은 영역에서 AI와 연관되어 있으며, 수익성을 고려하더라도 잠재적 일자리 대

체 범위가 정형과업 비중을 크게 상회함을 의미한다. 이러한 결과는 현 비용·수익구조하에서는 AI 자동화가 당장 고용·임금에 미치는 영향이 제한적일 수 있으나, 향후 AI 성능 향상과 비용 하락으로 경제성이 개선될 경우, 특히 AI가 모달리티가 명확히 정의된 과업을 중심으로 고숙련 비정형 인지 노동(high-skilled non-routine cognitive labor)까지 자동화할 수 있다면 고용대체(일자리 감소)와 임금조정 압력이 빠르게 확대될 수 있음을 시사한다.

따라서 앞서 추정한 준탄력계수를 이용하여, 직종별 AI 자동화가 향후 10년 동안 고용과 임금에 미치는 효과를 <표 5-9>와 <표 5-10>을 통해 정리하였다. 먼저, 현시점에서는 AI 자동화가 과업대체(task displacement) 수준에서 일자리 소멸(job displacement)까지 이어질지에 대한 불확실성이 크기 때문에, 단기적으로는 AI 자동화 가능 과업 비중을 장기적인 일자리 대체의 대리변수(proxy)로 사용하는 것이 타당하다. 다만, AI 기술의 발전과 비용 하락을 감안할 때 10년 후에는 현재의 단순노출도(AI 노출 과업 비중)가 실제 일자리 대체 잠재력을 더 잘 반영할 가능성이 높다. 따라서 단기(2025년 기준)에는 AI 자동화 가능 과업 비중을, 장기(10년 후)에는 AI 노출 과업 비중을 기준으로 고용·임금 효과를 추정하였다. 모의실험에 사용할 준탄력계수는 앞서 횡단면 분석에서 통계적으로 유의하게 추정된 값들의 평균을 사용하였으며, 고용은 -0.033을 사용하고, 임금은 -0.0058를 사용하였다.

<표 5-9>는 이러한 준탄력계수를 자동화 시나리오에 적용하여, AI로 인해 영향 받는 근로자 규모(대체 대상)와 이 가운데 실제로 경제성이 있는 AI 대체규모를 직종 대분류별로 제시한다. 여기서 대체 대상 규모는 해당 직종의 과업 중 일정 부분이 AI 기술에 노출되어 있어, 직무·과업 재편 압력을 받을 것으로 예상되는 근로자 수를 의미하며, 경제성 있는 대체규모는 Svanberg *et al.*(2024)에서 제시한 비용 기반 접근과 유사하게 해당 직무가 AI 자동화에 대해 채산성이 있는 근로자 수를 추정한 것이다. 추정 결과, 전문가 및 관련 종사자, 사무 종사자, 판매 종사자, 장치·기계 조작 및 조립 종사자 등 중·고숙련 직종에서 AI 대체 압력이 가장

<표 5-9> AI로 대체될 연간 근로자 규모

(단위: 명)

직종 대분류	대체 대상 규모		경제성 있는 대체 규모	
	2025년	10년 후	2025년	10년 후
관리자	304	5,395	36	1,993
전문가 및 관련 종사자	16,280	192,736	0	106,653
사무 종사자	25,542	297,290	0	56,398
서비스 종사자	476	12,000	138	3,736
판매 종사자	1,862	34,521	303	41,087
농림·어업 숙련 종사자	82	285	0	0
기능원 및 관련 기능 종사자	2,208	18,123	13	4,500
장치·기계 조작 및 조립 종사자	13,274	63,216	972	39,202
단순노무 종사자	1,987	14,034	0	2,135
합계	62,013 (0.5)	637,600 (5.2)	1,462 (0.01)	255,703 (2.1)

주: 괄호 안은 2024년 대비 근로자 규모 비율(%).
자료: 임금직업포털(최종접속일: 2025. 10. 10)을 바탕으로 저자 작성.

크게 나타나며, 10년 후에는 연간 약 63만 8천명이 AI 자동화의 영향을 받고, 그중 약 25만 6천명(2024년 근로자 수 대비 약 2.1%) 정도가 경제성이 있는 대체규모로 추정된다. 하지만 현재(2025년)는 경제성이 제한적이어서 실질적인 근로자 수 감소는 거의 미미(1.4천명)할 것으로 나타났다.

이는 제4장의 기업자료를 이용한 패널 IV 분석에서도 아직까지 AI 활용으로 인한 고용 감소가 명확하게 나타나지 않은 것과 일치하는 결과이다. 즉, 기술적으로는 AI의 영향 가능성이 존재하더라도, 실제 노동대체는 경제성, 조직 재설계, 데이터 구축, 규제와 책임 문제 등 다양한 현실적 제약에 의해 아직 크게 제약될 수 있다는 것이다. 다만, 이는 AI의 노동시장 영향이 작다는 뜻은 아니며, 그 영향이 단기적으로는 총고용 감소보다 기업 내부의 과업 재배치와 생산성 개선의 형태로 먼저 나타난다는 뜻에 가깝다. 특히 이러한 변화는 저숙련 육체노동보다는 중·고숙련 및 화이트칼라 직종에 상대적으로 집중될 가능성이 높다는 점에서, AI가

<표 5-10> AI 자동화가 직종별 시간당 실질임금에 미치는 영향

(단위: 연간 %p)

직종 대분류	포괄적 영향		제한적 영향	
	2025년	10년 후	2025년	10년 후
관리자	-0.04	-0.72	0.00	-0.27
전문가 및 관련 종사자	-0.08	-0.94	0.00	-0.52
사무 종사자	-0.13	-1.53	0.00	-0.29
서비스 종사자	-0.01	-0.23	0.00	-0.07
판매 종사자	-0.06	-1.08	-0.01	-1.28
농림·어업 숙련 종사자	-0.06	-0.19	0.00	0.00
기능원 및 관련 기능 종사자	-0.05	-0.41	0.00	-0.10
장치·기계 조작 및 조립 종사자	-0.13	-0.61	-0.01	-0.38
단순노무 종사자	-0.03	-0.24	0.00	-0.04
전체	-0.09	-0.91	-0.00	-0.37

자료: 임금직업포털(최종접속일: 2025. 10. 10)을 바탕으로 저자 작성.

비반복적·인지적 과업을 중심으로 영향을 미친다는 Webb(2020) 및 한 지우·오삼일(2023)의 결과와도 일치한다. 따라서 본 연구 결과는 AI의 현재적 효과는 생산성·매출 확대가 선행되고, 고용 감소는 아직 제한적이며, 그 영향은 중·고속련 직종을 중심으로 점진적으로 나타나는 과정으로 종합적으로 해석할 수 있음을 보여준다.

<표 5-10>은 동일한 시나리오하에서 AI 자동화가 직종별 시간당 실질임금에 미치는 영향을 요약한 것으로, 포괄적 영향은 직무 내 일부 과업이라도 AI 기술에 노출된 경우까지 포함한 임금 감소폭으로, 제한적 영향은 AI의 경제성으로 일자리가 소멸(또는 거의 완전대체)된 경우만을 고려한 임금 감소폭으로 해석할 수 있다. 전체 임금수준에서 보면, 포괄적 영향 기준으로 2025년에는 -0.09%p, 10년 후에는 -0.91%p의 평균 임금상승률 둔화가 예상되며, 제한적 영향 기준으로는 전체 임금효과가 현재(2025년)는 거의 없고(-0.00%), 10년 후에는 -0.37%p 정도 둔화되는 것으로 추정된다. 이는 자동화가 임금에 미치는 효과가 고용에 비해 상대적으로 작고, 상당 부분이 직종 내 구성효과(저임금 과업의 우선 축소와

잔존자 효과)와 SBTC에 의해 상쇄된다는 앞의 계량분석과 일치한다. 직종별로는 전문가·사무·판매·조작·조립 종사자의 임금상승률이 가장 크게 둔화되며, 특히 판매 종사자의 경우 일자리 소멸규모는 상대적으로 크지 않지만, AI 자동화의 경제성이 높고 반복적인 정보제공·결제처리·재고확인 등의 규칙 기반 과업 비중이 높기 때문에 제한적 영향 기준에서도 -1.28%p의 비교적 큰 임금 충격이 추정된다. 이러한 결과는 Webb(2020)과 한지우·오삼일(2023)이 제시하는 고노출 직종에서의 임금상승률 둔화와 같은 방향으로 해석할 수 있다.

마지막으로 본 연구는 앞서 추정한 고용·임금 준탄력계수를 AI 자동화 시나리오에 적용하여, 10년 후 직종 간 임금불평등이 어떻게 변화할지를 지니계수로 평가하였다. <표 5-11>을 보면 기준 시점인 2024년의 직종 간 지니계수는 0.1704이며, 임금 충격만을 고려할 경우에는 AI 기술이 현재 수준에 머무를 때 0.1700, 모달리티가 정의된 모든 과업이 경제성 있게 자동화될 정도로 기술이 발전하는 경우에는 0.1550으로 하락한다. 이는 본 연구에서 추정한 임금 준탄력계수와 마찬가지로 AI 자동화의 임금 충격이 중·고속런 직종에 상대적으로 집중되면서, 직종 간 임금격차가 일부 좁혀지는 효과를 반영한 결과로 볼 수 있다. 이러한 임금불평등 완화 방향은 Webb(2020)이 제시한 것처럼 AI·로봇·소프트웨어 노출도가 높은 고임금 직종의 임금상승률이 둔화될 수 있다는 분석, 그리고 한국 데이터를 이용해 AI 노출지수에 대한 임금탄력성을 가정하여 지니계수가 0.20에서 0.18로 감소할 수 있음을 보인 한지우·오삼일(2023)의 시뮬레이션 결과와도 정성적으로 일치한다. 반면, 고용 충격만을 고려하면, 지니계수는 AI 기술이 현재 수준일 때 0.1721, 기술이 크게 발전할 경우 0.1920까지 상승하여, 고임금·고속런 직종에서 고용이 상대적으로 더 크게 줄어드는 재배치 효과가 직종 간 임금분포를 오히려 더 불평등하게 만들 수 있음을 보여준다. 이는 Acemoglu and Restrepo(2022)가 과업대체(task displacement)는 특정 집단의 임금을 직접 낮추는 동시에 노동소득분배율을 떨어뜨리고, 산업 구성 및 파급효과를 통해 전반적 임금구조에 부정적 영향을 줄 수 있다고 지적한 것과 맥락을 같이한다.

<표 5-11> 향후 10년 후 AI 대체에 따른 임금불평등도: 지니계수⁹⁴

Baseline(2024년 기준) 0.1704	포괄적 영향		제한적 영향	
	AI 기술 현재 수준	AI 기술 발전	AI 기술 현재 수준	AI 기술 발전
임금 충격	0.1700	0.1550	0.1704	0.1607
고용 충격	0.1721	0.1920	0.1703	0.1778
임금 충격 + 고용 충격	0.1716	0.1744	0.1705	0.1675

주: 직종(중분류)별 시간당 임금 및 근로자 수를 이용하여 시산.
자료: 임금직업포털(최종접속일: 2025. 10. 10)을 바탕으로 저자 작성.

임금 충격과 고용 충격을 모두 반영할 경우, 포괄적 영향 시나리오에서는 AI 기술이 현재 수준일 때 지니계수가 0.1716으로 소폭 상승하고, 기술이 크게 발전하는 경우에는 0.1744까지 높아져, 임금압축 효과에도 불구하고 고용조정이 가져오는 불평등 심화 효과가 우세해질 수 있음을 시사한다. 제한적 영향 시나리오에서는 AI 기술이 현재 수준에 머무를 경우 지니계수가 0.1705로 기준과 거의 차이가 없고, 기술이 크게 발전하더라도 0.1675로 소폭 하락하는 데 그쳐, 경제성이 있는 완전대체만을 보수적으로 고려할 경우 AI가 직종 간 임금불평등에 미치는 영향이 제한적일 수 있음을 보여준다. 다만, 본 연구의 지니계수는 직종 간 평균임금과 고용만을 사용한 하한 추정치라는 점, 그리고 AI로 인한 신규 과업창출(new tasks 혹은 reinstatement)과 생산성 향상(productivity improvement) 효과는 고려하지 않았다는 점을 유의할 필요가 있다. 특히 본 연구의 결과는 Webb(2020)나 한지우·오삼일(2023)이 제시하는 임금탄력성 가정에 따른 불평등 완화 가능성과 Acemoglu 계열 연구가 경고하는 자동화 편향 경로에서의 불평등 심화 가능성 사이에서, 한국 직업구조에 특화된 하나의 보수적인 시나리오(lower bound)를 제시하는 것으로 해석하는 것이 바람직할 것이다.

94 본 연구는 직종 내 임금분산을 0으로 가정한 후, 시간당 평균임금과 근로자 수만을 이용하여 직종 간 불평등 지니계수를 계산하였다. 이는 직종 내 불평등을 제외하므로 개인 임금 지니계수의 하한(평등도 최대 추정)으로 해석하는 것이 바람직하다.

제3절 소 결

지금까지 본 장에서는 과업기반(task-based) 일반균형모형을 토대로, 제3장의 산업·직종별 AI 노출도와 자동화 가능성, 그리고 제4장에서 추정된 AI 활용에 따른 1인당 매출액 상승 효과를 결합하여 TFP 기여도를 추정하였다. Hulten 정리를 이용해 산업별 과업 생산성 충격을 Domar 가중치로 집계하되, Baqaee and Farhi(2019)의 비선형 근사식을 부분적으로 반영하여 구조 변화와 Baumol 효과를 점검한 것이 특징이다. 그 결과, AI 기술이 시간에 따라 증가하는 Baseline에서는 향후 10년간 TFP가 약 2.3%(연 0.23%p) 개선되는 것으로 추정했다. 이는 Acemoglu(2024)가 제시한 10년간 TFP 0.66%보다는 높은 수치이다. 반대로 AI 비용이 50% 하락하고 생산성 향상 효과가 표준오차 범위만큼 강화되는 Better 시나리오에서는 10년간 3.5%(연 0.35%p)로, 이는 Aghion and Bunel(2024)의 연 0.68%p, OECD(2024)의 연 0.25~0.6%p 범위와 비교할 때 중간 수준의 성장 여력을 시사한다. 다만, 서비스 부문의 Baumol 효과와 Brynjolfsson *et al.*(2021)이 제시한 생산성 J-커브를 감안하면, 단기에는 무형자본 축적과 조정비용으로 인해 체감되는 생산성 개선폭이 더 작을 수 있음을 유의할 필요가 있다.

제2절에서는 2014~24년 직종(중분류) 패널을 이용한 횡단면 IV 분석을 통해, 정형과업 비중과 leave-one-out 고용증감률이 직종별 고용 및 임금 변화에 미치는 준탄력계수를 추정하였다. 고용식에서 정형과업 비중 1%p 차이는 10년 고용증감률을 약 1.6%p 낮추는 음(-)의 효과를 보였고, 파급 효과 지표를 사용할 경우 효과는 -3.3%p 수준까지 확대되어 과업대체(displacement)가 장기 고용조정에 상당한 역할을 하고 있음을 보여준다. 임금식의 2SLS 결과에서는 정형과업 비중 1%p가 10년 시간당 실질임금 상승률을 약 0.5~0.7%p 낮추는 것으로 추정되며, 이는 Webb(2020)이나 한지우·오삼일(2023)이 로봇·소프트웨어 노출지수를 이용해 보고한 고노출 직종의 고용·임금 성장 둔화와 정성적으로 일치한다. 이러한 준탄

력계수를 제3장에서 구축한 AI 자동화·노출 지표에 적용하여 모의실험을 수행하였다. 포괄적 영향(직무 내 일부 과업이라도 AI에 노출된 경우)을 기준으로 할 때, 10년 후 연간 약 63.8만명의 일자리가 AI 자동화의 영향(대체 가능성)을 받을 수 있으며, 이 중 경제성까지 감안한 실제 대체 가능 규모는 10년 후 약 25.6만명(2024년 취업자 대비 약 2.1%)으로 추정되었다. 이는 국가데이터처가 제시한 향후 10년간 생산연령인구 연평균 감소규모(약 39만명)⁹⁵와 비교할 때, AI 자동화로 인한 일자리 축소가 생산연령인구 감소 속도보다 크지 않기 때문에 중·고숙련 직종(전문가·사무·판매·장치·조작 및 조립 종사자)을 중심으로 인력 재배치 여지를 만들 수 있음을 시사한다. 임금 측면에서도 10년 후 포괄적 영향 기준 전체 임금상승률 둔화폭은 -0.91%p, 제한적 영향 기준 -0.37%p로, AI 자동화가 임금수준에 미치는 부정적 효과는 존재하지만, 지니계수를 추정하면 Webb(2020)이나 한지우·오삼일(2023)의 시뮬레이션과 마찬가지로 중·고숙련 직종에 집중된 임금압축이 직종 간 임금격차의 일부를 완화시키는 방향성이 함께 나타난다. 다만, 고용의 부정적 효과로 노동소득분배율 및 임금불평등도가 악화될 가능성을 배제하지 못한다.

종합하면, 본 장의 결과는 한국의 산업·직종 구조에 특화된 과업기반 모형을 통해, (i) AI 도입 확산이 TFP와 GDP 성장 측면에서는 Acemoglu (2024)의 보수적 시나리오와 글로벌 낙관론 사이의 중간 수준의 성장 여력을 제공하되, (ii) 자동화 충격이 정형과업 비중이 높은 직종의 고용·임금에 장기적인 하방 압력을 가하고, (iii) 그 결과 직종 간 임금불평등은 큰 폭의 완화도, 급격한 악화도 아닌 제한된 재분배 효과에 그칠 가능성이 높다는 점을 보여준다. 이러한 결과는 제6장에서 보다 치밀한 정책 논의로 이어질 필요가 있다. 구체적으로, 성장 측면에서는 AI 생산성 효과를 극대화하기 위한 데이터·클라우드 인프라 투자, 무형자본(조직·인력·프로세스) 축적 지원이 중요하며, 분배 측면에서는 자동화로 인한 고위험 및 중·고숙련 직종을 겨냥한 직무·직종 전환훈련, 재교육, 사회안전

95 국가데이터처(<https://kosis.kr/index/index.do>)의 추계인구 자료의 중위 추계(기본 추계: 출산율-중위/기대수명-중위/국제순이동-중위)를 사용하였다(접속일: 2025. 10. 15).

망 보강을 통해 직무·과업 대체(displacement) 효과를 흡수(reinstatement)하고, 새로운 과업창출(new tasks)과 보완적 AI 활용이 확산되도록 규제·세제·노동시장 제도를 개선하는 정책 방안을 고민할 필요가 있다.

제6장

결론 및 정책 방안

제1절 본 연구의 요약 및 한계

1. 본 연구의 요약

본 연구는 서론에서 제시한 문제의식에 따라, AI 자동화가 과업·직업 수준에서 유발하는 미시적 변화를 거시경제 성과, 특히 총요소생산성(TFP)의 성장으로 연결하는 분석을 수행하였다. 기존 연구들이 거시적 파급효과를 추정하는 과정에서 외부 가정이나 선행 추정치를 상당 부분 준용해 온 것과 달리, 본 연구는 한국 자료에 기반하여 자동화 가능성, 경제성, 채택 가능성, 생산성 전이 경로 등 핵심 요인을 단계적으로 점검하고 추정하였다. 이를 통해 각 가정의 역할과 민감도를 명시적으로 확인함으로써, 추정 결과의 정합성과 재현 가능성을 제고하고 분석의 완성도를 높이하고자 하였다.

$$\begin{aligned} \{\text{향후 10년 AI에 의한 TFP 증가율}\}_{\text{제5장}} &= \{\text{AI에 노출된 GDP 비중} \\ &\times \text{AI의 경제적 수익성이 있는 과업 비중}\}_{\text{제3장}} \\ &\times \{\text{AI로 인한 생산성 향상}\}_{\text{제4장}} \\ &\times \text{AI에 노출된 노동소득분배율} \end{aligned}$$

우선 제2장에서는 생성형 AI의 기술 진화를 트랜스포머와 대규모 사전 학습, 지시추종·강화학습, 멀티모달, 에이전트화 등의 단계로 정리하고, 각 전환이 무엇을 가능하게 했는지와 경제적 함의를 설명하였다. 핵심은 AI가 과업 단위에서 대체와 보완을 동시에 유발하며, 자동화 범위는 성능뿐 아니라 측정 가능성, 데이터 요건, 검증 가능성, 규제제약에 의해 제한된다는 점이다. 또한 범용-거대(수평적)모형과 특화(수직적)모형의 병행 발전이 산업 생태계와 시장구조, 인적자본 수요를 재편할 수 있음을 논의하였다. 생산성 J-커브와 보완적 무형투자(조직·데이터·교육)의 필요성을 함께 제시하며 교육·훈련, 경쟁정책, AI 안전·책임 거버넌스 과제의 필요성을 설명하였다.

제3장에서는 한국고용직업분류 기준 직업별 수행과업을 대규모로 추출·정리하고, 각 과업을 과업대상(object)과 과업행위(verb)로 분해하여 AI 노출도를 단위과업 수준에서 계량화하였다. 특히 기존의 단일 노출도 접근을 확장해 결과측정 가능성, 데이터·모달리티 적합성, 맥락·판단·창의, 에이전트화 요소 등을 반영한 5대 지표(M, D, C, J, A)를 산출하고 직업·산업 단위로 집계하였다. 6,824개 단위과업을 분석한 결과, 현재 기술적으로 일부 과업을 자동화할 수 있는 일자리는 전체의 72%에 달하며 10년 후에는 90%까지 확대될 가능성이 있는 것으로 추정하였다. 그러나 경제성을 분석하면 현재의 비용구조하에서 실효적으로 자동화될 가능성이 있는 일자리는 전체의 1.4%, 매출액 기준으로는 1.8% 수준에 머무르는 것으로 나타났다. 특히 고숙련·고임금 사무 및 기술직은 AI 노출도가 높지만 맥락 의존성과 인간 판단의 필요성으로 인해 완전대체보다는 보완 효과가 클 것으로 나타났다. 반면, 저임금 단순노무직은 경제적 유인이 낮아 자동화 도입이 지연될 가능성이 크며, 지식집약 부문을 중심으로 변화가 선도될 것으로 전망되었다.

기업의 생산성을 패널 IV로 분석한 제4장에서는 AI 도입이 기업의 상용근로자 1인당 매출액을 대략 20%, 기업 매출액을 10% 수준에서 유의하게 증가시키는 것으로 추정되었다. 이러한 생산성 향상은 주로 총매출의 확대와 부분적인 고용조정을 통해 실현되며, 특히 제조업과 판매목적

의 AI 활용에서 효과가 뚜렷하게 관찰되었다. 고용규모 측면에서는 통계적으로 유의하지 않지만 최대 10% 이내의 감소 가능성이 확인되었다. 중요한 점은 AI가 단독으로 도입될 때보다 클라우드, 빅데이터 등 기존 4차 산업혁명 기술 인프라와 결합될 때 비로소 의미 있는 성과가 나타난다는 사실이다. 이는 AI는 그 자체로 독립적인 성장 요소이기보다는 기존 디지털 전환 위에서 시너지를 창출하는 범용기술임을 의미한다.

마지막으로 제5장에서는 과업기반 일반균형모형을 이용하여 향후 10년간 AI 확산이 기준(baseline) 시나리오를 따를 경우 한국경제의 총요소생산성(TFP)을 2.3%(연간 0.23%p) 증가시킬 수 있다고 추정하였다. 특히 AI의 생산성 향상 및 비용 증감의 민감도를 고려하면 TFP 성장은 1.5~3.5%(연간 0.15~0.35%p) 범위일 것으로 예상하였다. 이는 고노출 부문의 생산성 향상이 공급망을 통해 경제 전반으로 전파되는 승수효과(Domar 가중치)를 반영한 결과이다. 한편, 노동시장 측면에서는 장기적으로 연간 약 25.6만명(2024년 기준 취업자의 2.1%) 규모의 일자리 대체가 예상되며, 주로 전문가·사무·판매 등 중·고숙련 직종에 하방 압력이 집중될 것으로 예상되었다. 이에 따라 고임금 직종의 임금상승률이 둔화되는 임금압축 현상이 나타나 직종 간 임금불평등은 지니계수 기준 소폭 하락하거나 현 수준을 유지할 것으로 예상되었다. 다만, 수출 중심의 산업구조 덕분에 Baumol 효과에 따른 성장 둔화 위험은 전형적인 서비스 중심 선진국에 비해 상대적으로 적을 것으로 추정되었다.

2. 본 연구의 경제학적 의의와 한계

본 연구는 한국 노동시장의 자료를 이용하여 생성형 AI 확산을 기술진보 그 자체가 아니라 과업(task) 단위의 비용구조 변화로 해석하고, 그 미시적 변화가 기업성과와 거시변수로 누적·전이되는 경로를 하나의 분석 체계로 통합했다는 점에서 경제학적 의의가 있다. 우선 제2장에서는 AI 기술발전이 특정 기능의 성능 향상에 그치지 않고, 지식노동 과업의 품질·속도·비용 경계를 이동시키는 충격임을 설명함으로써 기술 충격을

경제학적 객체로 설명하였다. 제3장에서는 이러한 충격이 노동을 대체할 가능성과 시장에서 채택될 유인이 동일하지 않음을 명확히 하고, 자동화의 범위를 경제성(AI 구축·운영 비용 대비 인건비 절감)으로 구분함으로써 AI 기술의 확산을 내생화하는 토대를 제공하였다. 제4장에서는 기업수준에서 AI 활용과 생산성의 관계를 실증적으로 점검하여, 과업 단위 개선이 실제 산출·비용 지표로 연결될 수 있음을 확인하였다. 제5장에서는 과업기반 일반균형모형을 이용하여, AI 도입이 총요소생산성(TFP) 뿐 아니라 노동수요와 소득분배에 미치는 효과가 대체·보완·신규 과업 창출의 상대적 강도 및 확산 속도에 따라 달라질 수 있음을 제시하였다. 결과적으로 본 연구는 ‘AI 노출도-경제성-기업생산성-거시 과급’을 하나의 연속된 인과사슬로 연결함으로써, AI의 확산을 단순한 성장회계의 잔차가 아니라 측정 가능한 구조적 변화로 다루는 데 기여한다.

그러나 본 연구는 몇 가지 한계도 가지고 있다. 첫째, 과업기반 노출도와 경제성 분석은 과업기술서의 텍스트 정보와 AI 기능 발전에 크게 의존하므로, 실제 작업 현장에서의 보완재(조직학습, 데이터 축적, 업무 프로세스 재설계)와 제약(규제, 책임소재, 품질검증, 보안)을 완전하게 반영하기는 어렵다는 점이다. 즉, 측정된 자동화 가능성이 곧바로 실현된 자동화로 이어지지 않을 수 있다는 것이다. 더불어, 과업기술서는 정태적인 구조를 전제로 하고 있어, AI 도입 이후 인간이 비교우위를 갖는 새로운 노동집약적 과업이 창출되는 역동적 복원효과(reinstatement)를 완전히 포착하지는 못하는 한계가 있다. 둘째, 본 연구의 분석은 본질적으로 과거와 현재 데이터에 기반한 추세적 시나리오를 전제로 하므로, AI가 과거 디지털 기술과는 질적으로 다른 속도로 지적 노동을 자동화하거나, 범용 에이전트형 AI가 빠르게 확산되는 경우와 같은 비연속적 도약을 충분히 반영하지 못할 수 있다. 이 경우 본 연구의 정량적 결과는 AI의 장기 거시효과를 과소평가할 여지가 있으므로, 향후 연구에서는 기술발전 경로의 불확실성을 내생적으로 모형화하는 접근이 필요하다. 또한 다른 측면에서 본 연구는 AI가 과학기술 혁신과 아이디어 생성(idea generation)을 가속화하여 지식 축적과 신규 기술·제품 개발을 촉진하는 경로를 모형에 명시

적으로 포함하지 못하였다. 이 경우 장기 경제성장 효과는 본 연구의 TFP 기여 추정보다 더 커질 수 있으며, 본 연구의 결과는 그러한 지식축적 경로를 보수적으로 고려하지 않은 평가라는 점을 염두에 두고 해석할 필요가 있다. 넷째, 기업 단위 실증분석은 AI 도입의 내생성(생산성이 높은 기업이 AI를 더 빨리 채택할 가능성)과 측정오차(도입 강도, 활용목적의 이질성)를 완전히 제거하였다고 단정하기 어렵고, 단기 관측치로부터 장기적으로 일반화하는 데 제약이 있을 수 있다. 다섯째, 거시모형은 모수(AI 노출도, 채택률 등) 설정에 따라 성장 경로가 크게 달라질 수 있으며, 산업 간 연결(중간재 네트워크), 무형자본(데이터·조직) 축적, 국제 무역·글로벌 공급망을 통한 파급을 단순화할 가능성이 존재한다. 마지막으로 딥페이크나 온라인 조작과 같은 사회적 가치가 음(-)인 나쁜 과업(bad tasks)의 생성은 실질적인 사회적 후생을 감소시킬 수 있음에도 불구하고 TFP와 같은 양적 지표에서는 긍정적으로 계산될 수 있다는 측정상의 불확실성을 가지고 있다(Acemoglu, 2024).

제2절 AI 전환을 위한 정책 방안과 기업 전환 전략

1. AI 전환을 위한 정책 방안

본 연구의 분석 결과를 보면 AI의 경제적 잠재력은 생산성 향상과 더불어 새로운 부가가치 창출을 통해 미래의 성장동력이 될 것으로 기대된다. Chui *et al.*(2023)은 생성형 AI 기술이 전 세계적으로 연간 2.6~4.4조 달러의 가치를 창출할 수 있으며, 현재 근로시간의 60~70%에 해당하는 업무활동을 자동화할 잠재력이 있다고 분석한다. 그러나 이러한 효과가 현실화하려면 기업의 광범위한 AI 채택과 업무 프로세스 재설계, 인력 재교육 등 보완적 투자가 수반되어야 한다. 정부의 정책 역할은 시장 기능을 존중하는 가운데 이러한 보완 여건을 마련하고, AI 확산 과정에서 발생할 수 있는 부작용을 최소화하는 데 집중해야 한다. 따라서 본 연구

에서 추구하는 정책목표는 생산성 향상, 분배와 고용의 안정, 시장 경쟁력 강화로 요약될 수 있으며, 정책 수단으로는 합리적 규제 정립, 데이터 및 컴퓨팅 인프라 구축, 인력 양성과 빅데이터 활용 촉진 등이 중점적으로 논의될 것이다. 특히 본 연구는 정책 방안의 시급성에 따라 단기·중기·장기로 나누어 논의하고자 한다.

가. 단기적 정책 방안(1~2년): 선택적 자동화 대비와 기반 조성

1) AI의 부분적·선택적 자동화 대응 방안

본 연구의 추정으로는 현재 경제성이 있는 AI 자동화가 직접 영향을 미치는 고용·매출 비중은 2% 이내에 그친다. 이는 당장 전면적인 일자리 충격보다는 특정 직업군과 산업에서의 업무 재편이 이슈가 될 가능성이 높음을 의미한다. 따라서 단기적으로는 AI 도입으로 변화가 예상되는 분야를 선별하여 직무 재설계와 재교육(reskilling)을 선제적으로 지원해야 한다. 예를 들어 교육, 보건의료, 사회복지, 운송, 경영사무, IT, 영업·고객상담 등 본 연구에서 AI 자동화 영향 상위권으로 지목된 업종의 직무를 분석해 업무분장 체계를 재정립하고, 전환교육 프로그램을 마련하는 것이 시급하다. 기업 차원에서 이러한 변화가 원활히 이뤄지도록 정부는 직업훈련 보조금, 전문인력 파견 컨설팅 등을 제공할 필요가 있다.

2) AI 인프라 접근성 제고

기업들의 신속한 AI 활용을 돕기 위해 데이터·컴퓨팅 인프라 구축을 서둘러야 한다. 특히 중소기업이나 非IT 업종 기업들은 AI 도입에 필요한 데이터 축적, 클라우드 및 GPU 연산자원 확보, AI 인재 채용에 어려움을 겪을 수 있다. 국내 설문조사에서도 많은 기업들이 인프라 부족과 인력 부재, 비용 부담을 AI 미도입의 주된 이유로 꼽았다. 단기적으로 정부는 이러한 진입 장벽을 낮추는 정책을 시행해야 한다. 예를 들어 중소기업을 위한 공공 클라우드 및 공동 GPU 센터를 운영하여 저렴한 AI 연산자원을 빌려주고, 산업 데이터 플랫폼을 구축해 기업 간 데이터 공유

를 촉진하는 방안을 들 수 있다. 또한 AI 활용역량을 갖춘 인력을 양성하기 위해 직무재교육 프로그램을 지원하고, 기업과 교육기관 간 협력을 통해 AI 인재풀을 확충해야 한다. 특히 의료·복지, 예술·서비스 등 디지털 인프라가 취약한 분야에 대해 맞춤형 지원정책을 마련함으로써 부문 간 AI 활용 격차가 심화되지 않도록 해야 한다.

3) 합리적 규제 정비

AI 기술발전 속도를 감안할 때 법·제도 정비도 선제적으로 추진해야 한다. 단기적으로는 우선 명확한 책임소재와 윤리기준을 설정하는 것이 필요하다. 현재 많은 기업들이 AI 활용을 주저하는 이유 중 하나는 법적 책임과 규제의 불확실성이다. 이에 대응하여 정부는 AI 의사결정에 대한 민·형사상 책임 분담 기준, AI가 만든 결과물의 저작권·표준 등에 관한 가이드라인을 조속히 마련해야 한다. 또한 AI 신기술 테스트를 위한 규제샌드박스의 실효성을 강화하여야 한다. 예를 들어 AI 기술발전 속도에 맞춘 규제 유연성 확보(화이트리스트 규제 완화 등), 데이터 활용의 병목 현상 완화(최첨단 프라이버시 강화 기술(PET) 도입 등) 등이 있을 수 있다. 이러한 조치들은 기업이 안전한 환경에서 AI를 활용할 수 있게 해주어 초기 AI 도입을 촉진할 수 있다.

나. 중기 정책 방안(3~5년): AI의 보완적 활용 확대와 제도화

1) 노동 보완형 AI 확산

지금부터 3~5년의 시계를 가지는 정책의 초점은 AI를 통한 업무보완과 새로운 과업창출에 맞춰져야 한다. 본 연구의 분석 결과, 현재는 많은 직무가 AI 기술에 노출되어 있어도, 완전자동화되는 비중은 제한적임을 보여주었다. 이는 AI를 노동대체보다는 노동보조 수단으로 활용하도록 유도하는 정책 방향이 바람직함을 시사한다. 예컨대 의료·교육·돌봄·공공서비스 부문에서는 AI를 활용해 서비스 품질을 높이는 혁신을 지원해야 한다. 의료영상 판독을 돕는 AI, 교사의 수업준비를 지원하는 AI튜

터, 돌봄 인력의 업무를 경감하는 로봇 등이 그 사례이다. 이러한 보완적 활용이 확산되도록 해당 산업별로 검증된 AI 솔루션 보급사업, 현장적용 가이드라인 제정을 추진해야 한다. 이는 장기성장과 고용안정을 동시에 달성하는 기초가 될 수 있다. 한편, 중소기업과 지역기업의 AI 도입을 지속 지원하여 경제 전반에 AI 활용이 확산되도록 해야 한다. 앞으로는 많은 기업들이 클라우드, 빅데이터 등을 활용하게 될 것이므로, 클라우드·데이터·AI 패키지형 지원과 산업별 AI 레퍼런스 모형 공유를 통해 AI 도입비용을 낮추는 정책을 강화해야 한다. 이를 통해 타 산업 대비 도입이 늦었던 분야도 AI 활용의 혜택을 누릴 수 있게 하고, 선도기업과 후발기업 간의 디지털 격차를 완화할 수 있다.

2) 데이터 거버넌스 및 표준 확립

사실, AI 시대의 경쟁력은 데이터 활용 능력에서 나오므로, 데이터 인프라와 표준체계 구축은 중요한 정책목표이자 수단이 될 수 있다. 정부는 앞선 합리적 규제 정비를 통해 공공부문과 전략산업을 중심으로 표준화된 데이터베이스를 구축해 민간에 개방함으로써 AI 개발의 원천자원을 제공해야 한다. 또한 산업별 데이터 거버넌스 체계를 수립하여 기업 내부의 데이터 활용을 촉진하고, 개인정보 보호와 활용 간 균형을 맞추는 규범을 마련해야 한다. 특히 AI 기술 표준 및 인증제도를 도입하여 AI 제품과 서비스의 신뢰성 평가체계를 확립할 필요도 있다. 예를 들어 의료AI, 자율주행AI 등 안전이 핵심인 분야는 정부가 일정 수준의 성능검증 기준을 제시하고 인증함으로써 소비자와 기업 모두 안심하고 기술을 수용하도록 유도할 수 있다. 아울러 국제협력을 통해 AI 윤리·안전 기준의 국제표준화 논의에도 적극 참여하여, 한국 기업들이 해외시장에서 통용될 규범을 선제적으로 채택하도록 해야 한다. 이는 향후 각국의 AI 규제 차이로 인한 무역 장벽과 표준 경쟁에 대비하고, 국내 AI 기업의 글로벌 경쟁력을 높이는 데 이바지할 수 있다.

3) 사회적 대화와 안전망 강화

향후 AI 확산이 가져올 고용구조 변화와 분배 영향에 대비하여 AI 관련 노사정 협력을 제도화해야 한다. 특히 본 연구의 결과 AI 자동화가 중산층 전문직의 업무까지 영향을 미칠 수 있다고 전망함에 따라, 해당 직군을 중심으로 선제적 사회적 대화를 추진해야 한다. 우선 경영사무, 정보기술, 영업·고객상담, 간호·돌봄 등 반복 등장하는 직무들에 대해 노조, 기업, 정부가 함께 직무전환 훈련, 임금체계 개편, AI 윤리 가이드라인 등을 논의하는 상설협의체를 구성하는 것을 고려할 수 있다. 이를 통해 AI 도입에 따른 노동자 불안(Fear Of Becoming Obsolete)을 해소하고, 능동적인 적응을 지원해야 한다. 또한 사회안전망을 정비하여, 구조적 전환으로 일시적 실직이나 소득 감소를 겪는 근로자들을 보호해야 한다. 실업급여의 사각지대를 줄이고, 전직지원 서비스를 확충하며, AI로 대체되는 업무 분야 종사자들에게 맞춤형 재취업 프로그램을 제공하는 노력이 필요하다. 이러한 사회안전망 강화는 AI로 인한 분배 충격을 완화하고 사회적 수용성을 높이는 핵심 요소일 것이다.

다. 장기 정책 방안(5년 이상): 지속가능한 성장 기반 마련

1) 지속적인 인프라·무형자본 투자

장기적으로 정부는 AI를 활용한 생산성 도약을 지속가능하게 만들 기반을 설계·마련해야 한다. 우선 AI 연구개발(R&D) 역량을 꾸준히 강화하여 차세대 AI 기술도 국내에서 선도적으로 활용될 수 있도록 지원해야 한다. 이는 민간이 주도하되 정부는 기본 연구자금 지원, 산학협력 플랫폼 제공 등 생태계 조성자 역할을 맡아야 한다. 또한 AI 효과를 극대화하는 데 필수적인 무형자산(데이터, 조직역량, 인적자본)에 대한 투자를 지원해야 한다. 예컨대 기업이 직원 재교육이나 조직혁신에 투자하는 경우 세제상 인센티브를 제공하거나, 우수사례를 발굴해 확산시킴으로써 민간의 노력을 끌어내야 한다. 또한 장기적으로 교육제도 전반의 개편도 필요하다. 초·중등 및 고등교육에서 AI 소양과 디지털 역량을 강화하는

교과과정을 도입하고, 직업교육 훈련시스템을 평생교육 체제로 전환하여 노동생애 전반에 걸친 재훈련이 당연시되는 문화를 정착시켜야 한다. 이를 통해 향후 수십 년에 걸쳐 AI 기술 변화에 유연하게 대응하는 인력 기반을 마련할 수 있다.

2) 경쟁정책과 산업구조 대응

AI 시대에는 데이터와 알고리즘을 지배하는 소수의 기업이 시장지배력을 크게 높일 가능성이 크다. 아니, 이미 시작되었을 수 있다. 따라서 정책적으로 AI 시장의 공정한 경쟁규칙을 재점검하여, AI 기술 분야의 독과점 형성을 방지하고 혁신기업의 시장진입을 도와야 한다. 예를 들어 거대 AI 플랫폼 기업이 중소 경쟁사의 데이터를 부당하게 수집·남용하지 못하도록 데이터 독점규제를 도입하거나, 표준필수특허(SEPs)처럼 필수 AI 기술에 대한 접근권을 보장하는 국제규범 논의를 주도할 수 있다. 또한 산업 전반에 걸쳐 성장형 AI 확산 전략을 추진해야 한다. 대기업의 AI 기술이 협력사와 중소기업에도 이전되도록 인센티브를 제공하고, 산업별로 대·중소기업이 함께 참여하는 AI 이니셔티브를 만들어 생태계 전체의 경쟁력을 높여야 한다. 이는 AI로 인한 생산성 향상이 소수 기업에만 독점되지 않고 경제 전반으로 파급되도록 해줄 것이다.

3) 고용 및 분배 구조의 안정적 관리

향후 AI 기술이 장기적으로 노동시장에 미칠 영향에 대비하여 정교한 모니터링과 정책대응을 지속해야 한다. 특히 10년 이상을 내다볼 때, AI 성능 향상과 비용 하락으로 고숙련 직무까지 자동화 범위가 넓어질 가능성이 있다. 현재 추정으로는 10년 후에는 AI로 인한 일자리 감소가 전체 고용(2024년 기준)의 약 2.1% 수준으로, 생산연령인구 감소로 자연감소하는 노동력 범위 내에서 흡수 가능할 것으로 보이지만, 기술발전 속도가 가속화되면 일자리 대체 압력이 급격히 증가할 위험도 배제할 수 없다. 따라서 정부는 거시경제 전망과 노동시장 지표를 면밀히 추적하면서, 예상보다 큰 충격이 감지될 경우 곧바로 대응책을 가동할 수 있도록 준

비할 필요가 있다. 예를 들어 지역별·업종별 일자리 여건을 정기적으로 점검하여 AI로 인한 실업 증가 조짐이 보이면 실업부조 확대 등 단기적 부양책을 실시해야 한다. 아울러 노동이동성을 높이는 제도를 정비하여 한 직무에서 다른 직무로의 전환을 용이하게 하고, 연금·사회보험의 수급권 이동성(portability)을 강화함으로써 경력전환에 따르는 불이익을 줄여야 한다. 이러한 장기적 노력으로 정부는 AI로 인한 구조 변화가 사회 전반의 포용성을 해치지 않고 안정적으로 진행되도록 관리해야 한다.

2. 기업의 AI 전환 전략

AI 기술의 확산은 기업경영에도 중대한 변화를 가져올 전망이다. 앞서 분석된 바에 따르면, 국내 기업에서 AI를 도입한 경우 직원 1인당 매출액이 평균 5~20% 증가하고 총매출도 5~10% 확대되는 등 생산성 향상이 관측되고 있다. 다만, 아직까지는 고용 감소가 통계적으로 유의미하지 않을 정도로 제한적이어서, AI가 업무효율을 높이는 동시에 새로운 사업기회를 통해 매출을 늘리는 역할을 하고 있음을 시사한다. 이러한 결과는 기업이 AI를 인력대체 수단이 아니라 생산성과 매출 증대의 수단으로 활용할 때 얻을 수 있는 성과로 보인다. 결국 AI 도입 여부와 활용 능력이 앞으로 기업 경쟁력의 핵심 변수가 될 것으로 예상되므로, 기업들은 선제적인 AI 전환 전략을 수립해야 한다. 기업 전략 수립 시에는 업종 특성과 기업규모에 따라 상이한 접근이 필요하며, 조직 내부적으로도 AI 활용을 극대화할 수 있는 재편이 따라줘야 한다.

가. 주요 산업별 AI 도입 전략

1) 지식집약 서비스업

금융, 정보통신, 전문서비스와 같은 지식집약적 서비스산업은 AI 도입의 선도 영역이 될 가능성이 크다. 이들 업종은 디지털 데이터가 풍부하고 업무 프로세스가 정형화된 부분이 많아 AI를 적용하기 유리하고 이미

활용률도 높은 것으로 나타났다. 예를 들어 금융업의 경우 AI 챗봇을 활용한 고객응대, 신용위험 AI모형을 통한 대출심사, 자산운용 알고리즘 등이 빠르게 확산되고 있다. 정보기술(IT) 및 소프트웨어 산업에서는 AI를 활용한 코드 자동완성, 시스템 모니터링 등이 개발 생산성을 높이고 있다. 이러한 분야의 기업들은 사내 AI 역량을 강화하는 것이 관건이다. 구체적으로 도메인 특화 AI 모형을 자체 개발하거나 외부 솔루션을 맞춤형 구축하여 핵심 업무에 적용하고, 임직원들에게 AI 활용교육을 실시하여 데이터 사이언스와 프롬프트 엔지니어링 등 새로운 기술에 익숙해지도록 해야 한다. 실제 사례로 글로벌 금융기업 Bloomberg는 LLM을 자체 개발해 자사 금융 데이터에 특화된 AI 모형(BloombergGPT)을 구축함으로써 핵심 사업에 AI를 적극 활용하고 있다.⁹⁶ 이러한 자체 AI 역량 확보 전략은 외부 빅테크에 대한 의존도를 낮추고 해당 산업에서 AI 주도권을 가져오는 효과가 있다.

2) 제조업

제조업은 이미 자동화가 상당 부분 진행된 분야이지만, AI는 제조업의 품질 혁신과 운영 최적화를 한층 진전시킬 것이다. 제조기업은 AI를 활용한 예지보전(설비 고장 예측), 생산공정 제어 최적화, 수요 예측 및 재고관리 등에 집중할 수 있다. 이를 위해 생산공정 데이터와 IoT 센서 데이터를 수집·분석하는 스마트 팩토리 전환을 가속화해야 한다. 특히 AI 비전(vision) 기술을 활용한 불량품 검사, 생성형 AI를 이용한 신제품 설계 및 시제품 제작 등은 제조 현장의 생산성을 크게 높일 수 있는 영역이다. 제조업에서는 현장 인력의 디지털 역량 강화도 중요한 전략이다. 생산라인의 관리자와 기술자들이 AI 분석 결과를 이해하고 의사결정에 활용할 수 있도록 교육하고, 현장 제안 제도를 통해 근로자들이 AI 아이디어를 제시하도록 장려하는 조직문화가 필요하다. 또한 제조 대기업은 자사 공급망 전체에 AI 시스템을 도입하여 협력업체와 생산·물류 정보

96 본문 25쪽을 참고하기 바란다.

를 실시간 공유하고 최적화함으로써 가치사슬 전체의 효율성을 제고하는 방향으로 나아가야 한다. 이는 개별 기업의 벽을 넘어 산업 생태계 차원에서 AI 혁신을 확산시키는 전략이라 할 수 있다.

3) 보건의료·교육 등 인간서비스업

의료, 교육, 돌봄과 같은 분야는 AI 활용을 통해 서비스 품질 향상과 접근성 제고효과를 기대할 수 있다. 다만, 이러한 산업에서는 AI가 인간을 완전히 대체하기 어려운 영역이 많으므로 인력 보조적 활용 전략이 핵심일 수 있다. 의료 분야의 경우 병원들은 AI를 의사결정 지원 도구로 도입하고 있다. 예를 들어 AI 영상판독 솔루션은 의사의 진단을 보조하여 판독 속도를 높이고 정확도를 개선한다. 또 환자 문진정보를 자동으로 정리해주는 AI, 신약 개발에서 후보물질을 발굴하는 AI 등 전문가 시스템형 AI가 의료인력을 돕는 역할을 한다. 교육 분야에서도 AI 튜터, 에세이 자동채점, 학습자 맞춤형 콘텐츠 추천 등 교사 보조형 AI가 활용되도록 할 필요가 있다. 이러한 AI 도구들은 교사의 업무 부담을 줄이고 학생들에게는 개인맞춤형 학습 경험을 제공하여 전반적인 교육효과를 높일 수 있다. 기업 전략 측면에서는 병원, 학교와 같은 조직들이 AI 도입을 위해 도메인 특화 스타트업과 협력하거나, 정부의 시범사업에 참여해 초기 적용사례를 만드는 것이 중요하다. 아울러 이러한 서비스업에서 AI 윤리기준을 지키고 인간적 가치를 훼손하지 않도록 전문직 단체와 협의하며 AI 활용 지침을 마련하는 전략도 필요하다. 이는 기술 도입과 사회적 신뢰 형성을 동시에 달성하기 위해 필수적일 수 있다.

4) 크리에이티브 산업 및 기타 분야

예술, 미디어, 디자인 등 창조적 산업에서도 AI가 새로운 기회와 도전을 함께 가져오고 있다. 멀티모달 AI의 발달로 그림, 음악, 동영상 생성이 가능해지면서 크리에이터들은 AI를 창작 도구로 활용할 수 있게 되었다. 관련 기업들은, 반복적이고 기계적인 부분(예컨대 배경 이미지 생성, 초안 작성)은 AI에 맡기고, 디자이너와 작가들은 보다 고차원적인 창조

적 작업에 집중하도록 업무 프로세스를 재편할 준비를 해야 한다. 다만, 이 분야에서는 AI를 둘러싼 저작권 문제와 윤리적 쟁점이 크므로, 기업은 사전에 법률 검토를 거쳐 AI 활용 범위를 명확히 하고, 내부 윤리 가이드라인을 세워 AI와 인간 창작자의 공존 모형을 구축해야 한다. 예를 들어 미디어 기업은 AI로 생성한 콘텐츠를 활용할 때 ‘AI 보조 제작’이라고 명시하여 투명성을 확보하고, 크리에이터들과 수익분배 기준을 협의하는 등의 전략을 고려할 수 있다. 이러한 선제적 조치는 향후 AI로 인한 분쟁을 줄이고 업계의 혁신을 촉진할 수 있다.

나. 기업규모별 AI 전환 전략

1) 대기업 및 기업집단

대기업 및 기업집단은 한국에서 자본력과 인재풀을 활용하여 AI 전략을 선도할 수 있는 위치에 있다. 대기업의 AI 전환 전략으로는 첫째, 전사 차원의 AI 추진 조직을 구축하여 최고경영진 직속으로 AI 로드맵을 관리하도록 해야 한다. 이를 통해 기업 전략과 연계된 우선순위 과제를 선정하고, 연구개발(R&D)부터 현업 적용까지 일관되게 추진해야 한다. 둘째, 사내 데이터 자산의 통합과 플랫폼화를 들 수 있다. 대기업은 방대한 운영 데이터를 보유하고 있으므로, 이를 수집·저장·분석할 수 있는 자체 클라우드 데이터베이스를 만들고 다양한 부서가 활용할 수 있는 공통 AI 플랫폼을 개발해야 한다. 이를 통해 중복투자를 피하고, 한 부서의 AI 성과를 다른 부서로 확산시키는 규모의 경제를 얻을 수 있다. 셋째, 조직문화 및 인사제도 개편이 필요하다. AI 시대에 맞춰 직무 재분류와 평가체계를 손질하고, 사내 교육 프로그램을 통해 전 직원의 AI 문해력을 높여야 한다. 예를 들어 일부 글로벌 기업은 직원들에게 AI 관련 연수 이수를 의무화하고, AI 활용 능력을 새로운 핵심 역량으로 평가하기 시작했다. 이런 전략을 통해 대기업은 AI 혁신의 확산거점(hub) 역할을 수행하며 산업 전반의 디지털 전환을 주도할 수 있을 것이다.

2) 중견·중소 기업

중소기업의 AI 도입은 사실 대기업에 비해 인력, 자금 측면에서 어려움이 많지만, 선별적 전략으로 충분히 성과를 낼 수 있다. 첫째로, 외부 AI 서비스 활용 전략이 중요하다. 자체적으로 AI를 개발하기 어렵다면, 클라우드 기반의 AI API 서비스를 구독하여 필요 기능을 사용하는 것이다. 이를 통해 거대한 초기 투자 없이도 최신 AI 기술을 활용할 수 있다. 둘째, 작은 성공 경험 축적이 중요하다. 중소기업은 전사적으로 모든 영역에 한꺼번에 AI를 도입하기보다, 특정 문제부터 파일럿 프로젝트로 시작해 보는 것이 유효할 수 있다. 예를 들어 영업부서의 챗봇 도입, 제조소기업의 간단한 공정 자동화, 소매업의 재고관리 AI 도구활용 등 ROI(투자 이익)가 비교적 명확한 분야부터 시도해볼 수 있다. 셋째, 외부 전문기관과 협업하는 방법이 있다. 중소기업이 자체 AI팀을 꾸리기 어려운 경우, 대학 산학협력단, 정부 출연 연구소, 민간 AI 컨설팅업체와 협력하여 맞춤형 솔루션을 도입할 수 있다. 정부가 운영하는 AI 바우처사업이나 스마트공장 지원사업을 활용하면 비교적 낮은 부담으로 전문가 도움을 받을 수 있으므로 적극 참여하는 것이 바람직하다. 넷째, AI 자동화의 경제성을 높이기 위해 협업과 공동대응 전략을 모색할 필요가 있다. 특히 동종 업계 중소기업 협의체를 통해 공동으로 AI 솔루션을 개발하거나, 지역산업 클러스터 차원에서 함께 데이터 플랫폼을 구축하는 방안을 모색해야 한다. 예를 들어 중소 제조업 여러 곳이 연합하여 공동 AI 플랫폼을 만들고, 각사의 생산품 특성에 맞게 맞춤화하여 사용하는 모형이다. 이러한 연대 전략은 비용을 분담하고 모범사례를 공유함으로써 개별 기업의 부담을 줄이고 AI 도입의 성공 확률을 높일 수 있다.

3. 정책 방안의 한계와 위험 및 보완대책

본 연구에서 제시한 AI 전환 정책 방안에도 불확실성과 한계가 존재한다. 첫째, 기술발전 예측의 불확실성이다. AI 기술은 향후 경로가 매우 유동적이므로, 정책이 예상한 방향과 현실이 어긋날 위험이 있다. 예를

들어 자동화 진척 속도가 정부 예측보다 훨씬 빨라지면, 단기적 대응 위주였던 정책이 시의적절성을 잃고 노동시장 충격에 뒤처져 대응하게 될 수 있다. 이를 완화하기 위해 정부는 정책 효과에 대한 모니터링 체계를 구축하고, 주요 지표(생산성, 고용, 임금분포 등)를 지속적으로 점검하여 정책의 유연한 조정에 나서야 한다. 둘째, 정부개입의 역효과 가능성이 있다. 시장 효율성을 높인다는 명분으로 추진한 정책이 오히려 민간의 자생적 투자를 저해하거나, 특정 기업에 과도한 특혜로 작용할 우려가 있다. 예컨대 공공 데이터나 인프라 지원이 대기업에만 집중되면 경쟁 질서를 왜곡하고 중소기업의 의존성을 키울 수 있다. 따라서 정책설계 시 수혜 대상의 형평성을 고려하고, 민간이 스스로 해결할 수 있는 영역에는 과잉지원을 지양해야 한다. 셋째, 사회적 수용성 문제다. AI 규제 완화나 노동정책 개편 등은 이해관계자 간 견해차가 커서 실행에 난항을 겪을 수 있다. 특히 노동계는 AI로 인한 노동 환경 변화에 민감하므로, 정부가 일방적 정책을 추진할 경우 사회적 갈등으로 비화할 위험이 있다. 이를 해결하려면 사회적 대화기구를 통한 꾸준한 의견 수렴과 합의 도출이 필수적이다. 앞서 언급한 노사정 협의체를 내실 있게 운영하고, 이해당사자와의 소통 창구를 상시 가동함으로써 정책에 대한 신뢰와 지지를 확보해야 한다.

또 다른 위험은 자원배분과 지속가능성이다. AI 인프라 구축, 교육훈련 지원, 안전망 강화 등은 모두 재정투입을 필요로 하는데, 국가 재정여건을 감안하지 않은 과도한 지출은 정책 지속가능성을 해칠 수 있다. 따라서 우선순위 설정과 민간 협력펀드 조성 등을 통해 재정부담을 완화하는 방안을 병행해야 한다. 예를 들어 클라우드 GPU 인프라 구축은 정부 단독 투자보다는 민간 클라우드 기업과 협력하여 공동투자-공동활용 모형으로 추진하고, 직업훈련 비용도 기업이 일정 부분 분담하도록 인센티브 구조를 설계하는 식이다. 마지막으로, 국제 환경의 불확실성도 있다. 각국이 AI 패권을 둘러싸고 경쟁하는 상황에서 국내 정책만으로는 한계가 있을 수 있다. 해외 거대 AI 기업의 기술이 표준을 선도하면 국내 기업이 종속될 위험, 반대로 우리 규제가 국제 기준과 어긋나 비관세무역장벽으

로 작용할 위험 등을 꼽을 수 있다. 따라서 정부는 국제 공조와 표준화 작업에 적극 참여하여 우리의 정책이 글로벌 흐름과 조화를 이루도록 하고, 동시에 국내 기업의 이익을 대변하는 규범 형성에 목소리를 내야 한다. 이러한 다각도의 보완대책을 통해 정부 정책이 가진 불확실성과 부작용을 최소화하고, 정책목표를 실효성 있게 달성하도록 관리해야 한다.

- 과학기술정보통신부, 『기업정보화통계집』, 2025.
- 한요셉, 『인공지능으로 인한 노동시장의 변화와 정책방향』, 연구보고서 2023-03, 한국개발연구원, 2023.
- 한지우 · 오삼일, 「AI와 노동시장 변화」, BOK 이슈노트 제2023-30호, 한국은행, 2023.
- Acemoglu, D., “The Simple Macroeconomics of AI,” *Economic Policy*, 40(121), 2024, pp.13~58.
- Acemoglu, D. and S. Johnson, “Rebalancing AI,” *Finance and Development*, 60(4), December 2023.
- Acemoglu, D. and P. Restrepo, “The Race between Man and Machine: Implications of Technology for Growth, Factor Shares, and Employment,” *American Economic Review*, 108(6), 2018, pp.1488~1542.
- Acemoglu, D. and P. Restrepo, “Tasks, Automation, and the Rise in U.S. Wage Inequality,” *Econometrica*, 90(5), 2022, pp.1973~2016.
- Aghion, P. and S. Bunel, “AI and Growth: Where Do We Stand?” Working Paper, 2024.
- Baqace, D. R. and E. Farhi, “The Macroeconomic Impact of Microeconomic Shocks: Beyond Hulten’s Theorem,” *Econometrica*, 87(4), 2019, pp.1155~1203.
- Baumol, W. J., “Macroeconomics of Unbalanced Growth: The Anatomy of Urban Crisis,” *American Economic Review*, 57(3), 1967, pp.415~426.
- Bounfour, A., K. Edamura, T. Ishikawa, T. Miyagawa, A. Nonnis, and K. Tonogi, “New Developments in Total Factor Productivity Measurement reflecting Innovative Activities: Evidence from the Productivity J-curve in Advanced Countries,” VoxEU.org, March 12, 2025.
- Briggs, J., D. Kodnani, J. Hatzius, and G. Pierdomenico, “The Potentially Large Effects of Artificial Intelligence on Economic Growth,” Goldman Sachs Global Economics Analyst, March 26, 2023.

- Brynjolfsson, E., D. Li, and L. R. Raymond, “Generative AI at Work,” NBER Working Paper, No. 31161, 2023.
- Brynjolfsson, E., D. Rock, and C. Syverson, “The Productivity J-Curve: How Intangibles Complement General Purpose Technologies,” *American Economic Journal: Macroeconomics*, 13(1), 2021, pp.333~372.
- Cazzaniga, M., F. Jaumotte, L. Li, G. Melina, A. J. Panton, C. Pizzinelli, E. Rockall, and M. M. Tavares, “Gen-AI: Artificial Intelligence and the Future of Work,” IMF Staff Discussion Note SDN/2024/001, 2024.
- Chui, M., E. Hazan, R. Roberts, A. Singla, K. Smaje, A. Sukharevsky, L. Yee, and R. Zimmel, “The Economic Potential of Generative AI: The Next Productivity Frontier,” McKinsey Global Institute, June, 2023.
- Dell’Acqua, F., E. McFowland III, E. Mollick, H. Lifshitz-Assaf, K. C. Kellogg, S. Rajendran, L. Kraye, F. Candelon, and K. R. Lakhani, “Navigating the Jagged Technological Frontier: Field Experimental Evidence of the Effects of AI on Knowledge Worker Productivity and Quality,” Working Paper, 2023.
- Eloundou, T., S. Manning, P. Mishkin, and D. Rock, “GPTs are GPTs: Labor market impact potential of LLMs,” *Science*, 384(6702), 2024, p.1306.
- Felten, E., M. Raj, and R. Seamans, “Occupational Heterogeneity in Exposure to Generative AI,” SSRN Working Paper, 2023.
- Filippucci, F., P. Gal, and M. Schief, “Aggregate Productivity Gains from Artificial Intelligence: A Sectoral Perspective,” Working Paper, 2025.
- Gambacorta, L., H. Qiu, S. Shan, and D. M. Rees, “Generative AI and Labour Productivity: A Field Experiment on Coding,” BIS Working Papers, No. 1208, 2024.
- Gervais, A. and J. B. Jensen, “The Tradability of Services: Geographic Concentration and Trade Costs,” *Journal of International Economics*, 118, 2019, pp.331~350.
- Haslberger, M., J. Gingrich, and J. Bhatia, “No Great Equalizer: Experimental Evidence on Productivity Effects of Generative AI Use in the UK Labor Market,” Working Paper, 2025.
- Hulten, C. R., “Growth Accounting with Intermediate Inputs,” *The Review of Economic Studies*, 45(3), 1978, pp.511~518.
- Kalliamvakou, E., “Research: Quantifying GitHub Copilot’s Impact on Developer Productivity and Happiness,” Github/Blog, 2024.

- Li, Z., Y. Hua, T.-T. Vu, H. Zhan, L. Qu, and G. Haffari, “SCAR: Data Selection via Style Consistency-Aware Response Ranking for Efficient Instruction-Tuning of Large Language Models,” *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2025.
- Nordhaus, W. D., “Baumol’s Cost Disease: A Macroeconomic Perspective,” NBER Working Paper, No. 12218, 2006.
- Noy, S. and W. Zhang, “Experimental Evidence on the Productivity Effects of Generative Artificial Intelligence,” Working Paper, 2023.
- OECD, “Miracle or Myth? Assessing the Macroeconomic Productivity Gains from Artificial Intelligence,” *OECD Artificial Intelligence Papers*, No. 29, 2024.
- OECD, “Governing with Artificial Intelligence: The State of Play and Way Forward in Core Government Functions,” OECD Publishing, 2025.
- Oh, W. and K. Kim, “The Baumol Diseases and the Korean Economy,” *Emerging Markets Finance and Trade*, 51(S1), 2015, pp.S214~S223.
- Peng, S., E. Kalliamvakou, P. Cihon, and M. Demirer, “The Impact of AI on Developer Productivity: Evidence from GitHub Copilot,” Working Paper, 2023.
- Pham, L. H. and J. Sun, “Certified Continual Learning for Neural Network Regression,” *Proceedings of the 33rd ACM SIGSOFT International Symposium on Software Testing and Analysis (ISSTA 2024)*, 2024, pp.806~818.
- Pizzinelli, C., A. Panton, M. M. Tavares, M. Cazzaniga, and L. Li, “Labor Market Exposure to AI: Cross-country Differences and Distributional Implications,” IMF Working Paper, WP/23/216, 2023.
- Svanberg, M. S., W. Li, M. Fleming, B. C. Goehring, and N. C. Thompson, “Beyond AI Exposure: Which Tasks are Cost-Effective to Automate with Computer Vision?” Working Paper, 2024.
- Thompson, N. C., M. Fleming, B. J. Tang, A. M. Pastwa, N. Borge, B. C. Goehring, and S. Das, “A Model for Estimating the Economic Costs of Computer Vision Systems that use Deep Learning,” in *Proceedings of the 38th Annual AAAIConference on Artificial Intelligence*, 2024.
- Vaswani, A., N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention Is All You Need,” *Advances in Neural*

Information Processing Systems, 30, 2017.

Webb, M., "The Impact of Artificial Intelligence on the Labor Market," Working Paper, 2020.

<자료 및 웹사이트>

고용노동부, 「고용형태별근로실태조사」.

고용노동부, 「기업체노동비용조사」.

고용노동부, 「직종별사업체노동력조사」.

국가데이터처, 「기업활동조사」.

국가데이터처, 「지역별고용조사」.

국가데이터처, 「전국사업체조사」.

국가데이터처 홈페이지(<https://kosis.kr/index/index.do>, 최종접속일: 2025. 10. 15).

임금직업포털(<https://www.wagework.go.kr/pt/index.do>, 최종접속일: 2025. 10. 15).

한국생산성본부 홈페이지(<https://www.kpc.or.kr/>, 최종접속일: 2025. 10. 25).

한국소프트웨어산업협회(<https://www.sw.or.kr/site/sw/ex/board/List.do?cbIdx=304>, 최종접속일: 2025. 10. 15).

한국은행 경제통계시스템(<https://ecos.bok.or.kr/>, 최종접속일: 2025. 10. 25).

<https://ai-act-service-desk.ec.europa.eu/en/ai-act/article-50>(최종접속일: 2025. 10. 5).

<https://arxiv.org/pdf/2207.00810>(최종접속일: 2025. 10. 15).

<https://calvin-vision.net/wp-content/uploads/Publications/bearman16eccv.pdf>(최종접속일: 2025. 10. 15).

<https://cocodataset.org>(최종접속일: 2025. 10. 5).

https://csrc.nist.gov/glossary/term/generative_artificial_intelligence?(최종접속일: 2025. 10. 5).

<https://dextralabs.com/blog/best-open-source-llm-model>(최종접속일: 2025. 10. 5).

<https://encord.com/blog/choose-the-best-data-guide-computer-vision>(최종접속일: 2025. 10. 5).

https://events.ringcentral.com/events/agent-ai-moving-beyond-pilots-to-enterprise-impact/registration?utm_source=Disruptor(최종접속일: 2025. 10. 5).

<https://github.blog/news-insights/research/research-quantifying-github-copilots-impact-on-developer-productivity-and-happiness>(최종접속일: 2025. 10. 5).

<https://openai.com/index/clip>(최종접속일: 2025. 10. 5).
<https://openai.com/ko-KR/index/whisper>(최종접속일: 2025. 10. 5).
<https://pmc.ncbi.nlm.nih.gov/articles/PMC11102897>(최종접속일: 2025. 10. 15).
<https://python.langchain.com/docs/introduction>(최종접속일: 2025. 10. 5).
<https://research.google/blog/palm-e-an-embodied-multimodal-language-model>(최종접속일: 2025. 10. 5).
<https://runwayml.com/research/gen-2>(최종접속일: 2025. 10. 5).
<https://sites.research.google/med-palm>(최종접속일: 2025. 10. 5).
<https://stablediffusion.com>(최종접속일: 2025. 10. 5).
https://www.adobe.com/vn_en/products/firefly.html(최종접속일: 2025. 10. 5).
<https://www.anthropic.com/research/constitutional-ai-harmlessness-from-ai-feedback>
(최종접속일: 2025. 10. 5).
<https://www.bloomberg.com/company/press/bloomberggpt-50-billion-parameter-llm-tuned-finance>(최종접속일: 2025. 10. 5).
<https://www.brookings.edu/articles/machines-of-mind-how-generative-ai-will-power-the-coming-productivity-boom>(최종접속일: 2025. 10. 5).
<https://www.facebook.com/openai/posts/show-chatgpt-whats-in-your-fridge-and-get-recipe-ideas-in-time-for-dinner/1309628284292112>(최종접속일: 2025. 10. 5).
<https://www.ibm.com/kr-ko/think/topics/vision-language-models>(최종접속일: 2025. 10. 5).
<https://www.ibm.com/think/topics/autogpt>(최종접속일: 2025. 10. 5).
<https://www.ibm.com/think/topics/transformer-model>(최종접속일: 2025. 10. 5).
<https://www.imf.org/en/Blogs/Articles/2024/01/14/ai-will-transform-the-global-economy-lets-make-sure-it-benefits-humanity>(최종접속일: 2025. 10. 5).
<https://www.microsoft.com/en-us/research/project/vall-e-x>(최종접속일: 2025. 10. 5).
<https://www.midjourney.com/home>(최종접속일: 2025. 10. 5).
<https://www.reuters.com/legal/getty-images-lawsuit-says-stability-ai-misused-photos-trained-ai-2023-02-06>(최종접속일: 2025. 10. 5).
<https://www.reuters.com/technology/chatgpt-sets-record-fastest-growing-user-base-analyst-note-2023-02-01>(최종접속일: 2025. 10. 5).
<https://www.weforum.org/stories/2024/02/ai-creative-industries-davos>(최종접속일: 2025. 10. 5).

<https://www.weforum.org/stories/2024/02/ai-creative-industries-davos>(최종접속일:
2025. 10. 5).

<https://www.weforum.org/stories/2024/02/ai-creative-industries-davos>(최종접속일:
2025. 10. 5).

<https://x.com/gdb/status>(최종접속일: 2025. 10. 5).

부 록


1. AI 지동화: 경제성을 중심으로

<부표 1> 직능수준별 임직 필요조건


직능수준	설 명
LEVEL8	광범위하고 매우 철저한 준비가 필요함.
LEVEL7	특정 분야에서 매우 철저한 준비가 필요함.
LEVEL6	철저한 준비가 필요함.
LEVEL5	상당한 준비가 필요함.
LEVEL4	어느 정도의 준비가 필요하거나, 일부 직업은 상당한 준비가 필요함.
LEVEL3	어느 정도의 준비가 필요함.
LEVEL2	약간의 준비가 필요함.
LEVEL1	준비가 거의 필요 없음.

자료: 임금직업포털(<https://www.wagework.go.kr/pt/index.do>, 최종접속일: 2025. 10. 15).

[부도 1] 직업에 대한 전망과 AI score 관계




[부도 2] AI 자동화 5대 지표 분포




자료 저자 작성.

[부도 3] $AI\ score$ 의 분포(0 제외)




주: $AI\ score$ (X축)는 로그스케일로 조정.

[부도 4] C_j^M 의 분포




주: C_j^M (X축)은 로그스케일로 조정.

[부도 5] $C_j^{\text{데이터}}$ 의 분포 및 누적 분포




주: $C_j^{\text{데이터}}$ (X축)은 로그스케일로 조정

[부도 6] n_{ij} 의 분포




주: n_{ij} (X축)은 로그스케일로 조정.

[부도 7] n_{ij}^* 의 분포



주: n_{ij}^* (X축)은 로그스케일로 조정.

[부도 8] 기업규모별 경제성 있는 AI 자동화 과업 비중



자료: 저자 작성.

2. AI가 기업생산성에 미치는 영향

<부표 2> 약한 도구변수(Weak IV) 검정 통계

Stock-Yogo weak ID test critical values (10% maximal IV size)	7.03	
IV	Kleibergen-Paap rk Wald F	Cragg-Donald Wald F
leave-one-out AI 활용률	15.6	24.8
leave-지역·산업-out AI 활용률	1.42	3.88
지역·산업 AI 활용률	0.08	0.13

자료: 국가데이터처, 「기업활동조사」.

3. AI가 거시경제에 미치는 영향

가. AI 활용률의 변화 경로 추정 방법론

AI 기술의 발전으로 최종 AI 채택률이 15년간 상승한다고 가정하고, 15년간 AI 채택 경로를 S-curve 계열함수(Generalized Logistic (Richards))를 이용하여 추정한다. 모수를 추정하기 위해 확산 경로 중 최고 상승구간(최대 증가율 시점)을 기준(Baseline) 7년, 낙관(Better) 6년, 비관(Worse) 8년으로 두되, 이 시점을 정확히 일치시키기보다는 목표치에 가깝도록 수치적으로(numerically) 조정한다. 본 분석에서는 최대증가율 시점이 모형의 위치 모수와 일치하도록 모수화를 선택하여, Richards 함수의 형태를

$$z(t) = \frac{z_{15}}{(1 + \nu \exp(-k(t - t_0)))^{1/\nu}}$$

로 두고, t_0 가 최대증가율 시점(peak time)이 되도록 설정한다. 여기서 $\nu > 0$ 는 곡선의 비대칭성과 완만함을 조정하는 형태모수이며, $k > 0$ 는 확산

속도를 결정한다. 상한은 모형에서 추정된 z_{15} 으로 고정한다. 본 모수화의 장점은 ν 가 주어지면 두 개의 끝점(endpoint) 조건 $z(1)=z_1$, $z(15)=z_{15}$ 을 정확히 만족하는 (k,t_0) 를 해석적으로(analytically) 복원할 수 있다는 점이다. 구체적으로

$$u(t)=\left(\frac{z_{15}}{z(t)}\right)^{\nu}-1$$

로 정의하면 $u(t)=\nu \exp(-k(t-t_0))$ 가 성립하므로 $\ln u(t)$ 는 t 에 대한 선형식이 된다. 따라서

$$k=\frac{\ln(u(1)/u(15))}{15-1},\; t_0=1+\frac{\ln u(1)-\ln \nu}{k}$$

로 (k,t_0) 를 정확히 계산할 수 있다. 이때 끝점 제약은 항상 정확히 충족되며, 시나리오별 목표 최대증가율 시점 $\tilde{t}_0\in\{7,6,8\}$ 에 대해 $(t_0(\nu)-\tilde{t}_0)^2$ 를 최소화하도록 ν 를 수치적으로(numerically) 추정한다.


나. AI 활용의 장기 고용 및 임금 영향

<부표 3> 약한 도구변수(Weak IV) 검정 및 과식별 검정 통계

Stock-Yogo weak ID test critical values (10% maximal IV size)	13.43	
	Kleibergen-Paap rk Wald F	Cragg-Donald Wald F
IV	13.939	23.070
Hansen J p-value	0.5163	

자료: 고용노동부, 「고용형태별근로실태조사」, 「지역별고용조사」 및 임금직업포털(최종접속일: 2025. 10. 15)을 바탕으로 저자 작성.

[부도 9] 산업별 AI 활용의 TFP 기여: 15년 누적



자료: 저자 작성.

Macroeconomic Impact of AI Diffusion

Nam Changwoo

This report examines how artificial intelligence (AI), particularly modern, data-driven, and increasingly generative systems, is likely to affect Korea's productivity, growth, employment, and wages over the next decade or two. Three layers of evidence are integrated within a unified task-based framework: (i) micro-level measures of AI exposure and economic viability at the task and occupation levels, (ii) firm-level panel evidence on AI adoption and productivity, and (iii) a macroeconomic general-equilibrium model that aggregates task-level shocks into total factor productivity (TFP) and long-run labor market outcomes. The study defines AI as software systems that replicate human capabilities in learning, prediction, pattern recognition, perception, and natural language processing—a definition consistent with that used in the underlying firm survey and broad enough to encompass both earlier, narrow algorithms and more recent foundation models and AI agents.

Chapter 2 offers an accessible overview of the technological evolution of AI from traditional machine learning to transformer-based large language models and emerging agent-like systems. It emphasizes two features of particular macroeconomic relevance. First, advances in general-purpose and multimodal models have greatly expanded the range of tasks technically exposed to AI. Second, effective deployment requires complementary investments in data, organizational capacity, and human capital, suggesting that technical feasibility alone is a poor predictor of short-run economic impact.

Chapter 3 develops a task-based measure of AI automation potential tailored

to the Korean labor market. Using detailed work descriptions from the Korean Employment Classification of Occupations (KECO) and Workpedia, the study decomposes 537 occupations into 6,824 unit tasks and scores each task along five dimensions: measurability of outcomes, data availability and quality, context dependence, required human judgment necessity, and agentability (the ease with which an AI agent can execute a given task). These components are combined into a task-level AI score that captures effective automation potential rather than mere technical exposure. A cost–benefit framework inspired by recent work on computer vision and AI costs is then applied to identify tasks and task–firm combinations for which automation is economically viable, given realistic assumptions about data, development, inference, integration, and maintenance costs relative to labor savings. The findings are conservative by design. Under a naive exposure-only criterion, AI could potentially affect roughly 8–12% of current employment and 10–11% of current sales, concentrated in finance, insurance, R&D, ICT, and certain transport and business services. Narrowing the focus to tasks that are both technically automatable and economically viable reduces these shares to about 1–3% of employment and 1–2% of sales. This suggests that, in the near term, AI will likely induce selective and partial automation in specific occupations and industries, rather than a broad-based, immediate displacement of labor.

Chapter 4 analyzes firm-level evidence using the nationally representative Korean Survey of Business Activities for 2017–2023, which asks firms whether they use AI—defined in the questionnaire as software that replicates human learning, reasoning, perception, and natural language understanding—and other fourth industrial revolution (IR4) technologies. To address the endogenous timing of AI adoption, the analysis employs panel IV (2SLS) models with firm and year fixed effects, instrumenting AI adoption with industry-level economic viability measures from Chapter 3. In the preferred specifications, firms that adopt AI and related IR4 technologies exhibit statistically significant increases in log sales per employee on the order of 5–20%, driven primarily by higher sales rather than systematic employment cuts. Pure “AI only” effects, net of broader digitalization, are estimated with less precision, consistent with AI operating as a general-purpose technology that must be embedded in a broader digital and organizational transformation. As a robustness check, propensity-score matching and difference-in-differences estimates for AI first movers suggest modest but positive short-run effects on labor productivity, with

limited evidence of strong dynamic effects within the short observation window.

Chapter 5 incorporates these micro-level estimates into a task-based general-equilibrium model following the approach of Acemoglu and Restrepo to simulate AI-induced TFP paths over the next 10–15 years. Hulten’s theorem implies that, under certain assumptions, aggregate TFP change can be approximated by a Domar-weighted sum of task-level cost savings. The model therefore combines (i) the economically viable task shares by industry, (ii) firm-level productivity effects of AI, and (iii) alternative adoption scenarios—baseline, optimistic, and pessimistic—to trace out possible TFP trajectories. Under baseline assumptions, AI contributes a cumulative TFP gain of about 2.3% over a decade, nontrivial but below some of the more optimistic global projections. These simulations focus on the task automation channel and treat parameters as exogenous. They abstract from structural transformation, intangible capital accumulation, idea-generation effects, and potential discontinuities in AI capabilities. Then the analysis turns to long-run employment and wage effects across occupations. Using a cross-section of Korean 2-digit occupational categories over 2014–2024, the analysis estimates reduced-form relationships between changes in employment and real hourly wages and measures of routine and structured task content, while instrumenting for endogenous employment changes with leave-one-out labor-demand shocks. Occupations with higher routine task shares experience lower employment growth and somewhat lower wage growth over the decade, consistent with international evidence that automation pressure exerts downward pressure on labor demand and wage growth in exposed jobs. Combined with the AI exposure metrics presented earlier, these estimates imply that, under realistic adoption scenarios, the annual displacement and wage-drag effects attributable to AI are likely modest relative to existing demographic and structural trends, but non-negligible for specific groups.

Chapter 6 synthesizes these findings and discusses their implications for policy and business. For policymakers, the central message is that AI is unlikely to trigger an immediate, economy-wide employment collapse, but will require active management of selective automation, task restructuring, and skill upgrading in exposed sectors. The study argues for a market-friendly policy mix: clarifying AI-related regulation and liability, investing in data and compute infrastructure, strengthening education, training, and retraining systems, and fostering complementary innovations and organizational change. For firms, the

key insight is that productivity gains derive less from AI in isolation and more from integrating AI into workflows, data pipelines, and human capital strategies.

KDI 신간안내

RECENT KDI PUBLICATION

중대재해처벌법이 노동시장에 미친 영향

정수환

연구보고서 | 241쪽 | 정가 7,000원

본 보고서는 노동경제학적 관점에서 「중대재해 처벌 등에 관한 법률」의 영향을 분석하고, 이를 바탕으로 실증적인 증거에 기반한 정책 제언을 제시한다. 중대재해 처벌 등에 관한 법률의 시행이 안전관리인력 노동시장, 사망사고 발생, 고위험 직업의 노동수요 등 다양한 요소에 미치는 영향을 실증적으로 조망하고, 자체적으로 기업의 산업안전 실태 및 인식을 조사하였다.



에너지 산업 육성을 위한 시장 설계

윤여창

정책연구시리즈 | 53쪽 | 정가 4,000원

본고는 에너지 산업의 국내 육성을 위한 다양한 지원정책이 시장 경쟁과 자원배분의 효율성에 미치는 영향을 심층적으로 분석하였다. 특히 진입장벽을 낮추는 인프라 구축과 같은 수평적 지원정책의 효과와 국산화 비율에 따른 조건부 보조금이나 입찰 가점 부여와 같은 수직적 지원정책의 효과를 비교하여 분석함으로써, 국내 실정에 맞는 합리적인 정책 설계 방향을 제시하고자 하였다.



제약 산업에서의 정부 정책 효과 분석과 시사점

김형진

정책연구시리즈 | 84쪽 | 정가 4,000원

본 연구는 대표적인 혁신 산업인 바이오 산업을 중심으로 모태펀드의 혁신 촉진 효과와 파급효과를 실증적으로 분석함으로써, 정부 벤처투자 정책의 작동 메커니즘에 대한 이해를 확장하였다. 특히 정부 투자가 혁신 생태계 전반의 정보 환경을 개선하고 민간 자본의 참여를 촉진하는 매개 역할을 수행할 수 있음을 실증적으로 제시하였다.



플랫폼 담합 규율 방향에 관한 연구

조성익

정책연구시리즈 | 132쪽 | 정가 5,000원

담합은 가장 중요한 경쟁법 집행 대상 중 하나이다. 이에 본 연구는 전통적인 담합과 플랫폼 담합 사이의 차이를 분석하고, 그 구체적 내용이 무엇인지 확인한다. 이를 통해 향후 플랫폼 담합을 조사하고 처리하는 과정에서, 효율성 증진 가능성과 경쟁 촉진 가능성을 살펴볼 수 있도록 제도를 정비할 필요가 있음을 주장하고 있다.



도시공간 개발 및 교통시설 공급 정책에 따른 통근통행의 효율성 분석

김강수

정책연구시리즈 | 66쪽 | 정가 4,000원

본 연구는 도시공간 개발 및 교통시설 공급 정책이 통근 효율성에 미치는 효과를 실증적으로 분석하고자 한다. 이를 위해 시·군·구 단위의 평균 및 외부 통근시간, 외부 통근비용, 외부 통근시 승용차 이용률 등을 통근 효율성 지표로 설정하고, 시군구별 도시공간 개발 및 철도의 상이한 공급 시점을 고려한 순차적 이중차분모형을 구축하여 도시공간 개발 및 공급 시차에 따른 통근 효율성 개선 효과의 이질성을 분석하였다.



외국인 근로자 유입의 경제적 영향과 이주 결정요인 분석

정영욱

정책연구시리즈 | 148쪽 | 정가 5,000원

이민정책 수립의 가장 큰 난제는 노동시장의 복잡성을 반영한 정밀한 수요 예측이 어렵기 때문이다. 이에 본 연구는 외국인 근로자 유입이 내·외국인에게 미치는 영향을 실증적으로 분석하여 정책적 시사점을 얻고, 외국인 근로자의 한국 이주 결정요인들을 바탕으로 외국인 근로자 유치에 필요한 정책 방향을 모색한다.



부동산 PF 구조개선 방안에 관한 연구

황순주 편

연구보고서 | 273쪽 | 정가 8,000원

부동산 PF는 금융업과 건설업을 중심으로 우리 경제 전체의 중대한 위험요인으로 작용하고 있다. 반복되는 PF 위기는 문제의 원인이 무엇이고, 이를 해소하기 위한 정책방안에는 무엇이 있으며, 이러한 정책방안의 경제적 효과는 어떠한가? 본 연구는 이와 같은 다양한 질문에 답하기 위해 종합적인 제도연구 및 실증연구를 수행함으로써 부동산 PF의 구조를 개선하는 것을 목적으로 한다.



연구보고서 2026-01

시의 거시경제 영향 분석

인 쇄 2026년 7월 16일

발 행 2026년 7월 20일

저 자 남창우

발행인 김세직

발행처 한국개발연구원

등 록 1975년 5월 23일 제6-0004호

주 소 세종특별자치시 남세종로 263

전 화 (044) 550-4114

팩 스 (044) 550-4310

© 한국개발연구원 2026

ISBN 979-11-7566-108-0

값 7,000원

* 잘못된 책은 바꿔드립니다.

