

입사지원서

1. 기본 인적사항 및 지원 정보

성명	이 O O (가명: 이민혁)	지원 부문	클라우드 AI 플랫폼 엔지니어
생년월일	1996. 05. 14 (만 29세)	지원 구분	경력 (총 만 2년 10개월)
최종 학력	한국과학기술대학교 컴퓨터공학과 학사 졸업 (학점: 3.92 / 4.5)	연락처 / E-mail	010-XXXX-5821 / minhyuk.lee@cloudai-lab.io

2. 보유 기술 스택 (Technical Expertise)

Language & Core: Python Go C++ (Inference Optimization) SQL

Cloud & Infrastructure: Google Cloud Platform (GCP) Kubernetes (GKE) Terraform Docker Prometheus / Grafana

AI & Serving Frameworks: vLLM Triton Inference Server LangChain PyTorch Vertex AI

3. 주요 경력 사항 (총 2년 10개월)

넥스트클라우드 테크 (NextCloud Tech) / AI 인프라 엔지니어링팀

2022. 03 ~ 2024. 12 (2년 10개월)

대규모 기업 고객을 위한 LLM 분산 서빙 인프라 아키텍처 설계, Kubernetes 기반 추론 클러스터 운영 및 성능 최적화 담당

[Project 1] Enterprise LLM Inference Gateway 구축 및 경량화 (2023.05 ~ 2024.08)

- 주요 내용: 분산 GPU 환경에서 트래픽 버스트에 대응하기 위해 vLLM 및 PagedAttention 메모리 최적화 기법 적용
- 핵심 성과: 동시 요청 처리량(Throughput) 2.4배 향상, P99 응답 지연 시간 45% 단축 (120ms 달성), 클라우드 GPU 인스턴스 비용 월 35% 절감
- 기여도: 코어 서빙 게이트웨이 아키텍처 설계 100%, 커스텀 로드밸런싱 알고리즘 구현 80%

[Project 2] Kubernetes 기반 MLOps 파이프라인 무중단 배포 자동화 (2022.06 ~ 2023.03)

- 주요 내용: Kubeflow 및 Argo Workflows를 연동하여 모델 패키징부터 배포까지의 CI/CD 파이프라인 자동화 구축
- 핵심 성과: 모델 배포 소요 시간을 기존 3일에서 15분으로 단축, 카나리(Canary) 배포로 무장애 무중단 롤아웃 달성

4. 수상 실적, 오픈소스 기여 및 전문 자격

구분	명칭 및 프로젝트 내용	발행 기관 / 증빙
공인 해커톤 수상	2023 대한민국 인공지능 해커톤 최우수상 (초거대 언어모델 기반 기업 업무 자동화 파이프라인 부문)	과학기술정보통신부 장관상 (2023. 11)
오픈소스 메인테이너	Fast-Kube-RAG 오픈소스 리포지토리 제작 및 배포 (Kubernetes 기반 경량 벡터 검색 및 RAG 서빙 프레임워크)	GitHub 1,200+ Stars 달성 (메인 기여자 1인)
전문 기술 자격	• Google Cloud Professional Cloud Architect (PCA) • Certified Kubernetes Administrator (CKA)	Google Cloud / CNCF (유효 자격 보유)

5. 자기소개서 (Self-Introduction)

1. GOOG전자 지원 동기 및 입사 후 엔지니어로서 달성하고자 하는 비전

GOOG전자는 최첨단 가전 및 모바일 기기를 온디바이스(On-device) AI와 클라우드 인텔리전스로 결합하여 전 세계 수억 명의 일상을 혁신하고 있습니다. 저는 지난 3년간 넥스트클라우드 테크에서 분산 GPU 클러스터 및 초저지연 LLM 추론 서버 시스템을 개발하며 대규모 트래픽을 처리하는 인프라 역량을 쌓았습니다. GOOG전자가 추진 중인 글로벌 멀티 리전 클라우드 AI 백엔드 인프라에 저의 vLLM 및 Kubernetes 대규모 분산 최적화 역량을 결합하여, P99 지연시간 100ms 이하의 압도적 사용자 경험을 제공하는 차세대 AI 서버 플랫폼을 구축하고자 지원하였습니다.

2. 직무 전문성 및 가장 큰 성과를 창출한 핵심 프로젝트 경험

가장 주도적으로 이끈 성과는 'Enterprise LLM Inference Gateway' 구축 프로젝트입니다. 기존 시스템은 동시 사용자 급증 시 GPU 메모리 단편화(Memory Fragmentation)로 인해 OOM(Out of Memory)이 빈번히 발생하였고, 평균 지연시간이 250ms 이상으로 치솟았습니다. 저는 이를 해결하기 위해 vLLM의 PagedAttention 메커니즘을 벤치마킹하여 KV Cache를 논리적 블록 단위로 가상화하는 커스텀 메모리 매니저를 개발했습니다. 그 결과 동시 요청 처리량을 2.4배 향상시켰으며, P99 응답 시간을 45% 단축(120ms)하고 고가의 GPU 인스턴스 사용량을 35% 줄여 연간 약 1억 2천만 원의 인프라 비용을 절감하였습니다.

3. 기술적 난관에 부딪혔을 때 원인을 규명하고 돌파한 문제 해결 경험 (트러블슈팅)

8개 노드에 걸친 분산 텐서 병렬화(Tensor Parallelism) 환경에서 간헐적으로 추론 파이프라인이 멈추는 데드락(Deadlock) 장애가 발생했습니다. 단순 애플리케이션 로그에는 에러가 잡히지 않아, 저는 시스템 커널 레벨에서 eBPF 추적 도구와 NCCL 프로파일러를 연결하여 GPU 간 통신 패킷을 분석했습니다. 분석 결과, 특정 노드의 NIC 패킷 드롭으로 인해 NCCL All-Reduce 통신 링(Ring)에서 특정 랭크(Rank)가 타임아웃 대기 상태에 빠지는 것을 규명했습니다. 네트워크 MTU 최적화 및 RoCE v2 흐름 제어를 재설정하고, 비동기 헬스체크 기반의 자동 장애 노드 격리 로직을 적용하여 시스템 무장애 연속 가동 180일을 달성했습니다.

4. 팀 협업, 동료와의 갈등 조율 및 지식 공유 활동

인프라 엔지니어링팀과 AI 모델 연구팀 간에 배포 주기를 둘러싼 이견이 발생했을 때, 저는 일방적인 규칙을 강요하기보다 자동화된 'Canary Validation Pipeline'을 직접 설계하여 해결했습니다. 모델 연구원들이 슬랙(Slack) 봇 명령어로 스테이징 환경에서 모델 품질과 인프라 부하를 동시에 검증할 수 있게 함으로써 소통 비용을 획기적으로 줄였습니다. 또한 사내 기술 위키에 40여 편의 '클라우드 인프라 장애 대응 백서'를 연재하고 오픈소스 커뮤니티에 'Fast-Kube-RAG' 프레임워크를 공개하여 사내외 개발자들과 기술을 공유하는 데 앞장서 왔습니다.

위 기재 사항은 사실과 다름이 없으며, 허위 사실 기재 시 합격 및 입사가 취소될 수 있음을 확인합니다.

지원자: 이 오 오 (인)